SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

S1/25

El avión choca. ¿Qué puede pasar ahora?

Antes de analizar datos, necesitamos definir el experimento: qué puede ocurrir y qué vamos a medir.



1 Problema del relato

El avión se estrella en la cordillera. Desde este momento, pueden ocurrir muchos resultados posibles: distintos lugares de aterrizaje, condiciones del clima, estados físicos de las personas, rutas que toman, etc.
Antes de hacer cálculos, tenemos que definir qué puede pasar y qué vamos a medir.

2 La intuición no alcanza

No alcanza con decir "pueden pasar muchas cosas".
Necesitamos responder: ¿cuáles son todos los resultados posibles?
¿Qué eventos nos interesan (ej.: sobrevivir, encontrar refugio)?
¿Qué variable vamos a medir (ej.: gasto energético diario en kcal)?

3 Herramienta estadística

Experimento aleatorio, evento, espacio muestral y variable aleatoria

4 Ecuaciones

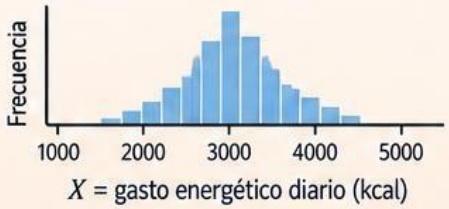
$$\Omega, \quad A \subseteq \Omega, \quad X : \Omega \to \mathbb{R}, \quad P(\Omega) = 1, \quad 0 \le P(A) \le 1$$

Componentes del experimento (ejemplos)

Ω **Espacio muestral Ω:**
todos los resultados posibles.
(todas las combinaciones de rutas, clima, estados físicos, decisiones, ...)

A **Evento A:**
un conjunto de resultados.
(ej.: "sobrevivir", "encontrar refugio", ...)

X **Variable aleatoria X:**
asigna un número a cada resultado.
(ej.: gasto energético diario en kcal)



5 Interpretación y decisión

El espacio muestral Ω: contiene todos los resultados posibles del experimento. Un evento A es un subconjunto de resultados (por ejemplo, "sobrevivir"). La variable aleatoria X asigna un número a cada resultado (por ejemplo, el gasto energético diario en kcal). Las probabilidades cumplen $0 \le P(A) \le 1$ y $P(\Omega) = 1$. Con estas definiciones claras, podemos pasar a modelar y responder preguntas concretas.

Decisión en el relato: Definimos qué resultados y qué variable vamos a analizar para evaluar la probabilidad de sobrevivir y planificar los próximos pasos.

2 ¿Cuál es la probabilidad de sobrevivir?

Después del accidente, lo primero es saber qué tan probable es sobrevivir en estas condiciones. No lo sabemos con certeza, pero podemos estimarlo con la experiencia de situaciones similares.



Herramienta: Probabilidad frecuentista y Bernoulli

La probabilidad se aproxima con la frecuencia en muchas repeticiones comparables. Modelamos cada persona como un ensayo de Bernoulli (sobrevive o no).

$$P(A) \approx \frac{n_A}{n}$$
$$X \sim Bernoulli(p)$$
$$E[X] = p, \quad Var(X) = p(1-p)$$

Interpretación: si en muchas situaciones similares sobrevive el 60%, estimamos $p \approx 0.60$ para una persona.

Decisión: usamos esta probabilidad para planificar alimentos, abrigo y estrategias de rescate.

3 ¿De cuántas formas se pueden armar los grupos de exploración?

Para buscar ayuda, debemos formar un grupo de exploración. Hay muchas formas de elegir quiénes van. Además, podemos combinar eventos como "ir por cierta ruta" y "llevar equipo".



Herramienta: Combinatoria, regla de la multiplicación e independencia

Contamos casos y combinamos eventos. Esto es la base de la Binomial y de Bayes.

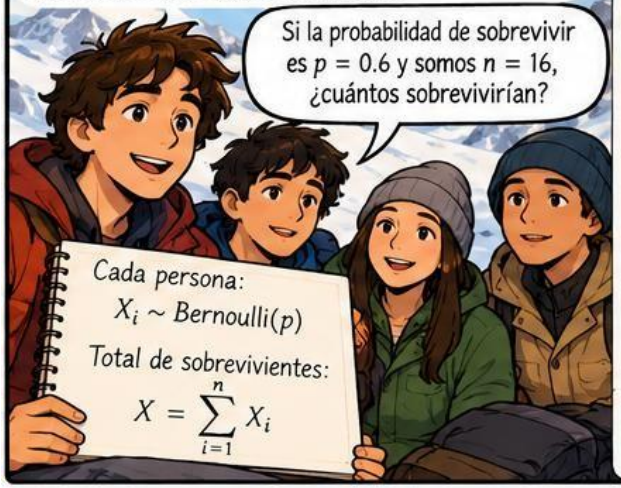
$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$
$$P(A \cap B) = P(A)\,P(B \mid A)$$
$$A \perp B \iff P(A \cap B) = P(A)P(B)$$

Interpretación: nos dice cuántas formas hay de armar el grupo y cómo combinar eventos (por ejemplo, elegir personas y que lleven cierto equipo).

Decisión: evaluamos distintas combinaciones de equipos y rutas, considerando su viabilidad.

4 ¿Cuántos sobrevivirían de n?

Si la probabilidad de sobrevivir por persona es p, para un grupo de n personas, el número de sobrevivientes es una variable aleatoria. Una persona es Bernoulli, muchas personas siguen una Binomial.



Herramienta: Distribución Binomial, parámetro y proporción

Modela el número de éxitos (sobrevivientes) en n ensayos independientes con probabilidad p.

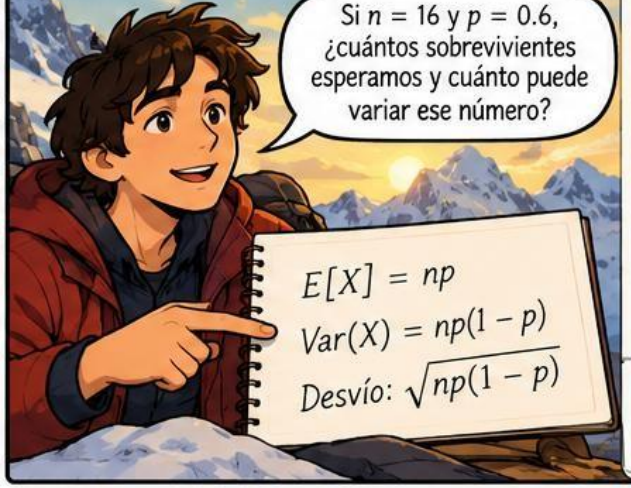
$$X \sim Bin(n,\, p)$$
$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$
$$\hat{p} = \frac{X}{n}$$

Interpretación: X es el número de sobrevivientes y $\hat{p}$ la proporción observada. p es un parámetro (fijo) y $\hat{p}$ un estadístico (aleatorio).

Decisión: nos da la distribución completa de cuántos podrían sobrevivir.

5 ¿Cuántos esperamos que sobrevivan y cuánto puede variar?

Necesitamos un número esperado de sobrevivientes y una idea de cuánto puede variar entre grupos. Así planificamos recursos y entendemos la incertidumbre.



Herramienta: Esperanza y varianza de una v.a.

Resumimos la distribución con un centro (esperanza) y una dispersión (varianza).

$$E[X] = np$$
$$Var(X) = np(1-p)$$
$$E[X] = \sum_x x\,P(X = x)$$

Interpretación: en promedio sobreviven np personas y la variación entre grupos es $np(1-p)$ (desvío $\sqrt{np(1-p)}$).

Decisión: usamos estos valores para planificar alimentos, abrigo y tamaño de los grupos de exploración.

6 Aviones pasan cerca pero no los ven



Que un avión pase por la zona no garantiza que nos vea.
Queremos saber: **si el avión cubre la zona, ¿cuál es la probabilidad de que nos detecte?**

Herramienta: Probabilidad condicional
La probabilidad cambia cuando condicionamos en un evento que ya ocurrió.

$$P(V \mid C) = \frac{P(V \cap C)}{P(C)} \neq 1$$

V: el avión nos ve
C: el avión cubre la zona

$P(V)$



Probabilidad baja

$P(V \mid C)$



Sigue siendo < 1
(puede fallar por clima, visibilidad, etc.)

Interpretación: aunque el avión cubra la zona, la probabilidad de que nos vea no es 1. Una condición cambia la probabilidad.

Decisión: no asumimos que "si pasan, nos ven". Planificamos señalización adicional.

7 El avión quedó fragmentado: aparece nueva evidencia



Tenemos una nueva evidencia y queremos actualizar nuestra creencia: **¿cuál es la probabilidad de que este fragmento sea de nuestro avión?**

Herramienta: Teorema de Bayes
Combinamos la probabilidad previa (prior) con la evidencia para obtener una probabilidad posterior.

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

$$P(B) = \sum_i P(B \mid A_i)P(A_i)$$

A: fragmento es de nuestro avión
B: tipo de fragmento encontrado
(i: otros posibles aviones)

Prior
$P(A)$



Antes de ver el fragmento, qué tan probable era.

Evidencia
$P(B \mid A)$



Qué tan probable es este fragmento si es de nuestro avión (o de otros).

Posterior
$P(A \mid B)$



Después de ver la evidencia, actualizamos la probabilidad.

Interpretación: si el fragmento es muy característico de nuestro avión, la probabilidad posterior aumenta. Si podría ser de muchos aviones, aumenta poco.

Decisión: usamos la evidencia para decidir si concentrar la búsqueda en esta hipótesis o explorar otras.

8 Escuchan por radio que suspendieron la búsqueda



Recibimos nueva información: suspendieron la búsqueda.
¿Qué tan probable es que realmente hayan dejado de buscarnos?
Y, con esa información, ¿qué hacemos nosotros?

Herramienta: Bayes + decisión bajo incertidumbre
Actualizamos probabilidades con la nueva información y elegimos la acción con mayor utilidad esperada.

$$P(H \mid E) \propto P(E \mid H)P(H)$$

$$E[U(a)] = \sum_h P(h \mid E)U(a,h)$$

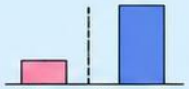
H: estado real (Ej.: siguen buscando / suspendieron)
E: información recibida por radio
U(a, h): utilidad de la acción a en el estado h

Nueva información
E (radio)



"Se suspende la búsqueda"

Actualizamos
$P(H \mid E)$



Decisión
Maximizamos
$E[U(a)]$



¿Nos quedamos esperando o salimos a buscar otra ruta?

Interpretación: la nueva información cambia nuestras probabilidades. Luego elegimos la acción con mayor utilidad esperada (ej.: quedarnos, explorar, buscar otra ruta).

Decisión: analizamos las consecuencias de cada opción y elegimos la que tiene mayor utilidad esperada con la evidencia actual.

9 ¿Cuántos eventos extremos pueden ocurrir?



Las tormentas fuertes son eventos poco frecuentes que ocurren en un intervalo de tiempo. Queremos estimar cuántas podrían ocurrir para planificar abrigo y resguardo.

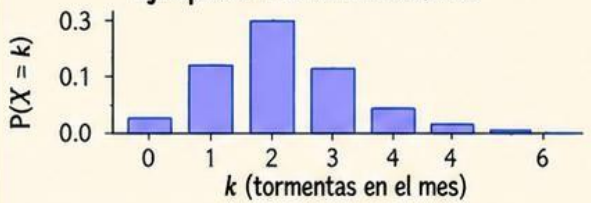
Herramienta: Distribución de Poisson

Modela el número de eventos en un intervalo, cuando ocurren de forma independiente y a una tasa promedio constante.

$$X \sim Pois(\lambda)$$
$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}$$
$$E[X] = Var(X) = \lambda$$

Supuestos:
- eventos independientes
- tasa λ constante
- se cuenta en un intervalo de tiempo o espacio

Ejemplo: $\lambda = 2$ **tormentas/mes**



Si λ = 2, la probabilidad de 0, 1, 2, ... tormentas se calcula con la fórmula de Poisson.

Decisión: estimamos el riesgo de varias tormentas para definir refugios y reservas de comida.

10 ¿Cuánto hasta el próximo evento?



En lugar de contar cuántas tormentas habrá, ahora queremos modelar el tiempo de espera hasta la próxima. Esto ayuda a decidir cuánto tiempo podemos planificar sin cambios.

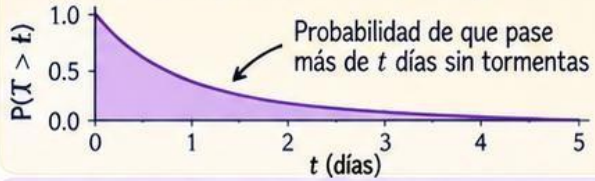
Herramienta: Distribución Exponencial

Modela el tiempo de espera entre eventos cuando ocurren según un proceso de Poisson con tasa λ.

$$T \sim Exp(\lambda)$$
$$f(t) = \lambda e^{-\lambda t} \qquad P(T > t) = e^{-\lambda t}$$
$$E[T] = \frac{1}{\lambda}$$

Supuestos:
- eventos independientes
- tasa λ constante
- memoria nula (lo que pasó antes no afecta lo que viene)

Función de supervivencia: $P(T > t) = e^{-\lambda t}$



Ejemplo: si $\lambda = 1/3$ tormentas por día (una cada 3 días en promedio), ¿cuál es la probabilidad de que pasen más de 5 días sin tormenta? $P(T > 5) = e^{-5/3} \approx 0.19$

Decisión: estimamos tiempos de espera para planificar salidas, revisar el clima y organizar recursos.

11 Avalancha: ocurrió algo extremo



Queremos cuantificar la probabilidad de un evento extremo (por ejemplo, acumulación de nieve o caída de nieve en 24 h) y entender que una probabilidad muy baja no significa que sea imposible.

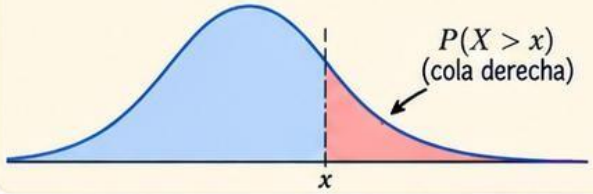
Herramienta: Distribución, cola y área de probabilidad

Usamos la función de distribución acumulada (CDF) para calcular probabilidades de regiones, especialmente la cola (eventos extremos).

$$P(X > x) = 1 - F(x) = S(x)$$
$$P(a < X < b) = F(b) - F(a)$$

Idea clave:
- la probabilidad es el área bajo la curva
- la cola mide eventos extremos
- una probabilidad pequeña no es cero

Distribución (ejemplo: Normal)



Ejemplo: si la acumulación de nieve en 24 h es $X \sim N(50, 20^2)$ cm, ¿cuál es la probabilidad de que $X > 100$ cm?

$P(X > 100) = 1 - F(100)$ Valor pequeño, pero no nulo.

Decisión: aunque la probabilidad sea baja, planificamos medidas de seguridad porque eventos extremos pueden ocurrir.

12 Los valores se agrupan alrededor de un centro



Herramienta: Distribución Normal

Modela muchas mediciones que se agrupan alrededor de un promedio, con una dispersión determinada.

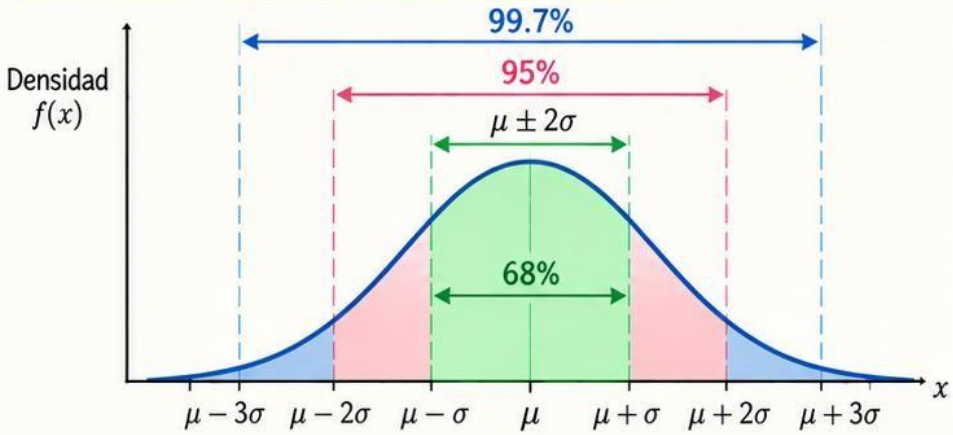
$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$P(\mu \pm \sigma) \approx 0.68$$
$$P(\mu \pm 2\sigma) \approx 0.95$$
$$P(\mu \pm 3\sigma) \approx 0.997$$

Interpretación: la distribución Normal queda completamente definida por su media μ (centro) y su desvío estándar σ (dispersión). La mayoría de los valores se concentran cerca de μ.

Distribución Normal y regla 68–95–99.7



Ejemplo con nuestro contexto

Supongamos que el gasto energético diario en la montaña sigue $X \sim N(\mu = 3200,\ \sigma = 600)$ kcal.

$$P(2600 \le X \le 3800) \approx 0.68$$
$$P(2000 \le X \le 4400) \approx 0.95$$
$$P(1400 \le X \le 5000) \approx 0.997$$

Decisión: esperamos que la mayoría de los días el gasto energético esté cerca de 3200 kcal. Esto nos permite planificar alimentos y estimar necesidades.

Supuestos (cuándo es válida)

- Datos continuos.
- Aproximadamente normal (o $\bar{X}$ normal por el TCL).
- Observaciones independientes.

¿Cuándo falla?

- Distribución muy asimétrica.
- Datos con outliers fuertes.
- Dependencia entre observaciones.

Recordá además

- Sesgo de selección: a quiénes medí ($P(i \text{ en } S)$ no es igual para todos).
- **Sesgo del estimador:** $Bias = E[\hat{\theta}] - \theta$.
- Error estándar: $SE = \sigma/\sqrt{\pi}$.

13 Pero el accidente ocurrió una sola vez: no puedo repetir 1972 miles de veces



El accidente de 1972 ocurrió una sola vez. No podemos repetirlo miles de veces, así que no conocemos la probabilidad "real" de todos los posibles resultados. Pero sí podemos usando datos (nuestra muestra) describir lo que observamos y, con modelos, inferir sobre lo que no vimos.

La intuición no alcanza: ¿Cómo pasamos de una sola muestra a conclusiones sobre toda la montaña?

De lo observado a lo que queremos saber

1. Frecuentista (con muchas repeticiones)

En muchas situaciones comparables, la probabilidad se aproxima con la frecuencia relativa.

$$P(A) \approx \frac{n_A}{n}$$



Muchas repeticiones

2. Descriptiva (en nuestros datos)

Con una muestra, resumimos la información con estadísticos.

$\overline{x}$ (media muestral)
s^2 (varianza muestral)



Lo que observamos

3. Inferencial (lo que no observamos)

Usamos un modelo (por ejemplo, Normal) para inferir sobre el parámetro de la población.

$$\overline{x} \longrightarrow \mu$$



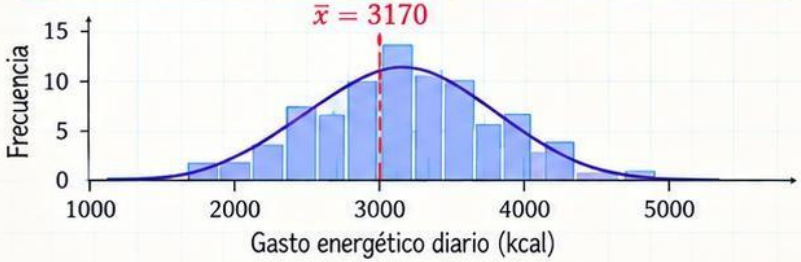
Conclusiones sobre toda la montaña (población)

Ejemplo con nuestros datos (gasto energético diario)

Supongamos que medimos el gasto energético diario (kcal) en una muestra de $n = 36$ personas en condiciones similares a las de la montaña.

Población (montaña):
$X \sim N(\mu = 3200, \sigma = 600)$

Muestra ($n = 36$):
$\overline{x} = 3170$ kcal
$s = 610$ kcal



¿Qué significa cada paso?

1 Frecuentista
Si pudiéramos repetir esta situación muchas veces, la probabilidad de ciertos eventos se aproxima con la frecuencia relativa: $P(A) \approx \frac{n_A}{n}$.

2 Descriptiva
Con esta única muestra, resumimos lo observado con $\overline{x}$ y s^2. Estos son estadísticos (varían entre muestras).

3 Inferencial
Bajo un modelo (por ejemplo, Normal) y supuestos razonables, usamos $\overline{x}$ para inferir sobre μ, el verdadero promedio de la montaña: $\overline{x} \longrightarrow \mu$.

Supuestos (para la inferencia con Normal)

- Datos independientes (cada medición no afecta a las otras).
- Distribución aproximadamente normal (o n grande, por el TCL).
- Varianza constante en la población.

Tres ideas clave

- ¿Con qué frecuencia? → se estima con la frecuencia relativa.
- ¿Qué pasó en mis datos? → lo resumimos con $\overline{x}$ y s^2.
- ¿Qué digo de lo que no observo? → inferimos μ usando $\overline{x}$ y un modelo.

Decisión en el relato

Con esta única muestra podemos estimar el gasto energético típico y su variabilidad para planificar alimentos y recursos, entendiendo la incertidumbre.

14 No conocemos la montaña



La montaña es la **población**: todas las posibles mediciones (por ejemplo, gasto energético diario de todas las personas en estas condiciones). Nosotros sólo podemos observar una parte de ella.

Herramienta: Población vs. Muestra

La población se describe con **parámetros**. De ella extraemos una muestra con datos observados.

Población (parámetros)

$$\mu,\ \sigma^2,\ \sigma,\ p$$



Toda la montaña (edad, condición física, rutas posibles, etc.)

Muestra (datos observados)

$$X_1, \ldots, X_n$$



Sólo una parte de la montaña

Interpretación: los parámetros describen la realidad completa aunque no la observemos. La muestra es un subconjunto de esa realidad y varía entre recorridos.

15 Primeras caminatas: sólo vemos pequeños recorridos



Cada recorrido es una **muestra posible** de la montaña. No todas las personas o rutas tienen la misma probabilidad de ser observadas.

Herramienta: Muestreo, sesgo y representatividad

Una muestra S es un subconjunto de la población $\mathcal{P}$.
Cada elemento i tiene una probabilidad de inclusión $P(i \in S)$, que puede ser diferente para cada persona o ruta.

$$S \subset \mathcal{P}, \quad P(i \in S)$$

Muestra representativa



Se parece a la población en sus características principales.

Muestra con sesgo



Sobre-representa ciertos grupos o rutas $P(i \in S)$ no es igual para todos).

Cambia entre recorridos



Cada recorrido da una muestra distinta de la montaña.

Interpretación: si la muestra no es representativa, nuestras conclusiones pueden estar sesgadas. El sesgo aparece por a quién observamos (selección), no por la fórmula.

16 Sólo caminamos hacia el oeste



Cómo seleccionamos las rutas (o personas) importa. Si siempre caminamos hacia el oeste, estamos usando un muestreo con sesgo de selección: algunas partes de la montaña no tienen chance de ser observadas.

Herramienta: Tipos de muestreo y sesgo de selección

El muestreo aleatorio simple da la misma probabilidad a todos.
El muestreo estratificado garantiza representación de cada grupo.

Muestreo aleatorio simple

$$P(i \in S) = \frac{n}{N}$$



Todos tienen la misma probabilidad de ser seleccionados.

Muestreo estratificado

$$n_h = n\,\frac{N_h}{N}$$



Se toma una muestra proporcional de cada estrato (por ejemplo, altitud, condición física, zona).

Interpretación: el problema puede estar en cómo conseguimos los datos. Un mal diseño de muestreo puede llevar a conclusiones erróneas aunque las fórmulas estén bien.

¿Cómo llevo esto a Z?

Estandarizamos para comparar con la Normal estándar: $Z = \dfrac{X - \mu}{\sigma}$

Nos permite llevar nuestros datos a una misma escala y calcular probabilidades.

17 ¿Qué cosas podemos medir?



Herramienta: Variables y tipos de variable

Una variable es una característica que medimos en cada individuo de la muestra.

Cualitativa (categórica)	Cuantitativa (numérica)
• **Nominal** (ej. tipo de equipo, grupo sanguíneo)	• **Discreta** (ej. nº de caminatas, nº de días)
• **Ordinal** (ej. nivel de experiencia: bajo, medio, alto)	• **Continua** (ej. temperatura, peso, gasto energético, distancia)

Notación: $X_1, \ldots, X_p$

Con p variables medimos diferentes aspectos de cada persona.

18 ¿Qué queremos explicar?



Herramienta: Variables → features y target

Según la pregunta, una variable puede ser explicativa (X) o variable objetivo (Y).

$$Y = f(X) + \varepsilon$$

Ejemplos en el relato:

- Y: gasto energético diario, supervivencia, tiempo hasta el próximo punto.
- X: temperatura, altitud, distancia, peso, estado físico, tipo de ruta, etc.

Interpretación: usamos las variables X (features) para explicar o predecir la variable Y (target), reconociendo que siempre hay variabilidad no explicada (ε).

19 ¿Cómo se distribuye el consumo/gasto energético?

El gasto energético diario de las personas en la montaña varía de un día a otro. Queremos **resumir los datos** que observamos: ¿cuál es el valor típico y qué tan dispersos están?



Herramienta: Estadística descriptiva

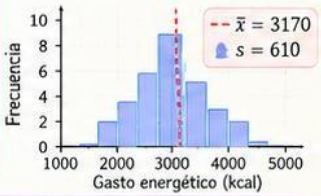
Resumimos la muestra con media, mediana, varianza y desviación estándar, y un histograma.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2$$

$$s = \sqrt{s^2}$$

Ejemplo: gasto energético diario (muestra $n = 36$)



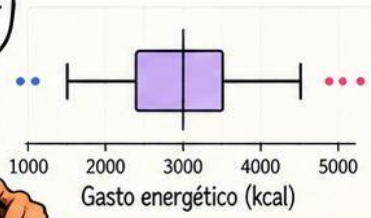
Interpretación: la media indica el valor típico y la desviación estándar cuánta variabilidad hay entre días. Es información de la muestra, no de toda la población.

20 ¿Hay caminantes que se alejan mucho del resto?

Puede haber días o personas con un gasto mucho más alto o más bajo que la mayoría. Queremos detectar estos valores que se alejan del grupo.



Boxplot del gasto energético diario (muestra $n = 36$)



Herramienta: Cuartiles, boxplot y outliers

Resumimos la distribución y detectamos valores atípicos usando el rango intercuartílico.

$$IQR = Q_3 - Q_1$$

$$x < Q_1 - 1.5\,IQR \quad \text{o}$$

$$x > Q_3 + 1.5\,IQR$$

Interpretación: los valores que caen fuera de estos límites se consideran outliers. Pueden ser días de esfuerzo extremo, mediciones inusuales o errores de registro. Analizarlos nos ayuda a tomar mejores decisiones.



21 ¿La media observada es la media "real"?



La intuición no alcanza

El promedio de la muestra puede ser distinto al promedio real de la población. ¿Cómo usamos nuestras mediciones para estimar lo que no observamos en toda la montaña?

Estadístico vs. parámetro

Parámetro (población)

- Describe una característica real de toda la población.
- Es fijo, pero generalmente desconocido.
- Ejemplos: $\mu,\ \sigma^2,\ \sigma,\ p$.

Estadístico (muestra)

- Se calcula con los datos que observamos.
- Varía entre muestras.
- Se usa para inferir el parámetro.
- Ejemplos: $\bar{x},\ s^2,\ s,\ \hat{p}$.

REALIDAD (montaña)

Variable X = gasto energético diario (kcal por persona)



Existe una población/modelo de todas las personas en la montaña.

existe una población/modelo

PARÁMETROS (desconocidos) $\mu,\ \sigma^2,\ \sigma,\ p$

Caracterizan la distribución de la población, pero en la práctica no los conocemos.

tomo una muestra

DATOS (muestra) $x_1, x_2, \ldots, x_n$



Medimos n personas y obtenemos valores concretos.

calculo

ESTADÍSTICOS (calculados en la muestra) $\bar{x},\ s^2,\ s,\ \hat{p}$



Resumimos la muestra con estadísticos.

quiero volver hacia arriba

INFERENCIA (del dato a la población) $\bar{x} \to \mu \quad s^2 \to \sigma^2 \quad s \to \sigma \quad \hat{p} \to p$

Usamos los estadísticos para estimar los parámetros de la población.

¿Cómo llevo esto a Z?

Ejemplo con nuestros datos

Población (montaña):

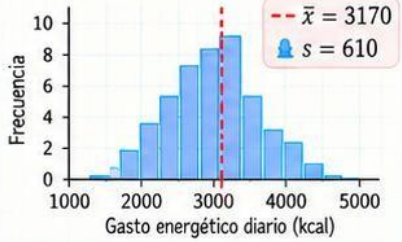
$X \sim N(\mu = 3200, \sigma = 600)$

Muestra ($n = 36$):

$\bar{x} = 3170$ kcal

$s = 610$ kcal

Distribución del gasto energético (muestra $n = 36$)



Supuestos (para inferir la media)

- Muestra aleatoria e independiente.
- Datos aproximadamente normales o n grande (TCL).
- Sin outliers muy fuertes.
- Si no se cumplen, usar métodos robustos o transformaciones.

Interpretación

Los estadísticos (como $\bar{x}$) varían entre muestras. No son el valor real, sino nuestra mejor estimación de un parámetro (μ) usando los datos disponibles.

Decisión en el relato

Con los datos de la muestra, estimamos el gasto energético típico de la población para planificar recursos y evaluar riesgos.

22 ¿Con qué apuntamos al valor real?



Herramienta: Estimación puntual

Usamos un estadístico calculado con la muestra para estimar un parámetro de la población.

$$\hat{\theta} \longrightarrow \theta$$

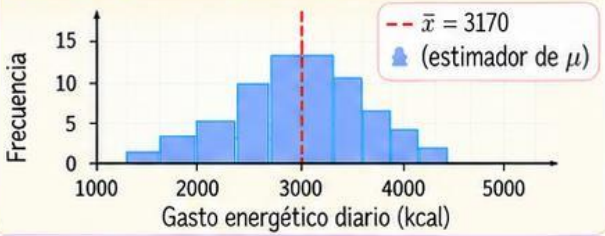
Ejemplos:

- $\bar{x}$ estima μ
- s^2 estima σ^2
- $\hat{p}$ estima p

Interpretación:

El estadístico es nuestro mejor valor puntual para el parámetro, basado en los datos que observamos.

Ejemplo: gasto energético diario



Supuesto:

- muestra representativa
- observaciones independientes

23 ¿Nuestro estimador apunta bien o está corrido sistemáticamente?



Herramienta: Sesgo del estimador

El sesgo es la diferencia entre el valor esperado del estimador y el parámetro verdadero.

$$Bias(\hat{\theta}) = E[\hat{\theta}] - \theta$$

Ejemplo numérico:

$$E[\hat{\theta}] = 108,\ \theta = 100 \Rightarrow Bias = 8$$

(sobreestima en promedio)

No confundir:

- **Sesgo de selección**: a quién observé ($P(i \in S)$ no es igual para todos).
- **Sesgo del estimador**: *cómo* estimé ($Bias(\hat{\theta}) = E[\hat{\theta}] - \theta$).
- **Error estándar**: cuánto fluctúa entre muestras ($SE = \sigma/\sqrt{n}$).

Interpretación:

Si el sesgo es 0, el estimador es insesgado.
Un sesgo positivo indica que el método tiende a sobreestimar y uno negativo que subestima.

24 ¿Por qué dividimos por $n-1$?



Herramienta: Corrección de Bessel y grados de libertad

Si usamos $\bar{x}$ en lugar de la media poblacional (desconocida), la varianza muestral con denominador n está sesgada. Dividir por $n-1$ lo corrige.

Varianza con n (sesgada)

$$\bar{s}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

$$E[\bar{s}^2] = \frac{n-1}{n}\sigma^2$$

Varianza con $n-1$ (insesgada)

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

$$E[\bar{s}^2] = \sigma^2$$

Intuición:

- Estimamos $\bar{x}$ con los mismos datos.
- Perdemos 1 grado de libertad.
- Reaparece en la t de Student con $df = n-1$.

Interpretación:

Dividir por $n-1$ nos da un estimador insesgado de la varianza poblacional.

De los datos (muestra) a la población (parámetro)

¿Cómo llevo esto a Z?

25 Dos estimadores insesgados: ¿cuál elegimos?



Herramienta: Eficiencia

Si dos estimadores son insesgados (su valor esperado es el parámetro), elegimos el que tiene menor varianza, porque da estimaciones más estables.

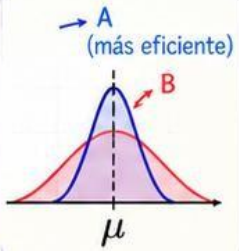
$$Var(\hat{\theta}_1) < Var(\hat{\theta}_2) \Rightarrow \hat{\theta}_1 \text{ más eficiente}$$

Ejemplo: dos estimadores insesgados de μ (gasto energético promedio)

Estimador A: $Var(\hat{\mu}_A) = 90^2$

Estimador B: $Var(\hat{\mu}_B) = 150^2$

Ambos apuntan a μ, pero el A es más eficiente porque tiene menor varianza.



Interpretación y decisión

Si no introducen sesgo, preferimos el estimador más eficiente, porque sus resultados fluctúan menos entre muestras. En la montaña, eso nos da estimaciones más confiables para planificar.

26 ¿Qué ocurriría si pudiéramos repetir muchas expediciones/ muestras?

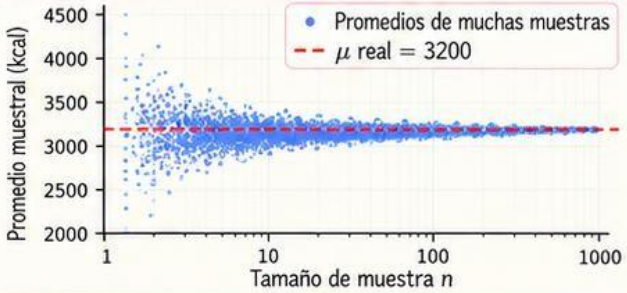


Herramienta: Ley de los Grandes Números (LGN)

Si tomamos muchas muestras independientes de la misma población, el promedio muestral (y la proporción muestral) converge en probabilidad al parámetro verdadero.

$$\bar{X}_n \xrightarrow{P} \mu, \qquad \hat{p}_n \xrightarrow{P} p$$

Ejemplo con simulación (gasto energético diario)



Interpretación y decisión

Con más observaciones, los estadísticos se estabilizan alrededor del parámetro. En la práctica, muestras más grandes dan estimaciones del gasto promedio más confiables para tomar decisiones en la montaña.

27 Más observaciones, más cerca de la montaña real



Herramienta: Consistencia

Un estimador es consistente si, al crecer el tamaño de muestra, la probabilidad de estar lejos del parámetro se hace cada vez más chica.

$$\hat{\theta}_n \xrightarrow{P} \theta \iff P(|\hat{\theta}_n - \theta| > \epsilon) \to 0$$

Intuición visual



Interpretación y decisión

Un estimador consistente nos da confianza: si pudiéramos repetir las expediciones muchas veces (muestras más grandes), nuestras estimaciones del gasto promedio se acercarían al valor real. Por eso, es clave diseñar muestras lo más grandes y representativas posible.



28 Tomamos muchas muestras de la montaña

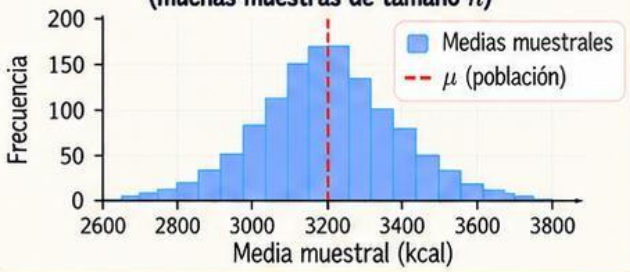


Herramienta: Distribución muestral

Si tomamos muchas muestras de tamaño n y calculamos la media en cada una, esas medias son variables aleatorias con su propia distribución.

$$\bar{X}_1, \bar{X}_2, \ldots, \bar{X}_m, \quad E[\bar{X}] = \mu, \quad Var(\bar{X}) = \frac{\sigma^2}{n}$$

Distribución de medias muestrales (muchas muestras de tamaño n)



Interpretación y decisión

- Ya no distribuimos personas: distribuimos estadísticos (las medias de las muestras).
- La distribución muestral de $\bar{X}$ tiene media μ y varianza σ^2/n. Nos permite evaluar qué medias son plausibles por puro azar.

29 Las medias empiezan a formar una campana

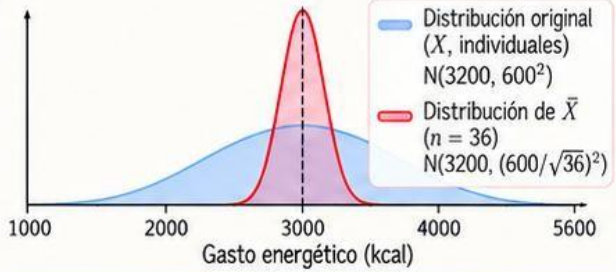


Herramienta: Teorema Central del Límite (TCL)

Bajo condiciones amplias (muestras independientes, varianza finita y n suficientemente grande), la distribución de $\bar{X}$ se aproxima a una Normal.

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1)$$

Distribución original vs. distribución de la media muestral



Supuestos (¿cuándo vale?)

- Muestras independientes (o aleatorizadas).
- Varianza finita en la población.
- n suficientemente grande (regla práctica: $n \geq 30$).
- Si hay colas muy pesadas o fuerte dependencia, la aproximación puede fallar o requerir n mayor.

30 ¿Cuánto varían nuestras medias?

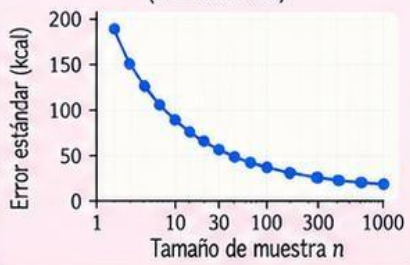


Herramienta: Error estándar

El error estándar mide la incertidumbre del estimador. No es la dispersión de los individuos, sino la variabilidad del estadístico entre muestras.

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}, \quad SE(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$$

Cómo disminuye el error estándar con n ($\sigma = 600$ kcal)



Ejemplo numérico

Si $\sigma = 600$ kcal:

- $n = 36 \rightarrow SE = 600/\sqrt{36} = 100$
- $n = 100 \rightarrow SE = 60$
- $n = 400 \rightarrow SE = 30$

Interpretación y decisión

- El error estándar indica cuánta variabilidad tienen nuestras medias muestrales por azar.
- A mayor n, menor SE: nuestras estimaciones son más precisas.
- Nos sirve para construir intervalos, hacer tests y decidir con evidencia, no solo intuición.

De muestras a decisiones confiables

¿Cómo llevo esto a Z?

31 ¿Nos equivocamos por sesgo o por variabilidad?

El error de nuestras estimaciones puede venir de dos fuentes: estar sistemáticamente corridos (sesgo) o fluctuar mucho entre muestras (variabilidad).



Herramienta: Error cuadrático medio (MSE)

El MSE mide el error total de un estimador, que se descompone en la variabilidad y el sesgo al cuadrado.

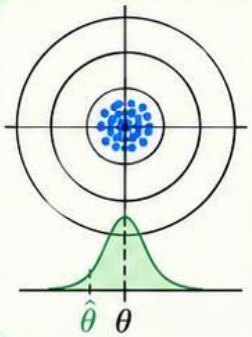
$$MSE(\hat{\theta}) = E\left[(\hat{\theta} - \theta)^2\right] = Var(\hat{\theta}) + Bias(\hat{\theta})^2$$

- $Var(\hat{\theta})$: cuánto fluctúa entre muestras (error estándar).
- $Bias(\hat{\theta})$: cuánto se aleja sistemáticamente del parámetro.
- Elegimos el estimador con menor MSE.

Importante:
- Puede haber bajo sesgo y alta varianza, o viceversa.
- El mejor estimador equilibra ambas fuentes de error.

Cuatro situaciones posibles

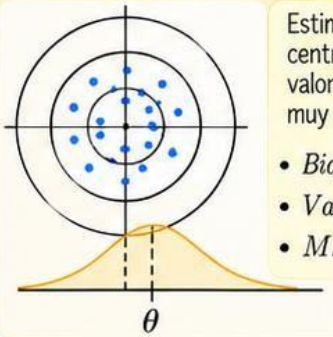
Bajo sesgo - Baja varianza



Estimaciones cercanas al valor real y con poca dispersión.

- $Bias(\hat{\theta}) \approx 0$
- $Var(\hat{\theta})$ pequeña
- MSE pequeño

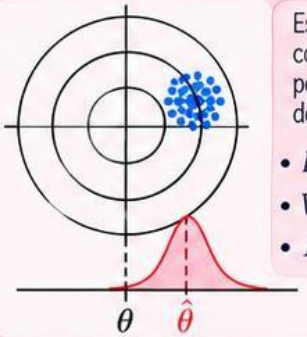
Bajo sesgo - Alta varianza



Estimaciones centradas en el valor real, pero muy dispersas.

- $Bias(\hat{\theta}) \approx 0$
- $Var(\hat{\theta})$ grande
- MSE grande

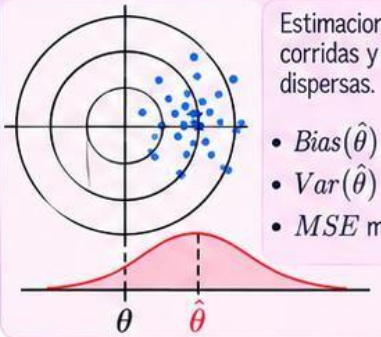
Alto sesgo - Baja varianza



Estimaciones consistentes, pero corridas del valor real.

- $Bias(\hat{\theta})$ grande
- $Var(\hat{\theta})$ pequeña
- MSE grande

Alto sesgo - Alta varianza



Estimaciones corridas y muy dispersas.

- $Bias(\hat{\theta})$ grande
- $Var(\hat{\theta})$ grande
- MSE muy grande

Ejemplo con simulación (gasto energético diario)

Comparamos dos estimadores de $\mu = 3200$ kcal: (A) insesgado y (B) con sesgo + alta varianza.

- Población: $X \sim N(3200,\ 600^2)$
- Muestras de tamaño $n = 36$
- Estimador A: $\bar{X}$ (insesgado)
- Estimador B: $\bar{X} + 300$ (sesgo de $+300$)

Estimador	Bias	Varianza	MSE
A: $\bar{X}$	≈ 0	$\approx \frac{600^2}{36} = 10\,000$	$\approx 10\,000$
B: $\bar{X} + 300$	≈ 300	$\approx 10\,000$	$\approx 100\,000$

Interpretación y decisión

Aunque ambos usen la misma muestra, el estimador B tiene mucho más error total porque está sistemáticamente corrido además de ser muy variable.

En la montaña, preferimos estimadores con menor MSE: más confiables para tomar decisiones.

¿Cómo llevo esto a Z?

32 ¿En qué rango está la media real de la montaña?



Herramienta: Intervalo de confianza (IC)

Un **intervalo de confianza** nos da un rango de valores plausibles para el parámetro poblacional, utilizando la variabilidad de la muestra.

Idea clave:

- El 95% describe el procedimiento, no es la probabilidad de que μ esté dentro.
- Cuanto mayor n, más angosto el intervalo (menor error estándar).

Media con σ conocida (Normal)

$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Usamos Z cuando la desviación estándar poblacional σ es conocida.

Media con σ desconocida (t)

$$\bar{x} \pm t_{\alpha/2,\, n-1} \frac{s}{\sqrt{n}}$$

Usamos t con $n-1$ grados de libertad cuando σ es desconocida.

Proporción

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Para estimar una proporción p.

Tamaño de muestra

$$n = \left(\frac{z_{\alpha/2}\ \sigma}{E} \right)^2$$

Para un margen de error E y un nivel de confianza $1-\alpha$.

Ejemplo numérico (media con σ conocida)

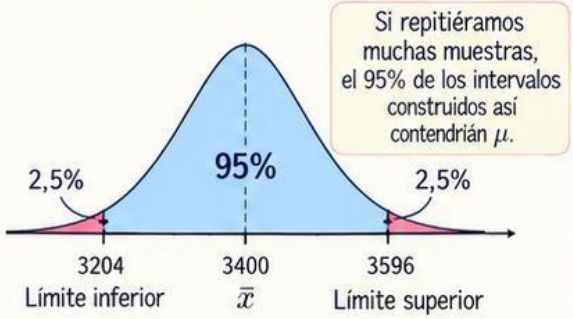
Datos de la muestra en la expedición:

- $\bar{x} = 3400$ kcal
- $\sigma = 600$ kcal (conocida)
- $n = 36$
- Nivel de confianza: 95% $(z_{0,025} = 1{,}96)$

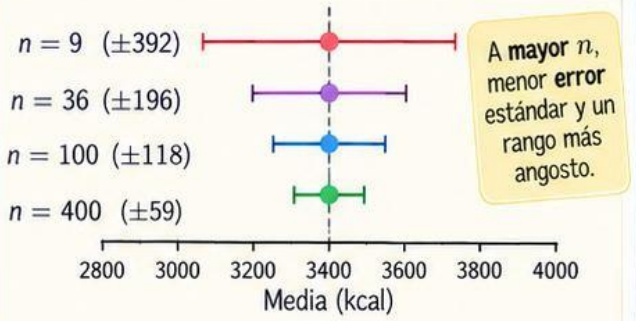
$$IC_{95\%} = 3400 \pm 1{,}96 \frac{600}{\sqrt{36}} = 3400 \pm 196$$

IC95%: [3204, 3596] kcal

Interpretación en la Normal



Efecto del tamaño de muestra



De una muestra a un rango plausible para el valor real (parámetro)

¿Cómo llevo esto a Z?

33 ¿La media de la montaña es μ_0?



Herramienta: prueba t de una muestra (o Z si σ conocida)

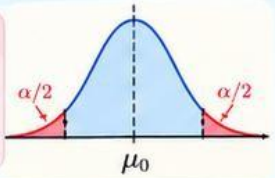
Comparamos la media muestral con un valor de referencia μ_0.

Z (σ conocida)

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

t (σ desconocida)

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad df = n - 1$$



Interpretación y decisión

- Si $|Z|$ (o $|t|$) es grande, la media observada es poco compatible con μ_0.
- Decidimos si hay evidencia de que el gasto promedio es distinto al valor de referencia.

Supuestos

- Muestra aleatoria e independiente.
- Normalidad en la población o n grande.
- Para **t**: σ desconocida.

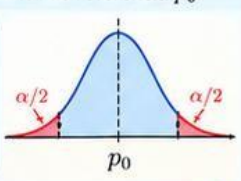
34 ¿La proporción de sobrevivientes es p_0?



Herramienta: prueba Z para una proporción

Comparamos la proporción muestral con un valor de referencia p_0.

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$



Ejemplo numérico

- $n = 50$
- $\hat{p} = 0{,}40$
- $p_0 = 0{,}50$

$$\rightarrow Z = \frac{0{,}40 - 0{,}50}{\sqrt{0{,}50(0{,}50)/50}} = -1{,}41$$

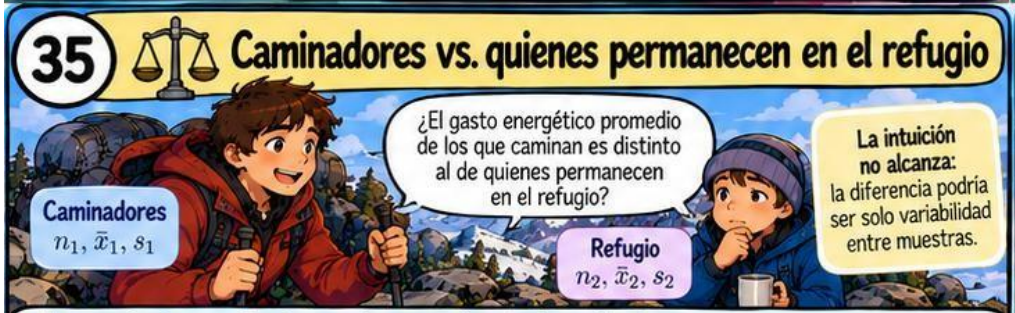
Interpretación y decisión

- Si $|Z|$ es grande, la proporción observada es poco compatible con p_0.
- Decidimos si hay evidencia de que la proporción real de sobrevivientes es distinta al valor de referencia.

Supuestos

- Muestra aleatoria e independiente.
- n suficientemente grande (np_0 y $n(1-p_0) \geq 10$).

35 Caminadores vs. quienes permanecen en el refugio



Herramienta: prueba t para dos muestras independientes

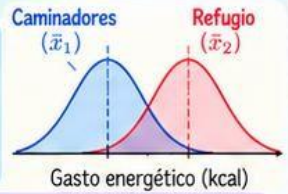
Comparamos las medias de dos grupos distintos.

t de Welch (varianzas desiguales)

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Varianza combinada (varianzas iguales)

$$s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}$$



Interpretación y decisión

- Si $|t|$ es grande, hay evidencia de que las medias poblacionales difieren.
- Decidimos si el gasto promedio es distinto entre caminadores y refugio.

Supuestos

- Muestras independientes.
- Normalidad o n suficiente.
- Varianzas iguales (para s_p^2) o usar Welch.

36 Peso antes/después

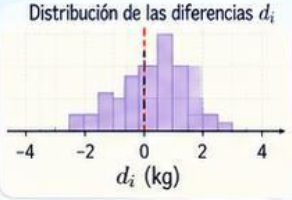


Herramienta: prueba t pareada

Analizamos las diferencias dentro de cada individuo.

$$d_i = x_{i,\text{después}} - x_{i,\text{antes}}$$

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad df = n - 1$$



Si la mayoría de diferencias es > 0, hay aumento de peso promedio.

Interpretación y decisión

- Si $|t|$ es grande, hay evidencia de un cambio promedio en el peso/gasto.
- Decidimos si hubo un aumento o disminución real.

Supuestos

- Mismos individuos (pareadas).
- Diferencias aproximadamente normales o n suficiente.

¿Cómo llevo esto a Z?

37 Refugio / caminatas cortas / caminatas largas



Herramienta: ANOVA (Análisis de la Varianza) → F

Comparamos las medias de más de dos grupos. La idea es separar la variabilidad total en dos partes: la que se debe a diferencias entre grupos y la que se debe a la variabilidad dentro de los grupos.

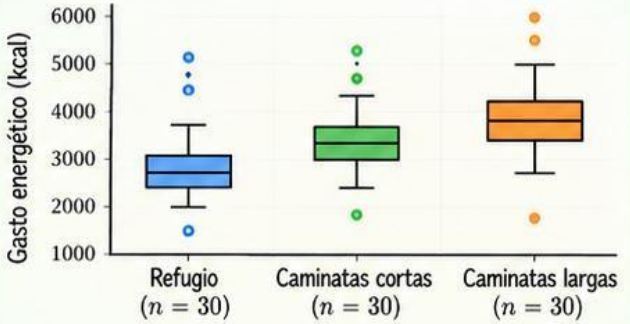
Estadístico F y descomposición de la variabilidad

$$F = \frac{MS_{\text{entre}}}{MS_{\text{dentro}}}, \qquad MS_{\text{entre}} = \frac{\text{SS}_B}{k-1}, \quad MS_{\text{dentro}} = \frac{SS_W}{N-k}$$

$$\text{SS}_B = \sum_j n_j(\bar{x}_j - \bar{x})^2$$

Ejemplo con nuestros datos (simulados)

Gasto energético diario (kcal) en tres grupos



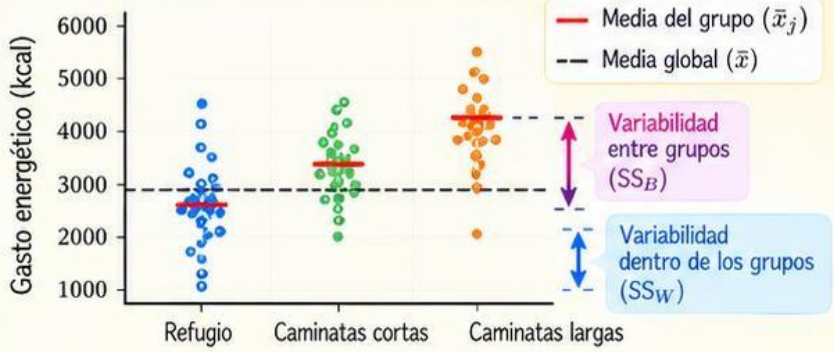
Supuestos

- Muestras independientes.
- Normalidad (aprox.) en cada grupo.
- Varianzas iguales entre grupos (o usar ANOVA de Welch si no se cumple).

¿Qué mide F?

- Si F es grande, la variabilidad entre grupos es mucho mayor que la variabilidad dentro.
- Concluimos que al menos una media poblacional es distinta.

Idea visual: descomposición de la variabilidad



Ejemplo numérico (simulado)

- $n_1 = 30$ (Refugio), $\bar{x}_1 = 2800$
- $n_2 = 30$ (Cortas), $\bar{x}_2 = 3200$
- $n_3 = 30$ (Largas), $\bar{x}_3 = 3800$
- $N = 90$, $k = 3$

Fuente	SC (SS)	gl	CM (MS)
Entre grupos (SS_B)	15 120 000	2	7 560 000
Dentro de grupos (SS_W)	41 940 000	87	482 184
Total	57 060 000	89	—

$$F = 7\,560\,000/482\,184 = \mathbf{15{,}68} \quad (p < 0{,}001)$$

Interpretación y decisión

- Como F es grande ($p < 0{,}001$), hay evidencia de que al menos una de las medias poblacionales difiere.
- Decisión en la montaña: el gasto energético no es el mismo entre refugio, caminatas cortas y largas. Conviene analizar qué grupos difieren (por ejemplo, con comparaciones múltiples) para planificar mejor.

Importante

- ANOVA detecta que existe al menos una diferencia, pero no dice cuáles.
- Si hay varianzas desiguales, usamos ANOVA de Welch o métodos robustos.

Más de dos grupos a la vez (ANOVA)

¿Cómo llevo esto a Z?

38 ¿Los sobrevivientes se reparten por zona como esperábamos?



Herramienta: χ^2 de bondad de ajuste (una vía)

Comparamos las frecuencias observadas con una distribución esperada para una única variable categórica.

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}, \quad df = k - 1$$

Ejemplo: sobrevivientes por zona

Zona	Observado (O_i)	Esperado (E_i)
Valle	18	15
Ladera	12	15
Cresta	6	15
Total	**36**	**45**

Cálculo:

$\chi^2 = 1{,}2 + 0{,}6 + 5{,}4 = 7{,}2$

$df = 3 - 1 = 2$

$p \approx 0{,}027$

Interpretación y decisión

- Si $p < 0{,}05$, la distribución observada difiere de la esperada.
- Hay evidencia de que los sobrevivientes no se reparten como el patrón propuesto (misma proporción en cada zona).
- **Decisión:** considerar que la zona sí influye en la distribución.

Supuestos

- Observaciones independientes.
- Categorías mutuamente excluyentes.
- Frecuencias esperadas E_i suficientemente grandes ($\approx \geq 5$).

39 ¿Actividad y supervivencia están asociadas?



Herramienta: χ^2 de independencia (tabla de contingencia)

Analizamos si dos variables categóricas están asociadas.

$$E_{ij} = \frac{(\text{total fila } i)(\text{total col. } j)}{N}$$

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad df = (r-1)(c-1)$$

Ejemplo: actividad vs. supervivencia

Actividad	Sobrevivió	No sobrevivió	Total
Refugio	12	18	30
Caminatas cortas	16	14	30
Caminatas largas	22	8	30
Total	**50**	**40**	**90**

Resultado (simulado) $\chi^2 = 6{,}83 \quad df = 2 \quad p \approx 0{,}033$

Interpretación y decisión

- Si $p < 0{,}05$, hay evidencia de asociación entre actividad y supervivencia.
- La proporción de sobrevivientes varía según el tipo de actividad.
- **Decisión:** la actividad parece estar relacionada con la supervivencia.

Supuestos

- Observaciones independientes.
- Frecuencias esperadas E_{ij} suficientemente grandes ($\approx \geq 5$).

40 ¿La variabilidad es la esperada? ¿Dos grupos varían igual?



Herramienta: χ^2 para una varianza y F para dos varianzas

Comparamos la variabilidad con un valor de referencia o entre dos grupos.

Una varianza (χ^2)

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}, \quad df = n - 1$$

Comparamos la varianza muestral con un valor de referencia σ_0^2.

Dos varianzas (F)

$$F = \frac{s_1^2}{s_2^2}, \quad df = (n_1 - 1, n_2 - 1)$$

Comparamos la variabilidad de dos grupos independientes.

Ejemplo 1: una varianza (simulado)

- $n = 36$
- $s = 700$ kcal
- $\sigma_0 = 600$ kcal

$\chi^2 = \frac{(36-1)700^2}{600^2} = 47{,}64$

$df = 35, \quad p \approx 0{,}047$

Hay evidencia de que la variabilidad es mayor a la esperada.

Ejemplo 2: dos varianzas (simulado)

- Grupo 1 (refugio): $s_1 = 500$, $n_1 = 30$
- Grupo 2 (largas): $s_2 = 800$, $n_2 = 30$

$F = \frac{500^2}{800^2} = 0{,}39$

$df = (29, 29)$

$p \approx 0{,}003$

La variabilidad difiere entre grupos.

Interpretación y decisión

- χ^2: si $p < 0{,}05$, la varianza es distinta del valor esperado.
- F: si $p < 0{,}05$, las varianzas de los grupos son diferentes.
- **Decisión:** la dispersión del gasto energético no es la misma (según el análisis) y esto puede afectar otras comparaciones.

Supuestos

- Muestras independientes (para F).
- Normalidad aproximada en cada grupo.
- Datos continuos.
- Para F, las varianzas se comparan como un cociente (siempre positiva).

Diferentes preguntas de la montaña, mismas ideas: comparamos con una distribución.

¿Cómo llevo esto a Z?

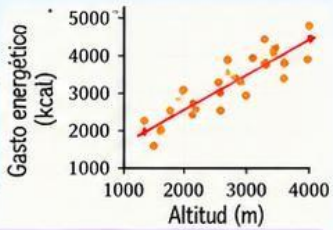
41 ¿Qué variable acompaña a cuál?



Herramienta: Correlación de Pearson

Mide la fuerza y dirección de la asociación lineal entre dos variables cuantitativas.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}, \quad -1 \le r \le 1$$



Interpretación y decisión

- $r > 0$: asociación positiva; $r < 0$: negativa.
- $|r|$ cerca de 1: relación lineal fuerte.
- Asociación ≠ causalidad.

Supuestos

- Relación aproximadamente lineal.
- Observaciones independientes.
- Sensible a outliers.

42 Pero acompañar no es causar



Herramienta: Confusores y Paradoja de Simpson

Un tercer factor puede crear o invertir una asociación entre X y Y.

$$P(Y \mid X) = \sum_z P(Y \mid X, z) P(z \mid X)$$

Idea clave

- Una asociación observada puede deberse a un tercero.
- Al estratificar o ajustar por z, la relación puede cambiar (o invertirse).

Ejemplo: mortalidad según distancia y altitud (confusor)

Distancia	Altitud baja	Altitud alta	Total
Corta	5/50 (10%)	25/50 (50%)	30/100 (30%)
Larga	1/50 (2%)	4/50 (8%)	5/100 (5%)
Total	6/100 (6%)	29/100 (29%)	35/200 (17,5%)

Interpretación y decisión

- Sin estratificar, parece que caminar más reduce la mortalidad (5% < 30%).
- Pero dentro de cada altitud la mortalidad es mayor en largas (8% > 2% y 50% > 10%).
- Decisión: considerar el confusor y analizar por estratos o con un modelo.

43 ¿Podemos modelar esa relación?

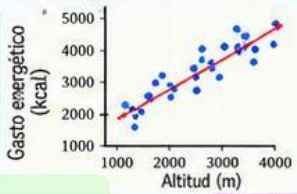


Herramienta: Regresión lineal simple

Modela la relación lineal entre una variable predictora X y una respuesta Y.

$$\hat{y} = \beta_0 + \beta_1 x$$

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$



Interpretación

- β_1: cambio promedio en Y por cada unidad de X.
- β_0: valor esperado de Y cuando $X = 0$.
- **Decisión:** usar el modelo para describir y predecir dentro del rango de datos.

Supuestos

- Relación lineal.
- Errores con media 0, varianza constante (homocedasticidad).
- Errores aproximadamente normales e independientes.

Cuidado

- Correlación ≠ causalidad.
- No extrapolar fuera del rango observado.
- Revisar outliers e influencia.

44 ¿Esa relación es real o es azar?



Herramienta: prueba t para la pendiente, R^2 y análisis de residuos

Evaluamos si la relación lineal es significativa y qué tan bien ajusta.

Prueba t sobre β_1

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}, \quad df = n - 2$$

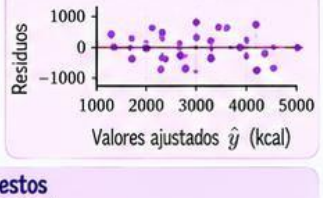
- H_0: $\beta_1 = 0$ (no hay relación lineal).
- Si $|t|$ es grande ($p < \alpha$), la pendiente es significativamente distinta de 0.

Coeficiente de determinación

$$R^2 = 1 - \frac{SSE}{SST}$$

- $0 \le R^2 \le 1$.
- Proporción de la variabilidad de Y explicada por el modelo.

Residuos $e_i = y_i - \hat{y}_i$



Interpretación y decisión

- Si $p < 0{,}05$, hay evidencia de una relación lineal.
- R^2 indica qué tan bien ajusta (no implica causalidad).
- Revisar que los residuos no muestren patrones.

Supuestos

- Linealidad.
- Errores independientes, homocedasticidad.
- Errores aproximadamente normales.

De la asociación a un modelo para decidir

¿Cómo llevo esto a Z?

45 Última expedición: ¿qué modelo usamos para decidir?



La intuición no alcanza: no podemos observar toda la montaña. Necesitamos un modelo de inferencia para usar la muestra y decir algo sobre el parámetro real.

Herramienta: Estadística inferencial

Usamos una muestra incompleta para estimar un parámetro de la población y tomar decisiones, cuantificando la incertidumbre.

$$\text{muestra} \longrightarrow \hat{\theta} \longrightarrow \theta$$

- **muestra**: Datos observados en una parte de la población
- $\hat{\theta}$: Estimador (calculado con la muestra)
- θ: Parámetro real de la población (desconocido)

Ejemplo en la montaña: gasto energético promedio

Medimos el gasto energético diario de n caminantes y queremos estimar la media poblacional μ.

Muestra (observada)



- $n = 36$ caminantes
- $\bar{x} = 3400$ kcal (promedio muestral)

→ **Estimador**

$$\hat{\mu} = \bar{x} = 3400 \text{ kcal}$$

→ **Parámetro real (desconocido)**



μ (media poblacional del gasto energético)

Modelo de inferencia



A partir de muchas muestras posibles, los estimadores tienen una **distribución muestral** (TCL, normalidad u otros supuestos) que nos permite medir la incertidumbre y decidir.

Supuestos del modelo

- Muestra representativa (sin sesgo de selección).
- Observaciones independientes.
- Distribución de la variable (normalidad o TCL para la media). Si σ es desconocida, usamos t.
- Para proporciones, muestras suficientemente grandes.
- Si no se cumplen, considerar transformaciones o métodos robustos (no paramétricos).

Tipos de preguntas que podemos responder

Estimar un parámetro p. ej. μ, p, σ^2.	→	Intervalos de confianza.
Probar una afirmación p. ej. $\mu = \mu_0$, $p = p_0$.	→	Test de hipótesis.
Comparar grupos p. ej. medias en 2 o más grupos.	→	t, ANOVA (F), χ^2.
Evaluar relaciones p. ej. asociación o efecto.	→	Correlación, regresión y test sobre β_1.

Interpretación y decisión

- El estimador $\hat{\theta}$ resume la muestra.
- El error estándar mide cuánto puede variar entre muestras.
- Con la distribución muestral (Z, t, χ^2, F) calculamos intervalos o p-valores para tomar decisiones sobre θ.
- Decisión: hacer una conclusión con una medida de incertidumbre (IC o test).

Cuidado: qué puede salir mal

- **Sesgo de selección:** no todos en la población tienen la misma probabilidad de ser observados ($P(i \in S) \neq P(i \in S')$).
- **Sesgo del estimador:** $Bias(\hat{\theta}) = E[\hat{\theta}] - \theta$.
- **Variabilidad (error estándar):** $SE = \frac{\sigma}{\sqrt{n}}$ (cuánto fluctúa entre muestras).
- **Supuestos violados:** pueden llevar a conclusiones incorrectas.

¿Cómo llevo esto a Z?

46 Distancias, calorías, temperaturas tienen unidades distintas



Herramienta: estandarización (puntaje Z)

Llevamos cada variable a la escala Z (media 0, desvío 1).

Dato individual

$$Z = \frac{x - \mu}{\sigma}$$

Media muestral

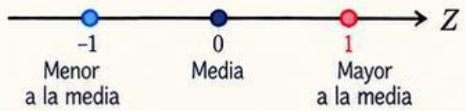
$$Z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

Interpretación y decisión

- Ahora todas las variables quedan en la misma escala (sin unidades) y son comparables.
- Un $Z > 0$ indica un valor por encima de la media.
- **Decisión:** podemos comparar magnitudes y combinar resultados de distintos problemas.

Ejemplo: misma persona, tres variables

Variable	Valor	μ	σ	Z
Distancia (km)	18	10	5	1,6
Calorías (kcal)	4000	3200	600	1,33
Temperatura (°C)	-5	-15	10	1,0



Supuestos

- Para datos individuales: la variable es (aprox.) normal.
- Para medias: vale por TCL (n grande) o normalidad.
- Independencia de las observaciones.

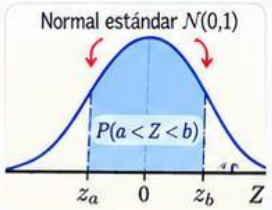
47 Python como máquina de probabilidad



Herramienta: funciones de distribución en Python

Con `scipy.stats` podemos calcular probabilidades y valores críticos.

$$\text{cdf}(z) = P(Z \le z) = \Phi(z)$$
$$\text{sf}(z) = 1 - \Phi(z)$$
$$\text{ppf}(q) = \Phi^{-1}(q)$$
$$P(a < X < b) = \Phi(z_b) - \Phi(z_a)$$



Ejemplo numérico en Python

```
from scipy.stats import norm
# Probabilidad a la izquierda de z=1.33
norm.cdf(1.33)                    → 0.9082
# Complemento (cola derecha)
norm.sf(1.33)                     → 0.0918
# Cuantil del 95%
norm.ppf(0.95)                    → 1.6449
# Probabilidad entre -1 y 1
norm.cdf(1) - norm.cdf(-1)        → 0.6827
```

Interpretación y decisión

- Las funciones nos dan el área bajo la curva (probabilidad) o el valor Z que deja un área dada.
- **Decisión:** podemos obtener p-valores, valores críticos y probabilidades exactas para tomar decisiones.

Supuestos

- Usar la distribución correcta (normal, t, χ^2, F, etc.).
- Estandarizar bien (usar la media, desvío y n correctos).

48 Obligamos a los datos a responder a Z



Herramienta: t, χ^2 y F como reescalas de Z

Todos se construyen a partir de variables normales estándar.

Chi-cuadrado

$$\chi^2_\nu = \sum_{i=1}^{\nu} Z_i^2$$

Suma de cuadrados de variables normales estándar.

t de Student

$$t_\nu = \frac{Z}{\sqrt{\chi^2_\nu / \nu}}$$

Normal estándar dividida por la raíz de un χ^2 escalado.

F de Fisher

$$F = \frac{\chi^2_{\nu_1} / \nu_1}{\chi^2_{\nu_2} / \nu_2}$$

Cociente de dos χ^2 escalados (varianzas).

Idea clave

- t aparece cuando σ es desconocida (estimamos con s).
- χ^2 se usa para varianzas y frecuencias.
- F compara varianzas (ANOVA).
- Todos son reescalas de Z, por eso se apoyan en la Normal.

Supuestos

- Normalidad de los datos (o TCL).
- Independencia de las observaciones.
- Para t: σ desconocida.
- Para F: varianzas independientes.

¿Cómo llevo esto a Z?

49 ¿Podemos confiar en la herramienta?

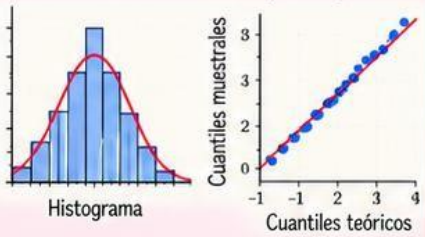


Herramienta: verificación de supuestos

Revisamos los principales supuestos antes de aplicar un test.

Normalidad (ej. Shapiro–Wilk)

$$H_0 : X \sim N(\mu, \sigma^2)$$



Independencia

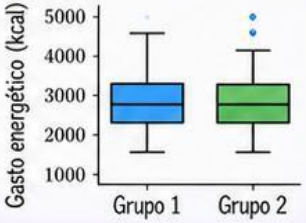
Las observaciones deben ser independientes (una no debe influir en otra).



En la montaña: evitar mediciones repetidas o rutas muy cercanas que no sean independientes.

Varianzas iguales (para comparar medias)

$$H_0 : \sigma_1^2 = \sigma_2^2$$



50 ¿Las señales encontradas son compatibles con "no hay personas cerca"?



Herramienta: hipótesis estadística

Planteamos una hipótesis nula y una alternativa sobre el parámetro de la población.

Formas comunes

$$H_0 : \theta = \theta_0$$

vs

$$H_1 : \theta \neq \theta_0 \quad \text{(dos colas)}$$
$$H_1 : \theta > \theta_0 \quad \text{(cola derecha)}$$
$$H_1 : \theta < \theta_0 \quad \text{(cola izquierda)}$$

Ejemplo en la montaña

$$H_0 : p = 0 \quad \text{(no hay personas cerca)}$$
$$H_1 : p > 0 \quad \text{(hay personas cerca)}$$

o para una media de señales:

$$H_0 : \mu = \mu_0 \quad \text{(nivel esperado de señales)}$$
$$H_1 : \mu > \mu_0 \quad \text{(más señales de lo esperado)}$$

Interpretación y decisión

- H_0 representa la situación de referencia (lo que queremos descartar).
- Comparamos lo observado con lo esperado bajo H_0 usando un estadístico de prueba (Z, t, χ^2 o F).
- Si el resultado es muy extremo, rechazamos H_0.

51 ¿Busco cualquier diferencia, aumento o disminución?

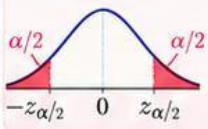


Herramienta: región de rechazo

Según la pregunta, comparamos el estadístico con un valor crítico.

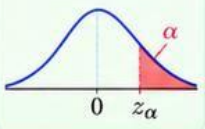
Prueba de dos colas (¿es distinto?)

$$|Z| > z_{\alpha/2}$$



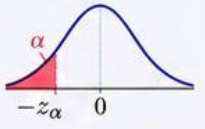
Prueba de cola derecha (¿es mayor?)

$$Z > z_\alpha$$



Prueba de cola izquierda (¿es menor?)

$$Z < -z_\alpha$$



Valores críticos comunes para Z (Normal estándar)

α	z_α	$z_{\alpha/2}$
0,10	1,282	1,645
0,05	1,645	1,960
0,01	2,326	2,576

Interpretación y decisión

- Rechazamos H_0 si el estadístico cae en la región extrema definida.
- La región se define según la pregunta, antes de ver el resultado.

¿Cómo llevo esto a Z?

52 ¿Qué tan extraordinario sería lo observado si H_0 fuera cierto?



Herramienta: p-valor y nivel de significancia

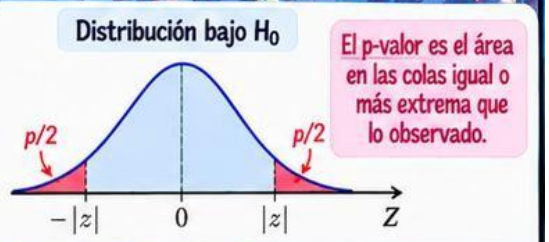
Probabilidad de obtener un resultado tan extremo o más, asumiendo que H_0 es cierta.

$$p = P(T \text{ tan extremo o más} \mid H_0)$$

Prueba bilateral:

$$p_{2\text{ colas}} = 2\,P(Z > |z|)$$

Rechazo H_0 $\Leftrightarrow$ $p < \alpha$



El p-valor es el área en las colas igual o más extrema que lo observado.

Interpretación y decisión

- p pequeño → resultado poco probable bajo H_0.
- Si $p < \alpha$ (ej. 0,05), rechazamos H_0.
- El p-valor cuantifica la evidencia, no la probabilidad de que H_0 sea verdadera.

53 Podemos equivocarnos



Herramienta: errores Tipo I y Tipo II, potencia

Evaluamos las probabilidades de cometer cada error.

Realidad	Decidimos rechazar H_0	Decidimos no rechazar H_0
H_0 cierta	Error Tipo I (α)	Decisión correcta ($1-\alpha$)
H_1 cierta	Decisión correcta (potencia $= 1-\beta$)	Error Tipo II (β)

$$\alpha = P(\text{rechazar } H_0 \mid H_0 \text{ cierta})$$
$$\beta = P(\text{no rechazar } H_0 \mid H_1 \text{ cierta})$$
$$\text{potencia} = 1 - \beta$$

En la montaña (ejemplo)

- **Tipo I (falso positivo):** concluir que la media del gasto cambió cuando en realidad no cambió.
- **Tipo II (falso negativo):** no detectar un cambio real en la media del gasto.

Qué influye en la potencia

- Tamaño de muestra (n): mayor n → mayor potencia.
- Tamaño del efecto (qué tan grande es la diferencia).
- Nivel de significancia (α): si lo bajamos, la potencia generalmente disminuye.

54 Probamos 20 hipótesis y una sale "significativa"



Herramienta: comparaciones múltiples

Si hacemos muchas pruebas, aumenta la probabilidad de al menos un falso positivo.

$$P(\text{al menos un falso positivo}) = 1 - (1-\alpha)^m$$

Corrección de Bonferroni

$$\alpha_{\text{Bonferroni}} = \frac{\alpha}{m}$$

Ejemplo numérico

Con $\alpha = 0{,}05$ y $m = 20$ pruebas:

$$P(\text{al menos un falso positivo}) = 1 - (1 - 0{,}05)^{20} \approx 0{,}64$$

Hay ≈ 64% de chance de que al menos una salga "significativa" por azar.

Tamaño de muestra y potencia

- Mayor n → mayor potencia (detectamos mejor efectos reales).
- Pero también podemos encontrar "significancias" muy pequeñas que pueden ser poco relevantes en la práctica (efecto muy chico).
- Mejor: definir hipótesis de interés antes de analizar y usar correcciones si se hacen muchas pruebas.

¿Cómo llevo esto a Z?

55 ¿Qué test uso para cada pregunta?



Caja de herramientas: ¿qué test uso en cada caso?

La pregunta en la montaña	Test	Estadístico	Distribución bajo H_0
¿La media es μ_0? (σ conocida o n grande)	Z una muestra	$\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}$	$N(0,1)$
¿La media es μ_0? (σ desconocida)	t una muestra	$\frac{\bar{x}-\mu_0}{s/\sqrt{n}}$	t_{n-1}
¿Dos grupos independientes difieren en media?	t independiente	$\frac{\bar{x}_1-\bar{x}_2}{SE}$	t_ν
¿Cambió la media en los mismos individuos?	t pareada	$\frac{\bar{d}}{s_d/\sqrt{n}}$	t_{n-1}
¿Tres o más medias difieren?	ANOVA (F)	$\frac{MS_{entre}}{MS_{dentro}}$	$F_{k-1,\,N-k}$
¿La proporción es p_0?	Z proporción	$\frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)/n}}$	$N(0,1)$
¿Los datos se ajustan a lo esperado?	χ^2 bondad de ajuste	$\sum \frac{(O-E)^2}{E}$	χ^2_{k-1}
¿Dos categóricas son independientes?	χ^2 independencia	$\sum \frac{(O-E)^2}{E}$	$\chi^2_{(r-1)(c-1)}$
¿La varianza es σ_0^2?	χ^2 varianza	$\frac{(n-1)s^2}{\sigma_0^2}$	χ^2_{n-1}
¿Dos grupos tienen la misma varianza?	F razón de varianzas	$\frac{s_1^2}{s_2^2}$	$F_{n_1-1,\,n_2-1}$
¿La pendiente de la regresión es cero?	t sobre β_1	$\frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$	t_{n-2}

Un mismo hilo: todo parte de Z



Z es la pieza base. Si σ es desconocida, aparece t. Si sumamos Z^2, obtenemos χ^2. Si comparamos dos χ^2, obtenemos F.

Z
Normal estándar
$Z \sim N(0,1)$

→

t
σ desconocida
$t = \frac{Z}{\sqrt{\chi^2_\nu/\nu}}$

→

χ^2
suma de cuadrados
$\chi^2_\nu = \sum_{i=1}^{\nu} Z_i^2$

→

F
cociente de varianzas
$F = \frac{\chi^2_{\nu_1}/\nu_1}{\chi^2_{\nu_2}/\nu_2}$

Supuestos generales

- Normalidad (o n grande por TCL).
- Independencia de observaciones.
- Varianzas iguales (según el test).
- Datos bien medidos y sin sesgos de selección importantes.

¿Cómo llevo esto a Z?

56 De inferir la montaña a aprender un modelo



Herramienta: modelos de ML (regresión)

Los parámetros se aprenden minimizando un error en los datos. Los hiperparámetros controlan el proceso.

Estimación de parámetros (ej. regresión lineal)

$$\hat{\beta} = \arg\min_{\beta} \sum_{i} (y_i - \hat{y}_i)^2$$

Proceso de entrenamiento

Datos (X, y) + Hiperparámetros (p. ej. max_depth, k, C) $\xrightarrow{fit}$ Parámetros aprendidos (β, w, b) → Modelo $\hat{f}(x)$

Parámetros vs. hiperparámetros

Parámetros del modelo (se aprenden)

- Regresión: β_0, β_1
- Modelos lineales: w, b
- Se estiman con los datos.

Hiperparámetros (los elegimos)

- Árboles: max_depth
- KNN: k
- Regularización: C, λ
- Controlan el proceso de entrenamiento.

Interpretación y decisión

- Elegimos un modelo y sus hiperparámetros.
- Entrenamos y obtenemos parámetros que describen cómo se relacionan las variables.
- Luego usamos el modelo para predecir y decidir.

57 La tabla de contingencia vuelve como matriz de confusión



Herramienta: matriz de confusión y métricas de clasificación

Comparamos las predicciones del modelo con los valores reales.

Matriz de confusión

	Real positivo (1)	Real negativo (0)
Predicho positivo (1)	TP (verdaderos +)	FP (falsos +)
Predicho negativo (0)	FN (falsos −)	TN (verdaderos −)

Métricas principales

$$\text{accuracy} = \frac{TP + TN}{N}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{TP + FN}$$

Errores del modelo: sesgo–varianza

El error de predicción se descompone en:

$$E[(y - \hat{f})^2] = \sigma_\varepsilon^2 + \text{Bias}^2 + \text{Var}$$

- **Sesgo:** error sistemático (modelo muy simple).
- **Varianza:** cuánta fluctúa entre muestras (modelo muy complejo).
- **Trade-off:** buscamos buen desempeño en datos nuevos (no solo en entrenamiento).

58 Nunca conocimos toda la montaña



Del mundo real a la decisión

Realidad (población)

- Distribución desconocida.
- Parámetros $(\mu, \sigma, p, \ldots)$.

→

Muestra (datos)

- Solo una parte de la población.
- Puede haber sesgo de selección.

→

Estadísticos (estimadores)

- $\bar{x}, \hat{p}, s, r, \hat{\beta}, \ldots$
- Tienen error estándar.
- Fluctúan entre muestras.

→

Modelos (distribuciones/ML)

- Normal, $t, \chi^2, F, \ldots$ o modelos de ML.
- Supuestos y hiperparámetros.

→

Inferencia (test, IC)

- p-valor, región crítica, IC.
- Cuantificamos incertidumbre.

→

Decisión

- Conclusión en contexto.
- Siempre con una probabilidad de error.

¿Cómo llevo esto a Z?

59 Los que volvieron: ¿y los que no?

Un dataset de sobrevivientes no es es población.



La intuición no alcanza

- ¿Podemos generalizar lo aprendido con los sobrevivientes al grupo completo?
- ¿Qué tan distintos pueden ser los que no observamos?
- Un análisis solo con quienes volvieron puede darnos una imagen sesgada.

Herramienta: sesgo del superviviente

La probabilidad de observar un dato condicionado a haber sobrevivido no es la misma que en la población.

$$P(\text{dato} \mid \text{sobrevivió}) \neq P(\text{dato})$$

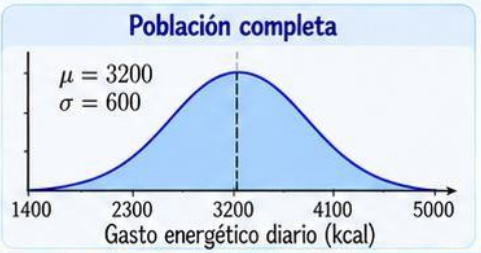
$$E[X \mid S = 1] \neq E[X]$$

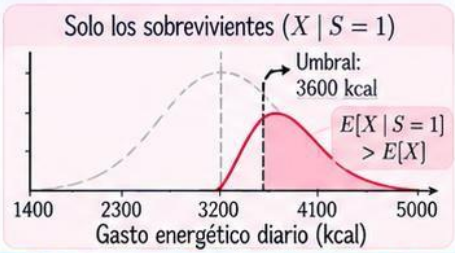
Idea clave

- Nuestro dataset es una muestra selectiva: $P(i \in S)$ no es igual para todos.
- El estimador puede ser sesgado: $Bias = E[\hat{\theta}] - \theta$.
- El error estándar mide cuánto fluctúa entre muestras: $SE = \sigma/\sqrt{n}$.

Ejemplo en la montaña: gasto energético y sobrevivencia

Simulamos el gasto energético diario en la población ($\mu = 3200$ kcal, $\sigma = 600$ kcal) y suponemos que sobrevivir requiere un gasto por encima de un umbral (3600 kcal).





Resultados de la simulación (números de ejemplo)

Población completa:

- Media: 3200 kcal
- Desvío: 600 kcal

Sobrevivientes ($X > 3600$):

- Media: 4031 kcal
- Desvío: 454 kcal
- Proporción que sobrevivve:
- Sesgo: $4031 - 3200 = 831$ kcal

La muestra de sobrevivientes tiene una media mayor porque solo observamos una parte de la distribución (la cola derecha).

Ejemplo clásico: aviones con agujeros



Aviones que volvieron

Se analizaban los agujeros en los aviones que volvían e ignoraban los que no volvieron.



Los que no volvieron (no observados)

Los aviones que no volvieron podían tener agujeros en otras partes críticas.

➡ Conclusión: reforzar solo las zonas que vemos puede ser una mala decisión.

Este sesgo también aparece en ML

Datos de entrenamiento (solo casos que "funcionaron")



- El modelo aprende de los casos observados.
- Si los datos están sesgados, aprende un mundo incompleto.
- Puede funcionar bien en la muestra, pero fallar en la realidad.

Otros ejemplos reales

- Estudios médicos: solo pacientes que sobrevivieron al tratamiento.
- Productos: solo opiniones de clientes satisfechos.
- Contrataciones: solo quienes fueron contratados.
- Datos en internet: solo contenido que se publica (lo que no se publica también es información).

¿Cómo reducir este sesgo?

- ✅ Diseños de muestreo que representen a toda la población.
- ✅ Modelos que tengan en cuenta la probabilidad de selección.
- ✅ Recolectar más datos y variables relevantes.
- ✅ Ser conscientes de las limitaciones al interpretar y decidir.

Siempre que decidimos con datos, recordemos que solo vemos una parte de la montaña.



¿Cómo llevo esto a Z?

SAMSUNG



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.