SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

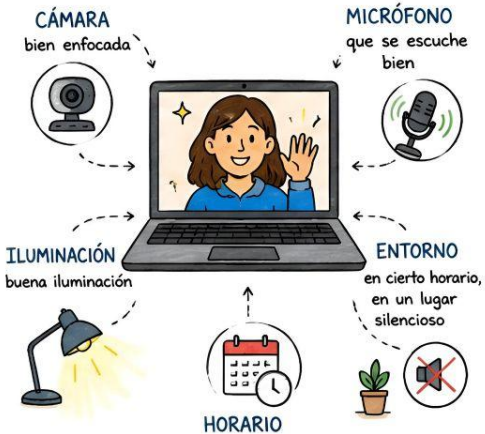
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



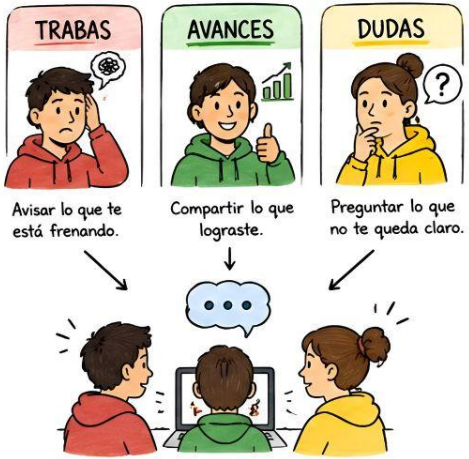
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



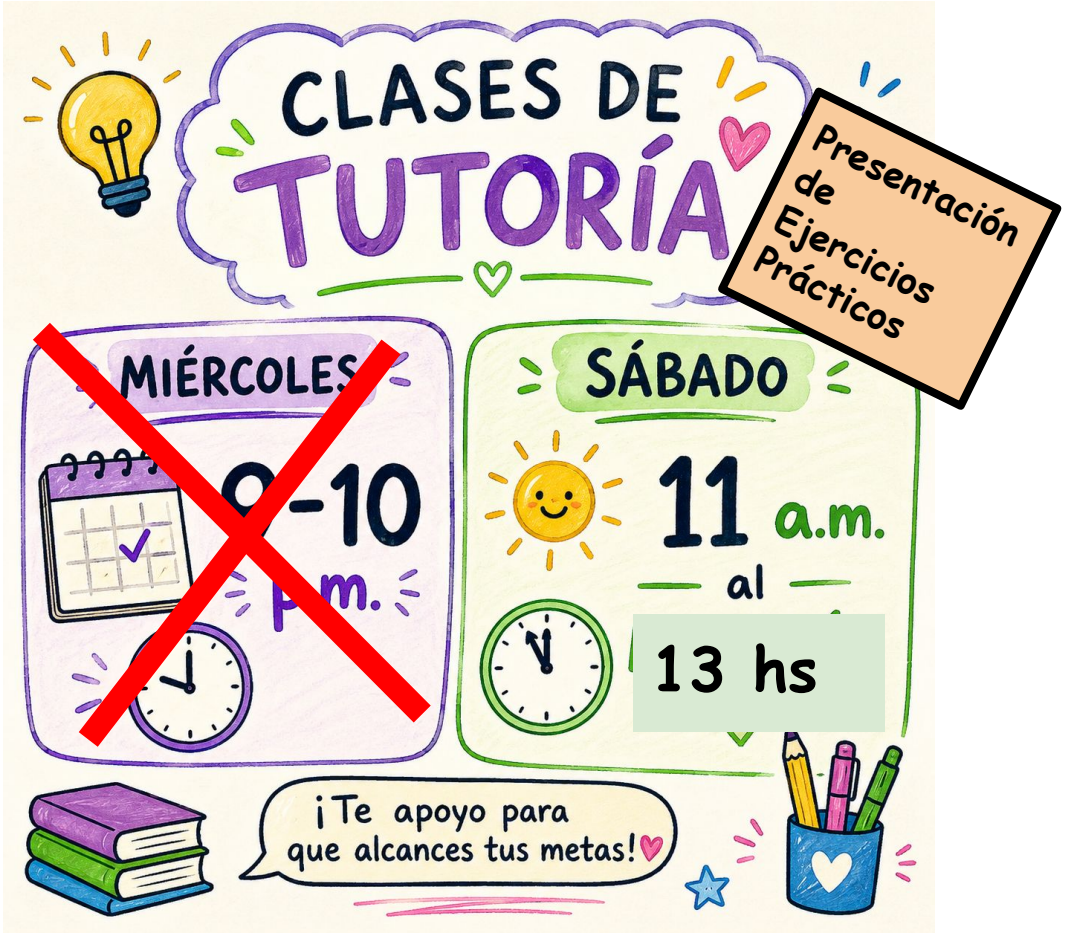
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS

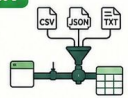


[Inscripción a la reunión - Zoom]

CLASE ANTERIOR

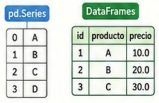
1. PANDAS — EJERCICIOS PROGRESIVOS

2.1 Estructuras de datos y pipeline



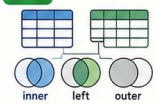
- Datos estructurados, semiestructurados y no estructurados
- Construcción del pipeline hacia `DataFrame`

2.2 Series y DataFrames



- Crear y explorar `Series` / `DataFrame`
- Selección: `loc` / `iloc`
- Índices y columnas
- Agregar, modificar y eliminar datos
- Ejercicio: productos + IVA + filtros

2.3 Combinar datos



- `pd.con...()`
- `pd.m...ge()`
- `in... / left / outer`
- `...ercicio`: empleados + depar...ntos

2.4 Ordenamiento e ...ices

- `sort_values()`
- `sort_index(`
- `MultiInd...`
- Ejercicio: ...entas + región + vendedor

2.5 Análisis de datos

- ...adísticas descriptivas
- `groupby()`
- *Pivoting*
- Muestreo

2. APIFY — RETOMAMOS EL CLIENTE



- Ejecutar un Actor
- Obtener resultados
- Procesar el output con Pandas

3. MAKE + REQUESTS



- Consumir APIs
- GET / POST
- JSON
- Requests vs. Make
- Llevar resultados a Pandas

4. DESAFÍO CREATIVO — UAV DRONE DATASET



FLUJO DE LA CLASE



CLASE DE HOY: LIBROS DE TERROR

Scraping + ETL + Búsqueda + NLP + Análisis

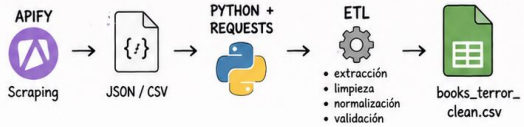
OBJETIVO: Construir un dataset de libros de terror a partir de datos de la web, limpiarlo y responder preguntas sobre disponibilidad, similitud y precios.

1. REVISIÓN RÁPIDA

- ✅ 2.3 Operaciones con Series
- ✅ 2.4 Operaciones con DataFrames
- ✅ 2.5 Combinar datos (concat / merge / join)

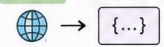


2. PIPELINE GENERAL

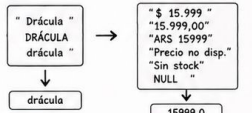


3. ETL BÁSICO

EXTRACT Obtener datos de Apify



TRANSFORM Limpiar y normalizar



LOAD Guardar dataset limpio → CSV

4. BÚSQUEDA PDF

¿Existe el PDF del libro?

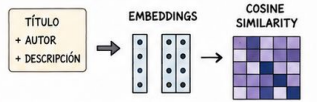


title	pdf_found	pdf_url
Drácula	✅	https://...
El exorcista	❌	—
It	✅	https://...

Discutimos límites legales y éticos de las búsquedas.

5. SIMILITUD SEMÁNTICA

¿Qué libros son similares entre sí?



Top pares más similares

book_a	book_b	similarity
Drácula	Carmilla	0.87
It	La llamada de Cthulhu	0.84
El exorcista	El resplandor	0.81
...	...	...

6. SEGUNDO EXPERIMENTO: ELEGIR UN TÍTULO Y OBTENER 50 REGISTROS

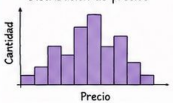
Ejemplo: DRÁCULA
50 publicaciones



title	seller	price	original_price	discount	date
Drácula	Vendedor A	12000	15000	20%	18/08/26
Drácula	Vendedor B	14500	—	0%	18/08/26
Drácula	Vendedor C	10999	13999	21%	18/08/26
...	...	...			

7. ANÁLISIS DE PRECIOS Y DESCUENTOS

Distribución de precios

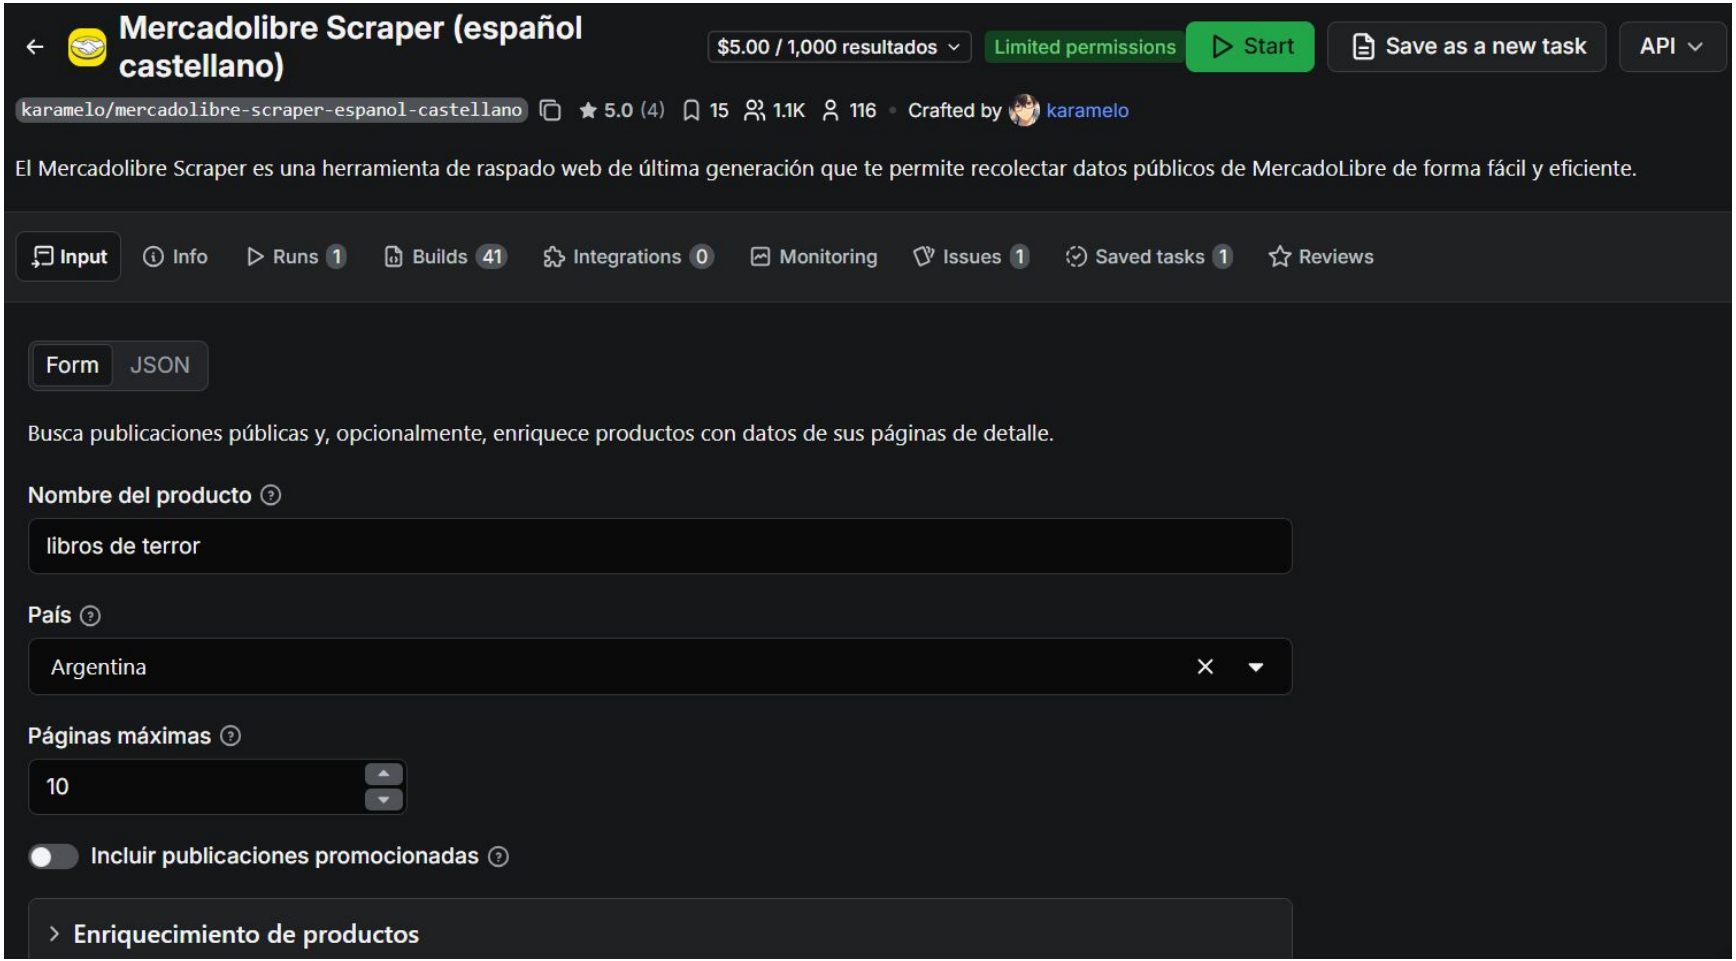


¿Tuvo descuentos?

`has_discount = (discount > 0)`

Comparar precios con vs sin descuento




Mercadolibre Scraper (español castellano)
$5.00 / 1,000 resultados
Limited permissions
Start
Save as a new task
API
karamelo/mercadolibre-scraper-espanol-castellano
5.0 (4)
15
1.1K
116
Crafted by karamelo
El Mercadolibre Scraper es una herramienta de raspado web de última generación que te permite recolectar datos públicos de MercadoLibre de forma fácil y eficiente.
Input
Info
Runs 1
Builds 41
Integrations 0
Monitoring
Issues 1
Saved tasks 1
Reviews
Form
JSON
Busca publicaciones públicas y, opcionalmente, enriquece productos con datos de sus páginas de detalle.
Nombre del producto
libros de terror
País
Argentina
Páginas máximas
10
Incluir publicaciones promocionadas
Enriquecimiento de productos

Run · Mercadolibre Scraper (español castellano) Actor

Actions API Share Export

Succeeded Actor succeeded with 478 results in the dataset | $2.390 | 2026-08-17 22:51 | 3 m 30 s | Show details

Output 478 | Log | Input | Storage | Live view | Triggered integrations 0

Vista general | All fields

Preview in new tab | Table | JSON

#	Dirección de imagen imgDireccion	Moneda Moneda	Precio actual nuevoPrecio	Precio anterior precioAnterior	Descuento precioDiscount	Título del artículo articuloTitulo	Cuotas installments	Promociones promociones	Cantidad vendida cantidadVendida	Env gra env
101		ARS	26000			Los Desmaravilladores - Loqueleo			100	✓
102		ARS	42550			Libro Quien pierde paga (TrilogÃÂa Bill...			100	✓
103		ARS	89388			Libro Estuche Stranger Things -	6 cuotas de		null	✓



DE OUTPUT A TABLA LEGIBLE

Objetivo: convertir datos crudos (desordenados, inconsistentes y con ruido) en una **tabla limpia, coherente** y lista para analizar.

IDEA CLAVE
Un buen análisis comienza con buenos datos.

OUTPUT CRUDO (DESORDENADO)

title	author	price	discount	availability	extra_col_1	extra_col_2
" drÁcula "	Bram Stoker	" $ 15.999 "	20 %	En Stock	NULL	abc123
IT	Stephen King	15.999,00		sin stock	-	xyz987
El exorcista	W. P. Blatty	ARS 13.500	Sin descuento	" Disponible "	foo	bar
La llamada de Cthulhu	H. P. Lovecraft	Precio no disponible	0	En stock	123	---
Drácula	Bram Stoker	15999	20%	EN STOCK	?	null

TABLA LIMPIA (LISTA PARA ANALIZAR)

title	author	price (ARS)	discount (%)	availability	source	scraped_at
Drácula	Bram Stoker	15999.00	20	available	MercadoLibre	2026-08-18
It	Stephen King	15999.00	0	unavailable	MercadoLibre	2026-08-18
El exorcista	W. P. Blatty	13500.00	0	available	MercadoLibre	2026-08-18
La llamada de Cthulhu	H. P. Lovecraft	NaN	0	available	MercadoLibre	2026-08-18
Drácula	Bram Stoker	15999.00	20	available	MercadoLibre	2026-08-18

¿QUÉ DEBO HACER?

Eliminar columnas innecesarias
Quitar columnas vacías, IDs internos, datos irrelevantes.

Limpiar texto
Quitar espacios extras, normalizar mayúsculas/minúsculas, corregir acentos.

Formatear precios
Convertir todos los formatos a números (float) en ARS.
Ej: "$ 15.999" → 15999.00

Formatear descuentos
Convertir a porcentaje numérico (0–100).
Ej: "20 %" → 20

Estandarizar disponibilidad
Mapear a: available / unavailable.

Agregar metadatos
Agregar fuente y fecha de scraping.

Validar y manejar faltantes
Detectar nulos, valores inválidos y decidir cómo imputar o marcar.

REGLAS DE TRANSFORMACIÓN CLAVE

PRECIOS
Normalizar a número (float)

Antes	Después
• " $ 15.999 "	15999.00
• "15.999,00"	
• "ARS 15.999"	
• "Precio no disponible"	NaN
• NULL / ""	

DESCUENTOS
Normalizar a porcentaje (0–100)

Antes	Después
• "20 %"	20
• "20%"	20
• "Sin descuento"	0
• "0"	0
• ""	0

DISPONIBILIDAD
Estandarizar valores

Antes	Después
• "En Stock"	available
• "en stock"	available
• "Disponible "	available
• "sin stock"	unavailable
• ""	unknown

TEXTO
Limpiar y normalizar

Antes	Después
• " drÁcula "	Drácula
• "Bram Stoker "	Bram Stoker
• "EL EXORCISTA "	El exorcista

Resultado: un dataset limpio, consistente y confiable para análisis, visualizaciones y modelos de NLP.





ENRIQUECER DATASET CON DUCKDUCKGO

Usamos **requests** para buscar en **DuckDuckGo** un resumen del libro y si existe un PDF en internet. Se agregan **2 columnas** al dataset.

OBJETIVO

Enriquecer cada libro con:

- summary → resumen del libro
- pdf_url → link al PDF (si existe)

DATASET LIMPIO → books_terror_clean.csv

PYTHON + REQUESTS → Enviamos consultas HTTP a DuckDuckGo

DUCKDUCKGO → Buscador web

INFORMACIÓN OBTENIDA → Resumen; Link PDF si existe

DATASET ENRIQUECIDO → books_terror_enriched.csv (con summary y pdf_url)

¿CÓMO FUNCIONA?

1. Construimos la consulta

```
"Drácula" filetype:pdf
"Drácula" resumen libro
```

2. Enviamos la consulta a DuckDuckGo usando `requests.get()`
3. Parseamos el HTML y extraemos:
   - el primer PDF encontrado (si hay)
   - el snippet con el resumen

EJEMPLO DE CÓDIGO (RESUMEN)

```python
import requests
from bs4 import BeautifulSoup
from urllib.parse import quote

# Buscar en DuckDuckGo
def duckduckgo_search(query, max_results=5):
    url = "https://html.duckduckgo.com/html/"
    resp = requests.get(url, params={"q": query}, headers=HEADERS, timeout=10)
    soup = BeautifulSoup(resp.text, "html.parser")

    # Extraer resultados
    results = []
    for r in soup.select(".result")[:max_results]:
        results.append({
            "title": r.select_one(".result__title").get_text(" ", strip=True),
            "url": r.select_one(".result__a")["href"],
            "snippet": r.select_one(".result__snippet").get_text(" ", strip=True)
        })
    return results
```

FUNCIONES PRINCIPALES

search_summary(title, author)

Busca el resumen del libro.

"Drácula" resumen libro → Drácula es una novela gótica escrita por Bram Stoker...

search_pdf(title, author)

Busca un PDF del libro.

"Drácula" filetype:pdf → https://.../dracula.pdf (o None si no se encuentra)

ANTES (DATASET LIMPIO)

title	author	price	discount
Drácula	Bram Stoker	15999.00	20
It	Stephen King	15999.00	0
El exorcista	W. P. Blatty	13500.00	0
...			

DESPUÉS (DATASET ENRIQUECIDO)

title	author	price	discount	summary	pdf_url
Drácula	Bram Stoker	15999.00	20	Novela gótica sobre el conde Drácula, el vampiro que viaja desde Transilvania...	https://.../dracula.pdf
It	Stephen King	15999.00	0	Un grupo de niños de Derry se enfrenta a una entidad maligna que adopta la forma de sus peores miedos...	https://.../it.pdf
El exorcista	W. P. Blatty	13500.00	0	Regan MacNeil, una niña poseída por una entidad demoníaca, es sometida...	None
...					

CONSIDERACIONES IMPORTANTES

- Encontrar un PDF no garantiza que sea legal, ni que tenga relación con el libro.
- Usamos la URL encontrada, no descargamos el PDF.
- Respetar límites de uso: hacer pausas entre consultas para no sobrecargar el buscador.
- El resumen proviene del snippet del resultado; puede no ser un resumen completo del libro.

COLUMNAS NUEVAS

summary
→ texto con el resumen encontrado

pdf_url
→ link al PDF encontrado o None si no existe



APLICACIÓN AL DATAFRAME

```python
for index, row in df.iterrows():
    df.loc[index, "summary"] = search_summary(row["title"], row["author"])
    df.loc[index, "pdf_url"] = search_pdf(row["title"], row["author"])
```

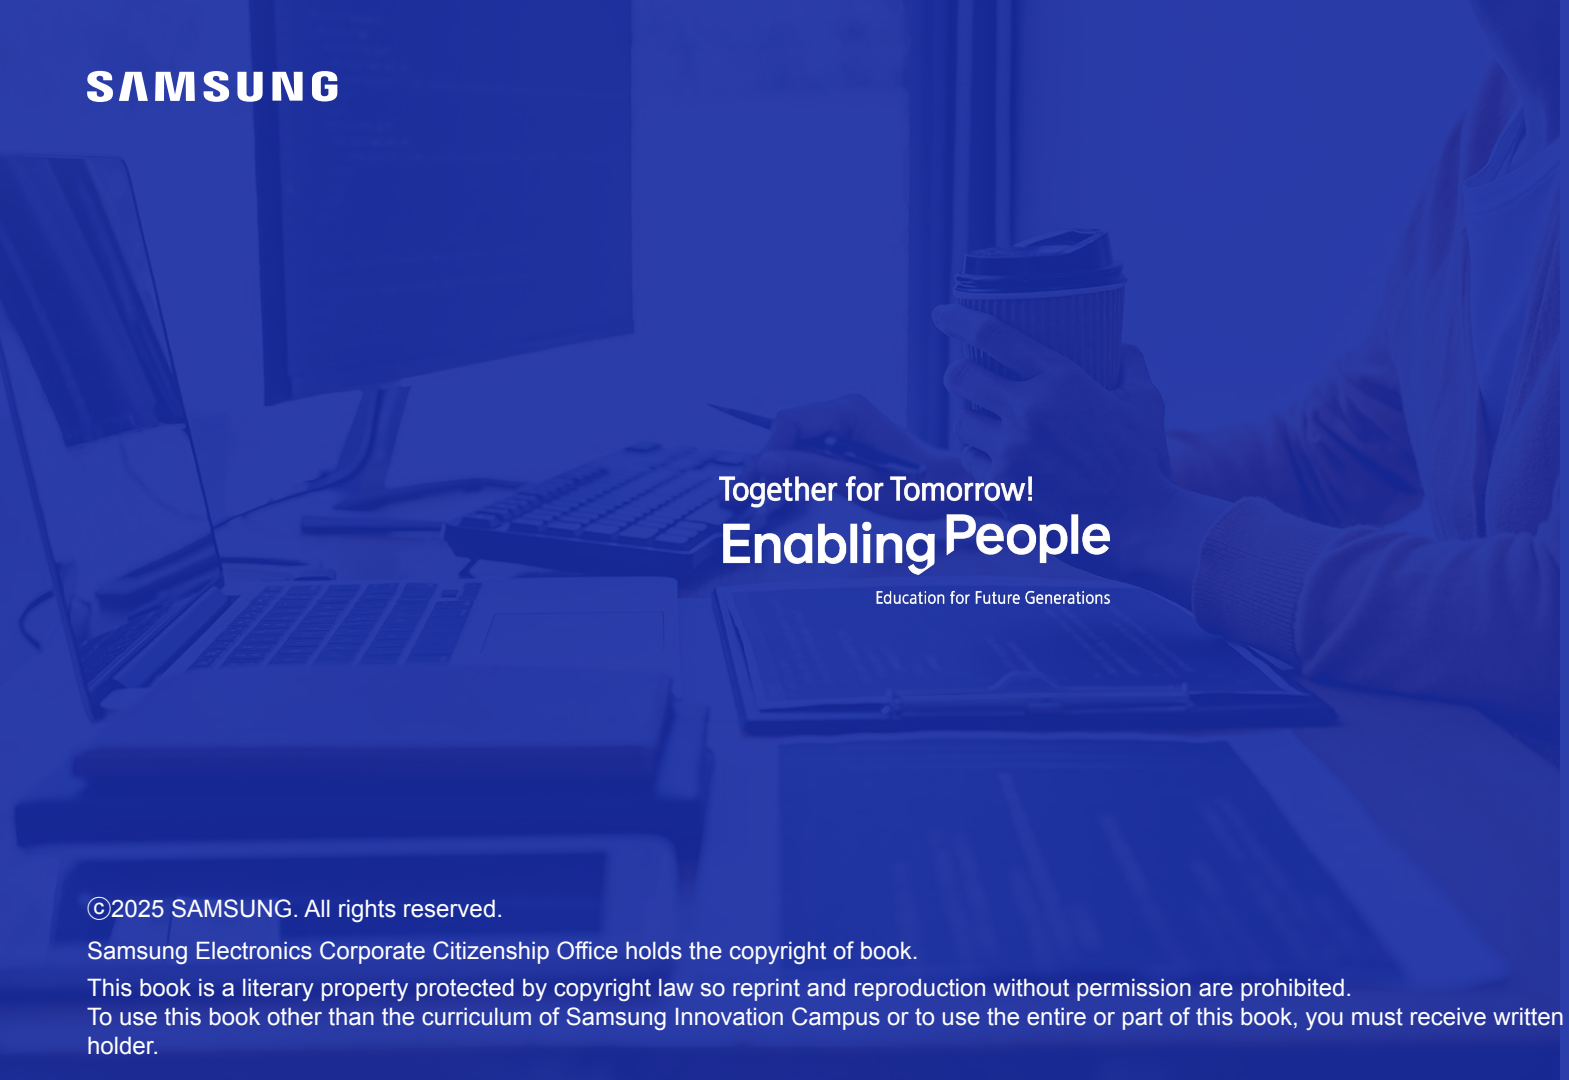
GUARDAR RESULTADO

```python
df.to_csv("books_terror_enriched.csv", index=False)
```

RESULTADO

Dataset más informativo listo para análisis, NLP y exploración.


¡COLABS DISPONIBLES PARA RECICLAR!
¡EL RISCO ES TUYO! ¡LANZÁTE Y HACELO!
1 ABRÍ UN COLAB
2 ELEGÍ UNO
3 USALO Y MEJORALO
4 APRENDÉ Y AVANZÁ
5 COMPARTÍ Y AYUDÁ
SIN MIEDO.
SIN DEPENDER.
SOLO HACER.
TÚ PUEDES
LINKS
clase_20_apify_api_ampliada.ipynb
clase_19_20_pandas.ipynb
PRACTICA_PRE_QUIZZ_1.ipynb
https://huggingface.co/sentence-transformers
https://pypi.org/project/duckduckgo-search/



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.