SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

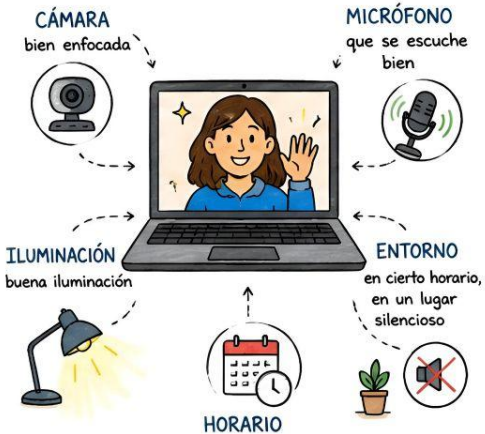
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



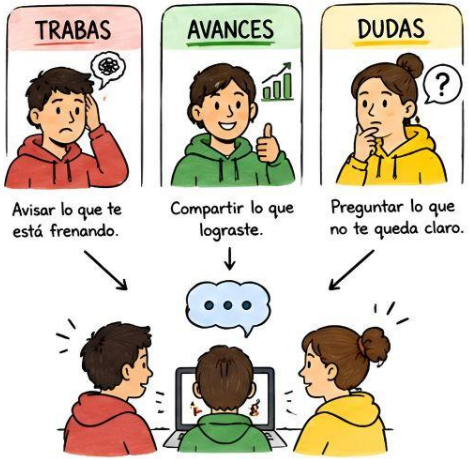
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



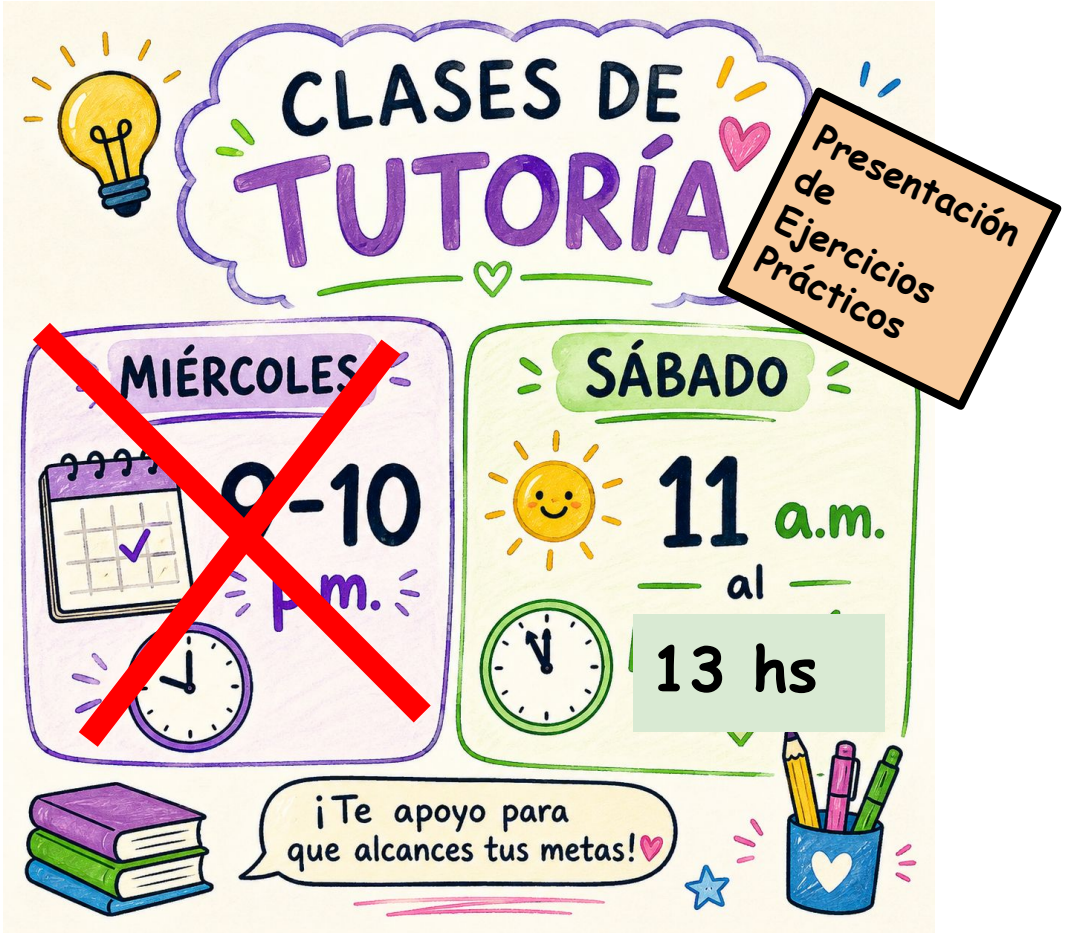
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS

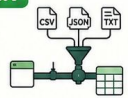


[Inscripción a la reunión - Zoom]

CLASE ANTERIOR

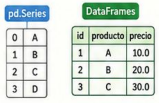
1. PANDAS — EJERCICIOS PROGRESIVOS

2.1 Estructuras de datos y pipeline



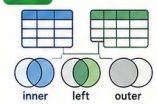
- Datos estructurados, semiestructurados y no estructurados
- Construcción del pipeline hacia `DataFrame`

2.2 Series y DataFrames



- Crear y explorar `Series` / `DataFrame`
- Selección: `loc` / `iloc`
- Índices y columnas
- Agregar, modificar y eliminar datos
- Ejercicio: productos + IVA + filtros

2.3 Combinar datos



- `pd.con...()`
- `pd.m...ge()`
- `in... / left / outer`
- `...ercicio`: empleados + depar...ntos

2.4 Ordenamiento e ...ices

- `sort_values()`
- `sort_index(`
- `MultiInd...`
- Ejercicio: ...entas + región + vendedor

2.5 Análisis de datos

- ...adísticas descriptivas
- `groupby()`
- *Pivoting*
- Muestreo

2. APIFY — RETOMAMOS EL CLIENTE



- Ejecutar un Actor
- Obtener resultados
- Procesar el output con Pandas

3. MAKE + REQUESTS



- Consumir APIs
- GET / POST
- JSON
- Requests vs. Make
- Llevar resultados a Pandas

4. DESAFÍO CREATIVO — UAV DRONE DATASET



FLUJO DE LA CLASE



CLASE DE HOY: LIBROS DE TERROR

Scraping + ETL + Búsqueda + NLP + Análisis

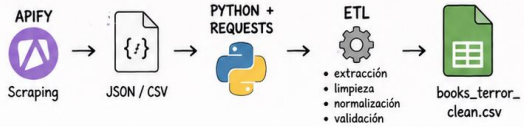
OBJETIVO: Construir un dataset de libros de terror a partir de datos de la web, limpiarlo y responder preguntas sobre disponibilidad, similitud y precios.

1. REVISIÓN RÁPIDA

- ✅ 2.3 Operaciones con Series
- ✅ 2.4 Operaciones con DataFrames
- ✅ 2.5 Combinar datos (concat / merge / join)

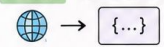


2. PIPELINE GENERAL

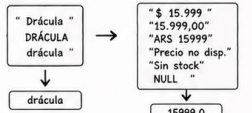


3. ETL BÁSICO

EXTRACT Obtener datos de Apify



TRANSFORM Limpiar y normalizar



LOAD Guardar dataset limpio → CSV

4. BÚSQUEDA PDF

¿Existe el PDF del libro?

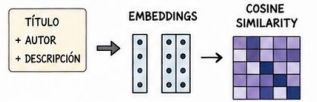


title	pdf_found	pdf_url
Drácula	✅	https://...
El exorcista	❌	—
It	✅	https://...

Discutimos límites legales y éticos de las búsquedas.

5. SIMILITUD SEMÁNTICA

¿Qué libros son similares entre sí?



Top pares más similares

book_a	book_b	similarity
Drácula	Carmilla	0.87
It	La llamada de Cthulhu	0.84
El exorcista	El resplandor	0.81
...	...	...

6. SEGUNDO EXPERIMENTO: ELEGIR UN TÍTULO Y OBTENER 50 REGISTROS

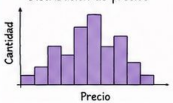
Ejemplo: DRÁCULA
50 publicaciones



title	seller	price	original_price	discount	date
Drácula	Vendedor A	12000	15000	20%	18/08/26
Drácula	Vendedor B	14500	—	0%	18/08/26
Drácula	Vendedor C	10999	13999	21%	18/08/26
...	...	...			

7. ANÁLISIS DE PRECIOS Y DESCUENTOS

Distribución de precios

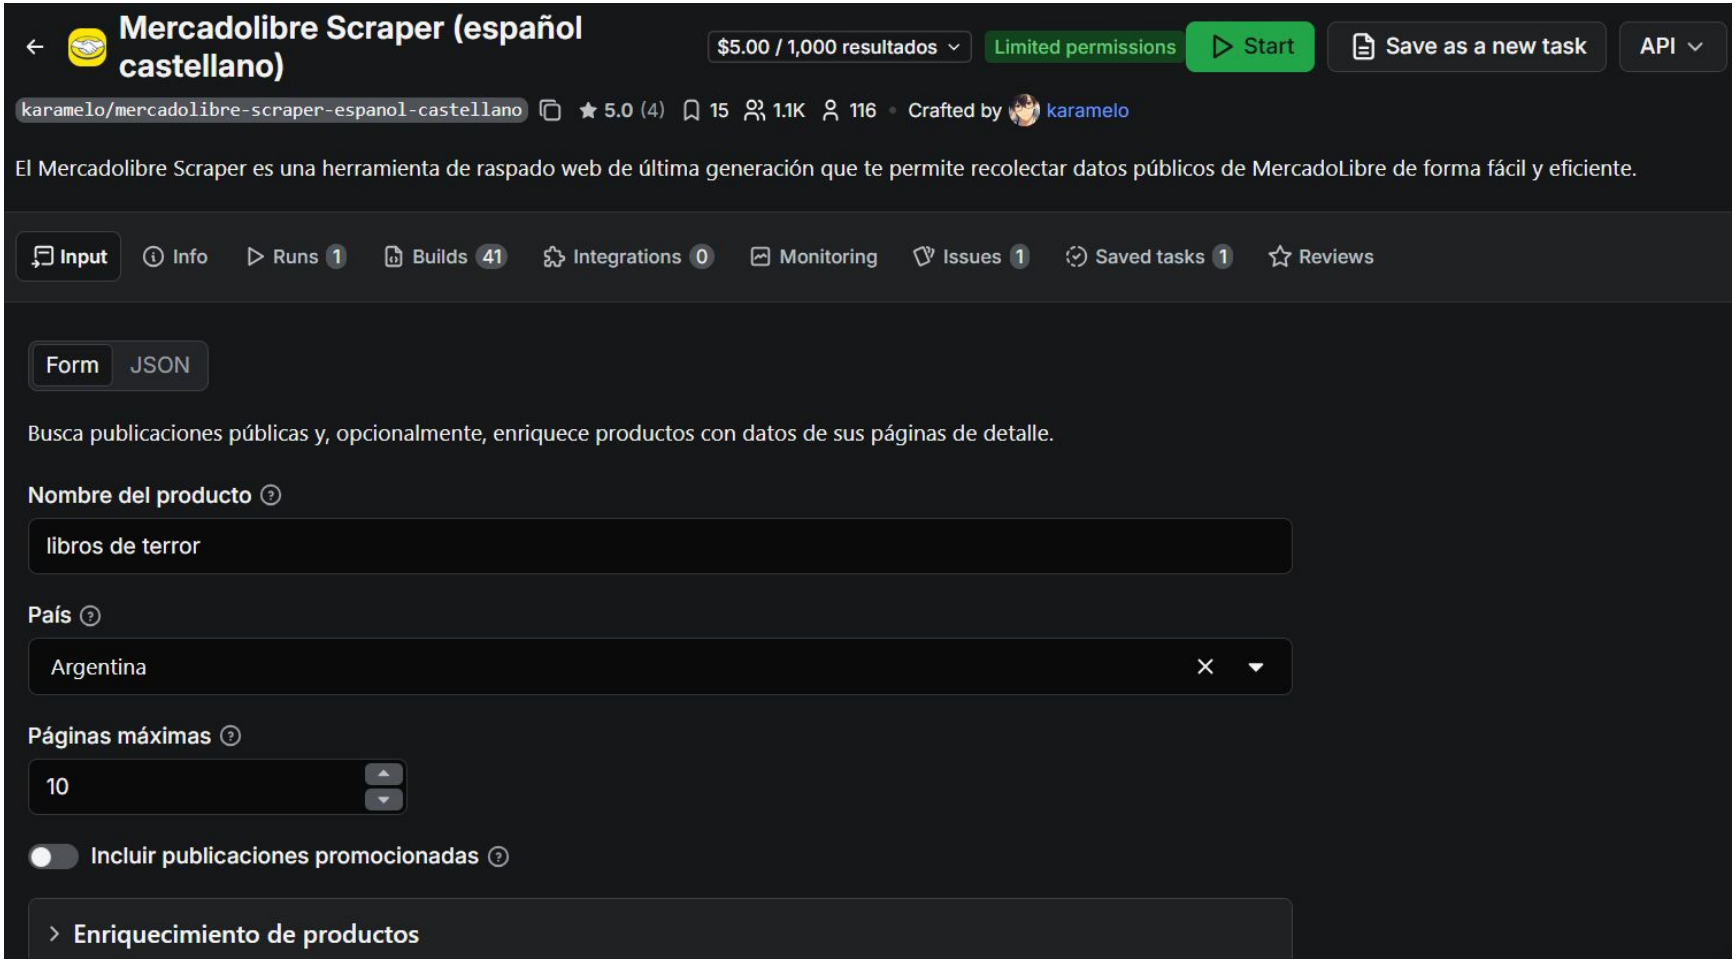


¿Tuvo descuentos?

`has_discount = (discount > 0)`

Comparar precios con vs sin descuento




Mercadolibre Scraper (español castellano)
$5.00 / 1,000 resultados
Limited permissions
Start
Save as a new task
API
karamelo/mercadolibre-scraper-espanol-castellano
5.0 (4)
15
1.1K
116
Crafted by karamelo
El Mercadolibre Scraper es una herramienta de raspado web de última generación que te permite recolectar datos públicos de MercadoLibre de forma fácil y eficiente.
Input
Info
Runs 1
Builds 41
Integrations 0
Monitoring
Issues 1
Saved tasks 1
Reviews
Form
JSON
Busca publicaciones públicas y, opcionalmente, enriquece productos con datos de sus páginas de detalle.
Nombre del producto
libros de terror
País
Argentina
Páginas máximas
10
Incluir publicaciones promocionadas
Enriquecimiento de productos

Run · Mercadolibre Scraper (español castellano) Actor

Actions API Share Export

Succeeded Actor succeeded with 478 results in the dataset | $2.390 | 2026-08-17 22:51 | 3 m 30 s | Show details

Output 478 | Log | Input | Storage | Live view | Triggered integrations 0

Vista general | All fields

Preview in new tab | Table | JSON

#	Dirección de imagen imgDireccion	Moneda Moneda	Precio actual nuevoPrecio	Precio anterior precioAnterior	Descuento precioDiscount	Título del artículo articuloTitulo	Cuotas installments	Promociones promociones	Cantidad vendida cantidadVendida	Env gra env
101		ARS	26000			Los Desmaravilladores - Loqueleo			100	✓
102		ARS	42550			Libro Quien pierde paga (TrilogÃÂa Bill...			100	✓
103		ARS	89388			Libro Estuche Stranger Things -	6 cuotas de		null	✓

BUSCAR SIMILITUD SEMÁNTICA ENTRE LIBROS CON sentence-transformers

Tomamos un libro pivote y comparamos su descripción con el resto para encontrar los más similares en significado.

IDEA CLAVE

No buscamos coincidencias exactas de palabras, sino significado.

1. DATASET DE LIBROS

Cada fila tiene: título, autor, y descripción del libro.

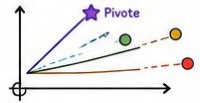
2. LIBRO PIVOTE

Elegimos un libro como referencia.

3. GENERAR EMBEDDINGS

Convertimos cada descripción en un vector numérico (embedding) que representa su significado.

4. SIMILITUD SEMÁNTICA



Calculamos la similitud (coseno) entre el pivote y todos los libros.

5. RESULTADOS

Obtenemos una lista ordenada de los libros más similares.

EJEMPLO DE DATASET

id	título	autor	descripción
1	Drácula	Bram Stoker	Novela gótica sobre el conde Drácula y su viaje desde Transilvania...
2	It	Stephen King	Un grupo de niños de Derry se enfrenta a una entidad maligna que adopta...
3	El exorcista	W. P. Blatty	Regan MacNeil, una niña poseída por una entidad demoníaca, es sometida...
4	La llamada	H. P. Lovecraft	Relato corto sobre horrores cósmicos e indescriptibles de existencia...
...	...	...	...

¿CÓMO FUNCIONA?

1. Elegimos el libro pivote (ej. Drácula).
2. Generamos embeddings para todas las descripciones.
3. Calculamos la similitud del pivote con cada descripción usando similaridad del coseno.
4. Ordenamos de mayor a menor similitud.

¿POR QUÉ FUNCIONA?

Los embeddings capturan el significado de las oraciones. Si dos descripciones hablan de temas parecidos, sus vectores estarán "cerca" en el espacio vectorial.



EJEMPLO DE CÓDIGO (PYTHON)

```python
from sentence_transformers import SentenceTransformer, util
import pandas as pd

# 1. Cargar dataset
df = pd.read_csv("libros.csv")  # columnas: id, titulo, autor, descripcion

# 2. Elegir libro pivote
pivote_id = 1  # Drácula
pivote_desc = df.loc[df["id"] == pivote_id, "descripcion"].values[0]

# 3. Cargar modelo y generar embeddings
model = SentenceTransformer("paraphrase-multilingual-MiniLM-L12-v2")
descripciones = df["descripcion"].tolist()
embeddings = model.encode(descripciones, convert_to_tensor=True)

# 4. Calcular similitud del pivote con todos
pivote_emb = model.encode(pivote_desc, convert_to_tensor=True)
sim_scores = util.cos_sim(pivote_emb, embeddings)[0]  # tensor (n,.)

# 5. Agregar scores y ordenar
df "score_similitud"] = sim_scores.cpu().numpy()
resultados = df.sort_values("score_similitud", ascending=False)
print(resultados[["id","titulo", "autor", "score_similitud"]].head(5))
```

RESULTADO EJEMPLO (TOP 5 SIMILARES AL PIVOTE: DRÁCULA)

id	título	autor	score_similitud	
1	Drácula	Bram Stoker	1.0000	← Pivote
4	La llamada de Cthulhu	H. P. Lovecraft	0.8123	
3	El exorcista	W. P. Blatty	0.7341	
2	It	Stephen King	0.6897	
5	Coraline	Neil Gaiman	0.6124	

Los puntajes van de -1 a 1

- 1: muy similar
- 0: sin relación
- -1: opuesto

MODELOS RECOMENDADOS

- paraphrase-multilingual-MiniLM-L12-v2 (rápido, liviano, multilenguaje)
- all-MiniLM-L6-v2 (muy usado, balanceado)
- distiluse-base-multilingual-cased (bueno para español)

APLICACIONES

- [x] Recomendación de libros
- [x] Búsqueda semántica
- [x] Agrupamiento por temática
- [x] Detección de contenido similar

TIP: Preprocesar bien las descripciones (quitar ruido, espacios, HTML, etc.) mejora la calidad de los resultados.



ANALIZAR VARIABILIDAD DE PRECIOS Y DESCUENTOS CON PANDAS + NUMPY

Tomamos un libro pivote, buscamos en MercadoLibre con Apify, obtenemos 50 resultados y analizamos la variabilidad de precios, descuentos y fechas.

IDEA CLAVE
Un mismo producto puede tener precios muy distintos. La estadística nos ayuda a medir esa variabilidad.

1 DEFINIR LIBRO PIVOTE



Título: Drácula
Autor: Bram Stoker
Descripción: Novela gótica sobre el conde Drácula y su viaje desde Transilvania...

Consulta de búsqueda:
"Drácula Bram Stoker libro"

2 BUSCAR EN APIFY

apify

Actor:
MercadoLibre Search

Obtenemos
~50 resultados

3 OBTENEMOS DATOS

Dataset crudo desde Apify

title	price	original_price	disc.	date	link
Drácula	15999	18000	11%	2025-05-10	link
Drácula Bram Stoker	13500	NaN	NaN	2025-05-09	link
Libro Drácula	22000	25000	12%	2025-05-09	link
...					

4 LIMPIEZA Y PREPARACIÓN CON PANDAS

- Normalizamos columnas
- Convertimos tipos numéricos
- Limpieza de descuentos ("20%" → 20)
- Parseo de fechas
- Eliminamos duplicados e inconsistencias

title	price	original_price	discount	date	link
Drácula	15999.0	18000.0	11.0	2025-05-10	link
Drácula Bram Stoker	13500.0	NaN	0.0	2025-05-09	link
Libro Drácula	22000.0	25000.0	12.0	2025-05-09	link
...					

5 ANÁLISIS ESTADÍSTICO CON NUMPY

NumPy

$$\mu = \frac{1}{n}\sum x_i$$

6 RESULTADOS E INSIGHTS



Respondemos preguntas clave:
- ¿Qué tan variable es el precio?
- ¿Hay descuentos importantes?
- ¿Las publicaciones son recientes?
- ¿Conviene esperar o comprar ahora?

A. OBTENER 50 REGISTROS CON APIFY

Usamos el Actor de MercadoLibre Search para obtener productos relacionados.

```
{
  "actor": "apify/mercadolibre-search",
  "input": {
    "query": "Drácula Bram Stoker libro",
    "maxItems": 50,
    "country": "AR"
  }
}
```

apify → Dataset (50 registros)

B. VISTA DEL DATASET LIMPIO (PANDAS)

title	price	original_price	discount	date
Drácula	15999.0	18000.0	11.0	2025-05-10
Drácula Bram Stoker	13500.0	NaN	0.0	2025-05-09
Libro Drácula	22000.0	25000.0	12.0	2025-05-09
Drácula edición bolsillo	9500.0	NaN	0.0	2025-05-08
...				

Ejemplo de limpieza:

```
df["price"] = pd.to_numeric(df["price"], errors="coerce")
df["original_price"] = pd.to_numeric(df["original_price"], errors="coerce")
df["discount"] = df["discount"].astype(str).str.replace("%","").replace("","0")
df["discount"] = pd.to_numeric(df["discount"], errors="coerce").fillna(0)
df["date"] = pd.to_datetime(df["date"], errors="coerce")
df = df.drop_duplicates(subset=["title","price","date"])
df.head()
```

C. ANÁLISIS ESTADÍSTICO CON NUMPY

PRECIOS

Cuenta (n)	50
Media (promedio)	15842.60
Mediana	14999.00
Mínimo	5990.00
Máximo	28990.00
Desv. Estándar	6123.47
Varianza	37484086.54
Percentil 25 (Q1)	10990.00
Percentil 75 (Q3)	18990.00
IQR (Q3 - Q1)	8000.00

Interpretación:
El precio tiene una variabilidad alta: la diferencia entre mínimo y máximo es de 23000 ARS.

DESCUENTOS (%)

Cuenta (n)	28
Media	15.71
Mediana	15.00
Mínimo	0.00
Máximo	45.00
Desv. Estándar	9.83
Percentil 75	20.00

Interpretación:
Hay descuentos importantes en algunos vendedores, pero no en todos.

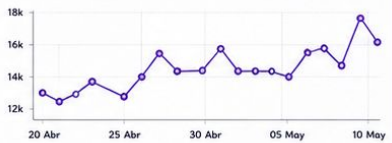
Ejemplo de cálculos con NumPy:

```
prices = df["price"].dropna().to_numpy()
discounts = df["discount"].dropna().to_numpy()
np.mean(prices), np.median(prices), np.std(prices), np.percentile(prices, [25,50,75])
np.mean(discounts), np.std(discounts), np.percentile(discounts, [25,50,75])
```

D. ANÁLISIS DE FECHAS (SI EXISTEN)

- Rango de fechas: 2025-04-20 → 2025-05-10
- Publicación más reciente: 2025-05-10
- Publicación más antigua: 2025-04-20
- Registros sin fecha: 0

Precio promedio por fecha



INSIGHTS FINALES

- Existen grandes diferencias de precios entre vendedores para el mismo libro.
- El descuento promedio es del 15.71%, pero algunos ofrecen hasta 45%.

F. ¿QUÉ APRENDEMOS?

- Integrar scraping (Apify) + pandas + numpy.
- Limpiar y transformar datos del mundo real.

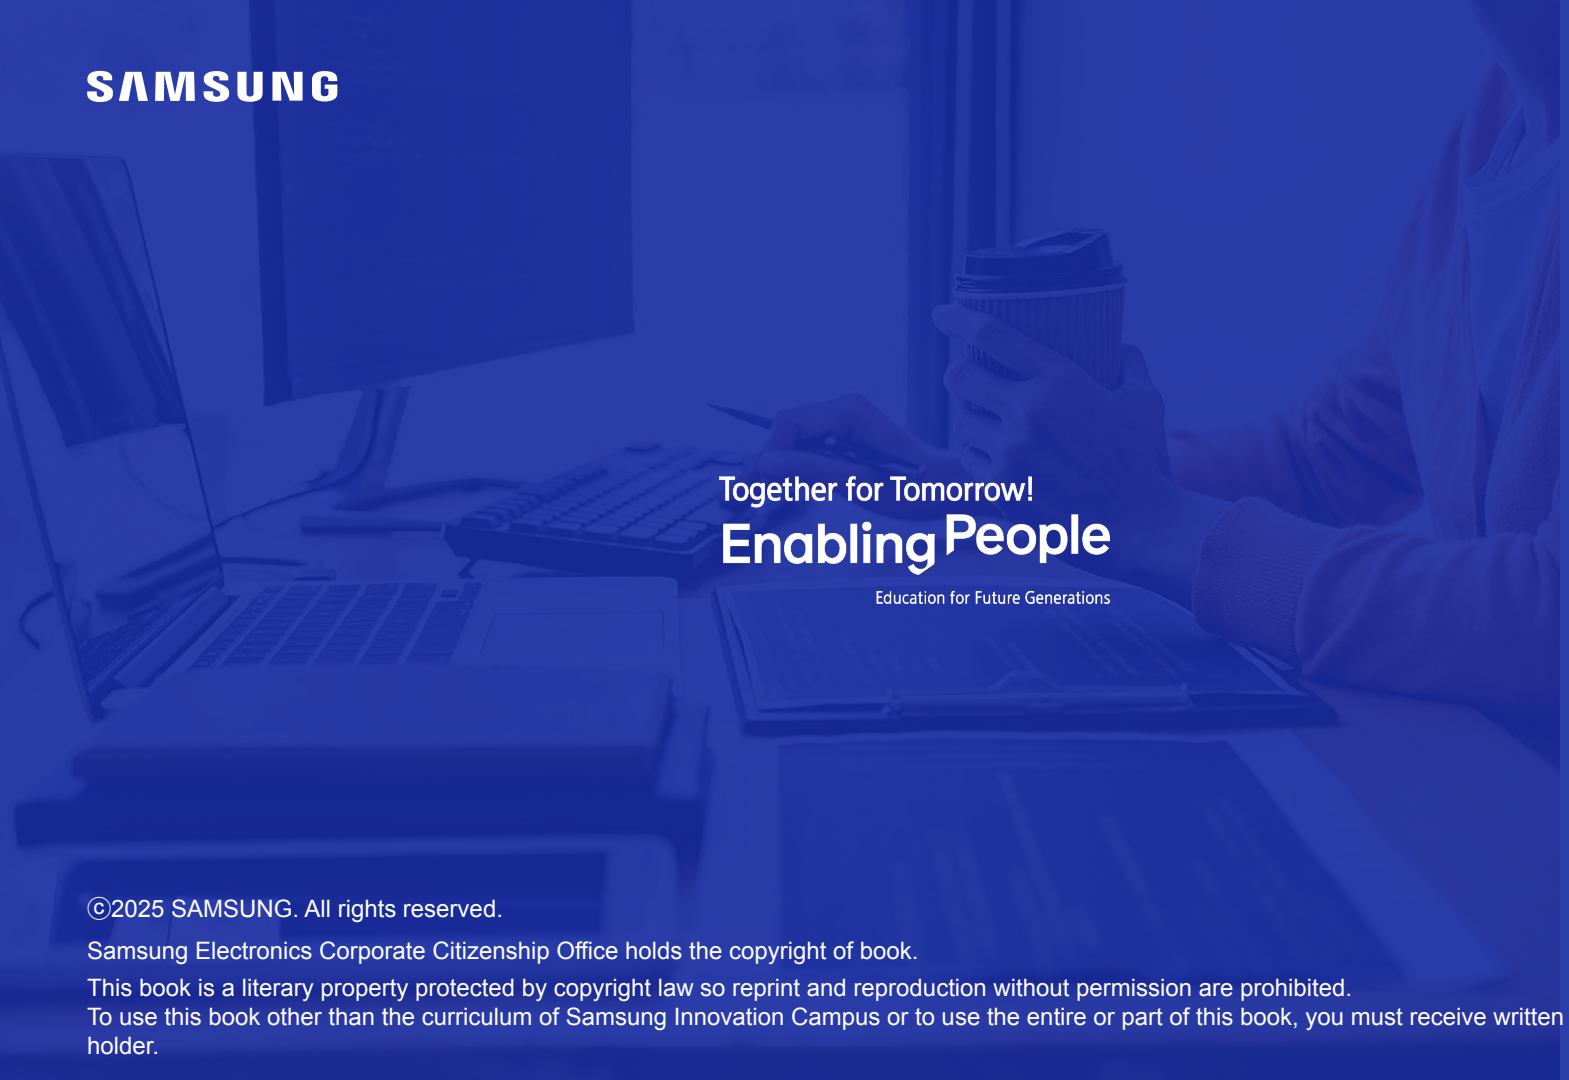
FUNCIONES NUMPY UTILIZADAS

- np.mean() promedio
- np.std() desviación estándar

TIP

Siempre visualiza los datos (histogramas, boxplots, líneas)


¡COLABS DISPONIBLES PARA RECICLAR!
¡EL RISCO ES TUYO! ¡LANZÁTE Y HACELO!
1 ABRÍ UN COLAB
2 ELEGÍ UNO
3 USALO Y MEJORALO
4 APRENDÉ Y AVANZÁ
5 COMPARTÍ Y AYUDÁ
SIN MIEDO.
SIN DEPENDER.
SOLO HACER.
TÚ PUEDES
LINKS
clase_20_apify_api_ampliada.ipynb
clase_19_20_pandas.ipynb
PRACTICA_PRE_QUIZZ_1.ipynb
https://huggingface.co/sentence-transformers
https://pypi.org/project/duckduckgo-search/



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.