SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

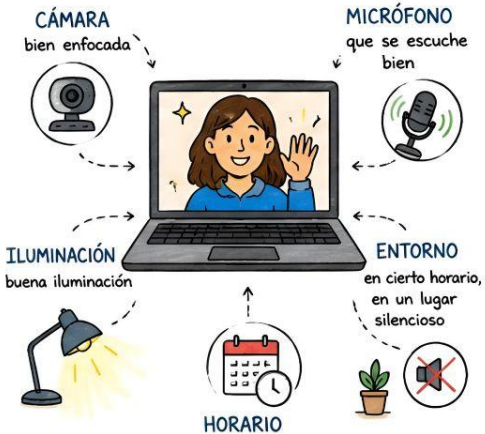
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



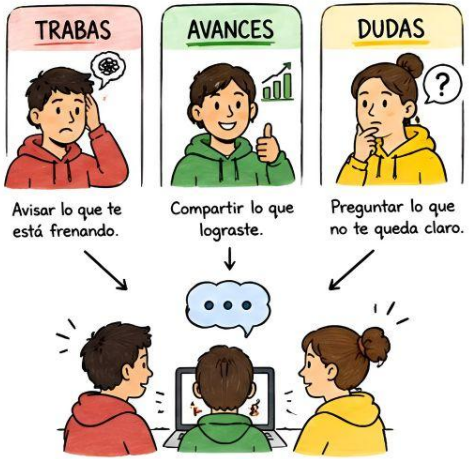
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



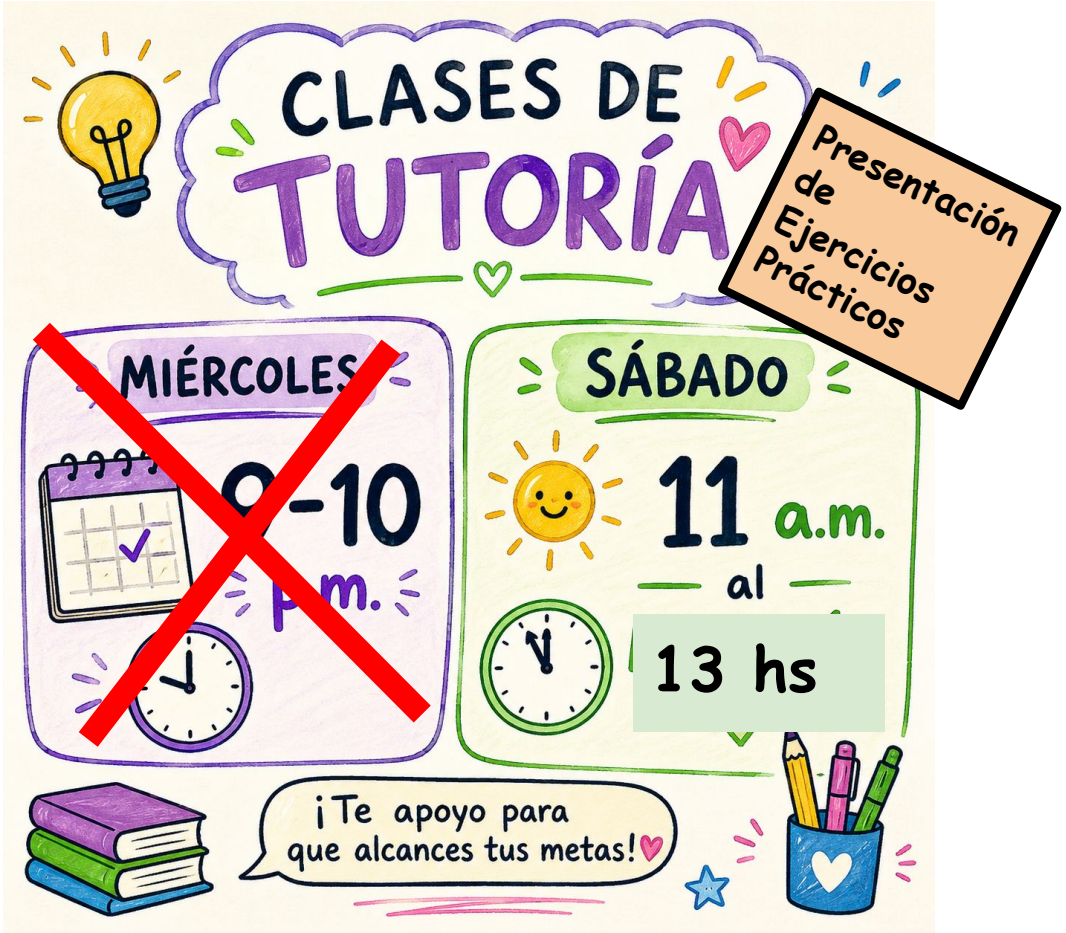
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS



[Inscripción a la reunión - Zoom]

RESUMEN DE LA CLASE ANTERIOR

DuckDuckGo + Resúmenes de Libros y Comparación con Sentence Transformers

1. DUCKDUCKGO: BUSCAR EL RESUMEN Y EL LINK PDF

Usamos duckduckgo_search para buscar el resumen del libro y el enlace al PDF.

```
from duckduckgo_search import DDGS

def buscar_libro(query, max_resultados=5):
    resultados = []
    with DDGS() as ddgs:
        for r in ddgs.text(query, max_results=max_resultados):
            resultados.append({
                "titulo": r.get("title"),
                "link": r.get("href"),
                "snippet": r.get("body")
            })
    return resultados
```

EJEMPLO DE USO

"resumen libro el exorcista pdf"

Lista de resultados

titulo	link	snippet
El exorcista - Resumen del libro	https://...	Resumen completo del libro El exorcista de William Peter...
El exorcista - PDF gratis	https://...	Descargar PDF del libro El exorcista...
...	...	...

Guardamos los resultados en una lista de diccionarios (ideal para trabajar con Pandas).

2. PIVOTE DE LIBROS: COMPARAR RESÚMENES

Convertimos los resúmenes en vectores con Sentence Transformers para medir similitud semántica entre libros.

PASOS

1. Buscar y obtener resúmenes de varios libros.
2. Guardarlos en una lista de diccionarios.
3. Convertir los resúmenes en embeddings.
4. Calcular similitud entre cada par de libros.
5. Crear una tabla (pivot) para comparar.

FLUJO GENERAL

Buscar resúmenes (DuckDuckGo) → Lista de dicts con: titulo, resumen, link → Embeddings con Sentence Transformers → Matriz de similitud (libro vs libro) → Pivot de comparación (Pandas)

La similitud se mide con cosine similarity (valores entre 0 y 1).
1 = muy similares | 0 = muy distintos

3. TODO CON PANDAS, LISTAS Y DICTS

ESTRUCTURAS CLAVE

- **LISTAS** — Para guardar varios resultados o textos.
- **DICTS** — Cada libro como un diccionario con claves (titulo, resumen, link...).
- **PANDAS DATAFRAME** — Para organizar, filtrar y pivotear la información.

EJEMPLO DE DICCIONARIO (LIBRO)

```
{
  'titulo': 'El exorcista',
  'resumen': 'Un sacerdote es enviado a exorcizar a una niña poseída...',
  'link_pdf': 'https://...',
  'fuente': 'DuckDuckGo'
}
```

→ Lista de dicts → DataFrame

4. EJEMPLO DE PIVOTE DE SIMILITUD ENTRE LIBROS

LIBRO	El exorcista	Drácula	Frankenstein	El resplandor
El exorcista	1.00	0.42	0.38	0.55
Drácula	0.42	1.00	0.47	0.50
Frankenstein	0.38	0.47	1.00	0.45
El resplandor	0.55	0.50	0.45	1.00

Esta tabla nos permite ver qué tan similares son los temas o contenidos entre los libros comparados.

PARA LLEVARSE DE LA CLASE

- DuckDuckGo nos ayuda a encontrar resúmenes y PDFs rápido.
- Organizamos la información con listas y diccionarios.
- Pandas convierte esa información en tablas poderosas.
- Sentence Transformers nos permite comparar el significado (realmente) entre textos.

RESUMEN DE LA CLASE DE HOY

REPASO DE PANDAS CON NUMPY PARA EL QUIZZ 2 + DEFINICIONES DE VARIABLES

Dataset: Mercado Libre - Libros de Terror

1. REPASO CONCEPTUAL

PANDAS — Trabajamos con datos en tablas.

- Explorar y entender los datos
- Filtrar y seleccionar
- Ordenar
- Agrupar y resumir
- Transformar columnas
- Manejar valores faltantes

NUMPY — Operaciones numéricas rápidas y eficientes.

- Arreglos y formas
- Operaciones matemáticas
- Cálculos vectorizados
- Condiciones
- Álgebra básica
- Estadística descriptiva

Pandas organiza y facilita el análisis. NumPy acelera los cálculos numéricos.

2. DEFINICIONES DE VARIABLES

¿LA COLUMNA ES TEXTO?

- SÍ → ¿EL NÚMERO YA ESTÁ DENTRO? (ej. "10% OFF", "6 cuotas de 11136")
  - SÍ → REGEX / PARSING — Extraemos números reales del texto
- NO, ES UNA CATEGORÍA REAL → ¿TIENE ORDEN?
  - SÍ → ORDINAL ENCODING — Preserva la jerarquía
  - NO → ONE-HOT / FREQUENCY / TARGET ENCODING — No inventamos un orden

EJEMPLOS CON EL DATASET DE LIBROS DE TERROR

COLUMNA	TIPO REAL	TRANSFORMACIÓN	EJEMPLO
precioDiscount "10% OFF"	Número disfrazado de texto	Regex	"10% OFF" → 10
promociones "Cupón 5% OFF"	Número disfrazado de texto	Regex	"Cupón 5% OFF" → 5
installments "6 cuotas de 11136"	Dos números en texto	Regex	"6 cuotas de 11136" → 6 y 11136
envioGratis / esTiendaOficial	Nominal binaria	astype(int)	True / False → 1 / 0
vendedor	Nominal, alta cardinalidad	Frequency / Target Encoding	Vendedor123 → frecuencia o target
Envio	Cualitativa ordinal	Ordinal Encoding	"Llega gratis hoy" → valor ordinal
highlight "ÚLTIMAS 2 UNIDADES"	Número extraíble + urgencia	Regex → numérica	"ÚLTIMAS 2 UNIDADES" → 2

ORDEN REAL DE ENVÍO

1. NaN
2. Envío gratis
3. Llega gratis mañana
4. Llega gratis hoy
5. Llega gratis hoy + FULL

Ese orden tiene sentido lógico. Por eso usamos ORDINAL ENCODING para que el modelo respete la jerarquía.

PARA LLEVARTE DE LA CLASE

Diagnóstico correcto (¿qué representa este dato?) → Transformación adecuada → Datos listos para entrenar modelos de Machine Learning!

DEL DATO CRUDO AL MODELO

¿QUÉ TIPO DE VARIABLE TENGO?

DATO CRUDO
texto, número, categoría, etc.

IDENTIFICAR LA VARIABLE

No se puede promediar ni sumar con sentido.

Se puede operar matemáticamente.

CUALITATIVA
Describe una cualidad (categoría)

CUANTITATIVA
Describe una cantidad (numérica)

PREGUNTA CLAVE
¿Tiene sentido decir que una categoría es "más" o "menos" que otra?

SÍ → ORDINAL

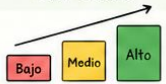
NO → NOMINAL

NOMINAL
sin orden



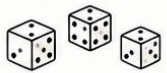
Ejemplos:
- Color de ojos
- Nacionalidad
- Tipo de sangre

ORDINAL
con orden



Ejemplos:
- Nivel educativo
- Nivel de satisfacción
- Talla de ropa (S, M, L, XL)

DISCRETA
contable



Ejemplo:
- Número de hijos
- Cantidad de productos
- Autos en un estacionamiento

CONTINUA
rango continuo



Ejemplo:
- Altura
- Temperatura
- Peso

IDEA CENTRAL

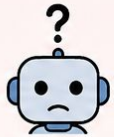
Tipo de variable → Transformación correcta → Datos listos para Machine Learning

Elegir la transformación correcta es clave para que el modelo aprenda relaciones reales y no inventadas.

LOS MODELOS NECESITAN NÚMEROS, PERO NO TODOS SE CREAN IGUAL

EL PROBLEMA

"Rojo"
"Bajo"
"10% OFF"



Modelo de ML
no opera directamente con texto

LA TRAMPA

No alcanza con decir:
"Es texto → lo convierto a números"

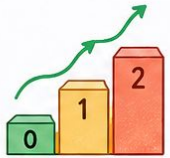
Primero debemos preguntarnos **QUÉ REPRESENTA** ese texto.

HAY DOS CAMINOS, SEGÚN EL TIPO DE VARIABLE

1 SI ES ORDINAL → ORDINAL ENCODING

Como hay un orden real, asignar números consecutivos preserva ese orden.

Bajo → 0
Medio → 1
Alto → 2




```
from sklearn.preproecssing
import OrdinalEncoder

encoder = OrdinalEncoder(
  categories=[['Bajo',
               'Medio', 'Alto']])

df['nivel_encoded'] =
  encoder.fit_transform(
    df[['nivel']])
```

Preserva: Alto > Medio > Bajo

2 SI ES NOMINAL → ONE-HOT ENCODING

Creamos una columna binaria por cada categoría.

Color	Rojo	Verde	Azul
Rojo	1	0	0
Verde	0	1	0
Azul	0	0	1

```
import pandas as pd

df_encoded = pd.get_dummies(
  df, columns=['color'])
```

ERROR CLÁSICO: LABEL ENCODING EN NOMINALES

Rojo = 0
Verde = 1
Azul = 2

→ El modelo puede interpretar: Azul > Verde > Rojo
¡Ese orden fue inventado!



¿POR QUÉ ES IMPORTANTE ELEGIR BIEN?



El modelo aprende patrones reales, no relaciones falsas.



Mejores métricas, predicciones más justas y confiables.



Evitamos sesgos que surgen de imponer órdenes inexistentes.

EN RESUMEN



Identifico el tipo de variable → Elijo la transformación correcta → Datos numéricos listos para el modelo →



Datos bien transformados = modelos que entienden la realidad.

REGEX NO ES ENCODING: EL NÚMERO YA EXISTE

DOS PROBLEMAS COMPLETAMENTE DIFERENTES

	ENCODING	REGEX / PARSING
¿Qué es la variable en el fondo?	Genuinamente cualitativa (categoría)	Cuantitativa, pero escrita como texto
¿El número existe antes de la conversión?	No — vos lo inventás como convención	Sí — el número ya está ahí, solo hay que extraerlo
Ejemplo	"Rojo", "Alto"	"10% OFF", "6 cuotas de 11136"
Herramienta	OrdinalEncoder, get_dummies (One-Hot), Frequency, Target Encoding	re.search(), re.sub(), patrones regex

IDEA CLAVE

Regex no inventa números.
Los encuentra.

Encoding representa categorías mediante números.

EJEMPLOS DE REGEX / PARSING

"10% OFF" → REGEX → 10 — Extraemos el número real

"Cupón 5% OFF" → REGEX → 5 — Mismo número, otro formato

"6 cuotas de 11136" → REGEX → 6 y 11136 — Extraemos 2 números

El dato numérico ya existe, solo está "escondido" en el texto.

EJEMPLO DE CÓDIGO

```python
import re

def extraer_porcentaje(texto):
    match = re.search(r"(\\d+)\\s*%", str(texto))
    return int(match.group(1)) if match else None

df["precioDiscount_num"] = (
    df["precioDiscount"].apply(extraer_porcentaje)
```

RESULTADO

"10% OFF" → 10 "Cupón 5% OFF" → 5

DIFERENCIA FUNDAMENTAL

ENCODING
Creamos una representación numérica para categorías que no son números originalmente.



REGEX
Extraemos números que ya existen en el texto, pero están "sucios".

No confundas herramientas para resolver problemas distintos.

CASO REAL: DATASET DE LIBROS DE MERCADOLIBRE

EN UN MISMO DATASET CONVIVEN LOS 3 CASOS

COLUMNA	TIPO REAL	TRANSFORMACIÓN	EJEMPLO
precioDiscount "10% OFF"	Número disfrazado de texto	Regex	"10% OFF" → 10
promociones "Cupón 5% OFF"	Número disfrazado de texto	Regex	"Cupón 5% OFF" → 5
installments "6 cuotas de 11136"	Dos números en texto	Regex	"6 cuotas de 11136" → 6 y 11136
envioGratis / esTiendaOficial	Nominal binaria	astype(int)	True / False → 1 / 0
vendedor	Nominal, alta cardinalidad	Frequency / Target Encoding	Vendedor123 → frecuencia o target
Envio	Cualitativa ordinal	Ordinal Encoding	"Llega gratis hoy" → valor ordinal
highlight "ÚLTIMAS 2 UNIDADES"	Número extraíble + urgencia	Regex → numérica	"ÚLTIMAS 2 UNIDADES" → 2

EJEMPLO: ORDEN REAL DE ENVÍO

1. NaN
2. Envío gratis
3. Llega gratis mañana
4. Llega gratis hoy
5. Llega gratis hoy + FULL

Este orden tiene sentido lógico. Por eso usamos ORDINAL ENCODING para que el modelo respete la jerarquía.

```
orden_envio = [
    'NaN',
    'Envío gratis',
    'Llega gratis mañana',
    'Llega gratis hoy',
    'Llega gratis hoy Enviado por FULL'
]
```

Definimos el orden correcto

```
df['Envio'] = df['Envio'].fillna('NaN')

encoder = OrdinalEncoder(categories=[orden_envio])

df['envio_encoded'] = encoder.fit_transform(df[['Envio']])
```

Aplicamos Ordinal Encoding

PARA LLEVARSE DE LA CLASE

Antes de transformar una columna, no preguntes solamente "¿cómo la convierto?"

Preguntá primero: "¿qué es realmente este dato?"

MAPA RÁPIDO

- NÚMERO ESCONDIDO EN TEXTO → REGEX / PARSING (extraemos)
- CATEGORÍA CON ORDEN → ORDINAL ENCODING (preserva jerarquía)
- CATEGORÍA SIN ORDEN → ONE-HOT / FREQUENCY / TARGET ENCODING (sin jerarquía falsa)



CLASIFICACIÓN DE COLUMNAS DEL DATASET MERCADOLIBRE (LIBROS DE TERROR)

Objetivo: antes de modelar, identificar qué representa cada columna y qué transformación necesita.

COLUMNA(S)	TIPO / CLASIFICACIÓN	¿QUÉ HACER?	EJEMPLO / NOTA
SKU, idPublicacion, idVariacion, idProductoUsuario, idProductoCatalogo	**Identificador** Clave única, no es variable estadística.	No se usa como feature, solo como clave índice.	SKU_12345 (clave)
Tiempo	**Cuant. continua (timestamp)** Fecha y hora.	pd.to_datetime() → extraer hora, día, minuto.	2024-08-20T14:35:22Z día hora minuto
Vendedor	**Cual-Nom** Alta cardinalidad, 39 categorías.	Frequency Encoding o agrupar en oficial / no oficial.	MASLIBROS Tienda oficial (una de 39 categorías)
articuloTitulo	**Texto no estructurado** Texto libre.	NLP: tokenización, TF-IDF, embeddings. No es encoding simple.	"It: (Eso) - Stephen King"
cantidadVendida	**Cuant-Disc** Valores contables (1000, 500...)	Ya es numérica, solo imputar nulos.	1000, 500, 250 ...
disponibleEn	**Vacía (100% nula)**	Descartar.	—
enStock	**Cual-Nom binaria** Verdadero / Falso.	astype(bool) / fillna(False) → 0/1.	True / NaN → 1 / 0
envioDesde	**Cual-Nom** Casi todo nulo, solo "USA".	Binaria: nacional vs. internacional.	USA / NaN
envioGratis, esCompraInternacional, esPrecioPorCantidad, esTiendaOficial	**Cual-Nom binaria** Booleanos.	Ya son 0/1 lógicos, astype(int) si hace falta.	True / False → 1 / 0
highlight	**Mixta: Cual-Ord + Cuantitativa** Frases de urgencia + número embebido.	Regex → extraer unidades restantes (cuantitativa) + Ordinal Encoding para frases.	"ÚLTIMAS 2 | ÚLTIMAS UNIDADES" "OFERTA IMPERDIBLE" → unidades: 2
installments	**Cuant-Disc + Cuant-Cont** Texto con cantidad + monto.	Regex → cantidad de cuotas (discreta) y monto de cuota (continua).	"6 cuotas de 11136" → cuotas: 6 monto: 11136
itemPosition	**Cuant-Disc (también ordinal)** Posición en ranking de resultados.	Ya numérica.	1, 2, 3, 4 ...
nuevoPrecio	**Cuant-Cont** Precio de venta.	Ya numérica.	12500, 24990, 35000 ...
numeroEvaluaciones	**Cuant-Disc** Conteo de evaluaciones.	Ya numérica, imputar nulos.	10, 25, 136 ...

CONVENCIONES

- **Cual-Nom:** cualitativa nominal (sin orden)
- **Cual-Ord:** cualitativa ordinal (con orden)
- **Cuant-Disc:** cuantitativa discreta (valores contables)
- **Cuant-Cont:** cuantitativa continua (valores medibles)
- **Identificador:** clave única, no se modela.
- **Constante:** mismo valor en todas las filas → no aporta información.
- **Vacía:** 100% nula → se descarta.

¿POR QUÉ IMPORTA?

"6 cuotas de 11136" → 6 + 11136

El modelo no entiende frases. Necesita números y categorías bien codificadas.

REGLA DE TRANSFORMACIÓN

- Identificador / Constante / Vacía / URL → descartar
- Cuantitativa como texto → Regex / parsing
- Cual-Nom → One-Hot / Frequency Encoding
- Cual-Ord → Ordinal Encoding
- Texto libre → NLP (TF-IDF / embeddings)
- Fecha/hora → datetime → features derivadas
- Cuantitativa numérica → imputar nulos + posiblemente escalar (StandardScaler)

TIP DIDÁCTICO Un buen modelo empieza con un buen entendimiento de los datos. Clasificar cada columna es el primer paso para transformar datos en información útil.

DEL DATASET AL MODELO: 3 TAREAS POSIBLES

CLASIFICACIÓN

¿Target? Sí, categórico
¿Qué busca? A qué categoría pertenece una fila.

REGRESIÓN

¿Target? Sí, numérico continuo
¿Qué busca? Predecir un valor numérico.

CLUSTERING / PATRONES

¿Target? No
¿Qué busca? Descubrir grupos o estructuras ocultas sin etiqueta previa.

1 CLASIFICACIÓN

¿El libro tendrá buena reputación?

Target: produtoReviews >= 4.5 vs. < 4.5
→ clasificación binaria



FEATURE	TIPO	TRANSFORMACIÓN
nuevoPrecio	Cuant-Cont	StandardScaler
cantidadVendida	Cuant-Disc	Imputar + escalar
esTiendaOficial	Cual-Nom binaria	Ya es 0/1 (0) (1)
envioGratis	Cual-Nom binaria	Ya es 0/1 (0) (1)
Vendedor	Cual-Nom, alta cardinalidad	Frequency Encoding
precioDiscount_num	Cuant-Disc	Numérica tras Regex (10% OFF)

MODELOS TÍPICOS
Regresión Logística • Random Forest Classifier
XGBoost Classifier

Importante: Label Encoding en "Vendedor" puede hacer creer al modelo que existe un orden entre vendedores. Eso genera una frontera de decisión incorrecta.

2 REGRESIÓN

¿Cuánto debería costar el libro?

Target: nuevoPrecio
→ valor continuo



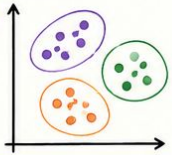
FEATURE	TIPO	TRANSFORMACIÓN
cantidadVendida	Cuant-Disc	Imputar + escalar
numeroEvaluaciones	Cuant-Disc	Imputar + escalar
produtoReviews	Cuant-Cont	Imputar + escalar
cantidadCuotas_num, montoCuota_num	Cuant-Disc / Cont	Numéricas tras Regex (6 cuotas $ 11.136)
Envio	Cual-Ord	Ordinal Encoding (lento → rápido)
esTiendaOficial	Cual-Nom binaria	Ya es 0/1 (0) (1)
Vendedor	Cual-Nom	Frequency o Target Encoding

MODELOS TÍPICOS
Regresión Lineal • Ridge/Lasso • Gradient Boosting Regressor

Importante: cantidadVendida puede estar en miles, mientras produtoReviews está entre 0–5. En modelos lineales, escalar evita que la diferencia de magnitudes distorsione los coeficientes.

3 CLUSTERING / PATRONES

¿Qué perfiles de publicaciones existen?
Sin target. Buscar grupos como:
🔥 Oferta agresiva: cupón + envío FULL + pocas unidades
📖 Publicación estándar: sin promoción



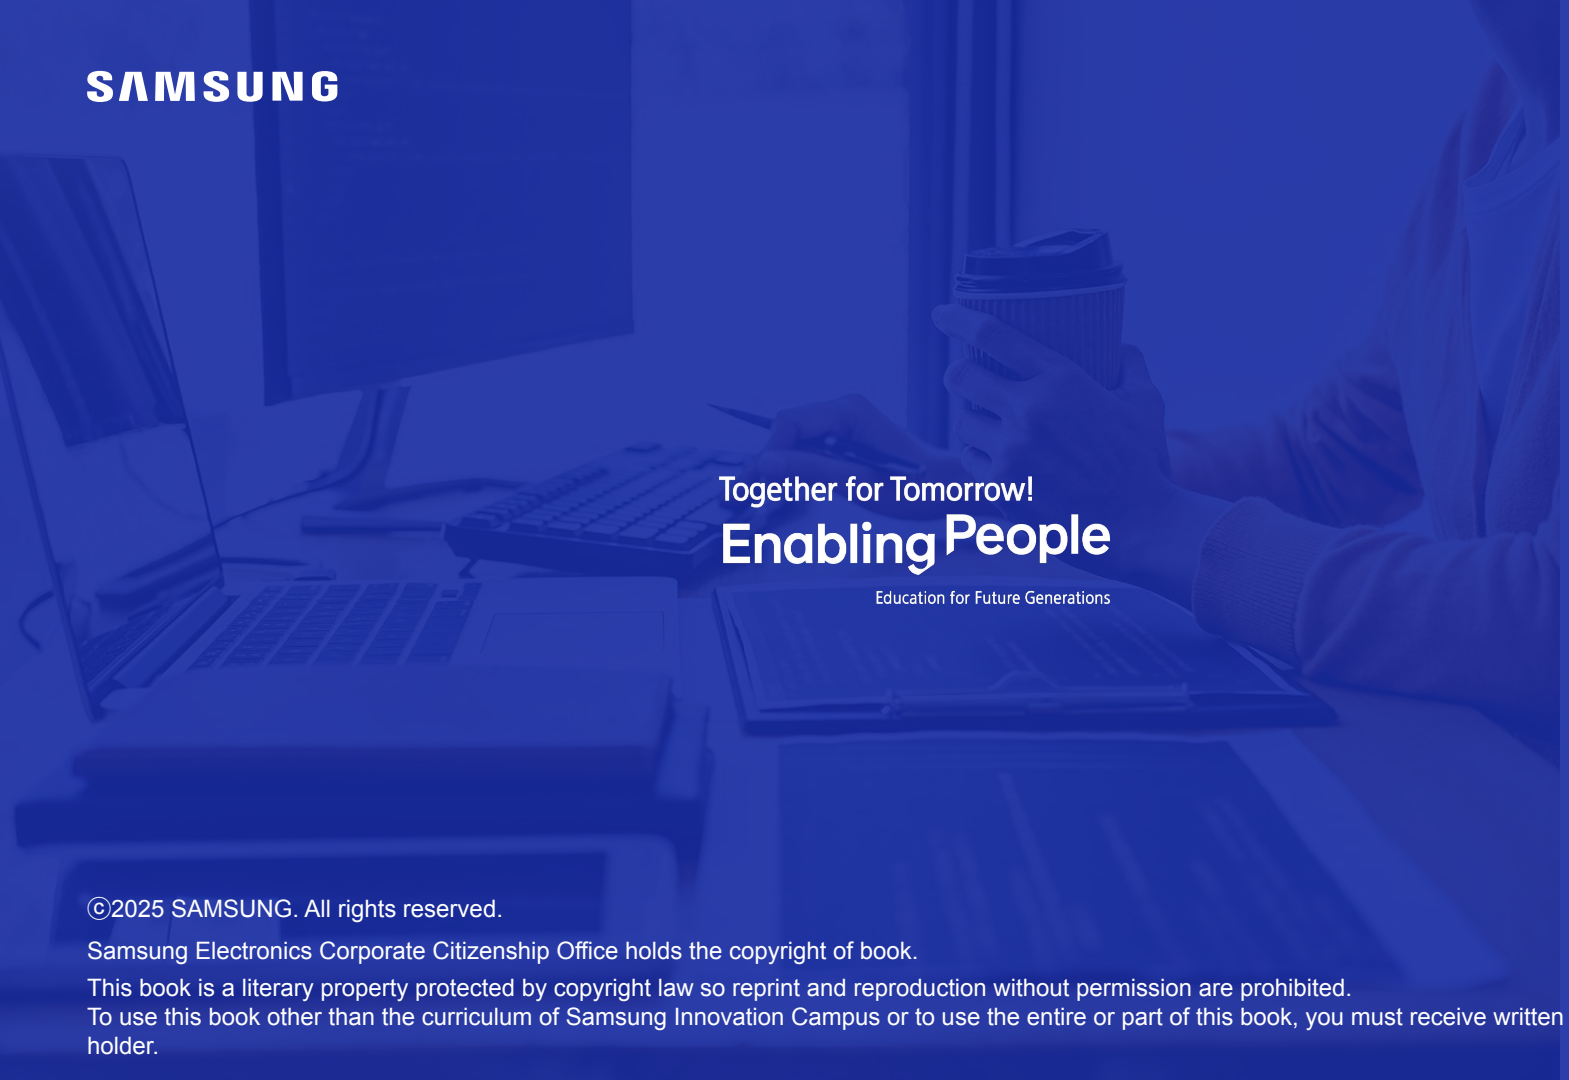
FEATURE	TIPO	TRANSFORMACIÓN
nuevoPrecio, precioAnterior_num	Cuant-Cont	Escalar obligatoriamente
precioDiscount_num, promocionDiscount_num	Cuant-Disc	Regex + escalar (10% OFF)
envioGratis, esTiendaOficial	Cual-Nom binaria	Ya es 0/1 (0) (1)
Envio	Cual-Ord	Ordinal Encoding (lento → rápido)
highlight → unidades restantes	Cuant-Disc / Ord	Regex + tratar como urgencia ordinal (QUEDAN 2!)

MODELOS TÍPICOS
K-Means • DBSCAN • PCA + clustering

Importante: K-Means trabaja con distancias. Si mezclamos 0/1 con precios de miles sin escalar, los precios dominan la distancia y el modelo puede ignorar las variables categóricas.

LEYENDA RÁPIDA

- Cuant-Cont: numérica continua
- Cuant-Disc: numérica discreta
- Cual-Nom: categórica nominal
- Cual-Ord: categórica ordinal (1 2 3)
- Fecha/hora: datetime
- Texto libre: NLP (TF-IDF, embeddings)



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.