SAMSUNG

# Samsung Innovation Campus

## Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

# Notas de Clase

## Generative AI Module

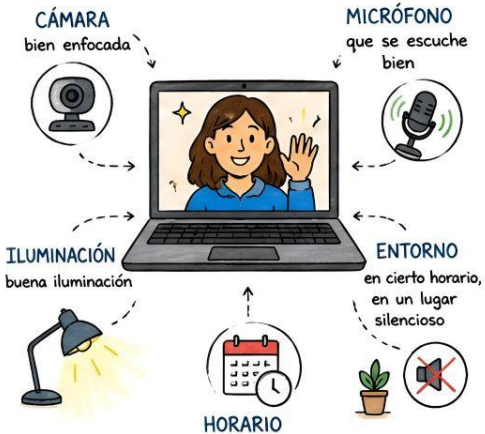
# OBJETIVOS DEL CURSO

**1** Se lleven como razonar un problema y saber cuando usar AI y cuando no.



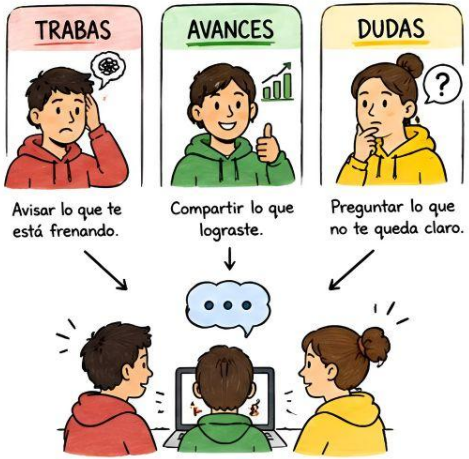

Primero pensar, después decidir.

**2** Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



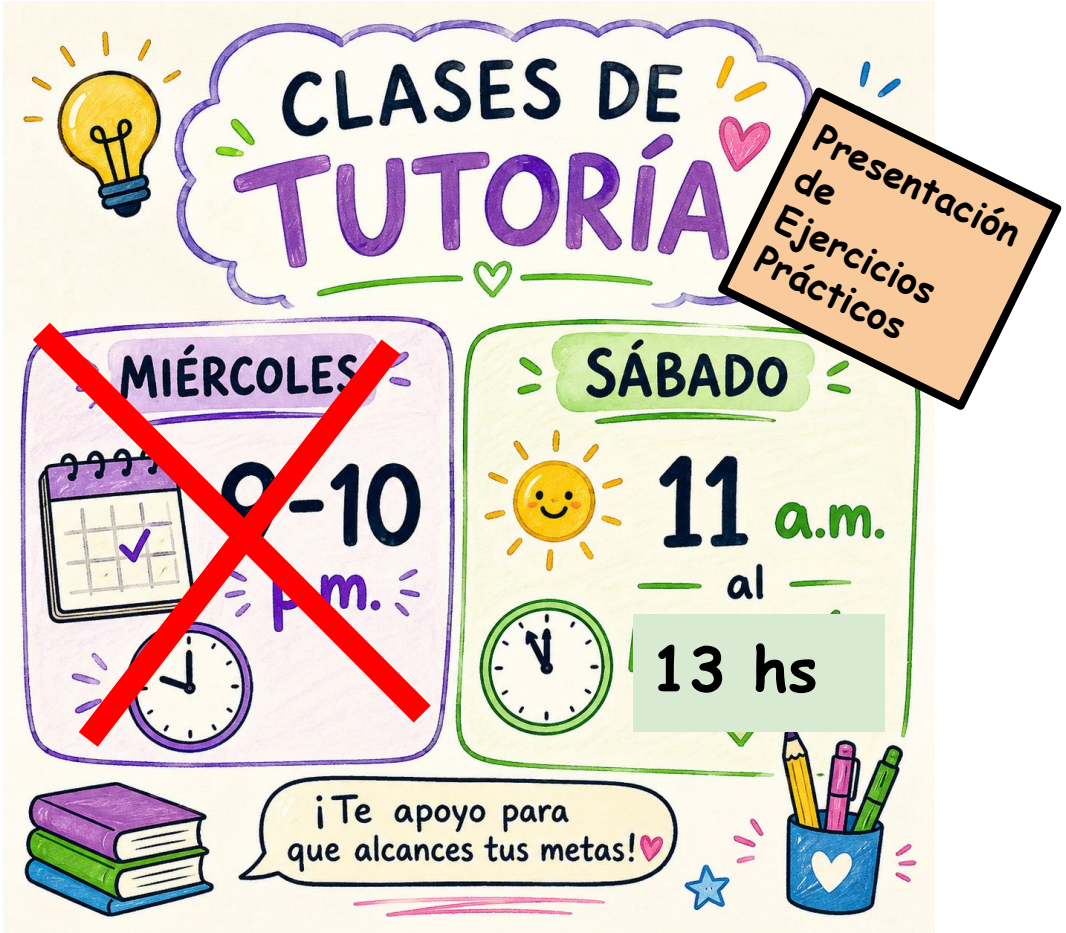

Tu meet es tu carta de presentación. ¡Cuidala!

**3** Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.




Comunicar a tiempo = mejores soluciones, menos estrés.

**PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS**




[Inscripción a la reunión - Zoom]

# RESUMEN DE LA CLASE ANTERIOR

## REPASO DE PANDAS CON NUMPY PARA EL QUIZZ 2 + DEFINICIONES DE VARIABLES

Dataset: Mercado Libre – Libros de Terror

### 1. REPASO CONCEPTUAL

**PANDAS**

Trabajamos con datos en tablas.

- Explorar y entender los datos
- Filtrar y seleccionar
- Ordenar
- Agrupar y resumir
- Transformar columnas
- Manejar valores faltantes

**NUMPY**

Operaciones numéricas rápidas y eficientes.

- Arreglos y formas
- Operaciones matemáticas
- Cálculos vectorizados
- Condiciones
- Álgebra básica
- Estadística descriptiva

Pandas organiza y facilita el análisis.
NumPy acelera los cálculos numéricos.

### 2. DEFINICIONES DE VARIABLES

¿LA COLUMNA ES TEXTO?

- ¿EL NÚMERO YA ESTÁ DENTRO? ("10% OFF" "6 cuotas de 11136")
  - SÍ → REGEX / PARSING — Extraemos números reales del texto
- NO, ES UNA CATEGORÍA REAL → ¿TIENE ORDEN?
  - SÍ → ORDINAL ENCODING — Preserva la jerarquía
  - NO → ONE-HOT / FREQUENCY / TARGET ENCODING — No inventamos un orden

### EJEMPLOS CON EL DATASET DE LIBROS DE TERROR

| COLUMNA | TIPO REAL | TRANSFORMACIÓN | EJEMPLO |
|---|---|---|---|
| precioDiscount "10% OFF" | Número disfrazado de texto | Regex | "10% OFF" → 10 |
| promociones "Cupón 5% OFF" | Número disfrazado de texto | Regex | "Cupón 5% OFF" → 5 |
| installments "6 cuotas de 11136" | Dos números en texto | Regex | "6 cuotas de 11136" → 6 y 11136 |
| envioGratis / esTiendaOficial | Nominal binaria | astype(int) | True / False → 1 / 0 |
| vendedor | Nominal, alta cardinalidad | Frequency / Target Encoding | Vendedor123 → frecuencia o target |
| Envio | Cualitativa ordinal | Ordinal Encoding | "Llega gratis hoy" → valor ordinal |
| highlight "ÚLTIMAS 2 UNIDADES" | Número extraíble + urgencia | Regex → numérica | "ÚLTIMAS 2 UNIDADES" → 2 |

### ORDEN REAL DE ENVÍO

1. NaN
2. Envío gratis
3. Llega gratis mañana
4. Llega gratis hoy
5. Llega gratis hoy + FULL

Ese orden tiene sentido lógico. Por eso usamos ORDINAL ENCODING para que el modelo respete la jerarquía.

### PARA LLEVARTE DE LA CLASE

Diagnóstico correcto (¿qué representa este dato?) → Transformación adecuada → Datos listos para entrenar modelos de Machine Learning!

# CLASE DE HOY: PROBABILIDAD Y VARIABLES ALEATORIAS

*Ejemplo: los patitos*

### 1. POBLACIÓN → MUESTRA → DATOS

- **POBLACIÓN**: Todos los elementos a estudiar.
- **MUESTRA**: Una parte de la población que observamos.
- **DATOS**: Características registradas de cada elemento de la muestra.

### 2. VARIABLES

Una variable es una característica que puede tomar distintos valores entre los elementos estudiados.

*Ejemplos:*
- Color
- Especie
- Género
- Peso
- Tamaño

### 3. VARIABLE DETERMINÍSTICA VS. ALEATORIA

**DETERMINÍSTICA**

Si conocemos las condiciones, el resultado queda determinado.

Ej.: peso ya medido = 500 g.

**ALEATORIA**

No conocemos el resultado antes de observarlo.

Ej.: qué especie tendrá el patito elegido al azar.

### 4. TIPOS DE VARIABLE

**CATEGÓRICA**

- NOMINAL (sin orden) — Ej.: color
- ORDINAL (con orden) — Ej.: tamaño (pequeño < mediano < grande)

**NUMÉRICA**

- DISCRETA (valores contables) — Ej.: cantidad de patitos — 0, 1, 2, 3, 4, ...
- CONTINUA (valores medibles) — Ej.: peso — 0, 250 g, 500 g, 750 g, 1000 g

### 5. ¿QUÉ ES UNA DISTRIBUCIÓN?

Describe cómo se reparten los valores posibles de una variable y con qué frecuencia, probabilidad o densidad aparecen.

Categórica (porcentajes) · Discreta (probabilidades) · Continua (densidad)

Importante: una distribución NO tiene que ser una campana normal.

### 6. TRES FORMAS DE HABLAR DE UNA DISTRIBUCIÓN

- DISTRIBUCIÓN DE DATOS OBSERVADOS — Proviene de una muestra real.
- DISTRIBUCIÓN POBLACIONAL — Corresponde a toda la población.
- DISTRIBUCIÓN DE PROBABILIDAD — Modelo teórico que puede aproximar a la poblacional.

### 7. EXPERIMENTO REPRODUCIBLE

Debe poder repetirse por otra persona bajo las mismas reglas, definiendo:

- Objetivo
- Población
- Procedimiento
- Condiciones
- Mecanismo aleatorio
- Variables
- Registro de datos

¡Siempre el mismo procedimiento!

Reproducible ≠ mismo resultado individual (el procedimiento es siempre el mismo, los resultados varían).

### 8. DEL ESPACIO MUESTRAL AL ESPACIO DE PROBABILIDAD

- $\Omega$ (espacio muestral): todos los resultados posibles.
- $\mathcal{F}$ (eventos/sucesos): subconjuntos de $\Omega$ que podemos considerar.
- $P$ (función de probabilidad): asigna probabilidad a cada evento de $\mathcal{F}$.

$(\Omega, \mathcal{F}, P)$ = espacio de probabilidad

### 9. ¿POR QUÉ "ESPACIO DE PROBABILIDAD"?

Analogía con espacio matemático: conjunto + estructura.

Espacio matemático = Espacio de probabilidad ($\Omega$ $\mathcal{F}$ $P$)

Idea clave final:

RESULTADOS → EVENTOS → PROBABILIDADES

No es una fórmula arbitraria, sino la construcción matemática completa del experimento aleatorio.

# ¿QUÉ ESTAMOS ESTUDIANDO?

**POBLACIÓN → MUESTRA → DATOS**

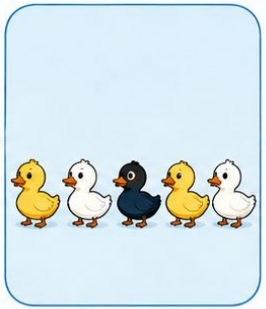
**1. POBLACIÓN**
Todos los patitos de la reserva.



**2. SELECCIONAMOS**
Elegimos algunos patitos.



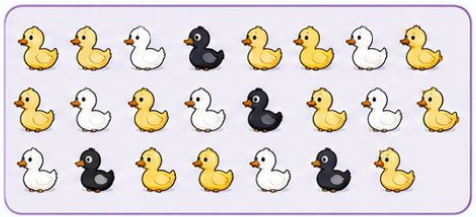
**3. MUESTRA**
Una parte de esa población que observamos.



**4. DATOS**
Observamos y registramos sus características.

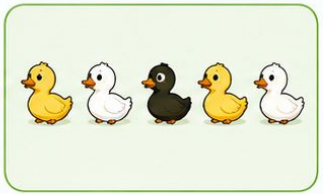



**POBLACIÓN**



↓ seleccionamos

**MUESTRA**



**Población:** todos los elementos que queremos estudiar.

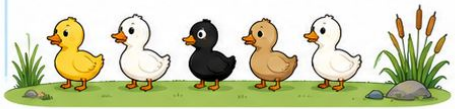
**Muestra:** una parte de esa población que observamos.

**Datos:** características o valores que registramos de cada elemento de la muestra.

**EJEMPLO**

Queremos estudiar los patitos de una reserva:

- **Población:** todos los patitos de la reserva.
- **Muestra:** 20 patitos seleccionados.
- **Datos:** color, especie, género, peso, edad...



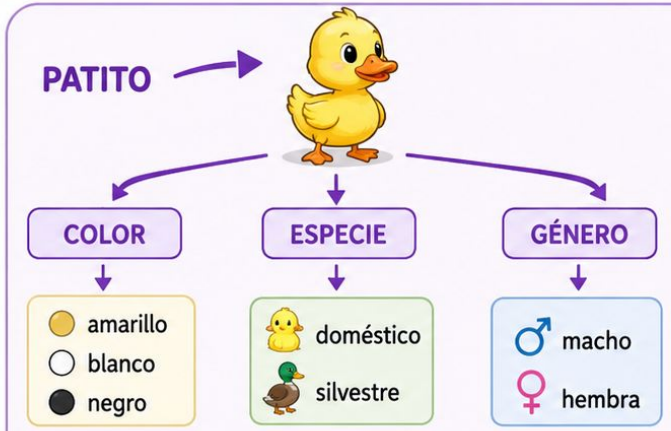
**IDEA CLAVE:**

Estudiamos una **muestra** para aprender sobre una **población.**

# ¿Qué observamos? Variables

Una **variable** es una característica que puede tomar distintos valores entre los elementos que estudiamos.

**Cada patito tiene características diferentes**




★ **Población:** todos los elementos que queremos estudiar.

★ **Variables:** son las características que describen a cada elemento de la población.

**Ejemplo**

| Patito | Color | Especie | Género |
|---|---|---|---|
| | Amarillo | Doméstico | ♀ Hembra |
| | Blanco | Silvestre | ♂ Macho |
| | Negro | Doméstico | ♀ Hembra |

**Pregunta fundamental**

¿Qué característica estamos observando de cada elemento?

**Idea clave:**
Una poblaación está formada por elementos, pero las **variables** describen las **características** de esos elementos.

Estudiamos una **muestra** para aprender sobre una **población**.



# ¿LA VARIABLE ES DETERMINÍSTICA O ALEATORIA?

## ¿SABEMOS EL RESULTADO ANTES DE OBSERVARLO?

### DETERMINÍSTICA

**Si conocemos las condiciones, el resultado queda determinado.**

Patito

↓

Regla conocida

↓

peso = 500 g




No necesitamos **probabilidad** para determinar el resultado.

### ALEATORIA

**Seleccionamos** un patito **al azar**.



↓

elegir uno

↓

¿?

Definimos:

$X$ = especie del patito seleccionado

Antes de seleccionarlo:

$X$ = ?

Después:

$X$ = silvestre

La variable es **aleatoria** porque antes de observar el resultado **no conocemos** qué valor específico tomará.



### Importante

**Aleatorio no significa "sin reglas".**
Significa que **no conocemos** de antemano el resultado individual.

**Ejemplo:**
No sabemos qué patito vamos a elegir, pero el proceso de selección tiene reglas (al azar).



# ¿Qué tipo de variable tenemos?

No todas las variables representan lo mismo

**VARIABLE**

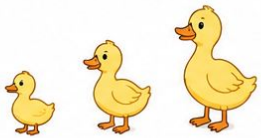
- **CATEGÓRICA** — Representan categorías
  - **NOMINAL** — No existe un orden natural
  - **ORDINAL** — Existe un orden
- **NUMÉRICA** — Representan cantidades
  - **DISCRETA** — Valores contables
  - **CONTINUA** — Valores medibles

Las variables **categóricas** representan categorías.

| Especie | Género | Color |
|---|---|---|
|  Doméstica |  Macho | Amarillo |
|  Silvestre |  Hembra | Blanco, Negro |

**ORDINAL**

Tamaño (ejemplo)



pequeño → mediano → grande

**Nominal:** no existe un orden natural entre las categorías.

**Ordinal:** existe un orden entre las categorías (pequeño < mediano < grande).

Las variables **numéricas** representan cantidades.

**Discreta**

$X$ = cantidad de patitos



$\{1, 2, 3, 4, \ldots\}$

**Continua**

$X$ = peso del patito (kg)




$\{0.501, 0.502, 0.5027, \ldots\}$

**Discreta:** toma valores enteros y contables. No admite fracciones.

**Continua:** puede tomar cualquier valor real dentro de un intervalo.

**EN RESUMEN**

Las variables pueden describir categorías (categóricas) o cantidades (numéricas).
Dentro de cada grupo, existen subtipos según si hay orden y si los valores son contables o medibles.



# Entonces... ¿qué es una distribución?

**Tenemos una variable. Ahora preguntamos:**

**¿Cómo están repartidos sus valores?**

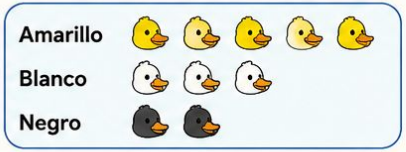
Supongamos que observamos 10 patitos:



**Contamos:**

| Color | Frecuencia |
|---|---|
| Amarillo | 5 |
| Blanco | 3 |
| Negro | 2 |

**Tenemos una distribución de los datos.**




**DEFINICIÓN**

Una **distribución** describe cómo se reparten los **valores** posibles de una variable y con qué **frecuencia, probabilidad** o **densidad** aparecen.

VARIABLE → VALORES → ¿CÓMO SE REPARTEN? → **DISTRIBUCIÓN**

**Distribución ≠ distribución normal**

Una distribución **NO** tiene que ser una campana.

Puede describir:

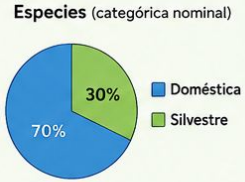


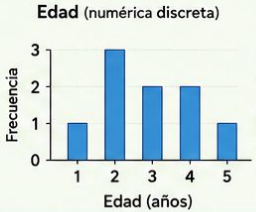


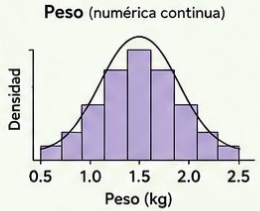

**IDEA CLAVE**

Una distribución **NO** es necesariamente una **campana normal.**



# Tres formas de hablar de una distribución

La misma idea aparece en distintos niveles

## ① DISTRIBUCIÓN DE DATOS OBSERVADOS

Tenemos una muestra:



Contamos los valores:

Color → frecuencia

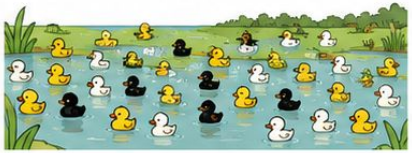
| Color | Frecuencia |
|---|---|
| Amarillo | 5 |
| Blanco | 3 |
| Negro | 2 |

Esto es una **distribución empírica u observada.**




## ② DISTRIBUCIÓN POBLACIONAL

Ahora pensamos en todos los patitos de la reserva:



...

Preguntamos:

¿Cómo están distribuidos los colores, especies, pesos, etc. en toda la población?

↓

Eso es la **distribución poblacional.**

## ③ DISTRIBUCIÓN DE PROBABILIDAD

Ahora seleccionamos un patito al azar.



$X$ = especie del patito seleccionado

Supongamos:

| Especie | P(X) |
|---|---|
| Doméstica | 0.70 |
| Silvestre | 0.30 |

→ VALORES POSIBLES ↓ PROBABILIDAD DE CADA VALOR ↓ DISTRIBUCIÓN DE PROBABILIDAD

**No son exactamente lo mismo**

**Distribución poblacional**



¿Cómo están repartidos los valores reales en la población?

**Distribución de probabilidad**

¿Qué valores puede tomar una variable aleatoria y con qué probabilidad?

Pero podemos utilizar una distribución de probabilidad para modelar una distribución poblacional.

**Y ahora podemos conectar con probabilidad**

EXPERIMENTO ALEATORIO

↓ Lanzar / seleccionar / observar

↓ ESPACIO MUESTRAL Ω — Todos los resultados posibles {...}

↓ EVENTOS O SUCESOS — Subconjuntos de Ω

↓ PROBABILIDAD $P$

↓ DISTRIBUCIÓN DE PROBABILIDAD

Por ejemplo, si el experimento es seleccionar un patito al azar:

$\Omega$ = { todos los patitos posibles }

Un evento podría ser:

$A$ = { patito de especie silvestre }

y entonces:

$P(A) = P$ (especie silvestre)

**Idea final de la clase:** Primero tenemos una población. Tomamos una muestra. Observamos variables. Las variables pueden ser categóricas o numéricas, determinísticas o aleatorias. Luego preguntamos cómo se distribuyen sus valores. Cuando existe incertidumbre, podemos describir esa distribución mediante probabilidades.



# ¿Qué es un experimento reproducible?

Un experimento debe poder repetirse por otra persona bajo las **mismas reglas.**



Si sigo los mismos pasos, puedo obtener resultados comparables.

## ¿Qué es un experimento?




**Población**

Todos los patitos de la reserva

## Para que sea REPRODUCIBLE hay que definir

| | |
|---|---|
| **Objetivo** | ¿Qué queremos medir u observar? |
| **Población** | ¿Sobre qué conjunto trabajamos? |
| **Procedimiento** | ¿Qué pasos seguimos? |
| **Condiciones** | ¿En qué condiciones lo hacemos? |
| **Mecanismo aleatorio** | ¿Cómo se elige o genera el resultado? |
| **Variables** | ¿Qué características observamos? |
| **Registro de datos** | ¿Cómo guardamos los resultados? |

## Ejemplo: nuestro experimento

1. Elegimos un patito al azar



2. Observamos la especie



3. Posibles resultados (Variable X)
   - Doméstica
   - Silvestre
4. Registramos el resultado



## Reproducible no significa mismo resultado

Repetimos el experimento varias veces:




| Resultados observados | |
|---|---|
| Especie | Frecuencia |
| Doméstica | 7 |
| Silvestre | 3 |
| Total | 10 |

Los resultados individuales cambian, pero el procedimiento es siempre el mismo.



## ¿Y si usamos la computadora?



1. Definimos reglas del experimento
2. Generamos número aleatorio
3. Obtenemos resultado



Usamos una "semilla" (seed) para poder repetir exactamente la misma simulación.

## Idea clave

> Un experimento reproducible debe tener claras sus reglas, sus condiciones y su forma de registrar los datos.



Objetivo + Azar + Procedimiento + Datos

# ¿POR QUÉ SE LLAMA "ESPACIO DE PROBABILIDAD"?

Antes de hablar de probabilidad, recordemos una idea más general:

## ESPACIO MATEMÁTICO

En matemática podemos construir un espacio tomando:

**CONJUNTO + ESTRUCTURA = ESPACIO**

La estructura indica qué podemos hacer matemáticamente con los elementos.

Por ejemplo:

$$(\mathbb{R}^2, +, \cdot)$$

No necesitamos estudiar aquí toda la estructura de un espacio vectorial.

La idea importante es:
Un "espacio" es un conjunto acompañado de una estructura que permite trabajar matemáticamente con él.

## APLICADO AL AZAR

Para nuestro experimento tenemos:

### ① $\Omega$ — RESULTADOS POSIBLES

$\Omega = \{$ amarillo, verde, azul $\}$



¿Qué puede ocurrir?

### ② $\mathcal{F}$ — EVENTOS

Los eventos son subconjuntos de $\Omega$.

Por ejemplo:

$$A = \{\text{amarillo, verde}\}$$
$$A \subseteq \Omega$$



"El patito seleccionado no es azul".

Entonces $\mathcal{F}$ reúne los eventos que podemos considerar.

$\mathcal{F}$ está formada por subconjuntos de $\Omega$.

### ③ $P$ — PROBABILIDADES

Asignamos probabilidades a esos eventos:

$$P(A) = 0.80$$

porque:

$$P(A) = P(\text{amarillo}) + P(\text{verde}) = 0.50 + 0.30 = 0.80$$

Y también:

$$P(\{\text{azul}\}) = 0.20$$

## AHORA TODO ENCAJA

$(\Omega, \mathcal{F}, P)$

- $\Omega$ — ¿Qué puede ocurrir?
- $\mathcal{F}$ — ¿Qué eventos podemos considerar?
- $P$ — ¿Qué probabilidad tiene cada evento?

$(\Omega, \mathcal{F}, P)$ **ESPACIO DE PROBABILIDAD**

El modelo matemático que describe qué puede ocurrir, qué eventos consideramos y con qué probabilidad.

## COMPARACIÓN FINAL

| Elemento | Pregunta |
|---|---|
| $\Omega$ | ¿Qué puede ocurrir? |
| $\mathcal{F}$ | ¿Qué eventos consideramos? |
| $P$ | ¿Qué probabilidad tiene cada evento? |
| $(\Omega, \mathcal{F}, P)$ | ¿Cómo modelamos matemáticamente el azar? |

## IDEA CLAVE

Resultados → Eventos → Probabilidades

No es una fórmula arbitraria: $(\Omega, \mathcal{F}, P)$ es la construcción matemática del experimento aleatorio.

# DEL ESPACIO MUESTRAL AL ESPACIO DE PROBABILIDAD

**EXPERIMENTO ALEATORIO:** Seleccionar un patito al azar del lago y observar su color.

## 1 ESPACIO MUESTRAL – $\Omega$

El espacio muestral contiene todos los resultados posibles.

Si los colores posibles son:

$\Omega = \{\text{amarillo}, \text{verde}, \text{azul}\}$

$\Omega$ responde: **"¿QUÉ PUEDE OCURRIR?"**



Amarillo Verde Azul

No decimos todavía qué resultado es más probable, solo cuáles son posibles.

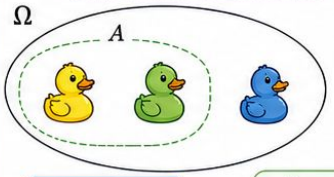
## 2 EVENTOS O SUCESOS – $\mathcal{F}$

Un evento es un subconjunto del espacio muestral.

Por ejemplo:

$A = \{\text{amarillo}, \text{verde}\}$

$A$ representa: "Seleccionar un patito que no sea azul".




$B = \{\text{azul}\}$

$B$ representa: "Seleccionar un patito azul".

En general: $A \subseteq \Omega$ (El evento $A$ es subconjunto de $\Omega$)

## 3 COLECCIÓN DE EVENTOS – $\mathcal{F}$

Tenemos una colección de eventos que podemos considerar.

$\mathcal{F}$ = colección de eventos

Ejemplo:

- {amarillo}
- {verde}
- {azul}
- {amarillo, verde}
- {amarillo, azul}
- {verde, azul}
- {amarillo, verde, azul} = $\Omega$
- $\emptyset$ (evento imposible)

$\mathcal{F}$ responde: **"¿QUÉ EVENTOS ESTAMOS CONSIDERANDO?"**

$\mathcal{F}$ está formada por subconjuntos de $\Omega$.

## 4 FUNCIÓN DE PROBABILIDAD – $P$

Asignamos una probabilidad a los eventos.

| Color | Probabilidad |
|---|---|
| Amarillo | 0.50 |
| Verde | 0.30 |
| Azul | 0.20 |

$P: \mathcal{F} \to [0,1]$

$P$ asigna una probabilidad a cada evento de $\mathcal{F}$.

$P(\text{amarillo}) = 0.50$

$P(\text{verde}) = 0.30$

$P(\text{azul}) = 0.20$

$A = \{\text{amarillo}, \text{verde}\}$

$P(A) = P(\text{amarillo}) + P(\text{verde})$

$= 0.50 + 0.30$

$= 0.80$

Hay un 80% de probabilidad de seleccionar un patito que no sea azul.

## LA CONSTRUCCIÓN



**1 $\Omega$** ESPACIO MUESTRAL ¿Qué puede ocurrir?



$\Omega = \{\text{amarillo}, \text{verde}, \text{azul}\}$

**2 $\mathcal{F}$** COLECCIÓN DE EVENTOS ¿Qué eventos consideramos?



$\mathcal{F}$ = colección de eventos

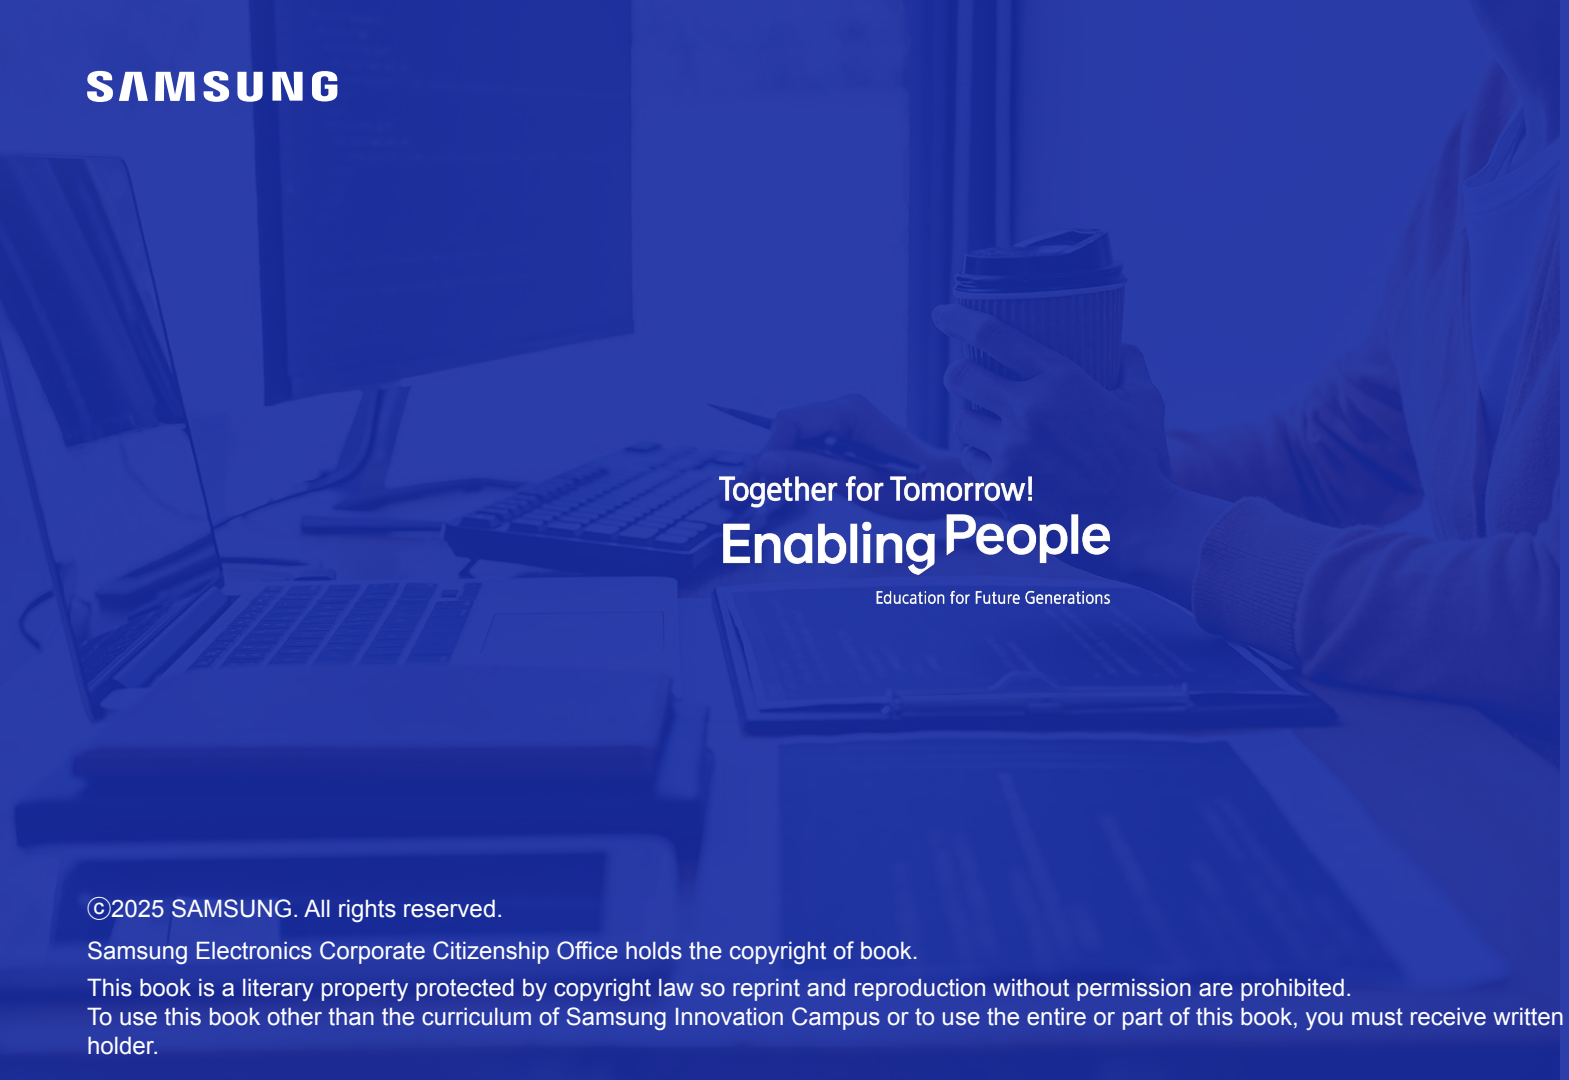
**3 $P$** FUNCIÓN DE PROBABILIDAD ¿Qué probabilidad tiene cada evento?




**4 $(\Omega, \mathcal{F}, P)$** ESPACIO DE PROBABILIDAD

Modelo matemático **completo** del experimento aleatorio.






ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.