SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

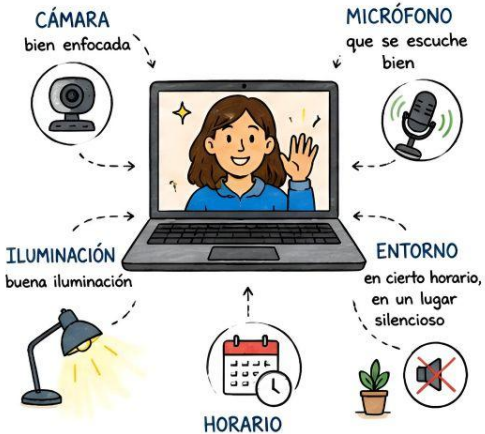
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



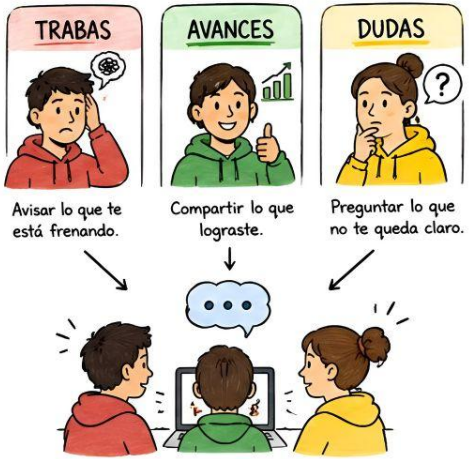
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



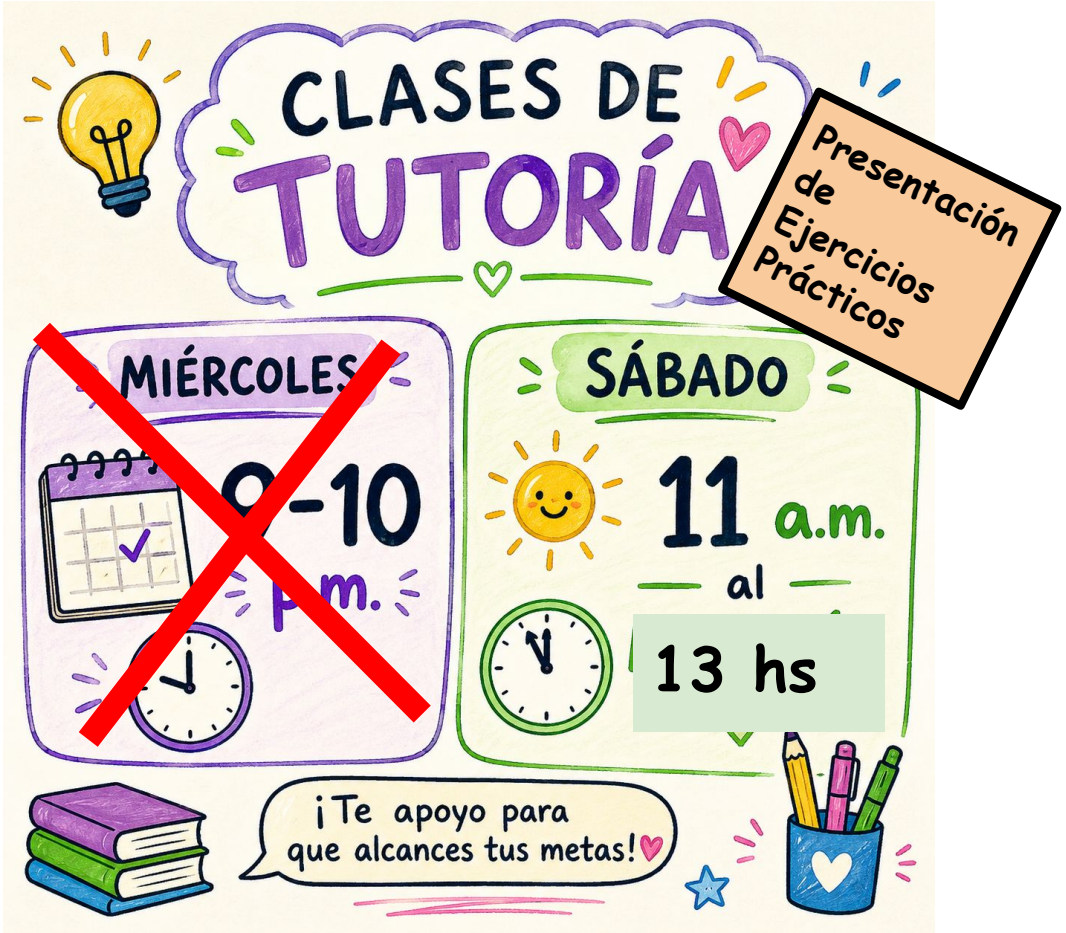
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS



[Inscripción a la reunión - Zoom]

Tres perfiles dentro de una solución de datos



Business Analyst

¿QUÉ necesitamos resolver?

- Problema
- Preguntas de negocio
- Reglas de negocio
- Diagrama de flujo
- ¿Qué datos necesitamos?
- Selección de variables

Transforma una necesidad de negocio en preguntas, reglas y requerimientos de datos.



Data Scientist

¿QUÉ dicen los datos?

- Datos
- ETL / preparación
- Pipeline
- EDA + Estadística
- Validación de features
- Modelo
- Evaluación

Construye pipelines, analiza estadísticamente los datos, comprueba que las variables sean adecuadas y desarrolla/evalúa modelos.



Solution Engineer

¿CÓMO lo llevamos a producción?

- Modelo + reglas + datos
- Make / n8n APIs / Apps
- Automatización
- Solución funcionando

Integra los componentes y convierte el análisis/modelo en una solución ejecutable, desde herramientas no-code/low-code hasta código completo.



Business Analyst → define el problema · **Data Scientist** → encuentra evidencia en los datos · **Solution Engineer** → convierte la solución en un sistema.

1. Población, muestra y estimadores

De la muestra a la población: aparecen los estimadores

Imaginemos un lago con **10.000 patitos.**



Población

Son **todos** los patitos que queremos estudiar.

Queremos conocer:

¿Cuál es el peso promedio de los 10.000 patitos?

El verdadero promedio es:

$\mu = ?$

En vez de pesar a los 10.000, elegimos **500** patitos.



500 patitos

Muestra

Calculamos su promedio:

$\bar{x} = 42$ g

Pero no conocemos μ.

Entonces:

$\bar{x}$ → nos sirve para estimar → μ

Parámetro vs. estadístico

POBLACIÓN → tiene parámetros	MUESTRA → tiene estadísticas
• Media → μ	• Media → $\bar{x}$
• Varianza → σ^2	• Varianza → s^2
• Proporción → p	• Proporción → $\hat{p}$



Idea clave

El estadístico que calculamos en la muestra puede utilizarse como **estimador** del parámetro de la población.

Slide 2 — ¿Cómo resumimos nuestros patitos?

No queremos repetir los 10 pesos cada vez.
Podemos **resumirlos**.

Tenemos 10 patitos y medimos su peso:

38, 40, 40, 41, 42, 43, 43, 44, 45, 64 g



Media

¿Cuál sería el peso promedio si repartimos todo el peso entre los patitos?

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$



La media nos da un valor central de referencia.

Mediana

Ordenamos los patitos por peso:

38 – 40 – 40 – 41 – **42** | **43** – 43 – 44 – 45 – 64

La mediana queda en el centro.

50% de los patitos queda por debajo y 50% por encima.



50% 50%

Moda

¿Qué peso aparece más veces?

40 g → 🐥🐥

43 g → 🐥🐥

Hay dos valores con mayor frecuencia.

Dispersión

Ahora imaginemos dos grupos de patitos:

Grupo A



40 – 41 – 42 – 42 – 43

Grupo B



20 – 30 – 42 – 54 – 64

Aunque sus medias pueden ser parecidas:

¿Están los patitos concentrados alrededor del promedio o muy separados?

Ahí aparecen:

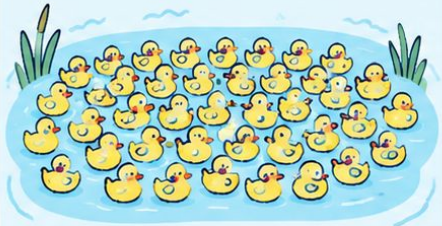
- **Rango** → máximo – mínimo
- **Varianza** → cuánto se alejan los pesos de la media
- **Desviación estándar** → medida de dispersión en gramos

3. ¿El estimador siempre da lo mismo?

Volvamos a nuestros 10.000 patitos.

Supongamos que conocemos mágicamente el verdadero promedio:

$\mu = 42$ g



10.000 patitos

Ahora sacamos distintas muestras de 500 patitos.

Muestra 1

500 patitos

$\bar{x}_1 = 42{,}1$ g

Muestra 2

500 patitos

$\bar{x}_2 = 41{,}7$ g

Muestra 3

500 patitos

$\bar{x}_3 = 42{,}4$ g

Muestra 4

500 patitos

$\bar{x}_4 = 41{,}9$ g

Los resultados son diferentes porque no elegimos exactamente los mismos patitos.

Pero todos intentan aproximarse a: $\mu = 42$ g

Idea importante

Un estimador es una herramienta para aproximarnos a un parámetro desconocido.

Si repetimos el muestreo:

muestra → estimador

muestra → estimador

muestra → estimador

⋮

obtenemos una idea de qué tan variable es nuestro estimador.

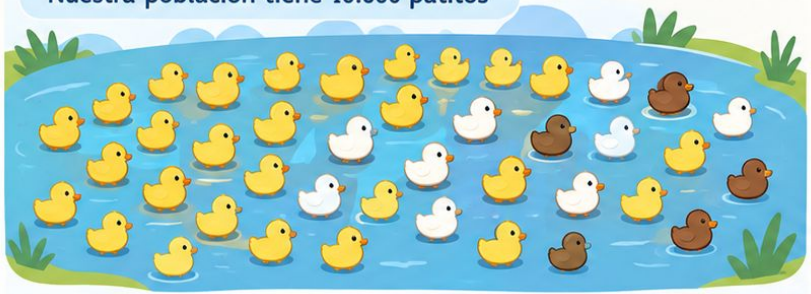
Slide 4

De los patitos a una distribución

Ahora no nos interesa solamente el peso. Queremos estudiar otra característica:

¿En qué color vienen los patitos?

Nuestra población tiene 10.000 patitos



Contamos:

6.000 amarillos	3.000 blancos	1.000 marrones

Entonces, las proporciones son:

$$\hat{p}_{\text{amarillo}} = \frac{6.000}{10.000} = 0,60$$

$$\hat{p}_{\text{blanco}} = \frac{3.000}{10.000} = 0,30$$

$$\hat{p}_{\text{marrón}} = \frac{1.000}{10.000} = 0,10$$

Distribución empírica (población)

Amarillo	Blanco	Marrón
0,60	0,30	0,10

¿Y si no conocemos todos los patitos?

Tenemos solamente 500:



Los contamos:

300 amarillos	150 blancos	50 marronês

Entonces:

$$\hat{p}_{\text{amarillo}} = \frac{300}{500} = 0,60$$

$$\hat{p}_{\text{blanco}} = \frac{150}{500} = 0,30$$

$$\hat{p}_{\text{marrón}} = \frac{50}{500} = 0,10$$

Usamos la muestra para **estimar** cómo es la población.



Idea clave

La distribución de colores que observamos en la muestra nos da una idea de cómo es la distribución en toda la población.

El hilo completo

Todo empezó con una pregunta sobre patitos:

¿Cómo puedo conocer las características de muchos patitos si no puedo estudiar cada uno?



Probabilidad

¿Qué puede pasar cuando observo un patito?

Éxito
Fracaso

Bernoulli
(un solo patito)

↓

Varios patitos
Binomial

↓

Cantidad de eventos en un intervalo
Poisson

↓

Si todos los resultados tienen la misma probabilidad
Equiprobabilidad

Estadística

Tengo muchos patitos:



Población
(10.000 patitos)

↓

Elijo algunos:



Muestra
(500 patitos)

↓

Calculo:

Media | Varianza | Proporción | etc.

↓

Uso esos valores para aproximar:

μ | σ^2 | p

Estimadores y distribución muestral

Cada muestra da un valor distinto de la media muestral:


$\bar{x}_1 = 42{,}1$ g

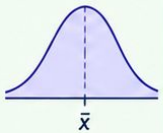

$\bar{x}_2 = 41{,}7$ g


$\bar{x}_3 = 42{,}4$ g


$\bar{x}_4 = 41{,}9$ g

...

Si repetimos muchas veces, obtenemos la **distribución muestral** de $\bar{x}$.



No estamos distribuyendo los pesos de los patitos, sino los valores que podría tomar nuestro estimador al cambiar la muestra.

De los patitos a una distribución

¿En qué color vienen los patitos?

Población (10.000 patitos)



Proporciones (distribución empírica)

Amarillo	0,60
Blanco	0,30
Marrón	0,10

¿Y si no conocemos todos los patitos?

Muestra (500 patitos)



Proporciones en la muestra

Amarillo	0,60
Blanco	0,30
Marrón	0,10

Estamos usando la muestra para estimar cómo es la población.

Pregunta final

¿La distribución que observo en mi muestra representa realmente a todos los patitos?

Muestreo

↓

Estimación

↓

Incertidumbre

↓

Distribuciones

↓

Inferencia estadística



Probabilidad + Estadística = Herramientas para entender y tomar decisiones con datos

¿De dónde salen la media y la varianza de cada distribución?

Para cualquier variable aleatoria discreta, la media y la varianza se calculan siempre igual:

$$\mu = E[X] = \sum x \cdot P(x) \qquad \sigma^2 = \mathrm{Var}(X) = \sum (x-\mu)^2 \cdot P(x) = E[X^2] - (E[X])^2$$

Pero en cada distribución los parámetros (p, n, λ) determinan directamente el resultado, sin tener que recalcular la suma cada vez.

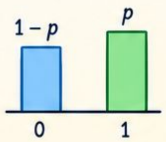
1. Bernoulli — $X \sim \mathrm{Ber}(p)$

- Valores posibles: $\{0, 1\}$
- Media: $\mu = E[X] = p$
- Varianza: $\sigma^2 = \mathrm{Var}(X) = p(1-p)$



Vínculo con el parámetro:

- p es literalmente la probabilidad de éxito, así que la media "es" p (el promedio de una variable 0/1 es la proporción de unos).
- La varianza es máxima cuando $p = 0.5$ (mayor incertidumbre) y cero cuando $p = 0$ o $p = 1$ (no hay azar).



2. Binomial — $X \sim \mathrm{Bin}(n, p)$

- Valores posibles: $\{0, 1, \ldots, n\}$
- Media: $\mu = n \cdot p$
- Varianza: $\sigma^2 = n \cdot p(1-p)$



Vínculo con el parámetro:

- La Binomial es la suma de n Bernoullis independientes, y la media/varianza de una suma de independientes es la suma de sus medias/varianzas → por eso μ y σ^2 son simplemente n veces las de Bernoulli.

Ejemplo: si $p = 0.2$ y $n = 5$ →
$\mu = 1$ (esperamos 1 éxito en promedio),
$\sigma^2 = 5 \cdot 0.2 \cdot 0.8 = 0.8$.

3. Poisson — $X \sim \mathrm{Po}(\lambda)$

- Valores posibles: $\{0, 1, 2, \ldots\}$ (sin tope)
- Media: $\mu = \lambda$
- Varianza: $\sigma^2 = \lambda$



Vínculo con el parámetro:

- λ ya representa el número promedio esperado de eventos, así que la media es directamente λ.
- Que la varianza también sea λ es la "huella" de que Poisson viene de una Binomial con $n \to \infty$ y $p \to 0$ manteniendo $n \cdot p = \lambda$ constante (la varianza $n \cdot p(1-p) \to \lambda \cdot 1 = \lambda$, porque $p \to 0$).



Tabla resumen

Distribución	Parámetro(s)	Media (μ)	Varianza (σ^2)
Bernoulli	p	p	$p(1-p)$
Binomial	n, p	$n \cdot p$	$n \cdot p(1-p)$
Poisson	λ	λ	λ

Idea clave

No hay que memorizar tres fórmulas sueltas — Binomial es "n Bernoullis sumadas" y Poisson es "el límite de la Binomial cuando los ensayos se vuelven infinitos y raros".

Por eso la media y la varianza de las tres están conectadas por la misma lógica: el parámetro no es un número arbitrario, es directamente la media (o el ingrediente de la media) del proceso que estás modelando.



De la tendencia a la predicción:
estacionalidad y series temporales

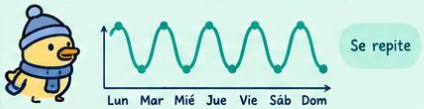


Componentes típicos de una serie temporal

1 Tendencia (trend)
Dirección general a largo plazo (sube, baja, se mantiene).



2 Estacionalidad (seasonality)
Patrones que se repiten en intervalos fijos (por día de semana, por mes, por temporada).



3 Ruido (noise/residual)
Lo que queda después de explicar tendencia y estacionalidad — la parte verdaderamente aleatoria.



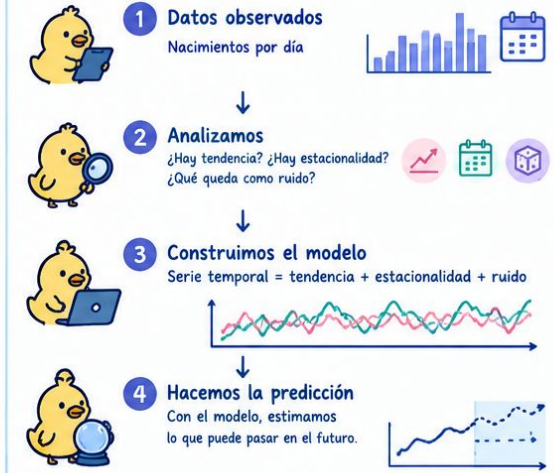
Ejemplo: nacimientos por día del año (CABA)



Conexión con todo lo anterior:

Equiprobabilidad → Observamos datos → Encontramos patrones → Modelamos esos patrones → Podemos predecir

Del dato a la predicción



La idea no es asumir que todos los resultados son iguales, sino aprender de cómo se comportan los datos.



De la tendencia a la predicción

Estacionalidad y series temporales



1 Componentes de una serie temporal

Tendencia (trend)
Dirección general a largo plazo (sube, baja o se mantiene).

Estacionalidad (seasonality)
Patrones que se repiten en intervalos fijos (por día de semana, por mes, por temporada).

Ruido (noise/residual)
Lo que queda después de explicar tendencia y estacionalidad — la parte verdaderamente aleatoria.

2 Ejemplo con nacimientos

Si miramos los nacimientos por día del año, los datos muestran estos componentes:



3 ¿Cómo se ve en la práctica?

Esos patrones nos permiten construir un modelo de serie temporal y predecir.

Datos observados (nacimientos por día)
↓
Analizamos los componentes (tendencia + estacionalidad + ruido)
↓
Modelo de serie temporal
↓
Predicción

4 ¿Qué conseguimos?



Ejemplo:

- Predecir picos de nacimientos.
- Anticipar mayor cantidad de incidentes en fines de semana.
- Planificar recursos según la temporada.

La idea clave

Equiprobabilidad (todos iguales) → Observamos datos (la realidad no es uniforme) → Encontramos patrones (tendencia y estacionalidad) → Modelamos (serie temporal) → Predicción (decisiones mejores)

La idea no es asumir que todos los resultados son iguales, sino aprender de cómo se comportan los datos.

Cuando la equiprobabilidad no se cumple: datos reales

Recordemos el gráfico de nacimientos en CABA (Clase 27, diapo 16):

Modelo idealizado (equiprobable)

Todas las barras tienen la misma altura: P(x) = 1/365.



Datos reales

Las barras varían: algunos días concentran más nacimientos que otros.



¿Qué hacemos cuando la equiprobabilidad falla?

1. Dejamos de asumir $P(x) = 1/365$ para todo x.



2. Estimamos cada probabilidad individual a partir de los datos:

$$\hat{p}_d = \frac{n_d}{N}$$

n_d = cantidad de nacimientos registrados el día d

N = total de registros

3. Esa estimación $\hat{p}_d$ es un estimador de la probabilidad poblacional real de nacer ese día.



Idea clave: Cuando el mundo no es equiprobable, no abandonamos la probabilidad — la **estimamos empíricamente** a partir de la frecuencia observada.

¿Qué es una tendencia?

Definición

Una **tendencia** es un patrón sistemático de **cambio** en los valores de una variable a lo largo del tiempo (o de otra dimensión ordenada), que no es puro azar.

Diferencia clave con "ruido aleatorio"

Ruido / azar	Tendencia
Variación impredecible, sin patrón (lo que asumimos en un modelo equiprobable).	Variación con dirección o forma reconocible (creciente, decreciente, cíclica).





Ejemplos con nuestros datos

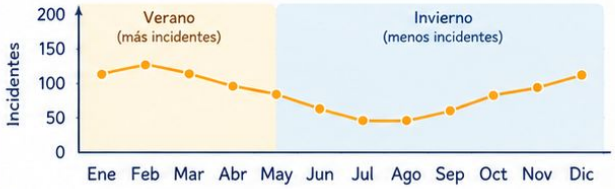
Tendencia semanal

Si los incidentes registrados en CABA aumentan sistemáticamente los fines de semana → hay una **tendencia semanal**.



Tendencia estacional

Si aumentan en verano y bajan en invierno → hay una **tendencia estacional**.



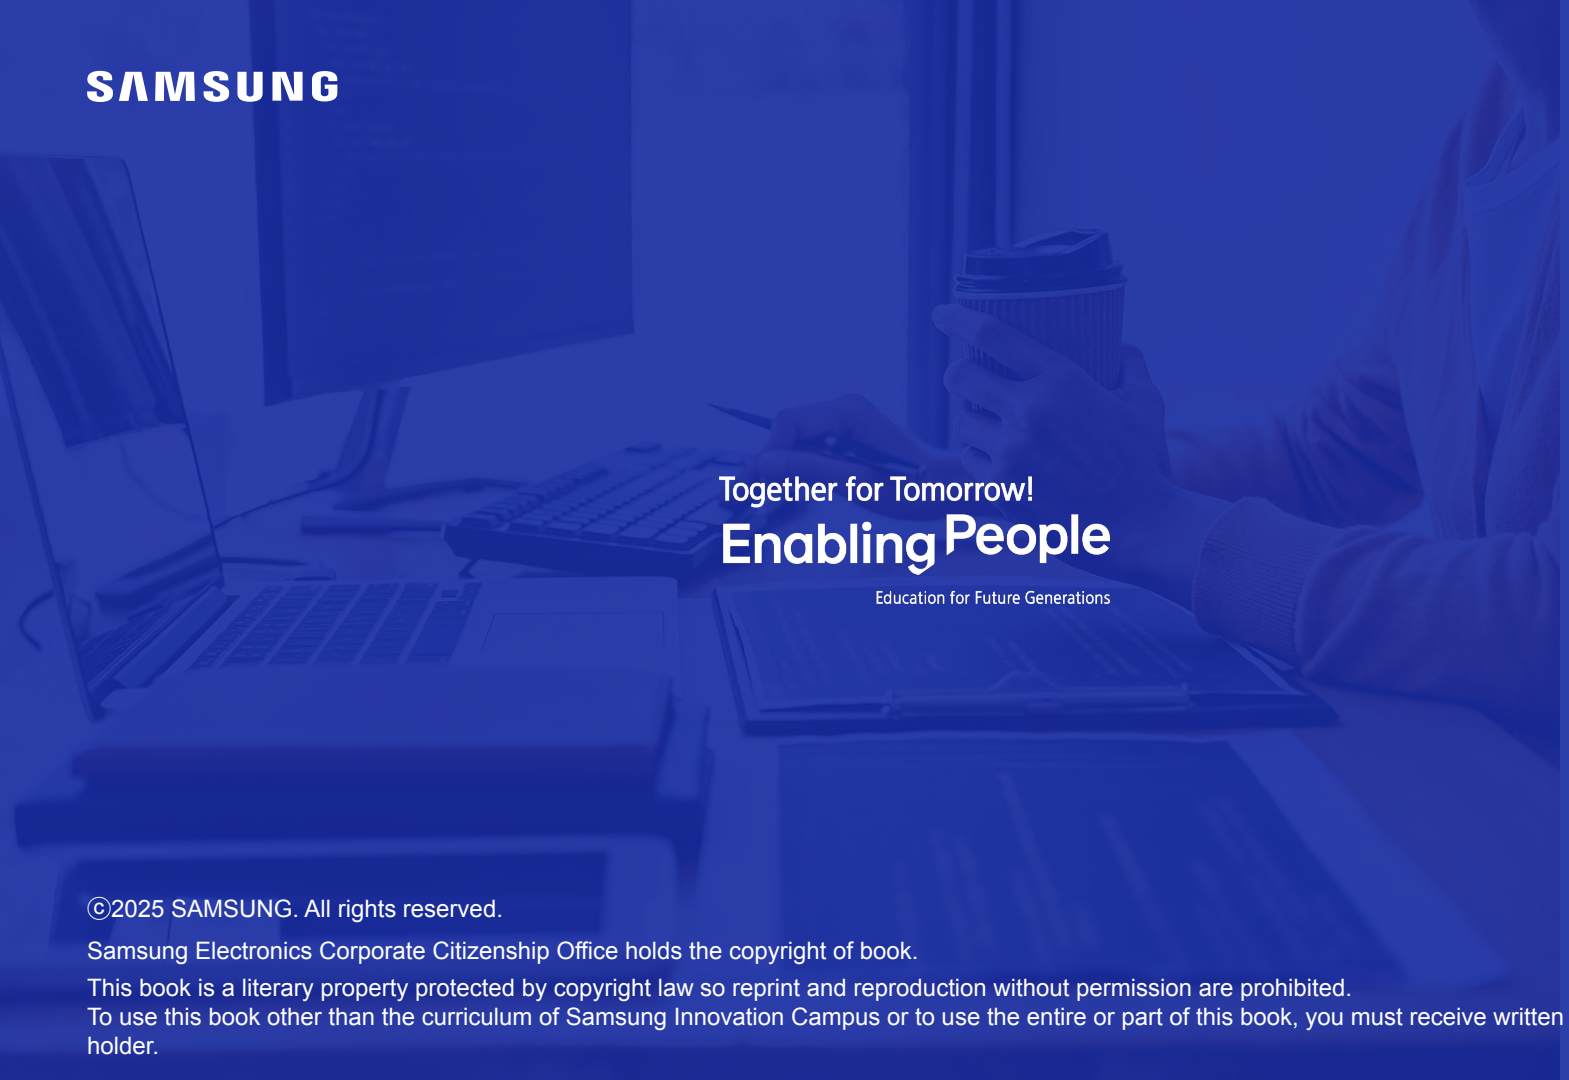
Pregunta pedagógica

Si veo que ciertos días tienen consistentemente más registros que otros, ¿es **casualidad (ruido)** o hay una causa sistemática (tendencia)?



Idea clave

Una **tendencia** es aquello que **rompe la equiprobabilidad** de forma **predecible** — no es que el dato sea "raro", es que sigue una **regla**.



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.