SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

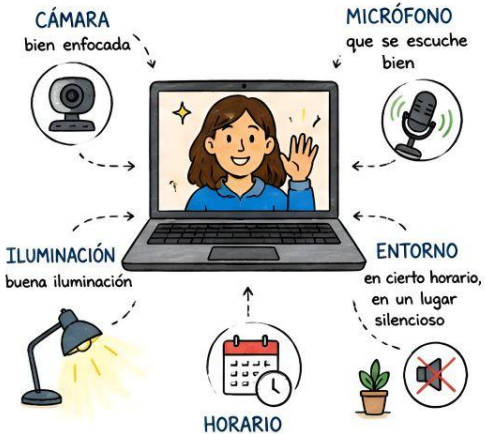
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



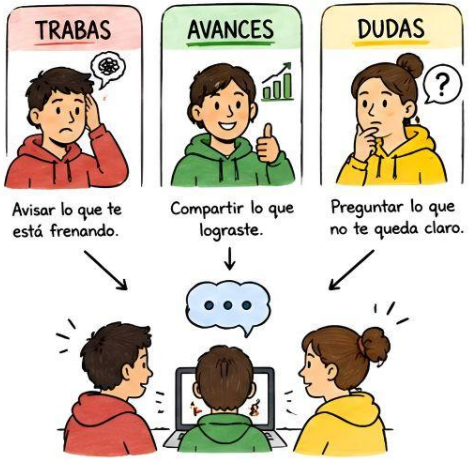
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



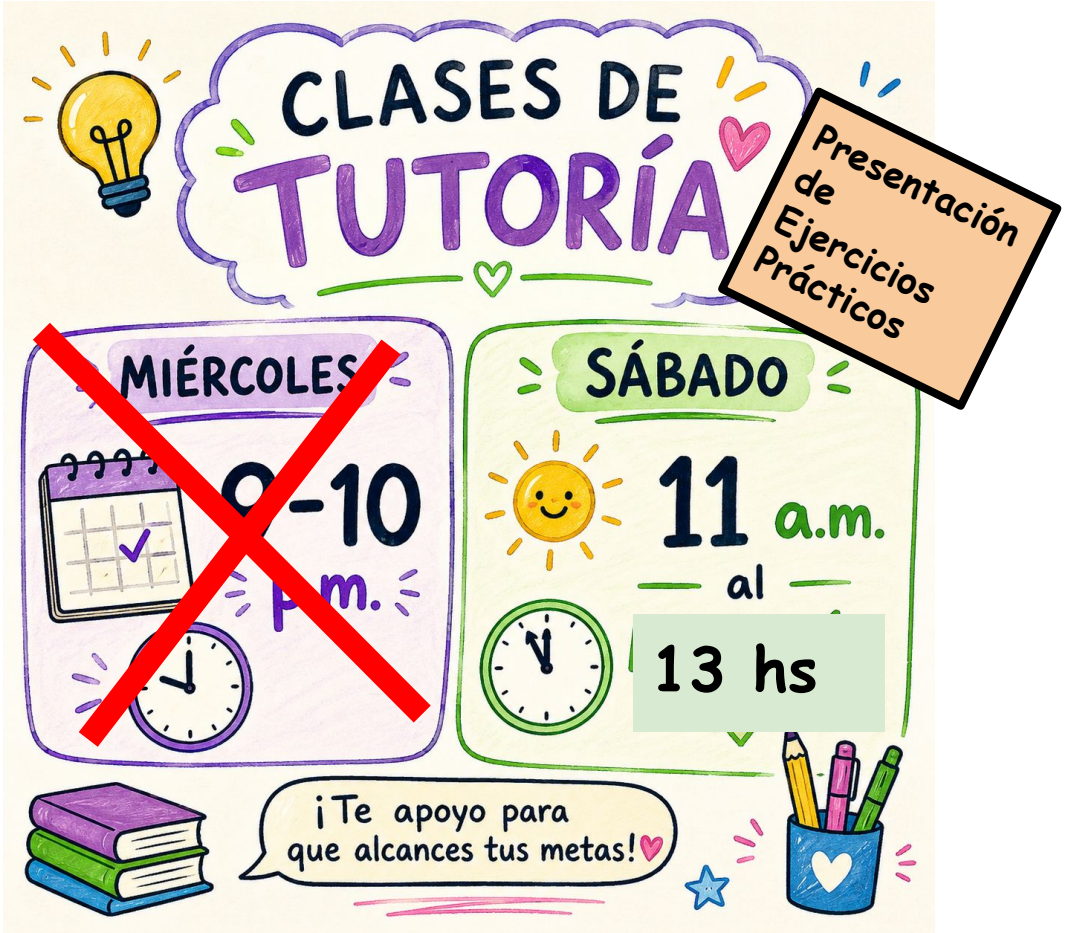
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS



[Inscripción a la reunión - Zoom]

Tres perfiles dentro de una solución de datos



Business Analyst

¿QUÉ necesitamos resolver?

- Problema
- Preguntas de negocio
- Reglas de negocio
- Diagrama de flujo
- ¿Qué datos necesitamos?
- Selección de variables

Transforma una necesidad de negocio en preguntas, reglas y requerimientos de datos.



Data Scientist

¿QUÉ dicen los datos?

- Datos
- ETL / preparación
- Pipeline
- EDA + Estadística
- Validación de features
- Modelo
- Evaluación

Construye pipelines, analiza estadísticamente los datos, comprueba que las variables sean adecuadas y desarrolla/evalúa modelos.



Solution Engineer

¿CÓMO lo llevamos a producción?

- Modelo + reglas + datos
- Make / n8n APIs / Apps
- Automatización
- Solución funcionando

Integra los componentes y convierte el análisis/modelo en una solución ejecutable, desde herramientas no-code/low-code hasta código completo.



Business Analyst → define el problema · **Data Scientist** → encuentra evidencia en los datos · **Solution Engineer** → convierte la solución en un sistema.

¿Qué es una tendencia?

Definición

Una **tendencia** es un patrón sistemático de **cambio** en los valores de una variable a lo largo del tiempo (o de otra dimensión ordenada), que no es puro azar.

Diferencia clave con "ruido aleatorio"

Ruido / azar	Tendencia
Variación impredecible, sin patrón (lo que asumimos en un modelo equiprobable).	Variación con dirección o forma reconocible (creciente, decreciente, cíclica).





Ejemplos con nuestros datos

Tendencia semanal

Si los incidentes registrados en CABA aumentan sistemáticamente los fines de semana → hay una **tendencia semanal**.



Tendencia estacional

Si aumentan en verano y bajan en invierno → hay una **tendencia estacional**.



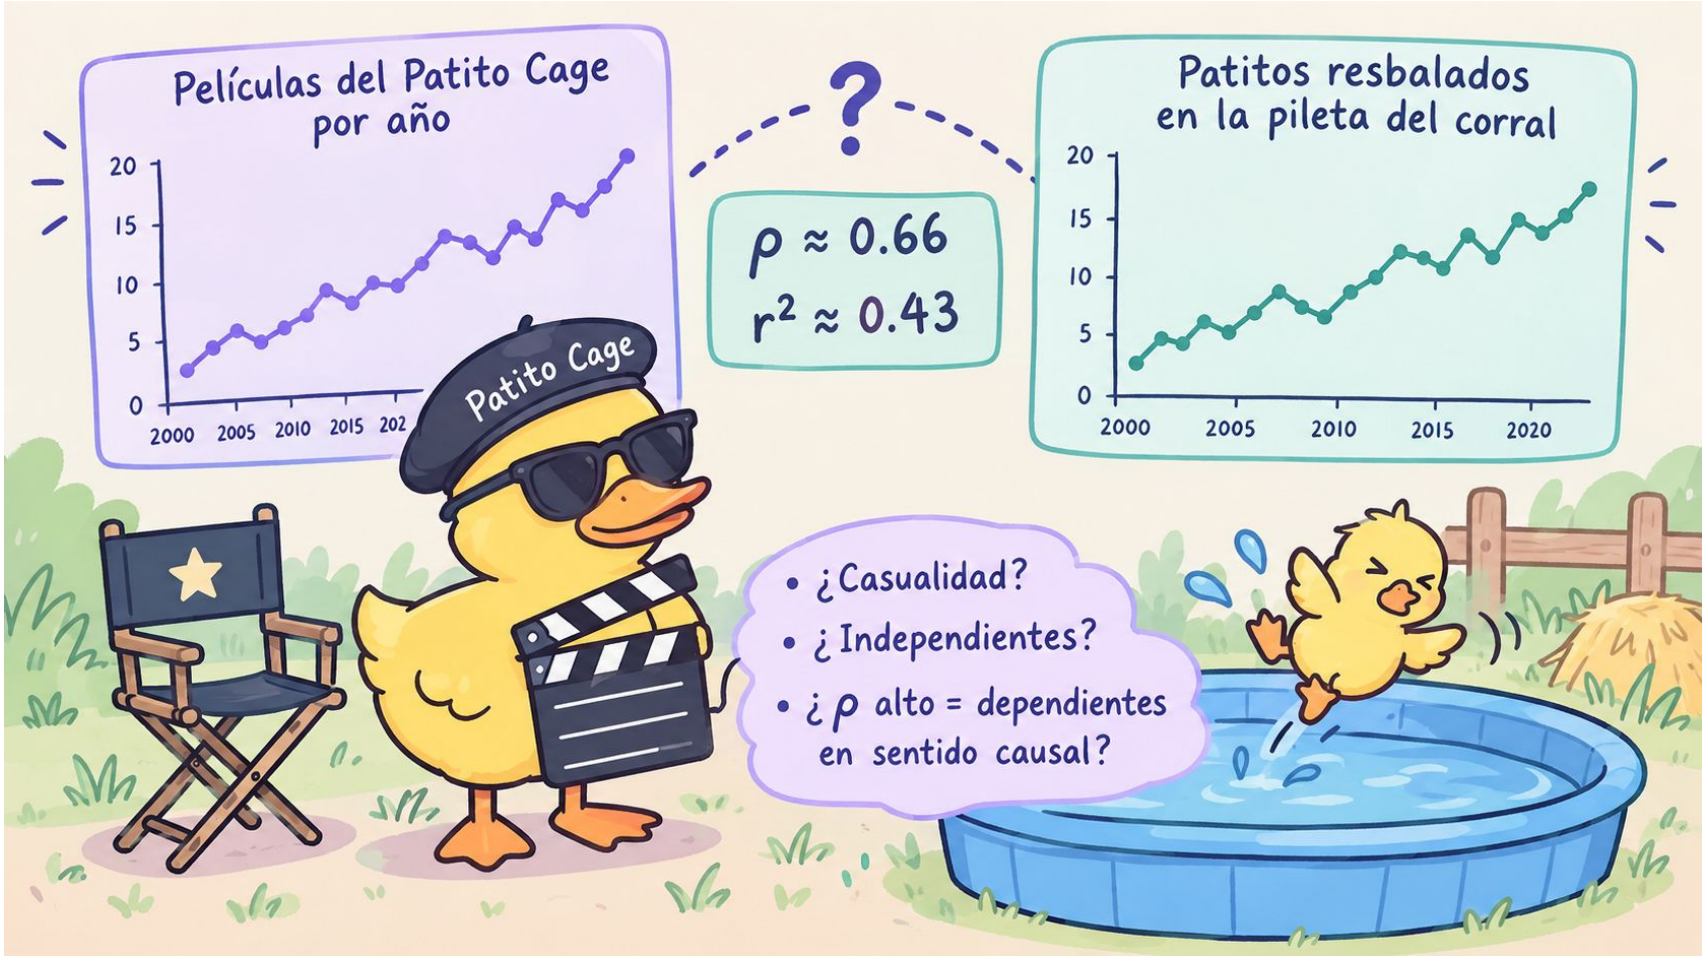
Pregunta pedagógica

Si veo que ciertos días tienen consistentemente más registros que otros, ¿es **casualidad (ruido)** o hay una causa sistemática (tendencia)?



Idea clave

Una **tendencia** es aquello que **rompe la equiprobabilidad** de forma **predecible** — no es que el dato sea "raro", es que sigue una **regla**.

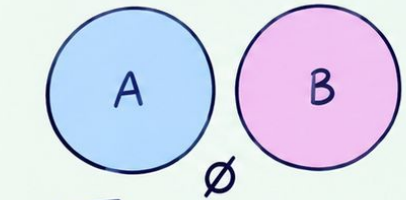

Películas del Patito Cage por año
20
15
10
5
0
2000
2005
2010
2015
202
?
ρ ≈ 0.66
r² ≈ 0.43
Patitos resbalados en la pileta del corral
20
15
10
5
0
2000
2005
2010
2015
2020
Patito Cage
• ¿Casualidad?
• ¿Independientes?
• ¿ρ alto = dependientes en sentido causal?

Repaso relámpago (Clase 26)

1 Excluyentes

$$A \cap B = \varnothing$$

$$\Rightarrow P(A \cup B) = P(A) + P(B)$$





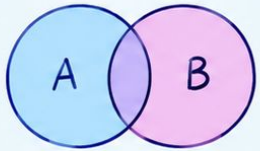
2 Independientes

$$P(A \cap B) = P(A) \cdot P(B)$$

$$\Longleftrightarrow$$

$$P(A \mid B) = P(A)$$

(la condicional no cambia)



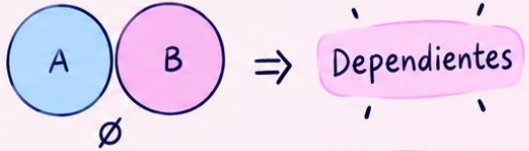
Pueden superponerse, pero no se afectan.



3 La trampa

Si $A \cap B = \varnothing$ y $P(A), P(B) > 0$, entonces $P(A \cap B) = 0 \neq P(A) \cdot P(B)$

$\Rightarrow$ Excluyentes $\Rightarrow$ Dependientes siempre (salvo caso degenerado).





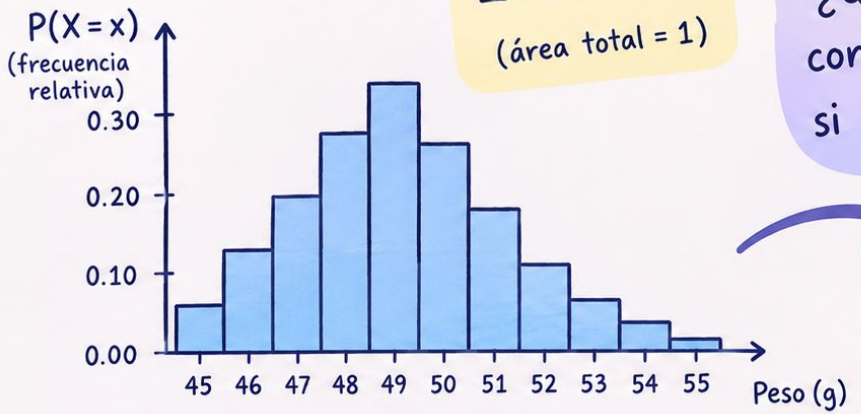
3. Del histograma a la densidad (camino A)

Peso de los patitos

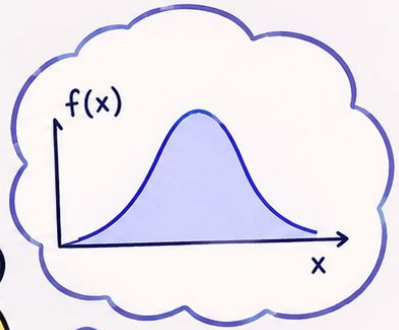
$\Delta x = 1$ g

$\sum P(x) \cdot \Delta x = 1$

(área total = 1)



¿Qué pasa con $P(X = x)$ si $\Delta x \to 0$?







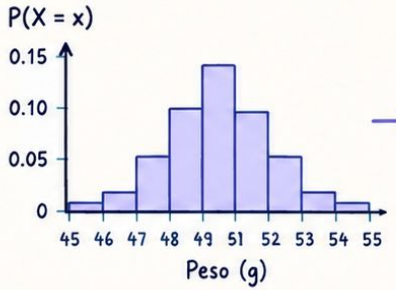
Afinando el redondeo
(rigor del límite)

Δx: 1g → 0.1g → 0.01g → dx

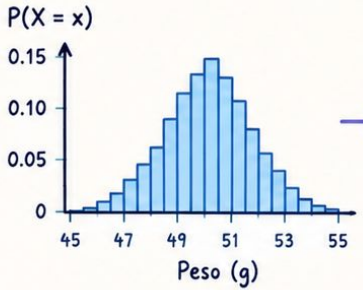
cada vez más fino



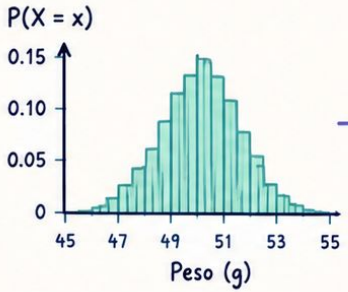
$\Delta x = 1g$



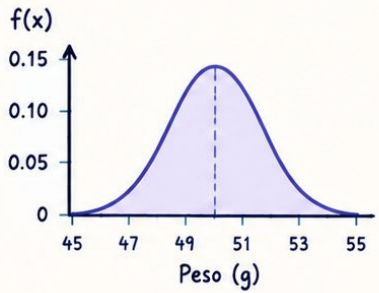
$\Delta x = 0.1g$



$\Delta x = 0.01g$



dx



Formalización del límite

$$\lim_{\Delta x \to 0} P(x \le X < x + \Delta x) = 0$$

La probabilidad de un intervalo cada vez más pequeño se hace cero.

$$\lim_{\Delta x \to 0} \frac{P(x \le X < x + \Delta x)}{\Delta x} = f(x)$$

Pero el cociente entre esa probabilidad y el ancho del intervalo converge a un valor finito, no a cero. Ahí nace la densidad.



Formalización de la densidad

1 $f(x) \geq 0$

- No es una probabilidad.
- Puede superar 1 (depende de la escala del eje X).



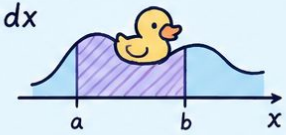
2 $\int_{-\infty}^{\infty} f(x)\,dx = 1$

- Normalización, equivalente continuo de $\sum P(x) = 1$.



3 $P(a \leq X \leq b) = \int_a^b f(x)\,dx$

→ Probabilidad entre dos valores.

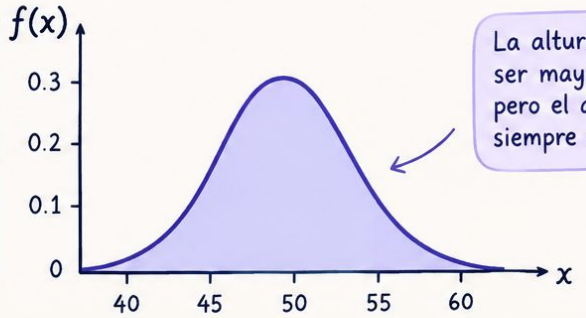


4 Consecuencia directa

$$P(X = x) = \int_x^x f(t)\,dt = 0$$

Por eso en continuo $P(X \leq x) = P(X < x)$.

Ejemplo visual: la densidad





Resumen

- $f(x) \geq 0$
- $\int_{-\infty}^{\infty} f(x)\,dx = 1$
- $P(a \leq X \leq b) = \int_a^b f(x)\,dx$
- $P(X = x) = 0$ (en continuo)

Camino B: proporción de patitos amarillos

Cada patito es un Bernoulli

$X_i \sim \text{Bernoulli}(p)$

i.i.d. (independientes e idénticos)



$X_i = 1$ (amarillo)

$X_i = 0$ (no amarillo)

$$Y = \sum_{i=1}^{n} X_i \sim \text{Binomial}(n, p)$$

(Clase 28)

Proporción muestral

$$\hat{p} = \frac{Y}{n}$$



Dominio de $\hat{p}$

$$\left\{0, \frac{1}{n}, \frac{2}{n}, \ldots, 1\right\}$$

$n + 1$ valores posibles

En resumen

$X_i \sim \text{Bernoulli}(p)$

↓

$Y \sim \text{Binomial}(n, p)$

↓

$$\hat{p} = \frac{Y}{n}$$



De proporción escalonada a proporción continua

1. La proporción muestral (discreta)

$X_i \sim \text{Bernoulli}(p)$, i.i.d. $\rightarrow$ $Y = \sum_{i=1}^{n} X_i \sim \text{Binomial}(n,p)$ (Clase 28)

$$\hat{p} = \frac{Y}{n}$$

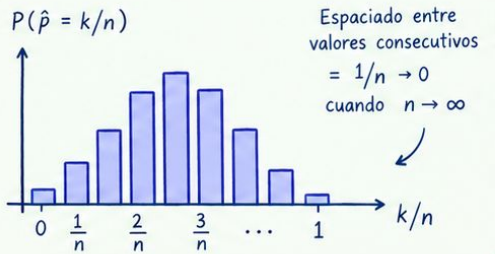
Dominio: $\left\{0, \frac{1}{n}, \frac{2}{n}, \ldots, 1\right\}$ ($n+1$ valores posibles)



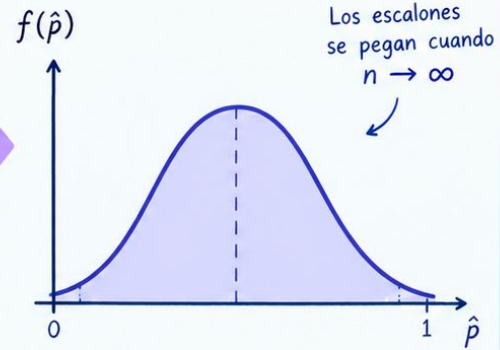
2. Proporción escalonada

$$P\left(\hat{p} = \frac{k}{n}\right) = C(n,k) \cdot p^k \cdot (1-p)^{n-k}$$

(Binomial reescalada por $1/n$)



3. Proporción continua (límite)



$$P\left(\hat{p} = \frac{k}{n}\right) = C(n,k) \cdot p^k \cdot (1-p)^{n-k}$$

$$E[\hat{p}] = \frac{E[Y]}{n} = \frac{np}{n} = p$$

$$\text{Var}(\hat{p}) = \frac{\text{Var}(Y)}{n^2} = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}$$



A medida que n crece, la distribución de $\hat{p}$ se aproxima a una distribución continua.

Población vs. Muestra: media, varianza y proporción

(Clase 29)



	Población	Muestra
Tamaño	N	n
Media	$\mu = \frac{1}{N}\sum_{i=1}^{N} X_i$	$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$
Varianza	$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(X_i-\mu)^2$	$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$
Desv. estándar	$\sigma = \sqrt{\sigma^2}$	$s = \sqrt{s^2}$
Proporción	p	$\hat{p} = \frac{Y}{n}$

¿Por qué (n−1) y no n?

$$E\left[\frac{\Sigma (x_i-\bar{x})^2}{n}\right] = \sigma^2 \cdot \frac{n-1}{n} < \sigma^2$$

El divisor n da un estimador sesgado hacia abajo ($\bar{x}$ minimiza esa suma para la muestra particular).

Dividir por $(n-1)$ corrige el sesgo: $E[s^2] = \sigma^2$.

La fila "Proporción" de esta tabla es exactamente lo que dedujiste en Slide 7.

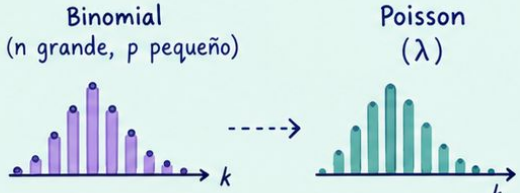
Los dos límites de la Binomial

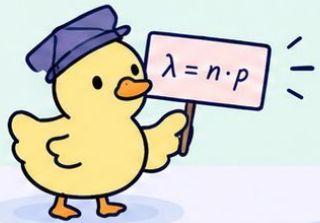
1. Binomial → Poisson

$n \to \infty, \quad p \to 0, \quad n \cdot p = \lambda$ (constante)

$\text{Binomial}(n, p) \to \text{Poisson}(\lambda)$

(Clase 28)



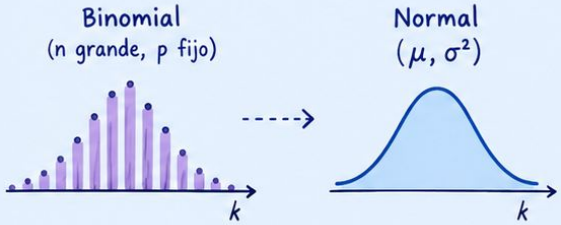


2. Binomial → Normal

$n \to \infty, \quad p$ fijo

$\text{Binomial}(n, p) \to \text{Normal}(\mu = np, \sigma^2 = np(1-p))$

(De Moivre-Laplace, caso particular del TLC)
(Clase 31)



Regla práctica

Usá la aproximación normal cuando:

$np \geq 5 \quad$ y $\quad n(1-p) \geq 5$



2.1 Distribución uniforme continua

Todos los valores del intervalo son igual de probables.



$X \sim U(a, b)$

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{para } x \in [a, b] \\ 0 & \text{fuera de } [a, b] \end{cases}$$

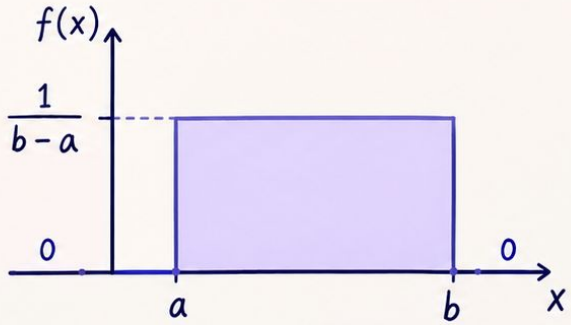
Media:

$$\mu = \frac{a+b}{2}$$

Varianza:

$$\sigma^2 = \frac{(b-a)^2}{12}$$

La forma de la densidad





Entonces...

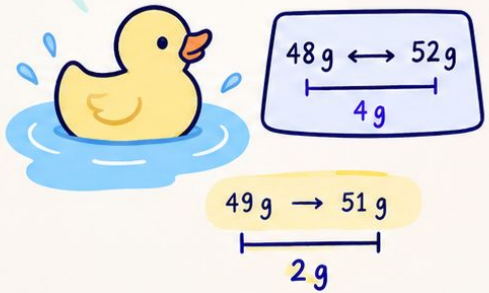
- $P(a \le X \le b) = (b-a) \cdot \frac{1}{b-a} = 1$
- $P(X = x) = 0$ (para todo x)

Ejemplo: patitos de juguete

Los patitos de juguete se fabrican con un peso dentro de una tolerancia pareja:

$a = 48\,g$ y $b = 52\,g$

$$P(49 \le X \le 51) = \frac{2}{4} = 0.5$$



A. Grados de libertad

¿Qué significa y de dónde salen?

gl = número de observaciones − número de parámetros estimados

Ejemplo con patitos



Pesamos n patitos y calculamos el promedio:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Los residuos son $x_i - \bar{x}$ y cumplen:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = 0$$

Si conozco $n-1$ residuos, el último queda forzado.

→ **Solo $n-1$ aportan información libre.**

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$

Ese $n-1$ son los grados de libertad.

Analogía mecánica



0 gl
Pata rígida
(no se adapta).



2 gl
Prótesis 2 engranajes
(2 formas de moverse).



3 gl
Prótesis 3 engranajes
(más posibilidades).



∞ gl
Pata biológica
(fluidez total).

- Menos gl = menos información y mayor incertidumbre.
- En la t, esto se traduce en colas más pesadas.

Independencia formal

15

X e Y independientes $\Leftrightarrow$

$$f(x,y) = f_X(x) \cdot f_Y(y)$$

para todo (x,y).

Consecuencia:

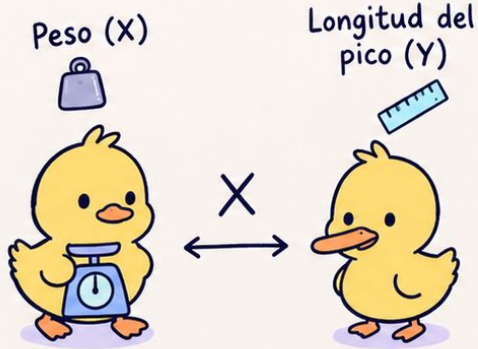
$$E[XY] = E[X] \cdot E[Y]$$

si son independientes
(no al revés necesariamente).

Mismo espíritu que

$$P(A \cap B) = P(A) \cdot P(B)$$

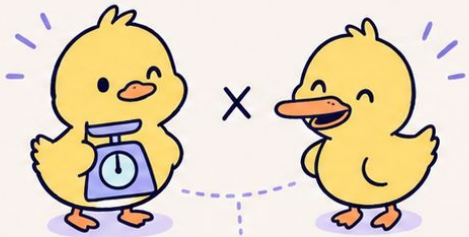
de eventos, trasladado
de eventos a densidades.



$f(x,y) = f_X(x) \cdot f_Y(y)$



$E[XY] = E[X] \cdot E[Y]$



(si son independientes)

Idea clave:

Independencia en continuo
= factorizar la densidad.

Y eso implica que la expectativa
del producto es el producto
de las expectativas.

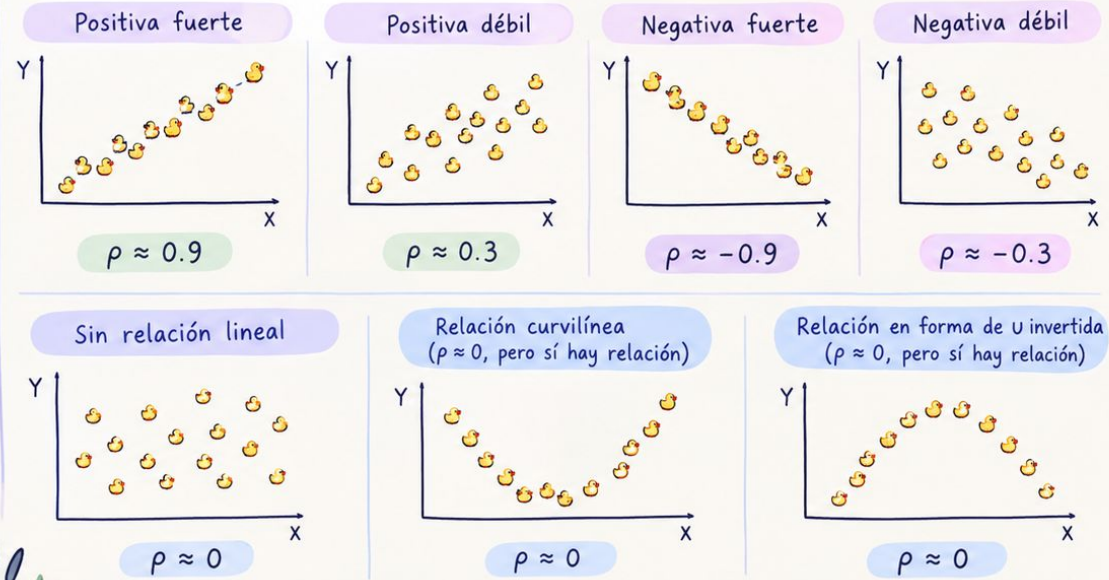
Covarianza y correlación

$$\mathrm{Cov}(X,Y) = E[(X-\mu_x)(Y-\mu_y)] = E[XY] - \mu_x\mu_y$$

$$\rho = \frac{\mathrm{Cov}(X,Y)}{\sigma_x \sigma_y} \qquad -1 \le \rho \le 1$$

(por Cauchy-Schwarz)

Ejemplos de patrones (y su correlación)

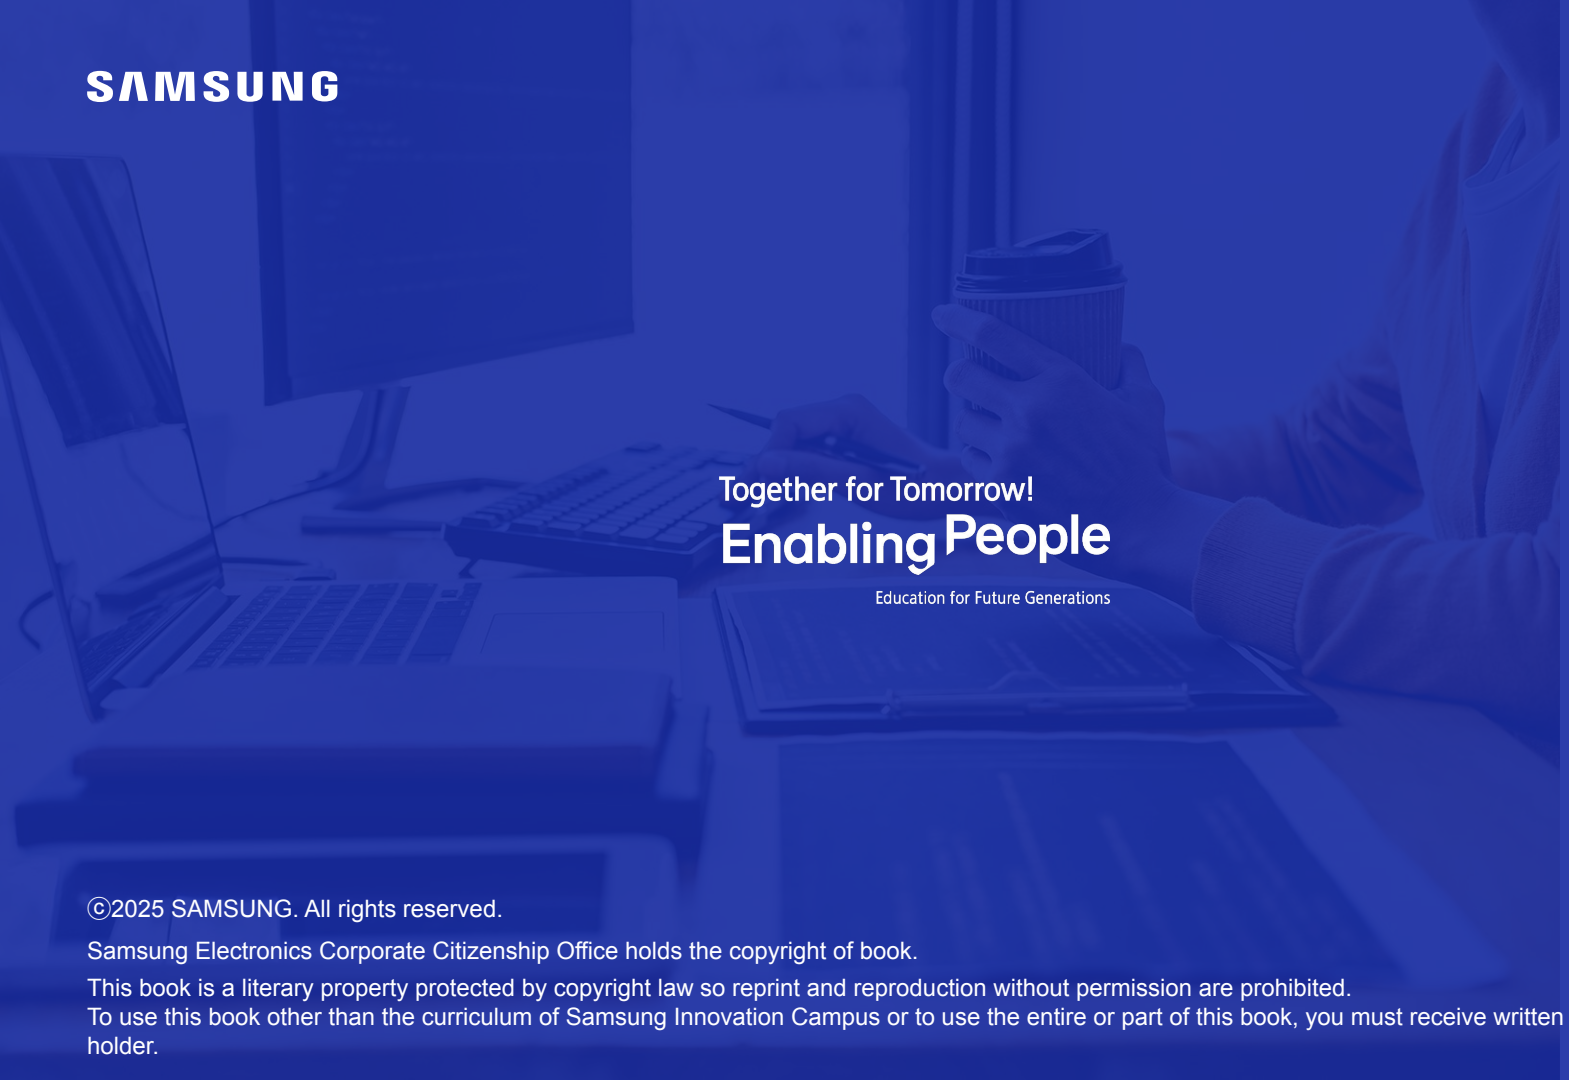


Ideas clave

- La correlación (ρ) mide una relación lineal.
- La independencia implica $\rho = 0$, pero $\rho = 0$ no implica independencia.
- La causalidad es otra cosa: requiere un modelo, no solo un coeficiente.




Películas del
Patito Cage por año
• más patitos
• más peliculas
• más piletas
• cada año
Patitos resbalados
en la pileta del corral
ρ ≈ 0.66
r² ≈ 0.43
Patito Cage
ρ alto no te dice por qué — te dice cuánto se mueven juntas.
El por qué (causalidad) necesita un modelo, no solo un coeficiente.



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.