SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

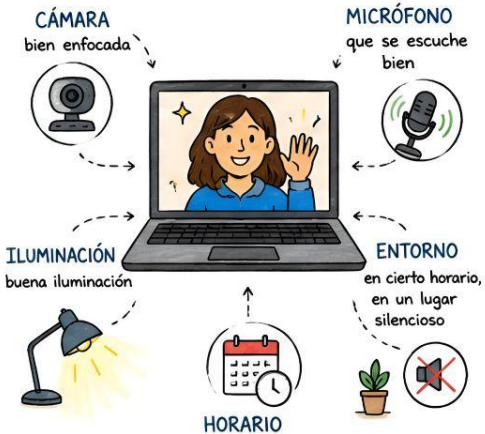
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



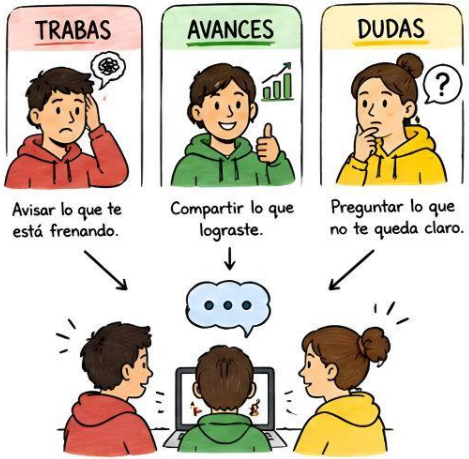
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



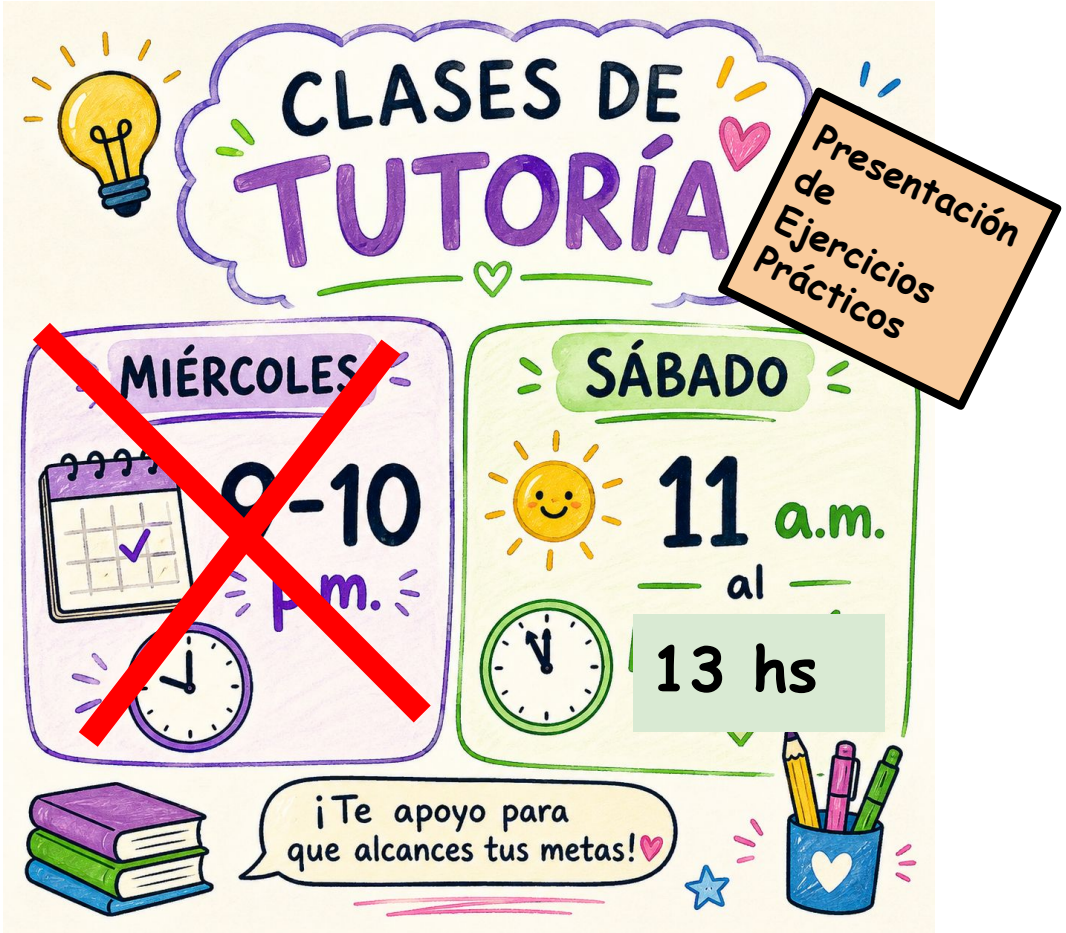
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS

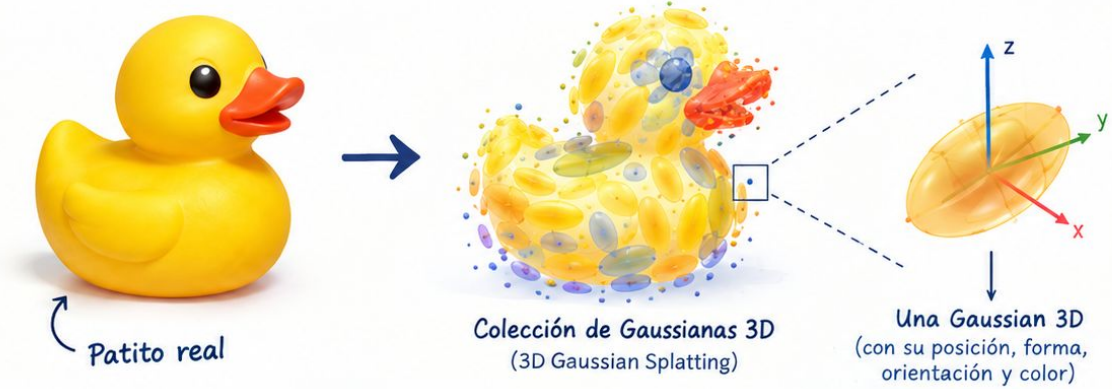


[Inscripción a la reunión - Zoom]

LÁMINA 1

El patito como nube de Gaussianas

De un patito real a una representación matemática



$$\mathcal{P} = \{(\mu_i, \Sigma_i, o_i, c_i)\}_{i=1}^{N}$$

Símbolo	Significado	En 3DGS
μ_i	posición	centro de la Gaussian
Σ_i	covarianza	forma y orientación
o_i	opacidad	contribución del splat
c_i	apariencia	color / SH

Parametrización de la covarianza

$$\Sigma_i = R_i S_i S_i^T R_i^T$$

o equivalentemente:

$$\Sigma_i = R_i \, \mathrm{diag}(s_i)^2 \, R_i^T$$

R_i: rotación | S_i: escala (o s_i: ejes de escala)

La Gaussian del paper

$$G_i(x) = \exp\left[-\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i)\right]$$

Importante:
$G_i(x)$ no es una PDF normalizada.
Su máximo es 1.

La contribución efectiva

$$\alpha_i(x) = o_i G_i(x)$$

Pregunta de la clase

¿Cómo pasamos de una colección de datos a una distribución, un estimador y finalmente una conclusión estadística?

3DGS: acá la Gaussian es el objeto matemático real del método.

LÁMINA 2 Variable discreta y PMF

¿Cuántos patitos hay?

1 Variable discreta

Una variable discreta toma valores aislados.

$$X \in \{x_1, x_2, \ldots\}$$

2 Función de masa de probabilidad (PMF)

La PMF asigna una probabilidad a cada valor:

$$p_X(x) = P(X = x)$$

$$p_X(x) \geq 0, \quad \sum_x p_X(x) = 1$$

3 Ejemplo: patitos amarillos

Contamos cuántos patitos de una caja son amarillos.

$$X = 0, 1, 2, \ldots, N$$



La PMF nos dice:

$$P(X = k)$$

es decir:

"¿Qué probabilidad hay de obtener exactamente k patitos amarillos?"

4 Momentos

Valor esperado

$$E[X] = \sum_x x p_X(x)$$

Varianza

$$Var(X) = E[X^2] - E[X]^2$$

5 Puente opcional con 3DGS

Podemos definir artificialmente:

$$I_i = 1\{\alpha_i(x) > \epsilon\}$$

y contar cuántas Gaussianas contribuyen a un píxel:

$$X = \sum_i I_i$$



Pero esto es un modelo probabilístico a que nosotros definimos, no una distribución que 3DGS asuma.

Patitos: el concepto principal.

En resumen

Variable discreta
Valores aislados.

PMF
Probabilidad por valor.

$E[X]$, $Var(X)$
Resumen de la distribución.

Puente con 3DGS
Relación conceptual, pero no es una distribución propia del método.

Patitos
El concepto principal de esta lámina.

LÁMINA 3 — Variable continua y PDF

Ahora el patito puede estar en cualquier posición

Una variable continua

puede tomar infinitos valores.
Por ejemplo:

X = altura de un patito

Su densidad es:

$$f_X(x) \geq 0$$

y:

$$\int_{-\infty}^{\infty} f_X(x)\,dx = 1$$

La probabilidad es un área:

$$P(a \leq X \leq b) = \int_a^b f_X(x)\,dx$$

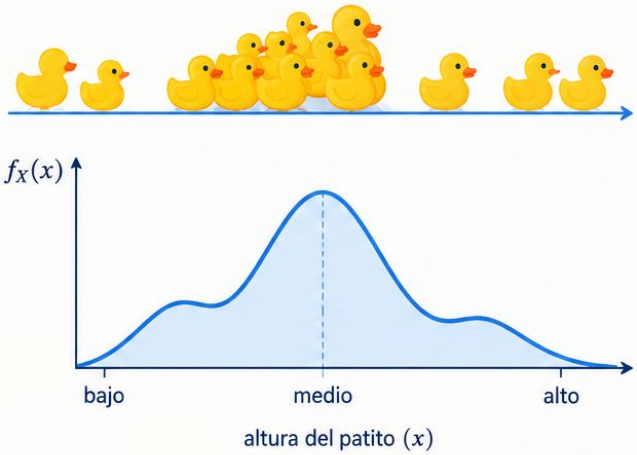
Y:

$$P(X = x) = 0$$

para una variable continua.

Visual

Una multitud de patitos distribuidos sobre una línea.
La densidad indica dónde están concentrados.



Conexión real con 3DGS

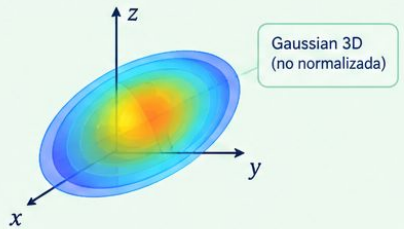
Una Gaussian normalizada en $\mathbb{R}^3$ sí puede interpretarse como una densidad:

$$f(x) = \frac{1}{(2\pi)^{3/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$$

Pero:

$$G(x) \neq f(x)$$

porque el kernel del paper no está normalizado.



Idea clave

En una variable continua, la probabilidad se mide con áreas bajo la curva, no con valores puntuales.

LÁMINA 4 — PMF, PDF y CDF

Tres maneras de describir una distribución

Misma idea:
una variable aleatoria
puede ser discreta o continua.



Misma familia, distintas formas!

Variable discreta

Toma valores aislados.

$$X \in \{x_1, x_2, \ldots\}$$

PMF (función de masa)

$$p_X(x) = P(X = x)$$

$$p_X(x) \geq 0 \qquad \sum_x p_X(x) = 1$$

Ejemplo: patitos amarillos

$$X = 0, 1, 2, \ldots, N$$

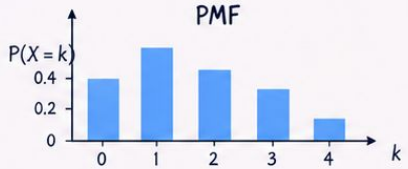
¿Qué probabilidad hay de obtener exactamente k patitos amarillos?

$$P(X = k)$$

$$E[X] = \sum_x x\, p_X(x)$$

$$\mathrm{Var}(X) = E[X^2] - E[X]^2$$





Variable continua

Puede tomar infinitos valores.

X = altura de un patito

PDF (función de densidad)

$$f_X(x) \geq 0$$

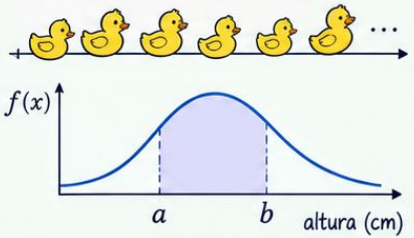
$$\int_{-\infty}^{\infty} f_X(x)\, dx = 1$$

$$P(a \leq X \leq b) = \int_a^b f_X(x)\, dx$$

$$P(X = x) = 0$$

(en una variable continua)

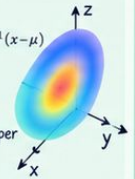
Visual: patitos en una línea



Conexión real con 3DGS

Una Gaussian normalizada en $\mathbb{R}^3$ puede interpretarse como una densidad:

$$f(x) = \frac{1}{(2\pi)^{3/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$$



Pero $G(x) \neq f(x)$, porque el kernel del paper no está normalizado.

CDF (función de distribución)

$$F_X(x) = P(X \leq x)$$

Para discreta:

$$F_X(x) = \sum_{t \leq x} p_X(t)$$

Para continua:

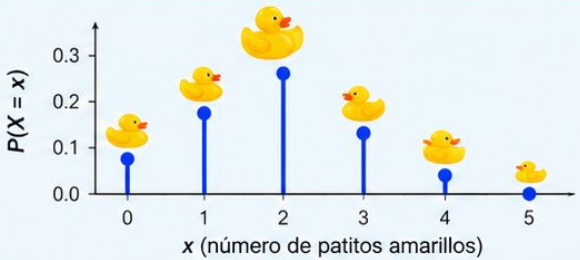
$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt$$

Si es derivable:

$$f_X(x) = F_X'(x)$$

	PMF (discreta)	PDF (continua)	CDF (ambas)
Qué representa	Probabilidad puntual	Densidad	Probabilidad acumulada
Fórmula	$p_X(x) = P(X = x)$	$f_X(x)$	$F_X(x) = P(X \leq x)$
Cómo se calcula la probabilidad	Suma de probabilidades	Área bajo la curva	Valor acumulado
Rango de la función	$0 \leq p(x) \leq 1$	$f(x) \geq 0$	$0 \leq F(x) \leq 1$
Normalización / límites	$\sum_x p(x) = 1$	$\int_{-\infty}^{\infty} f(x)\,dx = 1$	$F(-\infty) = 0, \quad F(\infty) = 1$

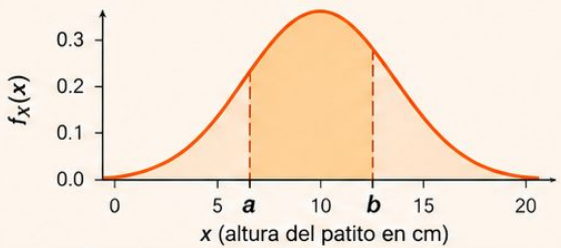
PMF — Variable discreta



La PMF da la probabilidad de cada **valor aislado**.

Ejemplo: *¿cuál es la probabilidad de obtener exactamente 2 patitos amarillos?*

PDF — Variable continua



La PDF indica **dónde están más concentrados los valores.** La probabilidad es el **área** bajo la curva.

Ejemplo: *¿cuál es la probabilidad de que la altura esté entre a y b?*

CDF — Probabilidad acumulada



La CDF da la **probabilidad acumulada.**

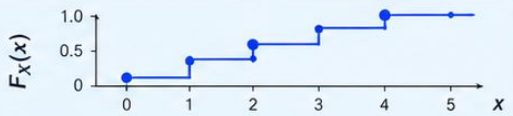
Ejemplo: *¿qué proporción de patitos mide como máximo 10 cm?*

$$F(10) = P(X \leq 10)$$

Relación entre PDF y CDF (variable continua)

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt \quad \Longleftrightarrow \quad f_X(x) = F_X'(x)$$

Versión discreta (CDF escalonada)



Para una variable discreta, la CDF es una función escalonada que acumula las probabilidades de la PMF.

SLIDE 5

Teorema Central del Límite (TCL)

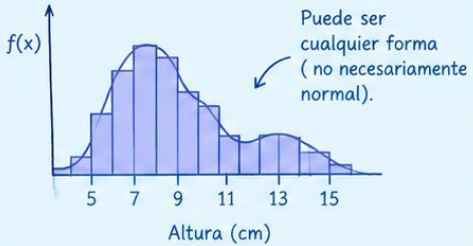
La distribución de la media muestral se vuelve (aprox.) normal, sin importar la forma original.

1 Población

Supongamos una población de patitos con una variable de interés, por ejemplo, la altura.



Distribución de la variable X (en la población)



2 Muestras

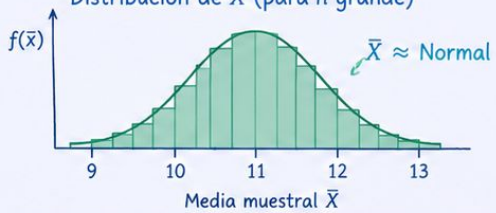
Tomamos muchas muestras de tamaño n y calculamos la media muestral $\bar{X}$.

Muestra 1	Muestra 2	Muestra 3
n = 5	n = 5	n = 5
$\bar{X}_1 = 10.8$	$\bar{X}_2 = 11.3$	$\bar{X}_3 = 10.6$

• • •

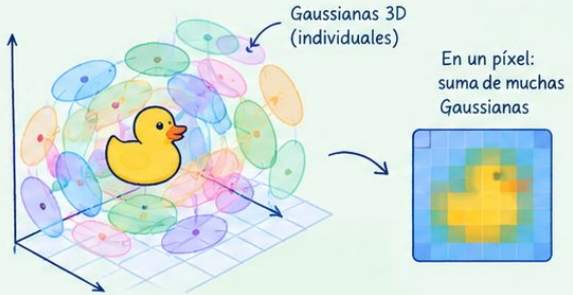
Si repetimos esto muchas veces, la distribución de las medias muestrales se aproxima a una normal.

Distribución de $\bar{X}$ (para n grande)



3 Conexión con 3D Gaussian Splatting

En 3DGS, cada píxel es la suma de muchas Gaussianas 3D. Por el TCL, la contribución total tiende a ser aproximadamente normal.



Idea clave

La media (o la suma) de muchas contribuciones independientes, aunque no sean normales, se distribuye aproximadamente como una Normal.

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

En resumen: el TCL nos permite usar la normal como aproximación, y en 3DGS esto se conecta con la suma de Gaussianas por píxel.

LÁMINA 6

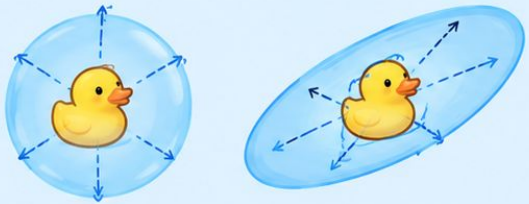
Covarianza: forma y orientación de la Gaussian

3DGS (conexión real)

La covarianza indica cómo se distribuyen las "masas" de la Gaussian en el espacio.

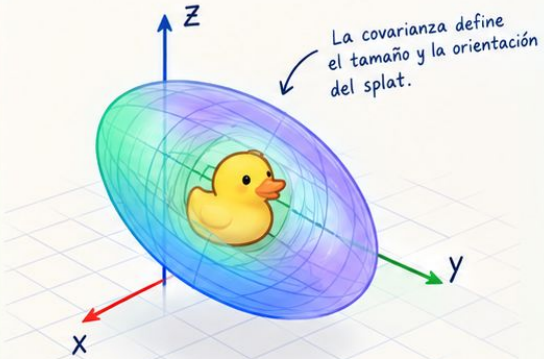
¿Qué significa la covarianza?

En 3DGS, cada Gaussian tiene una matriz de covarianza Σ que define su forma, tamaño y orientación.



Varianzas iguales (esférica) — Varianzas diferentes (elipsoidal)

Una Gaussian 3D = una elipsoide



Parametrización de la covarianza

$$\Sigma_i = R_i S_i S_i^T R_i^T$$

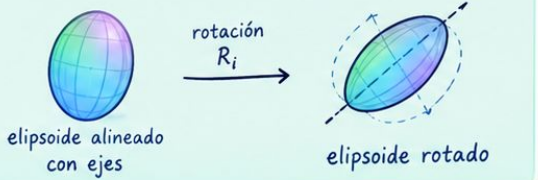
o equivalentemente

$$\Sigma_i = R_i \, \mathrm{diag}(s_i)^2 \, R_i^T$$

R_i : rotación (orientación)

S_i : escala (tamaños en cada eje)

s_i : $[s_x, s_y, s_z]$



La función de la Gaussian (kernel)

$$G_i(x) = \exp\left[-\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)\right]$$

Importante: $G_i(x)$ no es una PDF normalizada. Su máximo es 1.

La contribución efectiva en la imagen se expresa como:

$$\alpha_i(x) = o_i \, G_i(x)$$

o_i : opacidad (contribución del splat)

En resumen

- μ_i → posición (centro)
- Σ_i → forma y orientación
- o_i → opacidad
- c_i → color / SH

$$\left\{ P = \left\{ (\mu_i, \Sigma_i, o_i, c_i) \right\}_{i=1}^{N} \right.$$

colección de Gaussianas 3D

Puente

La covarianza también aparece en la estadística (matriz de covarianza de una muestra), pero en 3DGS tiene un rol concreto en la representación y el rendering.



La forma del splat no es casual, ¡es la covarianza!

LÁMINA 7

Población, muestra y estimador

De muchos patitos a un número que resume

Conceptos clave para inferir

1 Población

Todos los patitos que nos interesan.



Conjunto completo de elementos

Parámetro (desconocido)

μ verdadero promedo de altura de los patitos de la población

2 Muestra

Seleccionamos algunos patitos al azar.



Subconjunto de la población

Tamaño de muestra: n

3 Estimador

Calculamos un número a partir de la muestra para estimar el parámetro.

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

$\bar{X}$ = estimador del promedio de altura

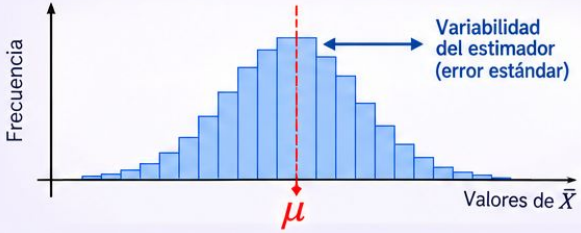
X_i = altura del patito i en la muestra

Estimador

- Es una variable aleatoria (depende de la muestra).
- Busca aproximar el parámetro μ.
- Cambia de una muestra a otra.

Distribución muestral del estimador

Si repetimos el muestreo muchas veces, obtenemos muchos valores de $\bar{X}$.



- La distribución muestral de $\bar{X}$ está centrada en μ.
- Tiene variabilidad (error estándar).
- Al aumentar n, se vuelve más concentrada.

Ejemplo con números

Altura de patitos (en cm)

Muestra (n = 5)	4.8	5.1	4.9	5.2	5.0

$$\bar{X} = \frac{4.8 + 5.1 + 4.9 + 5.2 + 5.0}{5} = 5.0 \text{ cm}$$



Este valor **(5.0 cm)** es una estimación del verdadero promedio μ de la población de patitos.

LÁMINA 8 — Tres límites que NO debemos confundir

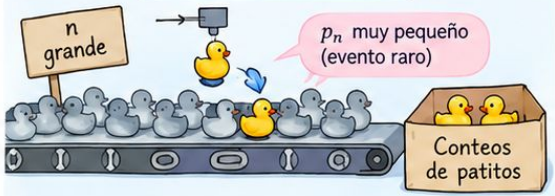
Diferentes situaciones, diferentes objetivos y diferentes conclusiones.

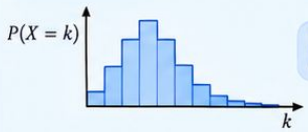
Los tres resultados involucran límites y distribuciones, pero no están diciendo lo mismo.

1. Binomial → Poisson

Muchos ensayos, evento muy raro, el número esperado de éxitos se mantiene.

$$X_n \sim \text{Bin}(n, p_n)$$
$$n \to \infty, \quad p_n \to 0, \quad np_n \to \lambda$$
$$X_n \xrightarrow{d} \text{Poisson}(\lambda)$$





Distribución de Poisson (discreta)

$$E[X] = np_n \to \lambda$$

Discreta → discreta

2. Binomial → Normal

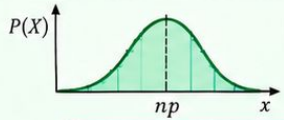
Muchos ensayos, probabilidad fija de éxito. La Binomial se aproxima por una Normal.

$$X_n \sim \text{Bin}(n, p) \quad (p \text{ fijo})$$
$$E[X_n] = np \qquad \text{Var}(X_n) = np(1-p)$$
$$Z_n = \frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0,1)$$

Por lo tanto, para n grande:

$$X_n \approx N\left(np, np(1-p)\right)$$





Normal de aproximación (continua)

Media: np
Varianza: $np(1-p)$

Discreta → aproximación continua

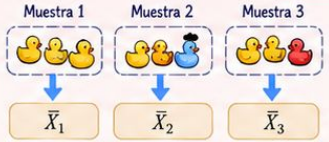
3. Teorema Central del Límite (TCL)

Muchas observaciones de una distribución cualquiera (con varianza finita). La media muestral se aproxima a una Normal.

$$X_1, \cdots, X_n \ \ iid \quad \text{con} \quad E[X_i] = \mu, \ \ \text{Var}(X_i) = \sigma^2 < \infty$$
$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \qquad \frac{\sqrt{n}\,(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0,1)$$

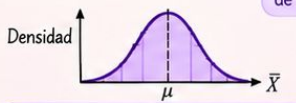
Por lo tanto, para n grande:

$$\bar{X}_n \approx N\left(\mu, \ \frac{\sigma^2}{n}\right)$$



La población original no necesita ser Normal.

Distribución muestral de la media (aprox. Normal)



Media: μ
Varianza: $\frac{\sigma^2}{n}$

Media muestral → aproximación Normal

Resumen de diferencias

Resultado	Condiciones	Qué se aproxima	Distrib. original → límite	Variable de interés
Binomial → Poisson	$n \to \infty, p \to 0, np \to \lambda$	X_n	discreta → discreta	conteos raros
Binomial → Normal	n grande, p fijo	X_n (estandarizada)	discreta → continua	conteos grandes
TCL	X_i iid, Var finita	$\bar{X}_n$ (estandarizada)	cualquiera → Normal	promedios

Corrección por continuidad

Al aproximar una Binomial (discreta) con una Normal (continua):

$$P(X \le k) \approx \Phi\left(\frac{k + 0.5 - np}{\sqrt{np(1-p)}}\right)$$

El +0.5 es la corrección por continuidad para ajustar el hecho de que X es discreta.

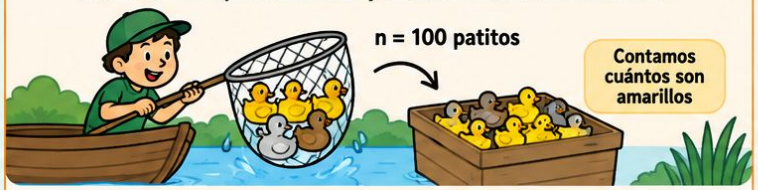
Regla práctica
(no es condición del teorema):

- $np \ge 5$
- $n(1-p) \ge 5$



Ejemplo 1: Binomial → Normal (conteo grande)

Pescás n = 100 patitos al azar y contás cuántos son amarillos.



$X \sim \text{Bin}(100, 0{,}3)$ — X = número total de patitos amarillos en la muestra.

Chequeo de la regla práctica:

$np = 100 \times 0{,}3 = 30 \geq 5$ ✓

$n(1-p) = 100 \times 0{,}7 = 70 \geq 5$ ✓

Aproximación Normal:

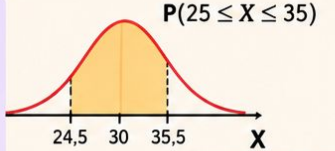
$\bar{X} \approx N(30,\ 21)$

(media = np, varianza = np(1 − p))

Pregunta típica:

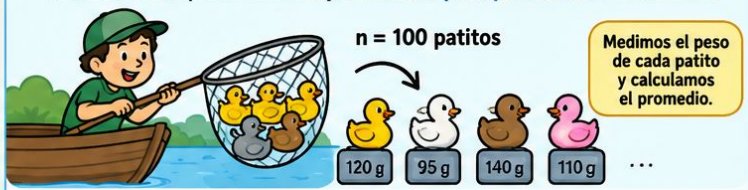
"¿Cuál es la probabilidad de pescar entre 25 y 35 patitos amarillos?"

Usás la Normal sobre X (con corrección por continuidad, $\pm 0{,}5$).



Ejemplo 2: TCL (promedio)

Pescás n = 100 patitos al azar y calculás el peso promedio de la muestra.



$$\bar{X} = \frac{1}{100} \sum_{i=1}^{100} X_i$$

$\bar{X}$ = peso promedio de la muestra. Cada X_i es el peso de un patito individual (variable continua, con forma de distribución cualquiera).

Teorema Central del Límite (TCL):

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

sin importar qué forma tenía la distribución del peso en la población (original) — solo necesita que X_i tenga varianza finita.

La distribución del peso en la población puede ser **cualquiera (no normal):**



Pero el **promedio muestral** $\bar{X}$ **se aproxima por una Normal:**



La diferencia en una frase con patitos:

Binomial→Normal: pescás patitos (¿amarillo sí/no?), contás el total de amarillos y se normaliza el conteo X (la suma).

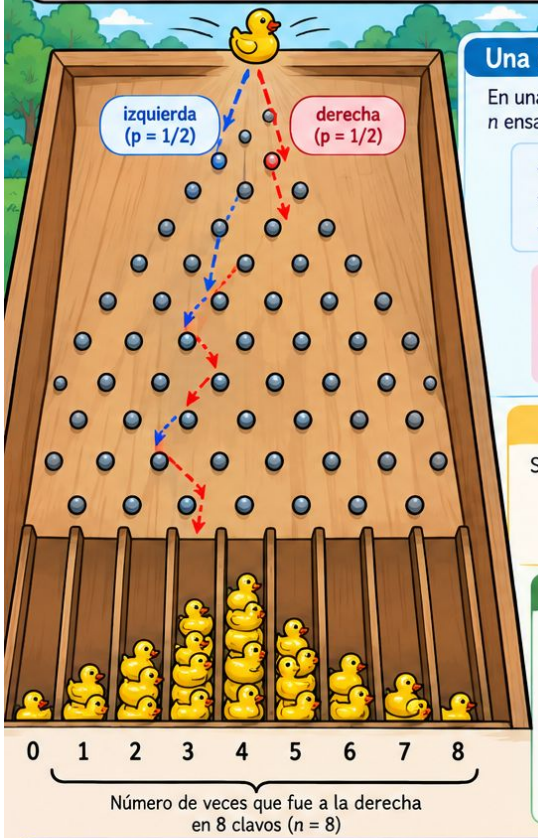
TCL: pescás patitos (peso, altura, etc.), calculás el promedio de esa medida y se normaliza el promedio $\bar{X}$ (la media).

El puente entre ambos: si en el TCL usás $X_i = 1$ (amarillo) o 0 (no amarillo) y en lugar de promediar sumás, el TCL aplicado a esa suma es exactamente Binomial→Normal. Por eso la lámina dice que es "un caso particular del TCL".

Ejemplo 2: Tabla de Galton

Cada bolita que cae pasa por varios clavos y en cada clavo toma una decisión: izquierda o derecha, con probabilidad 1/2 en cada una.

Después de muchos clavos, la distribución de bolitas en las columnas se parece a una Normal.



Una bolita = una Binomial

En una tabla con n clavos, cada bolita realiza n ensayos de Bernoulli:

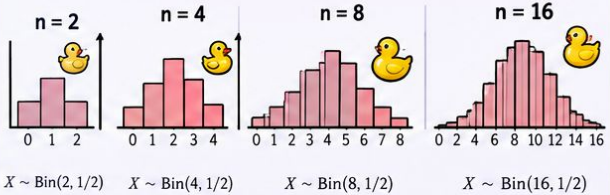
- **Éxito:** ir a la derecha ($X_i = 1$)
- **Fracaso:** ir a la izquierda ($X_i = 0$)
- **Probabilidad:** $p = 1/2$

$$X \sim \text{Bin}(n, 1/2)$$

X = número de veces que la bolita fue a la derecha (entre 0 y n).

Varias binomiales: cómo cambia la forma

A medida que aumentan los clavos (n), la distribución del número de veces que se va a la derecha se va pareciendo a una Normal.



$X \sim \text{Bin}(2, 1/2)$ $X \sim \text{Bin}(4, 1/2)$ $X \sim \text{Bin}(8, 1/2)$ $X \sim \text{Bin}(16, 1/2)$

Aproximación Normal para n grande

Si n es grande, la Binomial se aproxima por una Normal:

$$X \approx N\left(np,\ np(1-p)\right)$$

En la tabla de Galton: $p = 1/2$ ➡

$$X \approx N\left(\frac{n}{2}, \frac{n}{4}\right)$$

Ejemplo concreto: n = 16 clavos

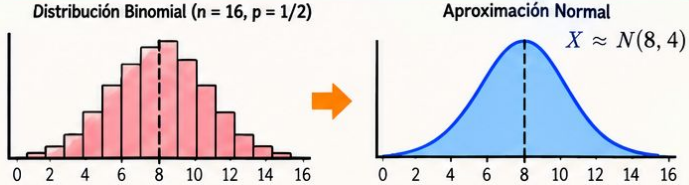
Una bolita pasa por 16 clavos.

$$X \sim \text{Bin}(16, 1/2)$$

$$\mu = np = 8$$

$$\sigma^2 = np(1-p) = 4$$

$$\sigma = 2$$



Idea clave: cada bolita tiene su propia Binomial, y al mirar muchas bolitas vemos la forma completa. Cuando n es grande, esa forma se parece a una Normal.

LÁMINA 9 Estimadores: de la muestra a la población

Usamos una muestra para estimar parámetros desconocidos de la población.

Patitos: concepto estadistico general de estimación.

Población (todos los patitos)



Parámetro desconocido:
μ = altura promedio de todos los patitos

Muestreo

Muestra (algunos patitos)



Datos observados:
$x_1, x_2, \ldots, x_n$
(alturas de los patitos de la muestra)

Estimación

Estimador

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

$\bar{X}$ es un estimador de μ (el promedio poblacional).

En 3D Gaussian Splatting



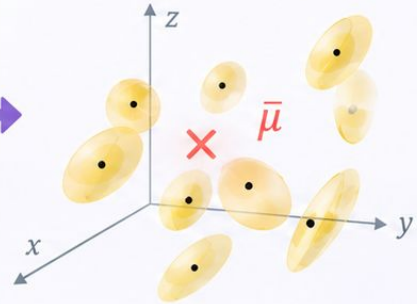
El patito se representa mediante una colección de Gaussianas 3D con parámetros $(\mu_i, \Sigma_i, o_i, c_i)$.

Muestra de Gaussianas



Seleccionamos un subconjunto de gaussianas de la escena.

Estimador del centro promedio



$$\bar{\mu} = \frac{1}{m}\sum_{i=1}^{m} \mu_i$$

Estimador del centro promedio de las gaussianas en la muestra seleccionada.

Idea clave: **un estimador** es una variable aleatoria (función de la muestra) que usamos para aproximar un parámetro desconocido de la población. En 3DGS, podemos estimar propiedades globales (como el centro promedio) a partir de una muestra de gaussianas.

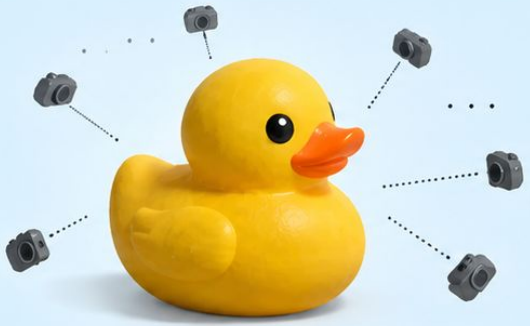
LÁMINA 10 — Inferencia estadística

De la muestra a la población (con Gaussian Splatting)

3DGS + Patitos
Estimamos parámetros de la escena a partir de una muestra de datos.

1 Población (escena real)

Parámetros verdaderos (desconocidos)



$$\Theta = (\mu, \Sigma, o, c, \ldots)$$

Parámetros reales de las Gaussianas de la escena (desconocidos)

2 Muestra (datos observados)

Imágenes desde varias cámaras



Reconstrucción 3DGS



Estimación de parámetros

$$\hat{\Theta} = (\hat{\mu}, \hat{\Sigma}, \hat{o}, \hat{c}, \ldots)$$

Parámetros estimados a partir de la muestra

3 Inferencia

Cuantificamos la incertidumbre

$$\hat{\Theta} \sim \mathcal{N}\left(\Theta, \mathrm{Var}(\hat{\Theta})\right)$$

El estimador varía de muestra en muestra.

Intervalo de confianza (ejemplo: posición)

$$\hat{\mu}_x \pm z_{\alpha/2}\,\mathrm{SE}(\hat{\mu}_x)$$



(verdadero, desconocido)

4 Interpretación con el patito



Estimación puntual
Un único valor estimado para la posición, forma, etc.



Intervalo de confianza
Rango de valores plausibles para el parámetro real.



Variabilidad muestral
Si tomamos otras imágenes, obtendríamos estimaciones diferentes.

LÁMINA 11 — Error estándar

¿Qué tan variable es un estimador?

El error estándar mide la variabilidad del estimador si repitiéramos el muestreo muchas veces.

1 Idea intuitiva

Si tomamos muchas muestras de patitos de la misma población, cada muestra produce un valor diferente de $\bar{X}$.



2 Definición

El error estándar de la media es la desviación estándar de la distribución muestral de $\bar{X}$:

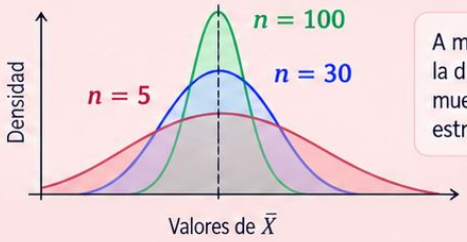
$$\mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

donde:

- σ: desviación estándar poblacional (desconocida en la práctica).
- n: tamaño de la muestra.

3 Interpretación

- Total: variabilidad de las medias muestrales.
- A mayor n, menor error estándar.
- Describe la precisión del estimador, no la variabilidad de los datosr individuales.

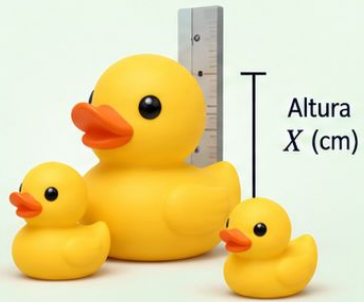


A mayor n, la distribución muestral es más estrecha.

4 Ejemplo con patitos

Suponemos que la altura de los patitos tiene $\sigma = 2$ cm.

Si $n = 5$:	$\mathrm{SE}(\bar{X}) = \frac{2}{\sqrt{5}} = 0.89$ cm
Si $n = 30$:	$\mathrm{SE}(\bar{X}) = \frac{2}{\sqrt{30}} = 0.37$ cm
Si $n = 100$:	$\mathrm{SE}(\bar{X}) = \frac{2}{\sqrt{100}} = 0.20$ cm



5 Conexión con 3D Gaussian Splatting

Puente

Si estimamos la posición media de un conjunto de Gaussianas 3D, el error estándar de ese estimador es:

$$\mathrm{SE}(\bar{\mu}) = \frac{\sigma_\mu}{\sqrt{n}}$$

- n: número de Gaussianas usadas en el estimador.
- σ_μ: variabilidad de las posiciones.
- A mayor n, mayor precisión en la posición media de la escena.

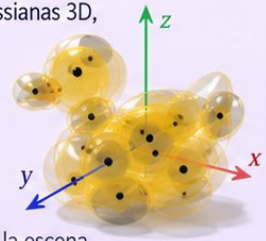


LÁMINA 12

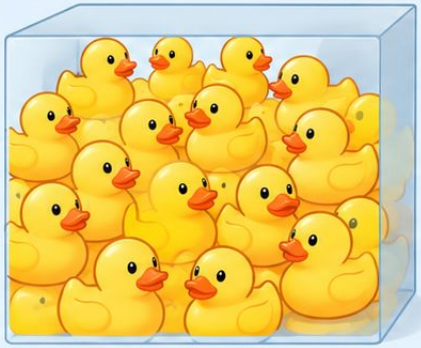
Distribución muestral de la media

Si repetimos muchas veces la extracción de muestras, obtenemos una distribución de medias.

3DGS: conexión real
Puente conceptual
Patitos: estadística general

Población

Todos los patitos de la caja

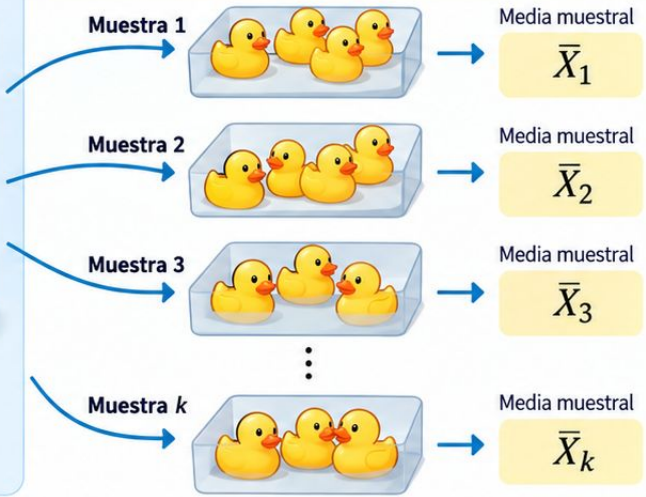


Media poblacional μ

Varianza poblacional σ^2

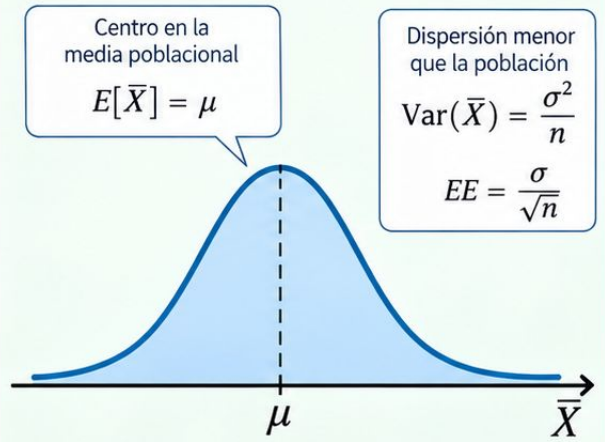
Muestras repetidas

Extraemos muchas muestras de tamaño n



Distribución muestral de $\bar{X}$

Las medias muestrales $\bar{X}_1, \bar{X}_2, \ldots$ forman una distribución.



Idea clave

Si tomamos muchas muestras aleatorias de la población y calculamos su media, esas medias varían, pero siguen una distribución con media μ y varianza σ^2 / n.

Resultado

$$\bar{X} \sim \text{(aprox.)}\ \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

(exacta si la población es normal)

Interpretación

La media muestral es un buen estimador de μ y su variabilidad disminuye al aumentar el tamaño de muestra n.

LÁMINA 13 — Distribución muestral de la media

1 Población de patitos

Todos los patitos de la fábrica tienen una altura con media μ y desviación σ.

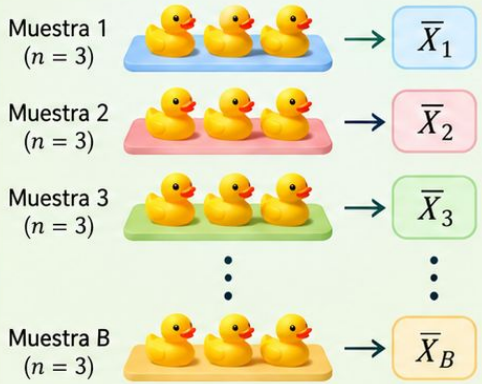


$$X \sim (\mu, \sigma^2)$$

Altura de un patito

2 Muestras de tamaño n

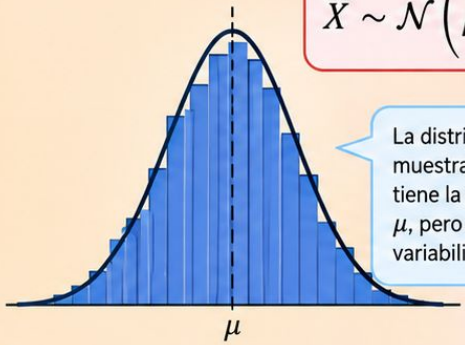
Tomamos muchas muestras aleatorias de n patitos.



3 Distribución muestral de $\bar{X}$

Si repetimos el muestreo muchas veces, obtenemos muchos valores de $\bar{X}$.

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

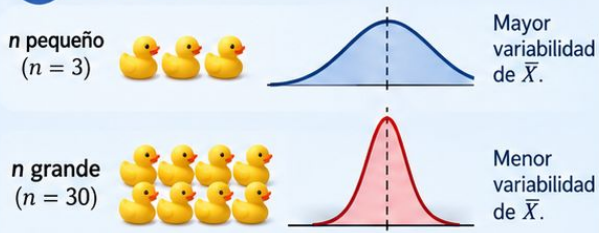


La distribución muestral de la media tiene la misma media μ, pero menor variabilidad: $\bar{\sigma}/\sqrt{n}$.

4 Propiedades

1. $E[\bar{X}] = \mu$ — La media muestral es un estimador insesgado.
2. $\mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}$ — La variabilidad disminuye al aumentar n.
3. $\mathrm{EE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$ — El error estándar mide la dispersión de $\bar{X}$.

5 Intuición



6 Conexión con 3DGS (opcional)

Si la altura (u otra propiedad) de los patitos representa algún parámetro de las Gaussianas en 3DGS (por ejemplo, escala s_i u opacidad o_i), la distribución muestral de la media describe cómo varía el promedio estimado de ese parámetro al muestrear un subconjunto de Gaussianas.



4 Propiedades

Si las muestras son aleatorias e independientes:

1. La media de la distribución muestral es la media de la población:

$$E[\bar{X}] = \mu$$

2. La desviación estándar de la distribución muestral (error estándar) es:

$$SD(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

5 Intuición

Cuanto mayor es n, menor es la dispersión de las medias muestrales.

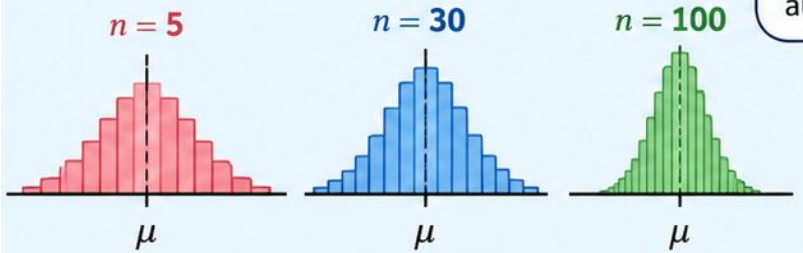




LÁMINA 14 — Test de hipótesis

¿Es una diferencia significativa o solo ruido?

1 Idea general

Queremos decidir si los datos son consistentes con una hipótesis nula o si hay evidencia a favor de una alternativa.



$$H_0: \ \mu = \mu_0 \quad \text{(no hay diferencia)}$$

$$H_1: \ \mu \neq \mu_0 \quad \text{(hay diferencia)}$$

2 Estadístico de test

Para la media (varianza conocida):

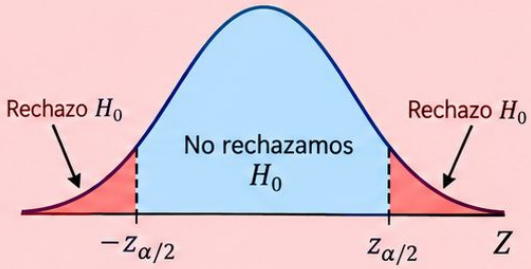
$$Z = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}}$$

Bajo H_0, el estadístico sigue una distribución conocida (por ejemplo, $Z \sim N(0,1)$).



3 Región de rechazo

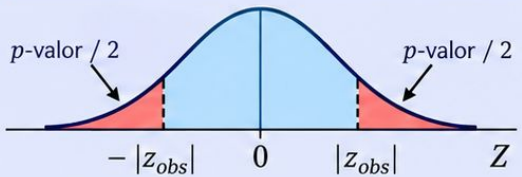
Para un test bilateral con nivel de significancia α :



4 p-valor

El p-valor es la probabilidad, asumiendo H_0, de observar un resultado tan extremo o más que el obtenido.

$$p\text{-valor} = P(|Z| \geq |z_{obs}| \,|\, H_0)$$



5 Decisión

Si p-valor $\leq \alpha$

→ **Rechazamos H_0**

Hay evidencia significativa a favor de H_1.



Si p-valor $> \alpha$

→ **No rechazamos H_0**

No hay evidencia suficiente para concluir que hay diferencia.



6 Ejemplo visual

¿La altura media de los patitos es diferente de 5 cm?

$$H_0: \ \mu = 5 \text{ cm}$$

$$H_1: \ \mu \neq 5 \text{ cm}$$



Muestra

$\overline{X} = 5.8$ cm

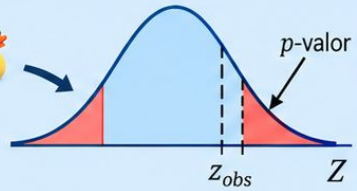


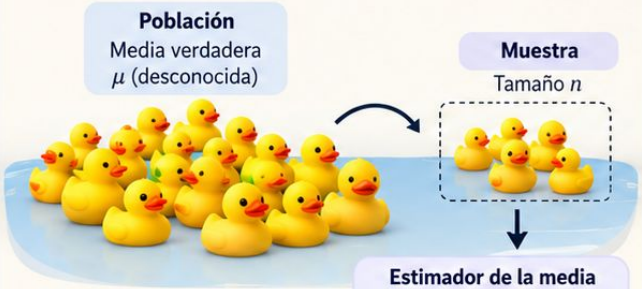
LÁMINA 15 — Error estándar y cuantificación de la incertidumbre

¿Qué tan precisa es nuestra estimación?

Patitos en la estadística de estimadores

1. De la muestra al estimador

Tomamos una muestra de patitos y calculamos el promedio de sus alturas.



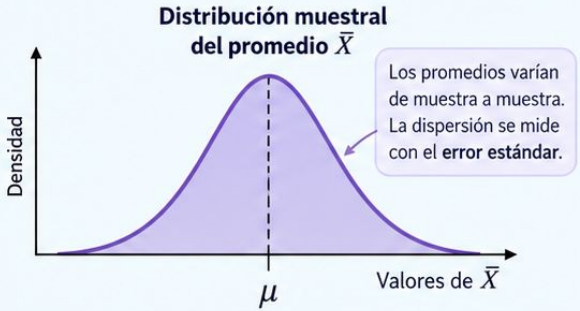
Estimador de la media

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

(altura promedio de la muestra)

2. Variabilidad muestral

Si repetimos el muestreo muchas veces, obtenemos diferentes promedios.



3. Error estándar

El error estándar mide la variabilidad del estimador $\bar{X}$ entre distintas muestras.

Error estándar de la media:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

σ: Desviación estándar de la población

n: Tamaño de la muestra

4. ¿Qué significa?

Un error estándar más pequeño indica una estimación más precisa.



Muestra pequeña $n = 4$

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{4}}$$

Mayor variabilidad en los promedios



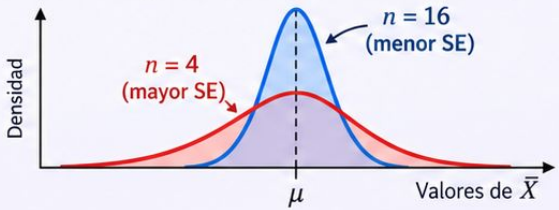
Muestra grande $n = 16$

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{16}}$$

Menor variabilidad en los promedios

5. Visualización intuitiva

Con muestras pequeñas los promedios están más dispersos.
Con muestras grandes se concentran alrededor de μ.



Al aumentar el tamaño muestral, el error estándar disminuye y nuestras estimaciones son más confiables.

LÁMINA 16 | Intervalos de confianza

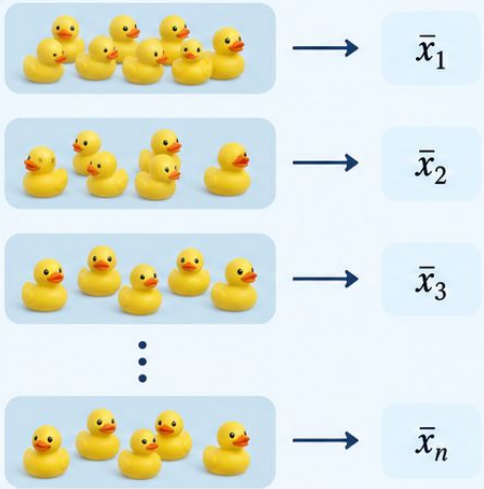
Un rango de valores plausibles para un parámetro



No conocemos el parámetro real, pero podemos estimarlo con un intervalo de confianza.

1 La idea

Repetir el experimento muchas veces

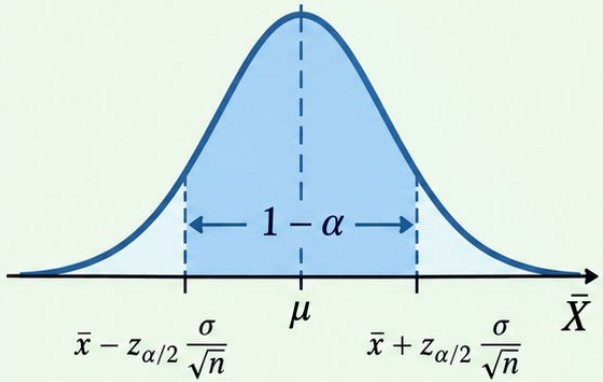


Cada muestra produce un estimador distinto. Si repetimos muchas veces, obtenemos una **distribución muestral.**

2 Distribución del estimador

El estimador tiene variabilidad

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

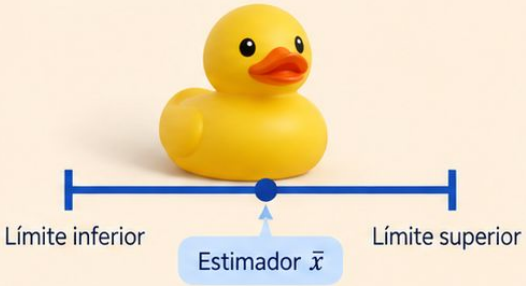


La distribución de $\bar{X}$ nos permite construir un rango de valores que, con alta probabilidad, contiene el parámetro real.

3 Intervalo de confianza

Fórmula e interpretación

$$IC(1-\alpha): \quad \bar{x} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$



Interpretación: Si repitiéramos el muestreo muchas veces, el $100(1-\alpha)\%$ de los intervalos construidos contendrían el parámetro real μ.

LÁMINA 17

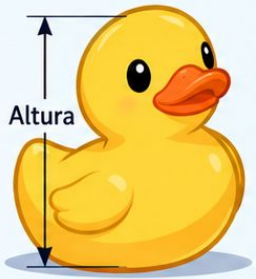
Intervalo de confianza para la media

Un rango de valores plausibles para el promedio verdadero

Patitos: concepto estadístico general

1 Tenemos una muestra

Medimos la altura de algumos patitos de una caja.



Muestra (n = 10)

5.1	5.3	5.2	5.0	5.4
5.1	5.2	5.3	5.1	5.2

(cm)

Media muestral

$$\bar{x} = 5.19 \text{ cm}$$

Error estándar

$$SE = \frac{s}{\sqrt{n}} = 0.10 \text{ cm}$$

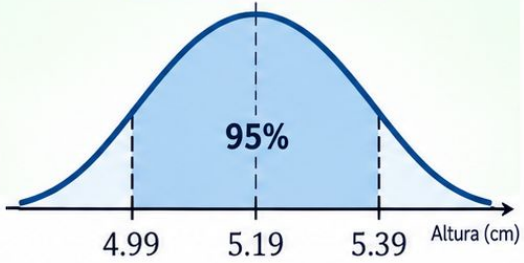
2 Construimos el intervalo

Para un nivel de confianza del **95%**:

$$\bar{x} \pm z_{0.975} \cdot SE$$
$$= 5.19 \pm 1.96 \cdot 0.10$$

$$\downarrow$$

$$(4.99,\ 5.39) \text{ cm}$$

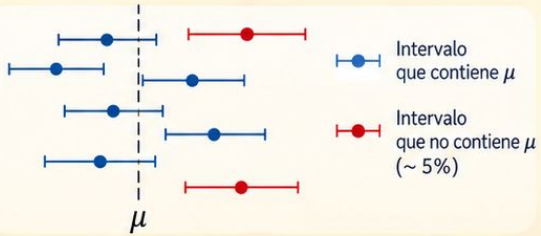


3 Interpretación

Estamos 95% confiados de que la media verdadera μ de la altura de los patitos está en este intervalo.

4 Repetimos el muestreo

Si tomamos muchas muestras, cada una genera un intervalo. Aproximadamente el 95% de ellos contendrá la media verdadera.



Idea clave



Un intervalo de confianza no dice que la media verdadera tiene 95% de probabilidad de estar en este intervalo (μ es fija), sino que el **procedimiento** tiene **95% de éxito** en repetidas muestras.

LÁMINA 18 — Intervalos de confianza

Un rango creíble para un parámetro desconocido

¿Qué es un intervalo de confianza?

Un intervalo de confianza (IC) es un rango de valores calculado a partir de una muestra, que con un cierto nivel de confianza (por ejemplo, 95%) se espera que contenga el verdadero valor del parámetro de la población.



Fórmula (media, σ conocida)

Para la media poblacional μ, con nivel de confianza $1-\alpha$, el intervalo es:

$$\mathrm{IC} = \left[\overline{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

donde:

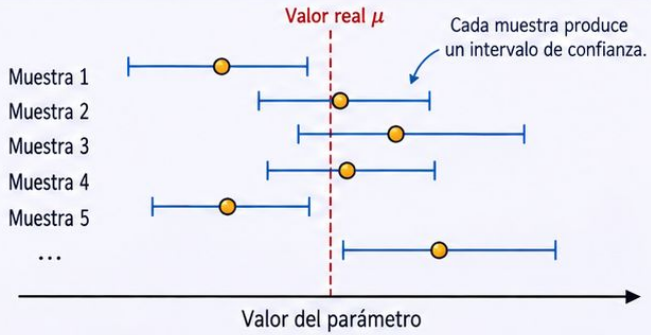
- $\overline{X}$ es la media muestral,
- σ es la desviación estándar poblacional,
- n es el tamaño de la muestra,
- $z_{\alpha/2}$ es el valor crítico de la normal estándar.

Interpretación frecuentista

Si repitiéramos el muestreo muchas veces y construyéramos un intervalo cada vez, el $(1-\alpha)\cdot 100\%$ de esos intervalos contendrían el verdadero valor del parámetro.

No significa que el parámetro tenga una probabilidad del 95% de estar dentro del intervalo (en el enfoque frecuentista).

Visualización



Conexión con 3D Gaussian Splatting

Podemos construir un IC para algún parámetro de las Gaussianas 3D, por ejemplo la posición de su centro μ_i, estimado a partir de múltiples reconstrucciones o muestras de datos.



LÁMINA 19 — Intervalos de confianza

Un rango de valores plausibles para el parámetro

1 Idea principal

Un intervalo de confianza (IC) es un rango de valores plausibles para un parámetro poblacional.



2 Fórmula general

Para la **media** (σ conocida o n grande):

$$IC_{1-\alpha} = \bar{x} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

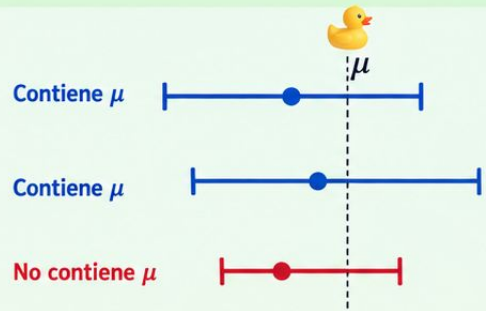
Si σ es **desconocida** (n pequeño):

$$IC_{1-\alpha} = \bar{x} \pm t_{n-1,1-\alpha/2} \frac{s}{\sqrt{n}}$$

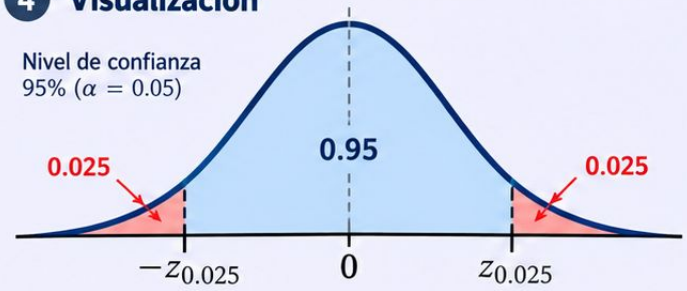
- $\bar{x}$: media muestral
- σ : desviación estándar poblacional
- s : desviación estándar muestral
- n : tamaño de muestra
- z, t : valor crítico según la distribución

3 Interpretación (frecuentista)

Si repitiéramos el muestreo muchas veces, el $100(1-\alpha)\%$ de los intervalos construidos contendría el verdadero valor del parámetro μ.

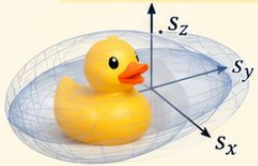


4 Visualización



5 Ejemplo con 3D Gaussian Splatting (puente)

Queremos estimar el tamaño medio (escala) s de las Gaussianas 3D a partir de una muestra de N splats y construir un IC del 95%.



Cada splat tiene una escala $s = (s_x, s_y, s_z)$

A partir de la muestra obtenemos $\bar{s}$ y construimos:

$$IC_{0.95} = \bar{s} \pm t_{n-1,0.025} \frac{s}{\sqrt{n}}$$

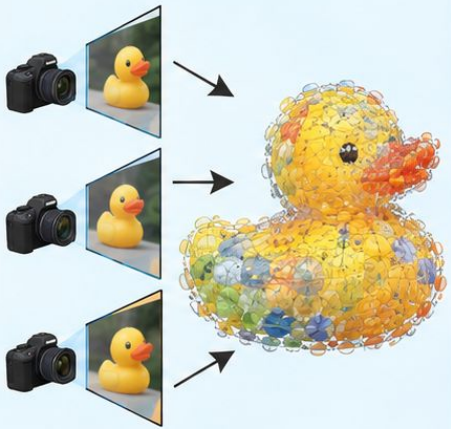
Interpretación: estamos 95% confiados de que el tamaño medio real de las Gaussianas de la escena está dentro de este rango.

LÁMINA 20 — Inferencia estadística en 3D Gaussian Splatting

De una muestra de cámaras a conclusiones sobre los parámetros de las Gaussiaaas

1 Muestra de datos

Observamos el patito desde varias cámaras y obtenemos imágenes.

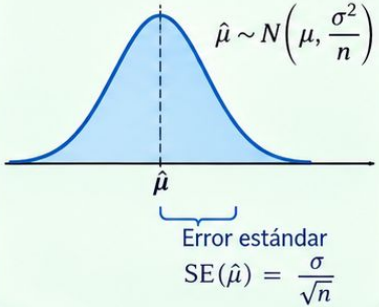


2 Distribución muestral de un estimador

A partir de la muestra, estimamos un parámetro (por ejemplo, la posición μ de una Gaussiana).

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

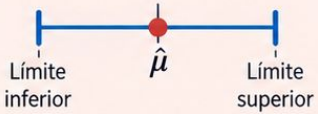
Si repetimos el proceso con otras muestras, $\hat{\mu}$ varía y sigue una distribución (aprox. normal).



3 Intervalo de confianza

Con un nivel de confianza $1-\alpha$, construimos un intervalo para el parámetro verdadero μ.

$$\hat{\mu} \pm z_{\alpha/2}\, SE(\hat{\mu})$$

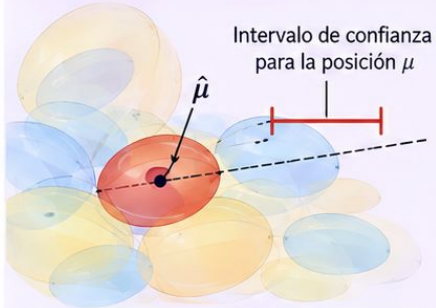


Interpretación:

Si repitiéramos el experimento muchas veces, el $(1-\alpha)100\%$ de los intervalos construidos contendría el valor verdadero μ.

4 Interpretación en 3DGS

El intervalo de confianza nos da un rango plausible para un parámetro de una Gaussiana del patito.



Aplicaciones:

- Cuantificar la incertidumbre en la posición, forma u opacidad de una Gaussiana.
- Comparar reconstrucciones con distinto número de vistas.
- Evaluar la fiabilidad de los parámetros estimados en nuevas escenas.

Idea clave

La inferencia estadística nos permite pasar de una muestra finita de observaciones (imágenes) a conclusiones cuantitativas sobre los parámetros de la escena representada con 3D Gaussian Splatting.

LÁMINA 21 — Cierre: de los datos a la inferencia en 3DGS

1 Datos: del mundo real a una nube de puntos

A partir de muchas imágenes de un patito real, obtenemos puntos 3D con color.

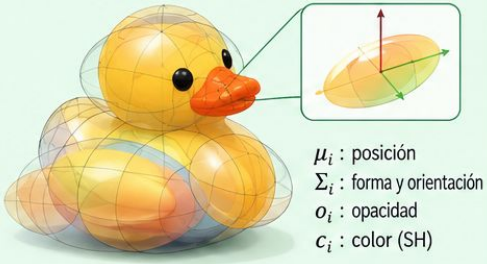


Nube de puntos 3D con color

2 Modelo: colección de Gaussianas 3D

Representamos el patito mediante una colección de Gaussianas 3D:

$$\mathcal{P} = \{(\mu_i, \Sigma_i, o_i, c_i)\}_{i=1}^{N}$$



μ_i : posición
Σ_i : forma y orientación
o_i : opacidad
c_i : color (SH)

3 Parámetros: estimación desde datos

Los parámetros de cada Gaussiana se estiman optimizando la discrepancia entre imágenes reales y renderizadas.

$$\mathcal{L}(\mathcal{P}) = \frac{1}{n}\sum_{j=1}^{n} \left\| I_j^{\text{real}} - I_j^{\text{render}}(\mathcal{P}) \right\|^2$$

Datos (imágenes) → **Optimización (gradiente)** → **Parámetros** $\{\mu_i, \Sigma_i, o_i, c_i\}$

4 Incertidumbre y variabilidad

Los datos de entrada tienen ruido y variabilidad, lo que se refleja en la estimación de los parámetros.



Imágenes ruidosas y con variabilidad

Diferentes reconstrucciones (misma escena, distintos datos)

5 Inferencia estadística

Usamos herramientas de probabilidad y estadística para cuantificar la incertidumbre en los parámetros y evaluar resultados.

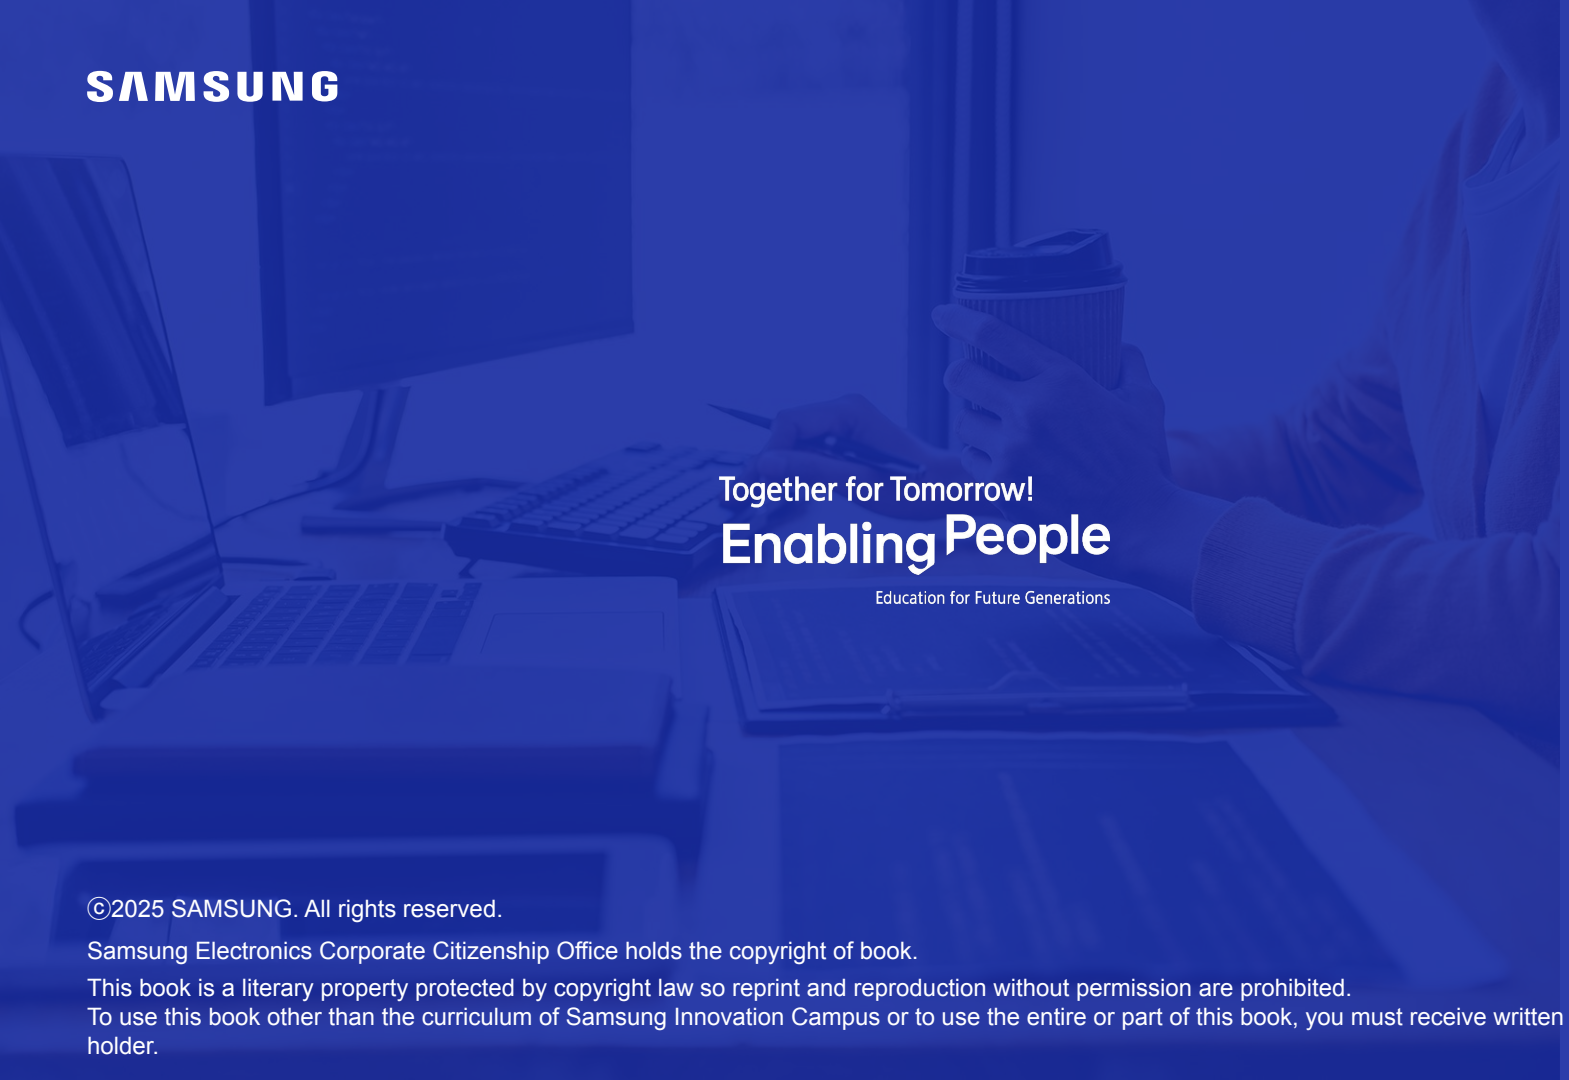
- Distribución muestral de los estimadores
- Error estándar
- Intervalos de confianza
- Tests de hipótesis
- ANOVA (comparar métodos o configuraciones)
- χ^2 para bondad de ajuste

6 Conclusión

De un problema del mundo real, pasamos a un modelo probabilístico con Gaussianas, estimamos parámetros desde datos y usamos inferencia estadística para cuantificar la incertidumbre y tomar conclusiones.



- Modelo matemático (3DGS)
- Parámetros estimados desde datos
- Incertidumbre cuantificada
- Conclusiones estadísticas sobre la reconstrucción



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.