SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

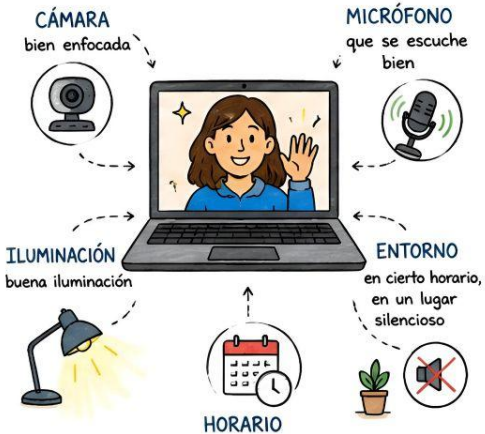
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



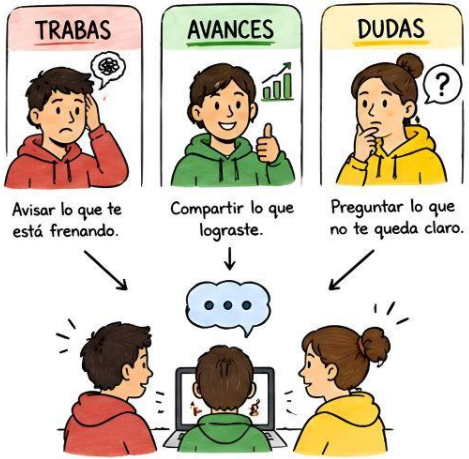
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



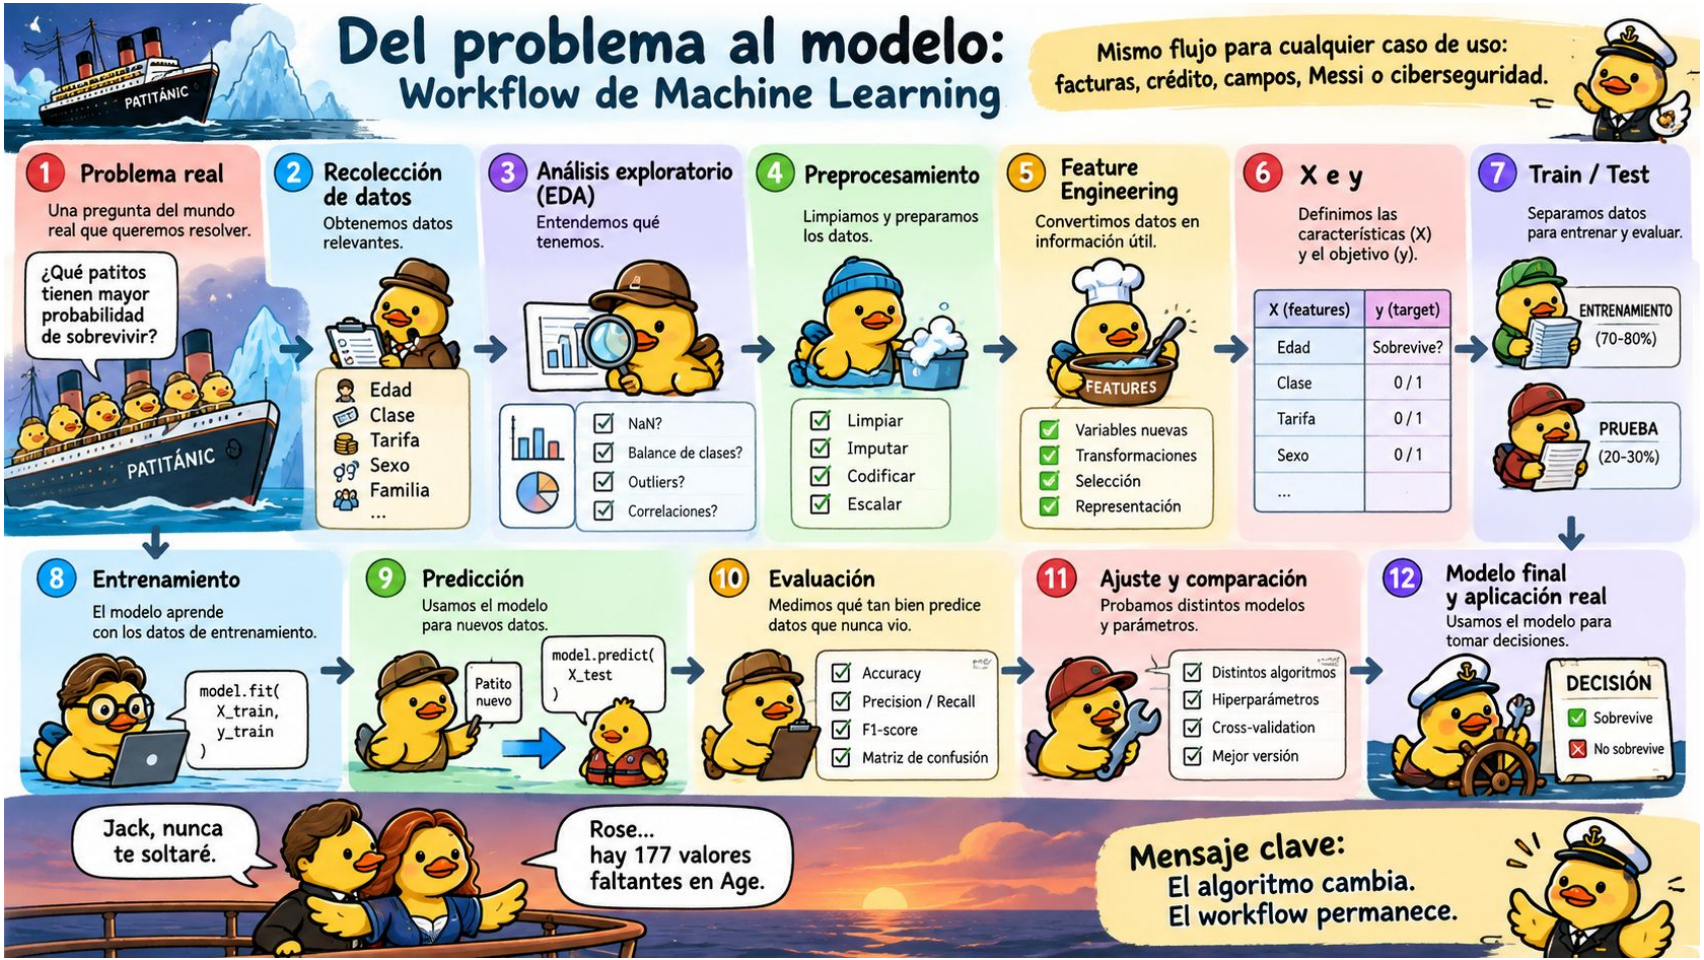
Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS


Del problema al modelo:
Workflow de Machine Learning
Mismo flujo para cualquier caso de uso:
facturas, crédito, campos, Messi o ciberseguridad.
1 Problema real
Una pregunta del mundo real que queremos resolver.
¿Qué patitos tienen mayor probabilidad de sobrevivir?
PATITÁNIC
2 Recolección de datos
Obtenemos datos relevantes.
Edad
Clase
Tarifa
Sexo
Familia
...
3 Análisis exploratorio (EDA)
Entendemos qué tenemos.
NaN?
Balance de clases?
Outliers?
Correlaciones?
4 Preprocesamiento
Limpiamos y preparamos los datos.
Limpiar
Imputar
Codificar
Escalar
5 Feature Engineering
Convertimos datos en información útil.
FEATURES
Variables nuevas
Transformaciones
Selección
Representación
6 X e y
Definimos las características (X) y el objetivo (y).
X (features)
y (target)
Edad
Sobrevive?
Clase
0 / 1
Tarifa
0 / 1
Sexo
0 / 1
...
7 Train / Test
Separamos datos para entrenar y evaluar.
ENTRENAMIENTO
(70-80%)
PRUEBA
(20-30%)
8 Entrenamiento
El modelo aprende con los datos de entrenamiento.
model.fit(
X_train,
y_train
)
9 Predicción
Usamos el modelo para nuevos datos.
Patito nuevo
model.predict(
X_test
)
10 Evaluación
Medimos qué tan bien predice datos que nunca vio.
Accuracy
Precision / Recall
F1-score
Matriz de confusión
11 Ajuste y comparación
Probamos distintos modelos y parámetros.
Distintos algoritmos
Hiperparámetros
Cross-validation
Mejor versión
12 Modelo final y aplicación real
Usamos el modelo para tomar decisiones.
DECISIÓN
Sobrevive
No sobrevive
Jack, nunca te soltaré.
Rose... hay 177 valores faltantes en Age.
Mensaje clave:
El algoritmo cambia.
El workflow permanece.

KNN – Decime con qué patitos andás y te diré quién sos

K-Nearest Neighbors (KNN) clasifica un nuevo dato mirando a los **K** ejemplos más parecidos del conjunto de entrenamiento. No aprende una regla, sino que usa la **similitud**.



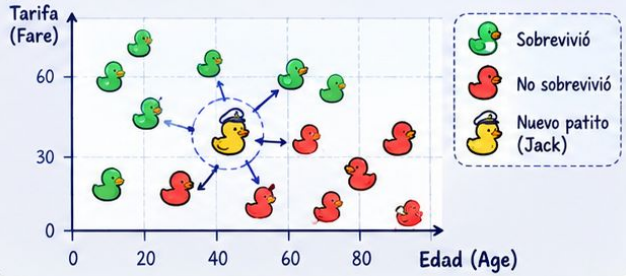
1. DESDE TITANIC: EL PROBLEMA

¿Sobrevive el nuevo patito?



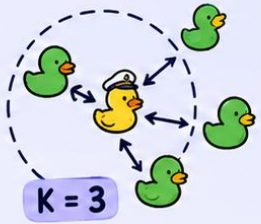
2. EN EL ESPACIO DE CARACTERÍSTICAS

Cada patito es un punto según sus variables (ejemplo: Edad y Tarifa).



3. VECINOS MÁS CERCANOS

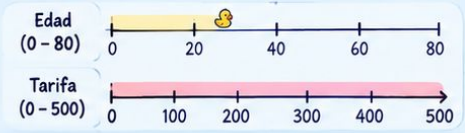
Si K = 3, buscamos los 3 patitos más cercanos. La clase se decide por mayoría.



En este ejemplo: 2 de 3 vecinos **sobrevivieron** → **Predicción:** **SOBREVIVIÓ**

4. IMPORTANCIA DE LA ESCALA

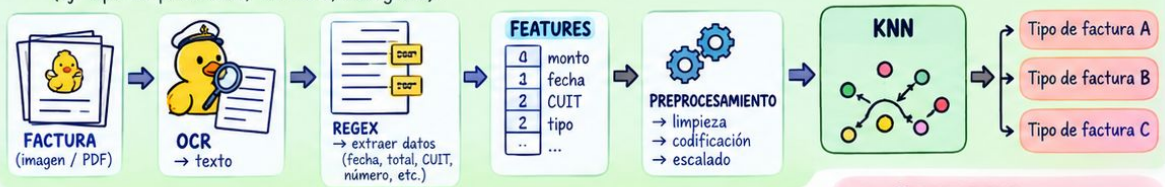
Si las variables tienen escalas muy diferentes, la distancia se distorsiona.





5. CASO DE USO REAL: CLASIFICACIÓN DE FACTURAS

Usamos KNN para clasificar o identificar facturas por similitud (ej. tipo de proveedor, formato, categoría).





CONCEPTOS CLAVE:

- Distancia (ej. distancia euclídea)
- Elección de K
- Escalado de variables (StandardScaler)
- Clasificación por mayoría
- Representación de datos

PARA LLEVARSE:

KNN no cambia al patito. Cambiamos cómo lo medimos y con quién lo comparamos.

3. Antes del modelo: Análisis de datos

Conozcamos a nuestros patitos: entendamos los datos antes de entrenar.



1 ¿Qué datos tenemos?

Cargamos el dataset Titanic

PassengerId	Survived	Pclass	Name	...
1	0	3	Braund, Mr.	...
2	1	1	Cumings, Mrs.	...
3	1	3	Heikkinen, Miss	
...	...	...	... ...	...

df.shape
(891, 12)

891 patitos
12 columnas

2 ¿Qué tipo de variables?

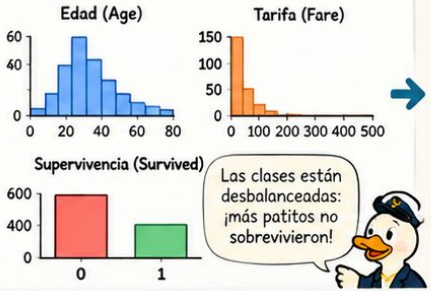
Identificamos tipos y columnas clave

Columna	Tipo	Ejemplo
Survived	numérica (0/1)	0
Pclass	categórica	3
Sex	categórica	male
Age	numérica	22.0
Fare	numérica	7.25
Embarked	categórica	S
Name	texto	"Braund, ..."

Tenemos variables numéricas, categóricas y texto.
El objetivo (y) es **Survived**.

3 ¿Cómo se distribuyen?

Exploramos los datos



Las clases están desbalanceadas: ¡más patitos no sobrevivieron!

4 ¿Hay problemas en los datos?

Detectamos valores faltantes, duplicados y outliers

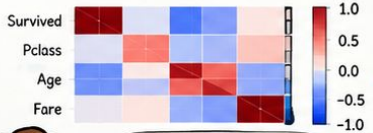
Valores faltantes (NaN)
Age: 177
Cabin: 687

Duplicados
0 (en este caso)

Outliers
Fare tiene valores muy altos algunos patitos pagaron mucho más que el resto.

5 Relaciones entre variables

Buscamos patrones y correlaciones



Parece que la tarifa (Fare) y la clase (Pclass) están relacionadas con la supervivencia...

6 Preprocesamiento

Limpiamos y preparamos los datos

Imputación
Rellenamos NaN (ej: **Age** con la mediana)

Codificación
Variables categóricas → números
(ej: **Sex**, **Embarked**)

Escalado
Estandarizamos variables numéricas
(ej: Age, Fare)

Selección de columnas
Elegimos las más relevantes

7 Feature Engineering

Creamos nueva información útil

FamilySize = SibSp + Parch + 1
¿Viaja solo o en familia?

Title
Extraemos el titulo del nombre
(Mr, Mrs, Miss, ...)

IsAlone
¿Está solo?

Fare_per_Person
Tarifa por persona del grupo

8 Resultado: nuestra tabla final

Lista para entrenar el modelo

X = características (features)

Pclass	Sex	Age	Fare	FamilySize	...
3	0	-0.5	-0.3	1	...
1	1	0.7	0.8	2	...
...	...	...	...	...	...

y = objetivo (target)

Survived
0
1
...

¡Ahora sí!
Nuestros datos están listos para entrenar y empezar a predecir qué patitos sobreviven.

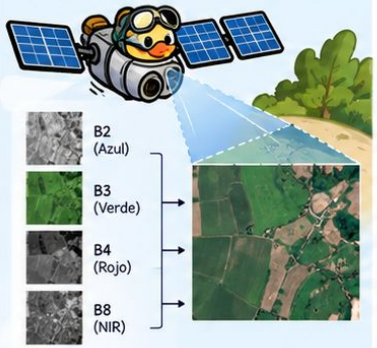
SVM ¿DE QUÉ LADO DEL CAMPO ESTÁ EL PATITO?

Clasificación de terrenos con imágenes Sentinel-2 (EuroSAT)

Jack Duck:
"Necesitamos una frontera que separe bien los terrenos y deje el mayor margen posible."

1 Datos: imágenes Sentinel-2

Parche de imagen satelital (64x64 píxeles) con bandas espectrales.



2 Preparación y análisis de datos

De las bandas extraemos características para cada imagen.

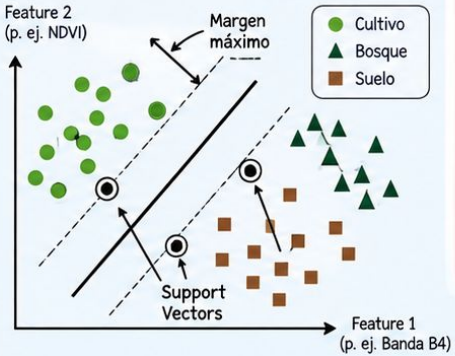
Features ejemplo:

- Bandas B2, B3, B4, B8 (promedio de píxeles)
- NDVI (vegetación)
- Textura (variabilidad)
- Índices de color



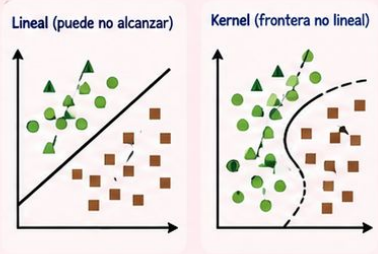
3 SVM: encontrar la mejor frontera

SVM busca el hiperplano que separa las clases con el mayor margen posible.



4 ¿Y si no es lineal?

Con kernels podemos separar clases más complejas.

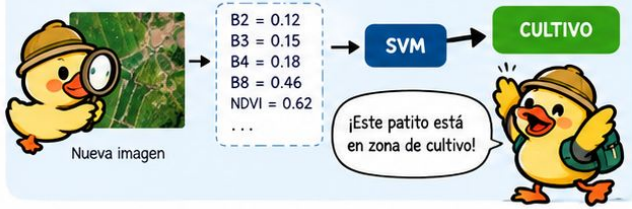


Idea clave

SVM no cambia, pero el resultado puede mejorar mucho si mejoramos las características que usamos (por ejemplo, agregando NIR o NDVI).

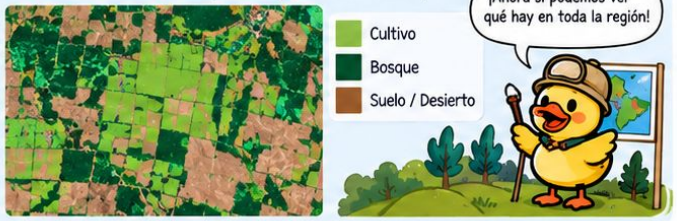
5 Predicción: ¿qué terreno es?

Una nueva imagen se transforma en features y el modelo SVM predice la clase.



6 Resultado: mapa de clasificación

Clasificamos muchos parches y generamos un mapa.



Caso de uso real

- **Dataset:** EuroSAT (Sentinel-2)
- **Tarea:** clasificar cultivo / bosque / suelo
- **Modelo:** SVM
- **Conceptos:** margen, support vectors, kernels, feature engineering

SLIDE 5

¿Número o clase? Dos formas de predecir



Mismo workflow, distintos objetivos.

¿QUÉ QUIERO PREDECIR?

UN NÚMERO
REGRESIÓN
Variable continua
(ej. rendimiento, precio)

UNA CLASE
CLASIFICACIÓN
Categorías
(ej. sobrevivió / no sobrevivió)



Caso 1: Messi Duck

Regresión

¿Podemos encontrar al próximo Messi?

Dataset:
StatsBomb Open Data
Datos de partidos y jugadores de fútbol (incluye a Messi)

Datos
- minutos
- tiros
- xG
- xA
- pases
- regates
- carries
- ...

Análisis de datos
- distribuciones
- correlaciones
- outliers
- NaN

Modelo lineal
Linear Regression
performance esperada

Regularización
Ridge / Lasso
- Ridge: reduce coeficientes
- Lasso: algunos coeficientes → 0

Resultado: predecir un número

Jugador	Minutos	xG	Predicción de rendimiento
Jugador A	900	0.45	0.62
Jugador B	1800	0.80	0.85
Messi Duck	2200	1.20	1.05





Caso 2: Hacker Duck

Clasificación

¿Esta conexión es normal o es un ataque?

Dataset:
UNSW-NB15
Tráfico de red con ejemplos de conexiones normales y ataques.

Datos
- protocol
- duration
- bytes
- packets
- service
- ...

Análisis de datos
- distribuciones
- balance de clases
- NaN
- tipos de variables

Naive Bayes

$$P(\text{clase} \mid X) = \frac{P(X \mid \text{clase})\,P(\text{clase})}{P(X)}$$

- clasificación probabilística
- simple y eficiente

Resultado
P(ataque) = 0.87
ATAQUE
P(ataque) = 0.12
NORMAL

Ejemplo: predicción probabilística

Conexión	Protocol	Bytes	Service	P(ataque)	Pratación	Predicción
A	TCP	200	http	0.87	0.87	ATAQUE
B	UDP	50	dns	0.12	0.12	NORMAL
C	TCP	1200	ftp	0.65	0.65	ATAQUE

Mismo workflow que Titanic: Problema → Datos → Análisis → Preprocesamiento → Features → Train/Test → Modelo → Predict → Evaluación → Ajuste → Aplicación

SLIDE 6

SVM: ¿De qué lado del campo está el patito?

Clasificación de terrenos con imágenes Sentinel-2



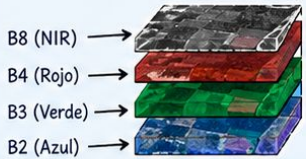
1 El problema

Queremos clasificar cada parche de imagen según el tipo de terreno.



2 Los datos: Sentinel-2 / EuroSAT

Usamos imágenes satelitales con varias bandas espectrales.



Bandas espectrales (una imagen = varias capas)



Parche de imagen (32x32 píxeles, por ejemplo)

3 Análisis de datos y features

Visualización RGB (bandas 4, 3, 2)



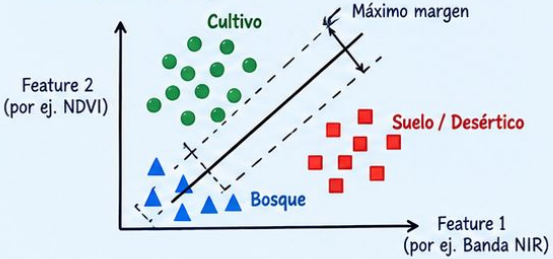
NDVI (NIR y Rojo)



- Analizamos la distribución de valores por clase.
- Creamos features: bandas espectrales, NDVI, etc.
- Exploramos correlaciones y separabilidad entre clases.

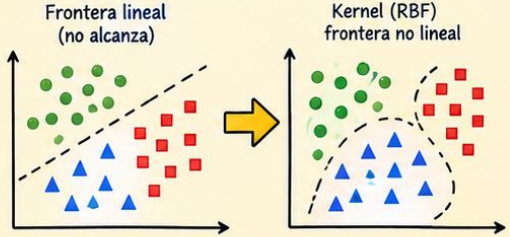
4 ¿Qué hace SVM?

SVM busca la frontera que mejor separa las clases cn el mayor margen posible.



5 Si no es lineal...

Cuando las clases no se pueden separar con una línea recta, usamos un **kernel** para una frontera no lineal.



6 Resultado: clasificación de terreno

SVM predice la clase del parche.
Esta decisión puede usarse para monitoreo agrícola, detección de deforestación o análisis de suelos.



SLIDE 7 - REGRESIÓN: EL PATITO MESSI

¿Podemos predecir el rendimiento de un jugador y encontrar al próximo Messi?

"Muchas variables, pero sólo algunas realmente importan.

1 PROBLEMA Y DATOS

¿Podemos predecir el rendimiento de un jugador a partir de sus estadísticas y encontrar al próximo Messi?

Dataset:
StatsBomb Open Data
(datos de partidos y jugadores)

StatsBomb Open Data

Ejemplo de features
tiros
goles (xG)
asistencias (xA)
pases
regates
carries
minutos
...

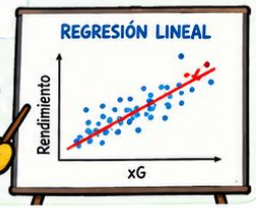
2 MODELO LINEAL

La regresión lineal busca una relación lineal entre las características y el rendimiento.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n$$

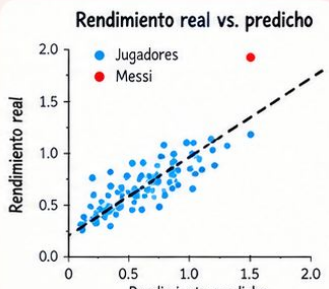
$\hat{y}$ = rendimiento esperado (ej. goles por partido)
x = estadísticas del jugador
β = pesos que aprende el modelo

Cada estadística aporta un poco al rendimiento final.



3 ¿FUNCIONA?

Comparamos los valores reales vs. predichos.

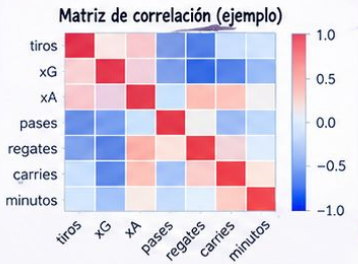


El modelo lineal tiende a subestimar a jugadores excepcionales como Messi.

Soy un outlier, ¿qué esperaban?

4 ¿Y SI TENEMOS MUCHAS VARIABLES?

Muchas estadísticas están correlacionadas entre sí.



¡Demasiadas variables! Algunas dicen lo mismo...

5 REGULARIZACIÓN: RIDGE Y LASSO

Agregamos una **penalización** para evitar que el modelo se sobreajuste y manejar variables correlacionadas.

Ridge (L2)

$$\min \sum(y_i - \hat{y}_i)^2 + \lambda \sum \beta^2$$

- Reduce el tamaño de los coeficientes.
- Mantiene todas las variables en el modelo.

Todos entrenan, pero con menos peso.

Lasso (L1)

$$\min \sum(y_i - \hat{y}_i)^2 + \lambda \sum |\beta|$$

- Puede llevar algunos coeficientes a 0.
- Realiza selección de variables.

¡Elijo sólo las variables más importantes!

6 RESULTADOS Y USO

Modelo	MAE ↓	R^2 ↑	# variables
Linear Regression	0.32	0.45	20
Ridge	0.28	0.52	20
Lasso	0.27	0.50	8

Con regularización mejora el rendimiento y el modelo es más simple.

¿Qué podemos hacer con este modelo?

- Evaluar a nuevos jugadores
- Comparar jugadores entre ligas
- Buscar perfiles similares al de Messi
- Identificar las estadísticas más importantes

8. ¿Cómo sé si mi patito aprendió?

Evaluación, métricas y mejora del modelo



1 Dividimos los datos



Dataset Titanic de patitos

- **Entrenamiento 70%** — Entrenamos con estos datos
- **Validación (opcional) 15%**
- **Test 15%** — Evaluamos en datos que el modelo nunca vio

2 Clasificación: matriz de confusión

Real \ Predicción del modelo	Sobrevive	No sobrevive
Sobrevive	Verdaderos Positivos (TP)	Falsos Negativos (FN)
No sobrevive	Falsos Positivos (FP)	Verdaderos Negativos (TN)

3 Métricas de clasificación

Accuracy
¿Qué proporción acertamos en total?

$$\frac{TP + TN}{TP + TN + FP + FN}$$

Precision
De los que predije que sobrevivían, ¿cuántos realmente sobrevivieron?

$$\frac{TP}{TP + FP}$$

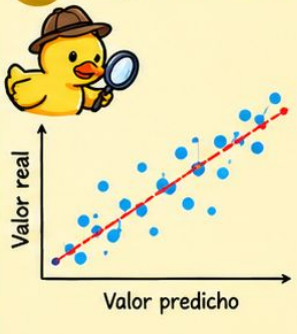
Recall (Sensibilidad)
De los que realmente sobrevivieron, ¿cuántos detecté?

$$\frac{TP}{TP + FN}$$

F1-score
Equilibrio entre precision y recall

$$\frac{2 \cdot (\text{Precision} \cdot \text{Recall})}{\text{Precision} + \text{Recall}}$$

4 Regresión: métricas



MAE
Error absoluto medio

$$\frac{1}{n} \cdot \sum |y_i - \hat{y}_i|$$

MSE
Error cuadrático medio

$$\frac{1}{n} \cdot \sum (y_i - \hat{y}_i)^2$$

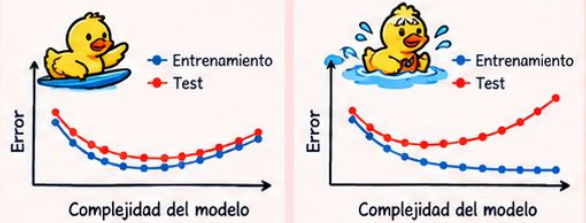
RMSE
Raíz del error cuadrático medio

$$\sqrt{\text{MSE}}$$

R^2
¿Qué proporción de la variabilidad explica el modelo?

$$1 - \frac{SS_{res}}{SS_{tot}}$$

5 ¿Está sobreajustando?



- Buen desempeño en ambos conjuntos
- Funciona muy bien en entrenamiento pero mal en test

6 Mejora del modelo

1. **Mejorar los datos** (limpiar, más datos, mejores features)
2. **Ajustar hiperparámetros** (K, max_depth, C, etc.)
3. **Probar otro modelo** (o un ensamble, como Random Fores
4. **Usar validación cruzada** (más robusto)
5. **Evaluar con la métrica correcta** (dependiendo del problema)

Slide 9:
¿Cómo sé si mi patito aprendió?

Evaluación del modelo, métricas y generalización



Clasificación

Ejemplo: Titanic → ¿Sobrevive el patito?

Matriz de confusión

Real \ Predicho	Sobrevive	No sobrevive
Sobrevive	**TP** (verdaderos positivos)	**FN** (falsos negativos)
No sobrevive	**FP** (falsos positivos)	**TN** (verdaderos negativos)

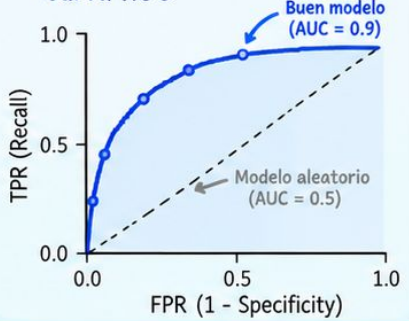
→ Patitos que sobreviven y el modelo lo predijo bien.

→ Patitos que no sobreviven y el modelo lo predijo bien.

Métricas principales

Accuracy	$\frac{TP + TN}{(TP + TN + FP + FIN)}$	Proporción total de aciertos.
Precision	$\frac{TP}{TP + FP}$	De los que predice como sobrevivientes, ¿cuántos realmente lo son?
Recall	$\frac{TP}{(TP + FN)}$	De los que realmente sobreviven, ¿cuántos logra detectar el modelo?
F1-score	$\frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$	Balance entre precision y recall.

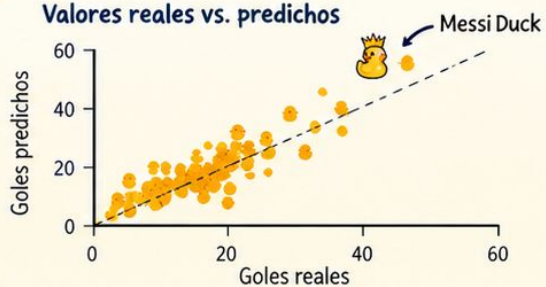
Curva ROC



Regresión

Ejemplo: Messi Duck → ¿Cuántos goles por temporada?

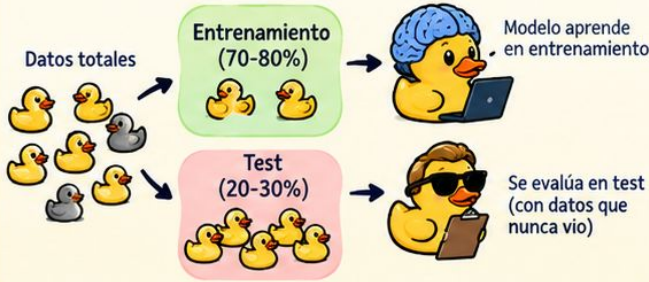
Valores reales vs. predichos



Métricas principales

MAE	$\frac{1}{n}\sum_{nn}^{N} \lvert y_i - \hat{y}_i \rvert$	Error promedio en la misma unidad (ej. goles).
MSE	$\frac{1}{n}\sum_{n}^{N} (y_i - \hat{y}_i)^2$	Penaliza más los errores grandes.
RMSE	$\sqrt{MSE}$	Mismo que MSE pero en la misma unidad.
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Qué proporción de la variabilidad de y explica el modelo.

Train vs Test: ¿generaliza realmente?



10 UN MISMO WORKFLOW, CINCO PROBLEMAS REALES

Distintos datos. Distintos algoritmos. El mismo proceso.

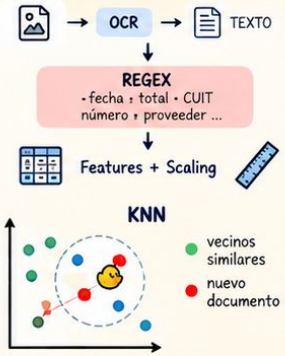


1 KNN
Procesamiento de facturas

¿A qué documento se parece esta nueva factura?



Dataset: SROIE / FATURA



2 Decision Tree → Random Forest
Scoring crediticio

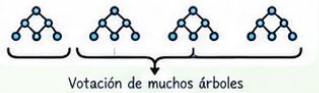
¿Le prestamos semillas a este patito?



Dataset: UCI Credit Default / FICO HELOC



Random Forest



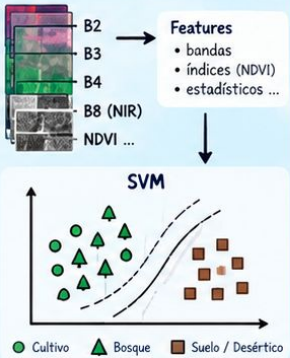
Probabilidad de default

3 SVM
Clasificación de terrenos con Sentinel-2

¿Qué hay en este campo desde el espacio?



Dataset: EuroSAT (Sentinel-2)

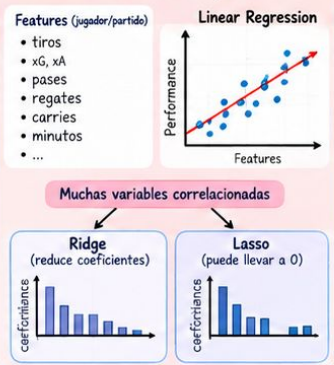


4 Linear Regression → Ridge / Lasso
Scouting deportivo (Messi)

¿Qué características hacen a un patito de élite?



Dataset: StatsBomb Open Data

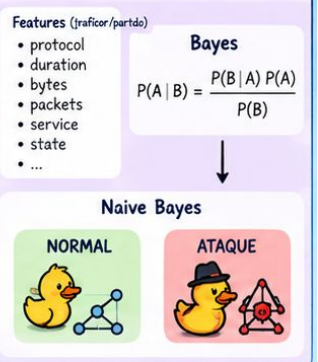


5 Naive Bayes
Detección de ataques de red

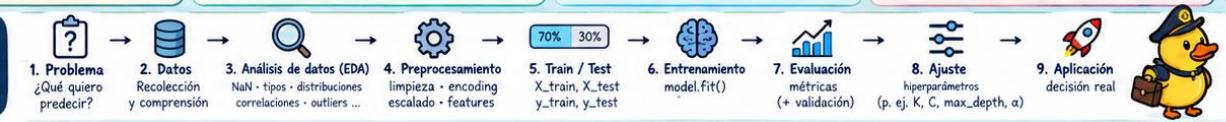
¿Esta conexión es normal o es un ataque?



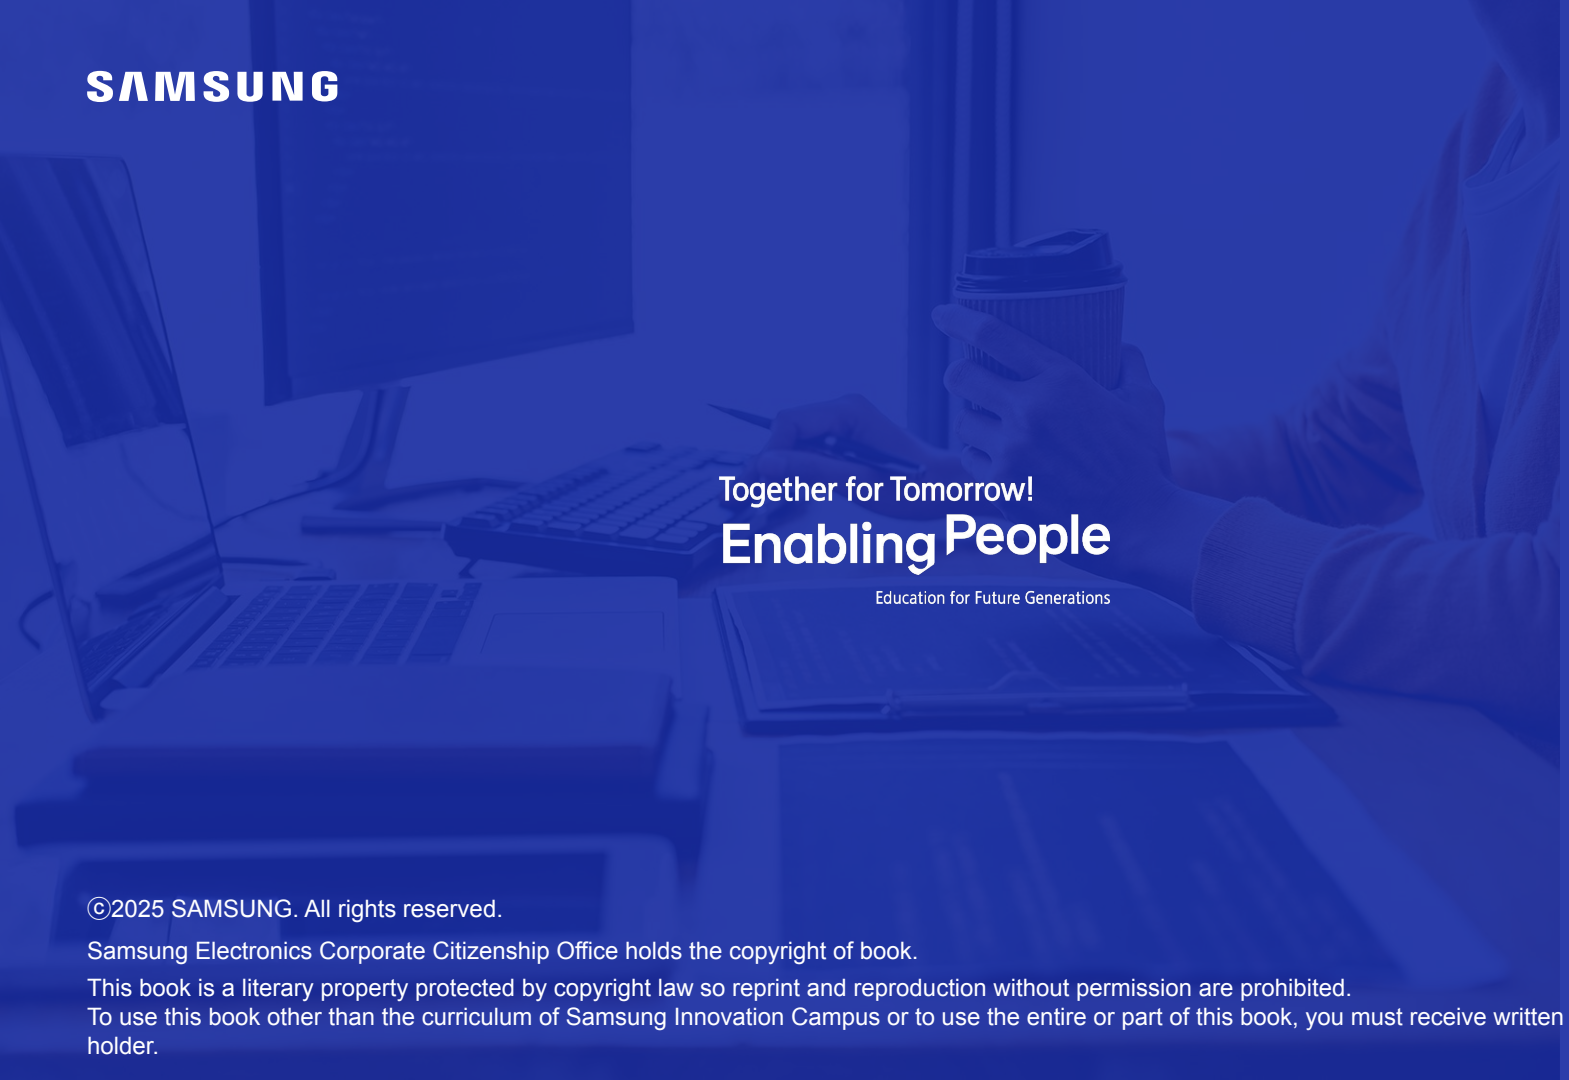
Dataset: UNSW-NB15



EL MISMO WORKFLOW END-TO-END



Cambia el problema.
Cambia el algoritmo.
El workflow siempre vuelve a navegar.



ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.