SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

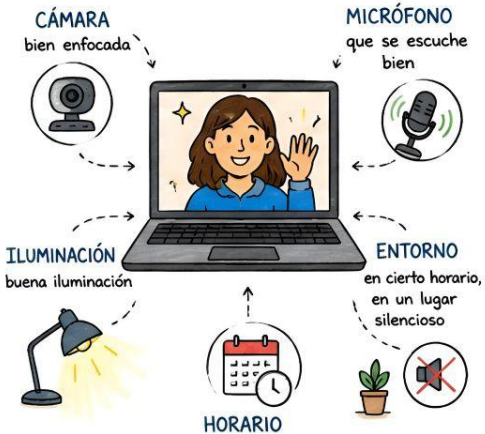
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



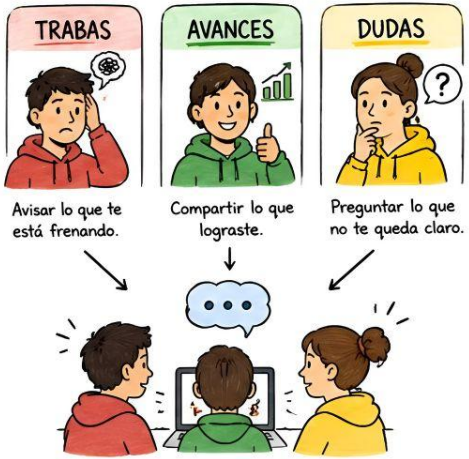
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS

Actividad grupal

Proyecto integrador de Machine Learning

Del problema a la solución: datos, modelo y automatización.

1 **Elegir problemática** — 2 Definir dataset — 3 Asignar roles y diseñar flujo

Paso 1 — Elegir una problemática

Hablen entre los integrantes del equipo y acuerden qué temática quieren investigar.

- Revisen las **cinco temáticas** disponibles.
- Conversen sobre qué **problema real** les interesa resolver.
- Identifiquen qué proceso les gustaría **mejorar, predecir, clasificar** o **automatizar**.
- Definan qué **valor** aportaría la solución a una empresa o organización.
- Elijan una temática por **consenso**, considerando su dificultad y los intereses del equipo.

Preguntas orientadoras

- ¿Qué problema queremos resolver?
- ¿Quién utilizaría nuestra solución?
- ¿Qué tarea podría facilitar o automatizar?
- ¿Cómo sabríamos si nuestra solución funciona?



ENTREGABLE DE ESTA ETAPA

Temática elegida, problema identificado y una pregunta de negocio.

PASO 2

Definir el dataset

Una vez elegido el problema, seleccionen los datos con los que van a trabajar.

1 Elegir una problemática — 2 **Definir el dataset** — 3 Asignar roles y diseñar el flujo

1 Explorar las opciones



- Revisen los datasets propuestos para la temática elegida.
- Comparen su fuente, tamaño, formato y nivel de dificultad.
- Consideren los objetivos del proyecto.

2 Analizar los datos



- Revisen las variables disponibles.
- Identifiquen qué representa cada registro.
- Determinen si los datos están limpios o requieren preprocesamiento.

3 Definir X e y



- Determinen cuál será la variable objetivo (y).
- Identifiquen las variables predictoras (X).
- Verifiquen que los datos permitan responder la pregunta de negocio.

4 Evaluar viabilidad



- ¿Se puede trabajar con Pandas y Scikit-learn?
- ¿Qué preparación necesitan los datos?
- ¿El dataset es adecuado para el nivel de dificultad del equipo?

5 Seleccionar y justificar



- Elijan el dataset final.
- Justifiquen por qué es el más adecuado.
- Indiquen su fuente y nivel de dificultad.
- Mencionen los principales desafios que anticipan.

Preguntas orientadoras

- ¿De dónde provienen los datos?
- ¿Qué representa cada registro?
- ¿Qué queremos predecir, clasificar o automatizar?
- ¿Podemos trabajar estos datos con Python, Pandas y Scikit-learn?
- ¿Qué preparación necesitarán antes de entrenar el modelo?

Ejemplo de información del dataset

Registro	Variable	Descripción	Tipo
1	age	Edad del cliente	Numérica
1	income	Ingreso mensual	Numérica
1	loan_amount	Monto solicitado	Numérica
1	history	Historial crediticio	Categórica
1	default	¿Incumple el pago?	**Binaria (y)**

Entregable

- Dataset seleccionado.
- Fuente (enlace).
- Nivel de dificultad.
- Justificación de la elección.
- Descripción breve de las variables principales y la variable objetivo (y).

PASO 3

Asignar roles y diseñar el flujo

Distribuyan las responsabilidades y diseñen cómo funcionaría la solución completa.

Trabajo en equipo
Cada rol aporta una mirada distinta para que la solución sea útil, viable y efectiva.



Business Analyst — 1 persona

Define el QUÉ y el PARA QUÉ.

- Identifica necesidades del negocio.
- Define la problemática y objetivos.
- Establece reglas de negocio.
- Determina resultados esperados y criterios de éxito.



Data Scientist — 1–2 personas

Desarrolla y valida el modelo.

- Explora y analiza los datos (EDA).
- Prepara variables y selecciona algoritmos.
- Entrena y evalúa el modelo.
- Interpreta resultados y métricas.



Líder Técnico — 1 persona

Define el CÓMO.

- Investiga y selecciona tecnologías.
- Diseña los pasos del proceso.
- Selecciona herramientas.
- Implementa automatizaciones con Make o n8n.

Diseño del flujo: responsabilidad compartida

El Business Analyst define qué necesita el negocio y qué debe hacer el proceso. El Líder Técnico define los pasos, herramientas e integraciones.

Business Analyst
Define necesidades, entradas, reglas de negocio y resultados esperados.

+

Líder Técnico
Define los pasos técnicos, herramientas e integraciones con Make o n8n.

→

Flujo de trabajo acordado
Entrada de datos → Procesamiento → Modelo ML → Decisión → Acción automatizada

Ejemplo de flujo (Scoring crediticio)

Solicitud de crédito
Formulario o API

→

Obtención de datos
Base de datos o archivo CSV

→

Procesamiento
Limpieza y preparación de variables

→

Modelo ML
Predicción de riesgo

→

Decisión
Aprobación, rechazo o revisión humana

→

Acción automatizada
Notificación por email o registro en sistema

Entregable de esta etapa

1. Integrantes del equipo.
2. Roles asignados y responsabilidades.
3. Primer esquema del flujo de negocio y técnico.
4. Herramientas propuestas (Make o n8n).

Agricultura satelital

Clasificación de cobertura terrestre con imágenes de satélite



Pregunta de negocio

¿Podemos identificar automáticamente tipos de cobertura terrestre utilizando imágenes satelitales?

Esta solución puede ayudar a organizaciones agrícolas, ambientales o gubernamentales a monitorear cultivos, bosques y otras coberturas terrestres.

Objetivo
Clasificar regiones agrícolas, bosques, pasturas y otras coberturas terrestres.

Modelo
Support Vector Machine (SVM).

Métricas de evaluación
Accuracy, precision, recall, F1 y matriz de confusión.

Desafío
Transformar imágenes en características numéricas y comparar diferentes bandas espectrales.

Datasets disponibles

Dataset	Fuente	Dificultad	Características principales
EuroSAT RGB	GitHub	Nivel 2	27.000 imágenes RGB, 10 clases de cobertura terrestre (bosques, cultivos, pasturas, etc.).
EuroSAT multiespectral	GitHub	Nivel 3	Imágenes Sentinel-2 con 13 bandas espectrales. Permite trabajar con bandas NIR y NDVI.
South Africa Crop Type	Radiant Earth	Nivel 4	Datos geoespaciales de parcelas agrícolas en Sudáfrica. Incluye diferentes tipos de cultivos y coberturas.

Flujo de trabajo (ejemplo)

1. Imagen satelital
Imagen de Sentinel-2 o EuroSAT

→

2. Extracción de características
Bandas espectrales, NDVI, texturas

→

3. Clasificación (SVM)
Prensición del tipo de cobertura

→

4. Resultado
Mapa de cobertura terrestre

Business Analyst

- Define qué coberturas terrestres necesita identificar la organización.
- Establece el uso de la información (ej. monitoreo de cultivos, detección de deforestación).
- Determina las salidas del proceso: reportes, mapas o alertas.

Data Scientist

- Explora el dataset y analiza las clases disponibles.
- Prepara las imágenes y extrae características numéricas.
- Entrena y evalúa el modelo SVM.
- Compara el desempeño utilizando diferentes bandas espectrales (RGB vs. multiespectral).

Líder Técnico

- Diseña los pasos técnicos del proceso.
- Define cómo se recibirán las imágenes y cómo se procesarán.
- Selecciona las herramientas e implementa automatizaciones con Make o n8n.
- Genera salidas automáticas (mapas, reportes o alertas).

Recomendación

Para **principiantes**, se recomienda utilizar **EuroSAT RGB** con un subconjunto de imágenes y características previamente extraídas. Permite trabajar con un dataset manejable y aplicar SVM sin una preparación demasiado compleja.

Procesamiento documental: facturas

¿Podemos automatizar la lectura y el procesamiento de facturas para reducir tareas manuales?

Temática
Procesamiento de documentos

Objetivo

Extraer automáticamente comercio, fecha, número de factura y total; clasificar documentos cuando existan etiquetas.



Técnicas y modelos

- OCR (reconocimiento de texto)
- Regex (extracción de campos)
- KNN (clasificación de documentos)

Desafío

Convertir documentos no estructurados en información útil y confiable.

Datasets disponibles

Dataset	Descripción	Dificultad	Enlace
SROIE	Imágenes de recibos con campos anotados para extracción de información.	Nivel 3 Intermedio	Hugging Face
FATURA	Facturas con campos estructurados, extracción y validación de datos.	Nivel 3 Intermedio	GitHub
Invoice datasets (Hugging Face)	Alternativas con imágenes, texto extraído o campos anotados.	Nivel 2–3 Básico / Intermedio	Hugging Face

Recomendación: SROIE con una muestra reducida y OCR previamente preparado para disminuir la dificultad.

Ejemplo de flujo automatizado

1. Recepción — Factura en formato imagen o PDF

→

2. OCR + Regex — Extracción de texto y campos clave

→

3. KNN — Clasificación de documentos

→

4. Registro — Almacenamiento en base de datos o sistema

Business Analyst

- Define qué información debe extraerse (comercio, fecha, número de factura, total, etc.).
- Establece las validaciones y reglas de negocio.
- Determina el uso de la información y quién la utilizará.

Data Scientist

- Explora y prepara los datos de entrenamiento.
- Extrae características del texto.
- Entrena y evalúa el modelo de clasificación (KNN).
- Valida la calidad de la extracción de campos.

Líder Técnico

- Selecciona las herramientas de OCR y procesamiento de texto.
- Diseña los pasos del flujo en Make o n8n.
- Integra la extracción, clasificación y registro.
- Define dónde se almacenarán los resultados y cómo se automatizará el proceso.

Scoring crediticio individual

¿Podemos estimar el riesgo de incumplimiento de un cliente antes de otorgar un crédito?

Aplicación real
Bancos, financieras y empresas de servicios financieros.

Objetivo
Clasificar clientes según su riesgo de incumplimiento de crédito.

Modelos
- Decision Tree
- Random Forest

Métricas de evaluación
- Precision
- Recall
- F1
- Matriz de confusión
- Interpretabilidad

Desafío
Comparar interpretabilidad, precision y recall, y comprender el costo de los errores de predicción.

Datasets disponibles

Dataset	Registros aprox.	Descripción	Dificultad	Enlace
German Credit Data	1.000	Datos tabulares de clientes con buen/mal riesgo.	Nivel 1	UCI
South German Credit	1.000	Datos similares al anterior con variables demográficas.	Nivel 1	UCI
UCI Credit Default	30.000	Clientes de tarjetas de crédito con etiqueta de incumplimiento.	Nivel 1	UCI
FICO HELOC	10.459	Solicitudes de línea de crédito con historial crediticio.	Nivel 2	Hugging Face
Give Me Some Credit	150.000 (entrenamiento)	Clientes con riesgo de morosidad en los próximos 2 años.	Nivel 2	Kaggle
Home Credit Default Risk	307.511 (entrenamiento)	Solicitudes de crédito con múltiples variables.	Nivel 3	Kaggle
Lending Club Loan Data	Millones (según versión)	Préstamos personales con datos de historial y comportamiento.	Nivel 3	Kaggle
BCRA — Central de Deudores	Variable	Historial crediticio argentino. Requiere preparación de datos.	Nivel 4	BCRA
BCRA — Deudores y morosos	Variable	Datos históricos de deudores y morosidad.	Nivel 4	BCRA
Home Credit Risk Model Stability	Millones	Gran escala, múltiples tablas y variables.	Nivel 4	Kaggle

Ejemplo de flujo automatizado

Solicitud de crédito → Ingreso de datos del cliente

Obtención de datos → Consulta de fuentes internas o externas

Scoring con ML → Predicción de riesgo (Decision Tree / Random Forest)

Decisión → Aprobación, rechazo o revisión manual

Roles en el flujo

Business Analyst
- Define los criterios de riesgo.
- Establece reglas de negocio.
- Determina resultados esperados.
- Define qué acciones tomar con la predicción.

Data Scientist
- Explora y prepara los datos.
- Entrena y evalúa los modelos.
- Interpreta los resultados.
- Colabora en la integración del modelo.

Líder Técnico
- Diseña los pasos del proceso.
- Selecciona herramientas.
- Implementa la automatización en Make o n8n.
- Integra el modelo al flujo.

Recomendación para principiantes

Utilizar **UCI Credit Default** o **German Credit Data**, que tienen datos tabulares y permiten aplicar Decision Tree y Random Forest sin preprocesamiento complejo.

Desafío argentino opcional
Utilizar datos históricos del BCRA para construir un modelo de deterioro crediticio, con datos previamente preparados y anonimizados.

Estadística deportiva

¿Podemos predecir el rendimiento de un deportista utilizando estadísticas históricas?



Objetivo

Predecir una variable numérica de rendimiento a partir de estadísticas históricas.

Modelos

- Linear Regression
- Ridge Regression
- Lasso Regression

Métricas de evaluación

- MAE (Error Absoluto Medio)
- RMSE (Raíz del Error Cuadrático Medio)
- R^2 (Coeficiente de determinación)

Desafío

Seleccionar predictores relevantes y evitar utilizar información futura.

Datasets disponibles

Temática	Dataset	Descripción	Dificultad
Messi y fútbol	StatsBomb Open Data	Eventos de partidos, pases, tiros, regates y ubicaciones. Incluye datos de Messi y otras competiciones.	Nivel 3 Intermedio
CrossFit Games	CrossFit Games datasets	Clasificaciones, puntajes y resultados por evento. Incluye resultados individuales por workout.	Nivel 2 Básico
Juegos Olímpicos	120 Years of Olympic History	Resultados históricos de atletas y competiciones. Permite analizar diversas disciplinas deportivas.	Nivel 2 Básico
Las Leonas	Datos históricos FIH	Resultados y estadísticas del hockey femenino. Requiere recopilar datos históricos de la FIH.	Nivel 4 Avanzado

Ejemplo de flujo automatizado

1. **Recolección de datos**
   Resultados y estadísticas desde APIs o archivos
2. **Preparación de características**
   Limpieza, agregación y variables relevantes
3. **Modelo de regresión**
   Predicción del rendimiento (Linear, Ridge o Lasso)
4. **Reporte y visualización**
   Actualización automática de predicciones y dashboards en Make o n8n

Ejemplos de predicciones

- **Messi y fútbol:** estimar rendimiento por partido (goles, asistencias, xG) utilizando estadísticas anteriores.
- **CrossFit Games:** predecir puntos en una prueba a partir de resultados previos.
- **Juegos Olímpicos:** analizar factores asociados al rendimiento de atletas; para regresión de marcas deportivas se necesitan datos adicionales.
- **Las Leonas:** estimar goles por partido utilizando resultados históricos recopilados.

Roles en el proyecto

Business Analyst
Define qué indicador deportivo se quiere predecir, para quién y con qué finalidad.

Data Scientist
Explora datos, prepara variables, entrena modelos y evalúa resultados.

Líder Técnico
Diseña los pasos para actualizar estadísticas, ejecutar predicciones y generar reportes automáticamente.

Recomendación

CrossFit Games, siempre que el dataset seleccionado incluya resultados por prueba.

Es una buena opción para trabajar regresión numérica con un nivel de dificultad manejable.

Ciberseguridad

Detección de ataques en tráfico de red

Pregunta de negocio

¿Podemos **detectar tráfico** potencialmente malicioso antes de que comprometa una red?

Objetivo

Clasificar tráfico de red como normal o malicioso para detectar ataques de forma temprana.

Modelos

Gaussian Naive Bayes.

Métricas de evaluación

Recall, precision, F1 y matriz de confusión.

Desafío

Reducir falsos negativos y generar alertas útiles para el equipo de seguridad.

Datasets disponibles

Dataset	Registros aprox.	Dificultad	Características
NSL-KDD	125.973	Nivel 2	Conexiones de red, protocolos y etiquetas de ataque.
CICIDS2017	2.8 millones	Nivel 3	Flujos de red con tráfico benigno y ataques.
UNSW-NB15	2.5 millones	Nivel 3	Tráfico de red normal y malicioso.
CICIDS2017 (Hugging Face)	Variable	Nivel 2–3	Versiones tabulares preparadas para ML.

Recomendación

NSL-KDD con variables numéricas seleccionadas y clasificación binaria "normal / ataque".

Es un buen punto de partida para estudiantes principiantes, con datos tabulares y variables interpretables.

Ejemplo de flujo automatizado

Recepción de datos
Logs de red, archivos o API

→

Preprocesamiento
Limpieza, selección de variables

→

Modelo ML
Gaussian Naive Bayes (clasificación)

→

Generación de alertas
Notificación por email, Slack o Dashboard

Business Analyst

- Define qué situaciones representan un riesgo.
- Establece qué eventos deben notificarse.
- Define a quiénes se enviarán las alertas y qué acciones se tomarán.

Data Scientist

- Explora los datos (EDA).
- Prepara las variables y selecciona características.
- Entrena y evalúa el modelo.
- Analiza los resultados y propone mejoras.

Líder Técnico

- Diseña los pasos técnicos del proceso.
- Selecciona herramientas e integraciones.
- Implementa la automatización con Make o n8n.
- Integra el modelo en el flujo y genera las alertas.

Actividad integradora

Muestreo y Análisis Exploratorio de Datos (EDA)

Capítulo 4 (Probabilidad y Estadística) → Capítulo 5 (Preparación de datos para ML)

Objetivo

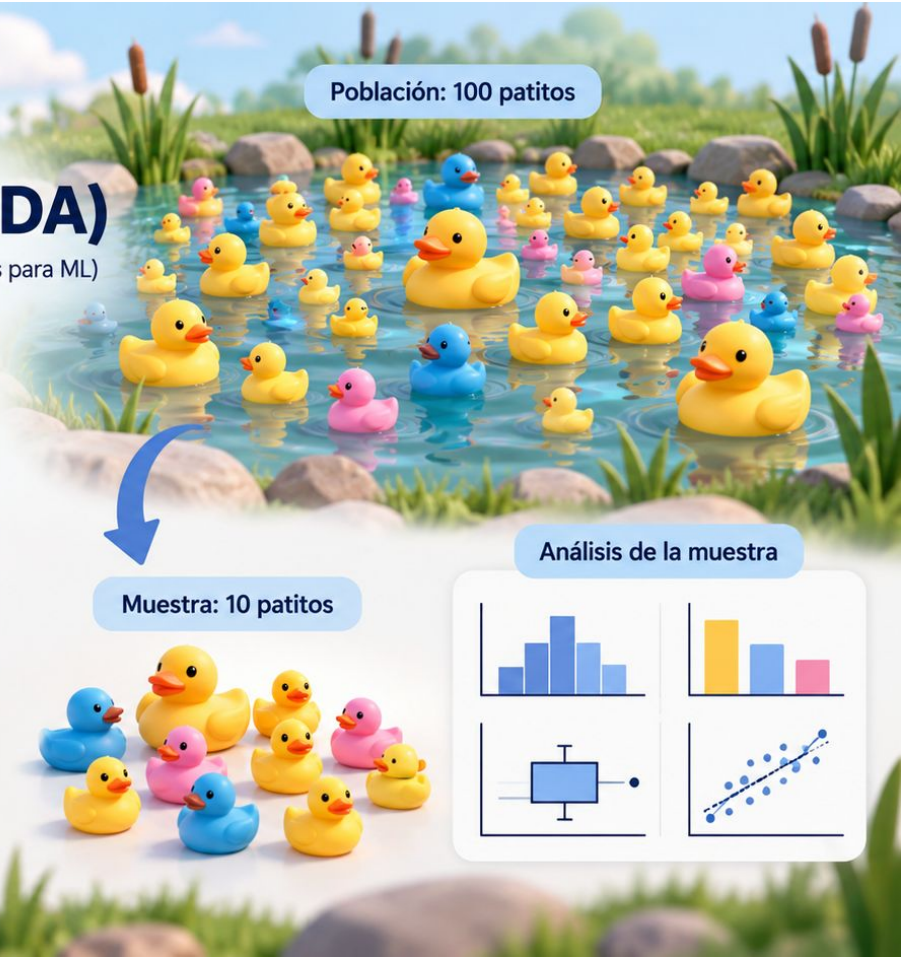
Aprender a seleccionar muestras, explorar distribuciones, identificar patrones y evaluar la representatividad de los datos.

La situación

Tenemos 100 patitos de diferentes colores, tamaños y pesos. Queremos conocer sus características sin tener que estudiar a todos.

Importante

Primero seleccionamos una muestra y después exploramos los datos.
Todavía no se entrena ningún modelo: antes hay que entender qué datos tenemos.



2 Elegí tu dataset de Hugging Face

Cada equipo trabajará con un dataset real de Hugging Face para aplicar los conceptos de muestreo y análisis exploratorio de datos (EDA).



Temática	Dataset	Formato	Dificultad	Descripción
Agroindustria	Crop Yield dhyann2815/india-crop-yield-prediction	CSV	Baja	Datos de cultivos, rendimiento, clima y región.
Investigación médica	PubMed RCT armanc/pubmed-rct20k	Texto	Media	Resúmenes de artículos científicos con oraciones anotadas.
Facturas y tickets	SROIE Voxel51/scanned_receipts	Imagen/OCR	Media	Imágenes de facturas con anotaciones de texto (para OCR).
E-commerce	E-commerce ai-training-datasets/ecommerce.json	JSON	Baja	Conversaciones de e-commerce con categorías y metadatos.
Visión artificial	COCO 2017 finedet/coco2017	Imagen/OCCO	Alta	Imágenes con múltiples objetos y anotaciones (detección y segmentación).

Consigna inicial

Para el dataset que elijan, identifiquen:

1. ¿Qué representa cada fila o registro?
2. ¿Cuántas observaciones tiene?
3. ¿Qué variables contiene? ¿Cuáles son numéricas y cuáles categóricas?
4. ¿Qué población real pretende representar el dataset?
5. ¿Qué limitaciones tiene en términos de representatividad?



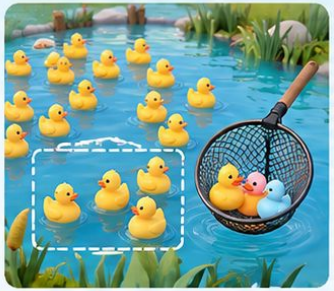
Slide 3
Muestreo

Cinco formas de seleccionar patitos

Distintos métodos de muestreo nos dan muestras diferentes. Veamos cómo funcionan con nuestros 100 patitos.

1. Aleatorio simple

Todos los patitos tienen la misma probabilidad de ser seleccionados.



Ejemplo con patitos

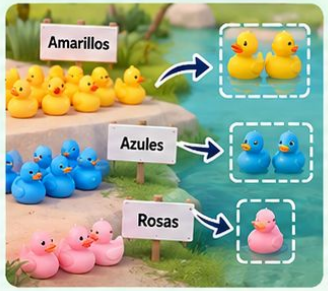
Seleccionar 10 patitos al azar de los 100 del estanque.

Aplicación en datasets

Seleccionar el 10 % de los registros al azar.

2. Estratificado

Dividimos la población en grupos y tomamos una muestra de cada uno.



Ejemplo con patitos

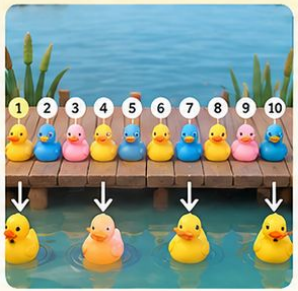
Seleccionar el 10 % de patitos amarillos, azules y rosas.

Aplicación en datasets

Tomar un 10 % de cada categoría (por ejemplo, por clase, región o tipo de dato).

3. Sistemático

Seleccionamos cada k observaciones después de un inicio aleatorio.



Ejemplo con patitos

Elegir un inicio aleatorio y luego seleccionar cada décimo patito.

Aplicación en datasets

Seleccionar cada k registros del dataset, con un inicio aleatorio.

4. Por conglomerados

Elegimos grupos completos de individuos.



Ejemplo con patitos

Seleccionar un estanque completo (por ejemplo, todos los patitos del estanque B).

Aplicación en datasets

Elegir grupos completos, cuando existan agrupaciones reales (por ejemplo, artículos completos, imágenes de una misma carpeta o registros de una región).

5. Por conveniencia

Seleccionamos los datos más accesibles; puede introducir sesgos.



Ejemplo con patitos

Seleccionar los 10 patitos más cercanos al muelle.

Aplicación en datasets

Tomar el primer 10 % de los registros del dataset (por su orden original).

4 Aplicá el muestreo con Python

Seleccionemos diferentes muestras de nuestro dataset.

Los mismos métodos que usamos para los patitos podemos aplicarlos a cualquier dataset de Hugging Face.



1. Aleatorio simple



Seleccionamos un porcentaje al azar de registros.

```
# 10 % de la población al azar
muestra_aleatoria = df.sample(
    frac=0.1,     # 10 %
    random_state=42  # para reproducir
)
```

2. Estratificado



Tomamos un porcentaje de cada categoría o estrato.

```
# 10 % de cada categoría (ej.: color)
muestra_estratificada = (
  df.grouuby('color', group_keys=False)
   .apply(lambda x: x.sample(frac=0.1,
                             random_state=42))
)
```

3. Sistemático

Seleccionamos cada k registros, con un inicio aleatorio.



```
# cada k registros
k = 10
inicio = np.random.randint(0, k)
muestra_sistematica = df.iloc[inicio::k]
```

4. Por conglomerados

Seleccionamos grupos completos de registros.



```
# seleccionamos un subconjunto de grupos
grupos = df['estanque'].unique()
grupos_seleccionados = np.random.choice(
    grupos, size=2, replace=False)
muestra_conglomerados = df[
   df['estanque'].isin(grupos_seleccionados)
]
```

5. Por conveniencia

Seleccionamos los registros más accesibles (ej.: los primeros).



```
# primeros 10 % de los registros
n = int(0.1 * len(df))
muestra_conveniencia = df.head(n)
```

Consideraciones importantes

- **Datasets pequeños**: se puede aumentar la proporción de la muestra.
- **Datasets grandes**: fijar un límite de registros para trabajar en Colab.
- **PubMed**: los artículos pueden funcionar como conglomeados.
- **COCO**: seleccionar imágenes completas con todas sus anotaciones.
- Los métodos no producen muestras con el mismo tamaño ni con las mismas probabilidades de selección. El equipo debe registrar esas diferencias.

¿Todas als muestras representan lo mismo?

Tenemos una población de 100 patitos de tres colores:

- 60 amarillos (60 %)
- 30 azules (30 %)
- 10 rosas (10 %)

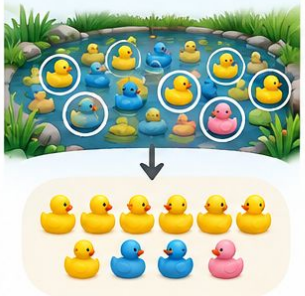


Distribución original

60	(60 %)
30	(30 %)
10	(10 %)

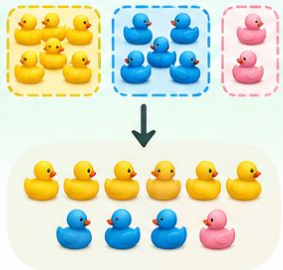
1. Aleatorio simple

Seleccionamos 10 patitos al azar de todo el estanque.



2. Estratificado

Tomamos el 10 % de cada color, respetando sus proporciones.



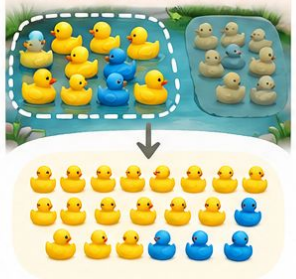
3. Sistemático

Seleccionamos cada k observaciones (en este ejemplo, cada 10), con un inicio aleatorio.



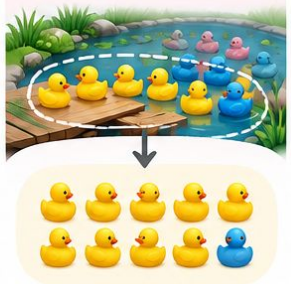
4. Por conglomerados

Elegimos un grupo completo de patitos (en este ejemplo, un estanque con 20 patitos).



5. Por conveniencia

Seleccionamos los primeros 10 patitos (los más cercanos).



Método	Tamaño de la muestra (n)	Fracción (f = n / N)	Amarillos	Azules	Rosas	Categorías presentes
Aleatorio simple	10	10 %	7	2	1	7 amarillos, 2 azules, 1 rosa
Estratificado	10	10 %	6	3	1	6 amarillos, 3 azules, 1 rosa
Sistemático	10	10 %	8	2	0	8 amarillos, 2 azules, 0 rosas
Conglomerados	20	20 %	15	5	0	15 amarillos, 5 azules, 0 rosas
Conveniencia	10	10 %	9	1	0	9 amarillos, 1 azul, 0 rosas

6 Exploración inicial: ¿qué datos tenemos?

Nuestro dataset de patitos



Vista de los datos (primeras filas)

id	peso_g	color	tamaño	estanque
1	520	amarillo	mediano	A
2	610	azul	grande	A
3	430	rosa	pequeño	B
4	480	amarillo	mediano	B
5	590	amarillo	grande	A

Comandos de Pandas

```
df.shape
df.head()
df.info()
df.describe(include="all")
df.isna().sum()
df.duplicated().sum()
```



df.shape
¿Cuántas observaciones y variables?

```
(100, 5)
```

100 patitos y 5 variables

df.head()
Primeras filas del dataset

id	peso_g	color	...
1	520	amarillo	...
2	610	azul	...
3	430	rosa	...
4	480	amarillo	...
5	590	amarillo	...

df.info()
Tipos de variables y memoria

```
<class 'pandas.DataFrame'>
RangeIndex: 100 entries,
Data columns (total 5):
 #  Column    Non-Null Dtype
 0  id        100      int64
 1  peso_g    100      int64
 2  color     100      object
 3  tamaño    100      object
 4  estanque  100      object
dtypes: int64(2),
object(3)
memory usage: 4.0+ KB
```

df.describe(include="all")
Estadísticos descriptivos

	peso_g	color	tamaño
count	100	100	100
mean	515.2	NaN	NaN
std	85.6	NaN	NaN
min	320	NaN	NaN
25%	460	NaN	NaN
50%	510	NaN	NaN
75%	590	NaN	NaN
max	720	NaN	NaN

df.isna().sum()
Valores faltantes

```
id          0
peso_g      2
color       0
tamaño      0
estanque    0
```

Hay 2 patitos sin registro de peso.

df.duplicated().sum()
Registros duplicados

```
0
```

No hay patitos duplicados.

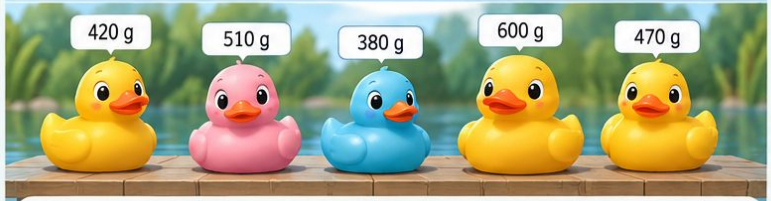
- Identificar tipos de variables (numéricas y categóricas).
- Detectar valores faltantes, duplicados e inconsistencias.
- Para textos e imágenes, construir una tabla de metadatos (longitud, dimensiones, cantidad de anotaciones, categorías, etc.).

7 Estadística descriptiva: ¿cómo son nuestros patitos?

Analizamos las características principales de cada muestra para entender cómo son nuestros datos.

Variables numéricas

Describen cantidades, por ejemplo: peso o tamaño.



Media	Mediana	Varianza	Desviación estándar
467 g	**470 g**	**5 620 g²**	**75 g**
Promedio de los valores.	Valor central ordenando los datos.	Qué tan dispersos están los valores.	Dispersión en las mismas unidades.

Mínimo	Máximo	Rango	Cuartiles e IQR
380 g	**600 g**	**220 g**	$Q1 = 410$ g $Q2 = 470$ g $Q3 = 520$ g IQR = 110 g
Valor más pequeño.	Valor más grande.	Máximo – Mínimo.	



La estadística descriptiva nos permite resumir la información y comparar cómo son los patitos en cada muestra y en el dataset completo.

Fórmulas principales

Media muestral

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Suma todos los valores y divide por la cantidad de observaciones.

Varianza muestral

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n} (X_i - \bar{X})^2$$

Mide qué tan dispersos están los valores respecto de la media.

Variables categóricas

Describen grupos o etiquetas, por ejemplo: color o estanque.



Amarillos	Azules	Rosas	Blancos
12	**9**	**6**	**3**
(40 %)	(30 %)	(20 %)	(10 %)

Color	Frecuencia absoluta	Frecuencia relativa
Amarillo	12	0,40 (40 %)
Azul	9	0,30 (30 %)
Rosa	6	0,20 (20 %)
Blanco	3	0,10 (10 %)

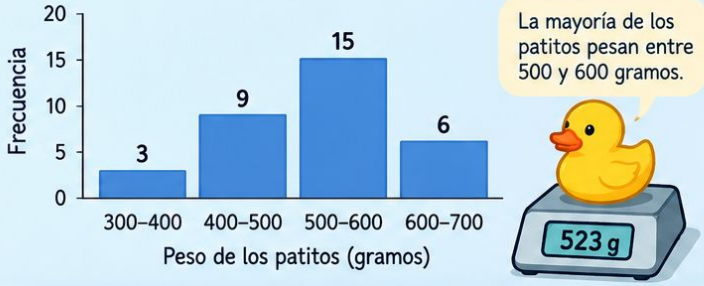
Importante: si el dataset solo tiene categorías, analizamos proporciones y frecuencias en lugar de calcular medias.

Slide 8. Visualización: cuatro formas de entender los datos

Los gráficos nos ayudan a ver patrones, comparar grupos y detectar valores atípicos.

1. Histograma

Muestra la distribución de una variable numérica.



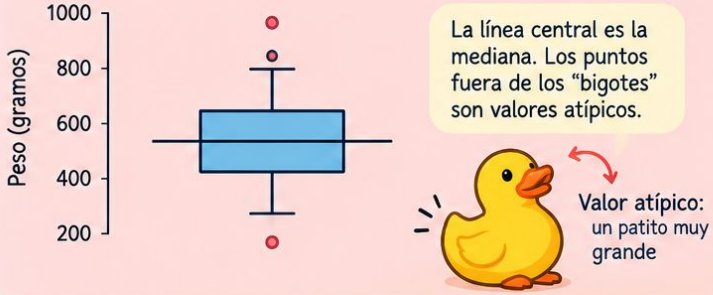
2. Gráfico de barras

Muestra las frecuencias por categoría.



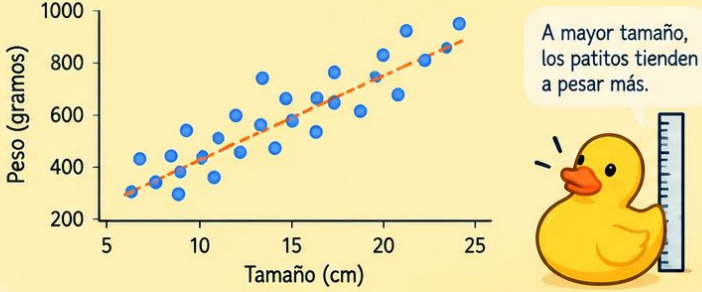
3. Boxplot

Muestra la mediana, los cuartiles y los valores atípicos.



4. Gráfico de dispersión

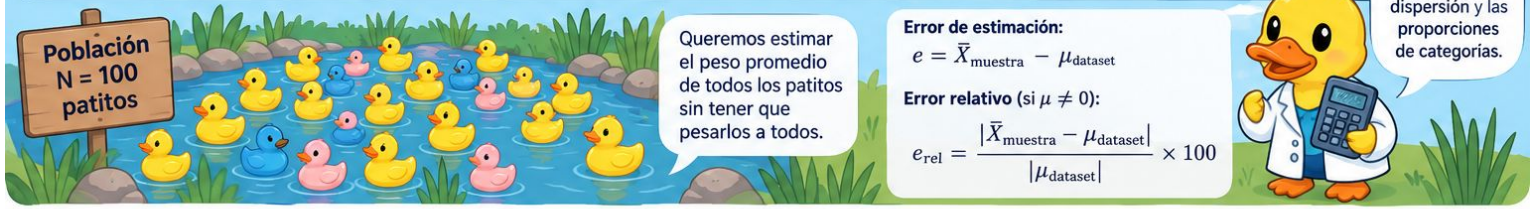
Muestra la relación entre dos variables numéricas.



Si alguno de estos gráficos no corresponde al dataset, pueden reemplazarlo por otro y justificar la elección.

Slide 9. Comparación: ¿qué muestra representa mejor la población?

Analizamos cómo se comparan las cinco muestras con el dataset completo.



Error de estimación:

$$e = \bar{X}_{\text{muestra}} - \mu_{\text{dataset}}$$

Error relativo (si $\mu \neq 0$):

$$e_{\text{rel}} = \frac{|\bar{X}_{\text{muestra}} - \mu_{\text{dataset}}|}{|\mu_{\text{dataset}}|} \times 100$$

Dataset completo (Población)	
N	100
Peso promedio (g)	520
Desv. estándar (g)	80
Mín – Máx (g)	320 – 760
Proporción de colores	
Amarillo	60 %
Azul	25 %
Rosa	15 %

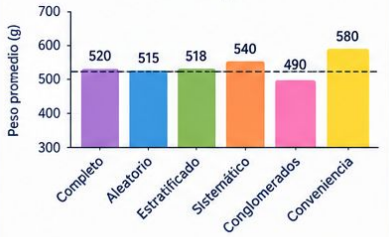
Aleatorio simple	
n	10
Peso promedio (g)	515
Desv. estándar (g)	78
Mín – Máx (g)	340 – 730
Proporción de colores	
Amarillo	60 %
Azul	20 %
Rosa	20 %

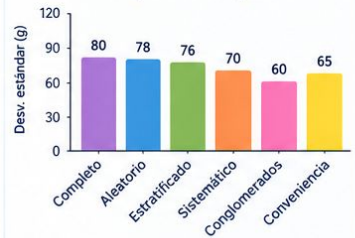
Estratificado	
n	10
Peso promedio (g)	518
Desv. estándar (g)	76
Mín – Máx (g)	330 – 740
Proporción de colores	
Amarillo	60 %
Azul	25 %
Rosa	15 %

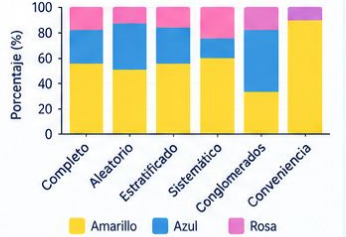
Sistemático	
n	10
Peso promedio (g)	540
Desv. estándar (g)	70
Mín – Máx (g)	420 – 700
Proporción de colores	
Amarillo	70 %
Azul	20 %
Rosa	15 %

Conglomerados (1 estanque)	
n	10
Peso promedio (g)	490
Desv. estándar (g)	60
Mín – Máx (g)	370 – 610
Proporción de colores	
Amarillo	10 %
Azul	80 %
Rosa	10 %

Por conveniencia (los primeros 10)	
n	10
Peso promedio (g)	580
Desv. estándar (g)	65
Mín – Máx (g)	450 – 760
Proporción de colores	
Amarillo	90 %
Azul	10 %
Rosa	0 %







¿Qué observamos?

- La muestra estratificada es la que más se parece al dataset completo.
- La muestra por conveniencia **sobreestima** el peso promedio y casi no incluye patitos rosas.
- La muestra por conglomerados (un estanque) no representa bien la diversidad de colores.
- La muestra aleatoria simple se aproxima bien, pero puede variar entre repeticiones.

10 Entregable y discusión final

Actividad integradora: Muestreo y Análisis Exploratorio de Datos (EDA)
Cap. 4 (Probabilidad y Estadística) → Cap. 5 (Preparación de datos para ML)

Notebook de Google Colab

El trabajo debe incluir:

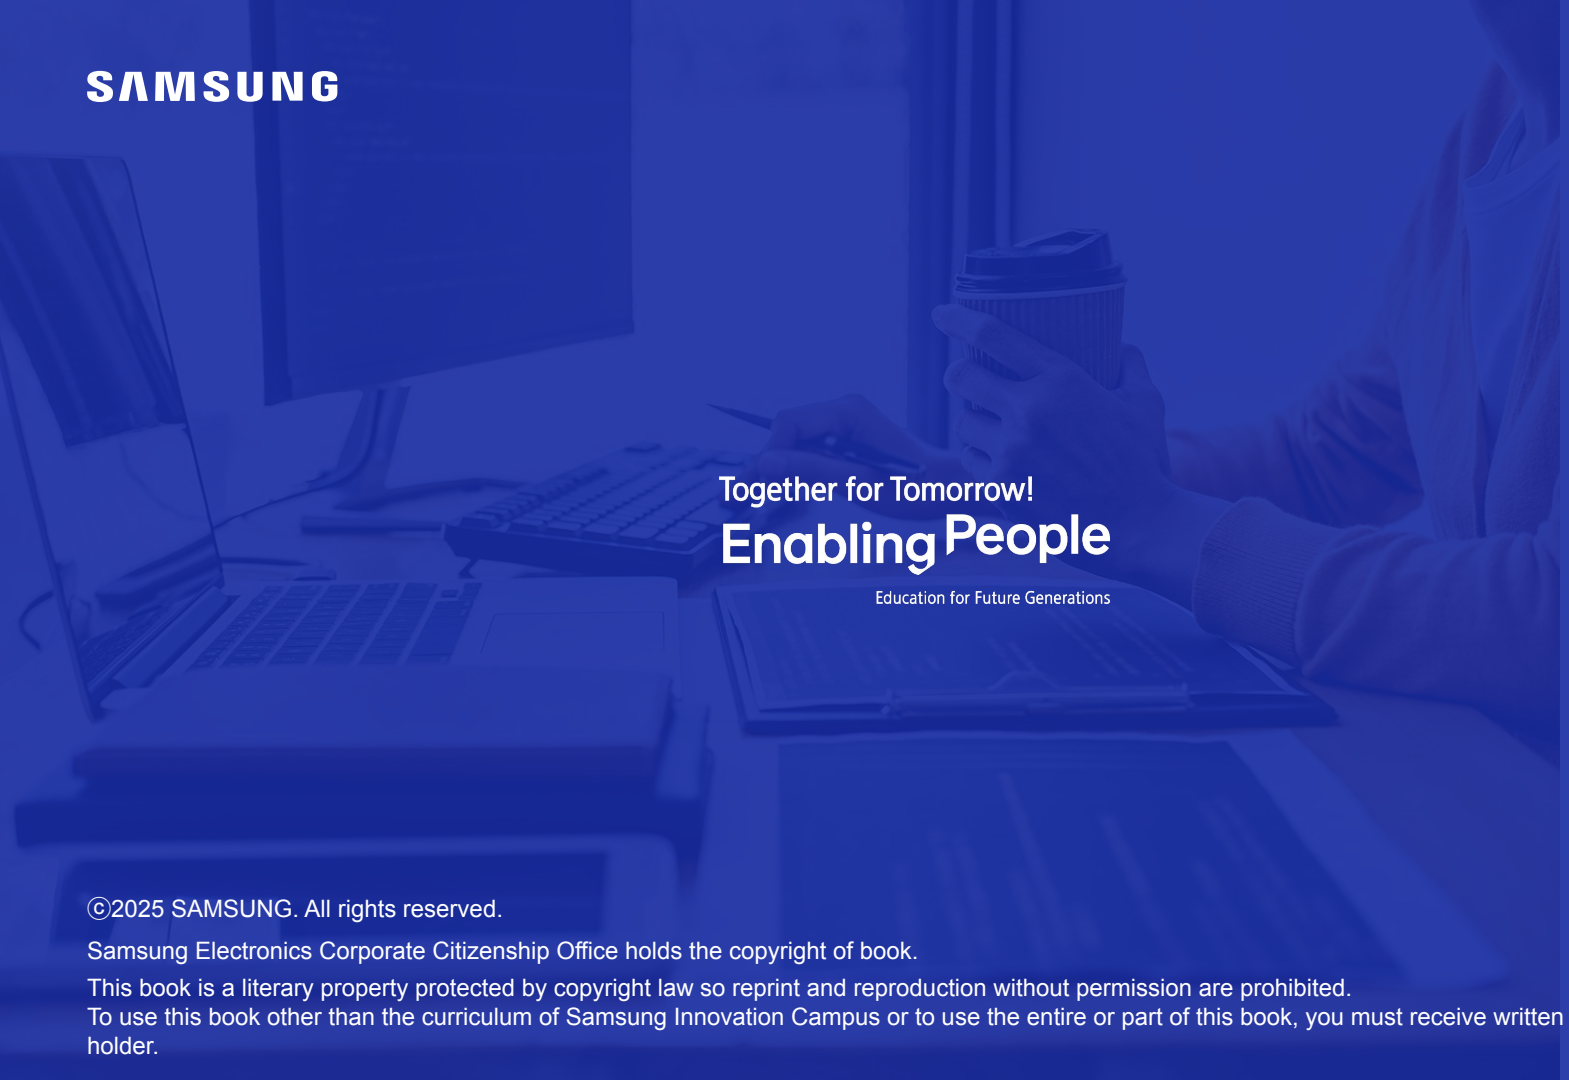
1. Dataset seleccionado y pregunta de investigación.
2. Descripción de la población, observaciones y variables.
3. Implementación de los cinco métodos de muestreo, o justificación de los no aplicables.
4. Tabla comparativa de tamaños y composición de las muestras.
5. Exploración de estructura, faltantes, duplicados y estadísticos descriptivos.
6. Cuatro visualizaciones pertinentes.
7. Comparación entre el dataset completo y las muestras.
8. Conclusión sobre representatividad, posibles sesgos y limitaciones.

Pregunta final

Si dos equipos utilizan el mismo dataset, pero seleccionan muestras diferentes, ¿pueden llegar a conclusiones estadísticas distintas?

¿Cómo podemos identificar cuál de las muestras representa mejor los datos originales?





ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.