SAMSUNG

Samsung Innovation Campus

Generative AI Module

Together for Tomorrow!
Enabling People
Education for Future Generations

Notas de Clase

Generative AI Module

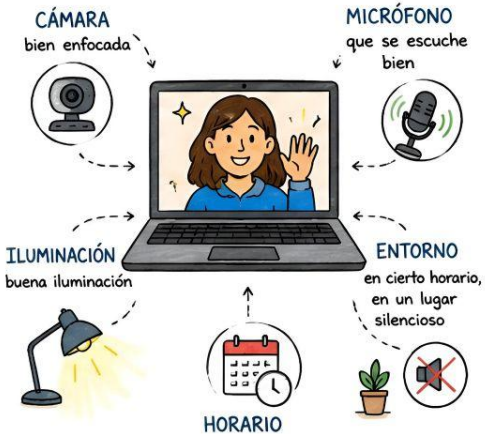
OBJETIVOS DEL CURSO

1 Se lleven como razonar un problema y saber cuando usar AI y cuando no.



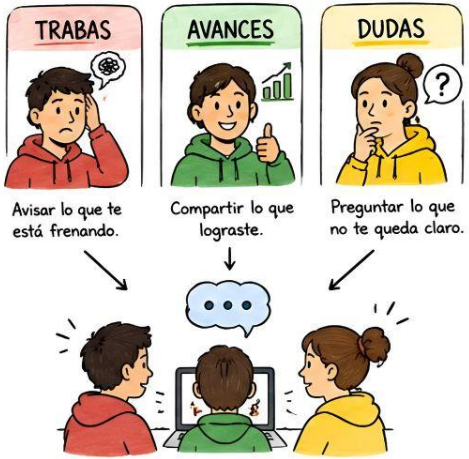
Primero pensar, después decidir.

2 Organizar su vida para tener meets, eso implica tener tu carta de presentacion en buenas condiciones:



Tu meet es tu carta de presentación. ¡Cuidala!

3 Poder comunicar trabas, avances y dudas a tiempo, es preferible equivocarse aca que con una deadline.



Comunicar a tiempo = mejores soluciones, menos estrés.

PENSAR. ORGANIZAR. COMUNICAR. = CRECER JUNTOS

1 Del dato al modelo: objetivos

P&E no es un prerrequisito “aparte”: es el lenguaje con el que razona ML.

Al terminar vas a poder:

1. Leer un dataset como una muestra de una distribución.
2. Justificar cada feature con un hallazgo estadístico del EDA.
3. Explicar qué supuesto probabilístico hace cada modelo.
4. Ver la validación como inferencia (errores Tipo I y II).
5. Reconocer leakage y drift como violaciones de supuestos.
6. Ubicar cualquier caso según tipo de dato, tarea y área de ML.



Puente P&E → ML

Descriptiva	Estimación	Inferencia	Distribución que cambia
↓	↓	↓	↓
EDA	Entrenar	Validar	Drift

2 El mapa del puente y los tres ejes

Del problema al modelo

ETAPA EN ML		CONCEPTO EN P&E
Dataset	↔	Muestra i.i.d. de una población
Feature / target	↔	Variable aleatoria X / condicional Y|X
EDA	↔	Estadística descriptiva
Feature Engineering	↔	Transformación de variables aleatorias
Entrenar	↔	Entimar parámetros (MLE / MAP)
Validar / comparar	↔	Estimar error / test de hipótesis
Producción	↔	Cambio en P(X) o en P(Y|X)

Los tres ejes para ubicar cualquier problema

1 TIPO DE DATO — ¿Qué variable aleatoria tenés?

- **Estructurado** — tablas, registros
- **Semi-estructurado** — JSON, logs, imágenes
- **No estructurado** — texto, audio, video

2 TAREA — ¿Qué distribución estimás?

- **Clasificación** — $P(Y=k \mid X)$
- **Regresión** — $E[Y \mid X]$
- **Detección de patrones** — $P(X)$ o $P(X \mid k)$
- **Inferencia generativa** — $P(X)$

3 ÁREA — ¿Qué supuestos son razonables?

ML clásico · Series de tiempo · Fraude · NLP · Visión · Recomendación · LLM



Puente P&E → ML

El tipo de dato define QUÉ variable aleatoria tenés;
la tarea define QUÉ distribución estimás;
el área define QUÉ supuestos son razonables.

3 Muestra, variables aleatorias y estimadores

El dataset es una muestra de una distribución

1. **Cada fila es una realización de** (X, Y).
   Suponemos que los datos de train son i.i.d. de una misma distribución $P(X, Y)$.
2. **Cada columna es una variable aleatoria** X_j.
   Puede ser numérica, categórica, ordinal, etc.
3. **Qué estimamos según la tarea:**
   - Regresión: $E[Y \mid X]$ (valor esperado).
   - Clasificación: $P(Y = k \mid X)$ (probabilidad de clase).
4. **Todo lo calculado en train es un estimador.**
   Tiene sesgo y varianza: media del scaler, mediana del imputador, tasa por categoría, coeficientes, métricas.
5. **Con pocos datos, los estimadores son ruidosos.**
   Necesitamos suficientes observaciones para generalizar.



Población (distribución generadora)

$P(X, Y)$

Muestra (dataset de train)

	X_1	X_2	⋯	X_p	Y
	20	3	⋯	1	0.8
	35	1	⋯	0	1.2
	28	4	⋯	1	1.0

Estimación (a partir de la muestra)

$\hat{\theta} = \text{estadístico}(X)$

- Sesgo
- Varianza
- Convergencia (Ley de los Grandes Números)
- Intervalos (TCL)

04 EDA: entender los datos para decidir

El Análisis Exploratorio de Datos (EDA) describe cómo se comportan las variables y orienta las transformaciones y features que vamos a crear.

¿Qué miramos?

- **Distribución de cada variable** (forma, centro, dispersión)
- **Relación entre variables** (correlación, patrones)
- **Valores atípicos** (errores o casos reales)
- **Datos faltantes** (magnitud y patrón)
- **Tipo de variable** (numérica, categórica, ordinal, texto, fecha)

Ejemplo: peso de patitos

El peso (g) de 20 patitos tiene una distribución asimétrica.



Relación con otra variable

El peso está relacionado con el alimento diario (g).



Hallazgos y decisiones

Hallazgo del EDA	Posible decisión en ML
Distribución asimétrica	Transformación (p.ej. log) o modelos robustos
Relación entre variables	Crear features (p.ej. razón, interacción, agregados)
Valores atípicos	Verificar errores, usar transformaciones o modelos robustos
Datos faltantes	Imputación (estrategia según el patrón de faltantes)
Variable categórica de alta cardinalidad	Agrupar, target encoding o embeddings (según el contexto)



Puente P&E → ML

El EDA usa **estadística descriptiva** (distribuciones, correlaciones, resúmenes) para **entender la muestra**. Sus hallazgos **guían la transformación de variables aleatorias** y la construcción de **features**.

5 Distribución de variables

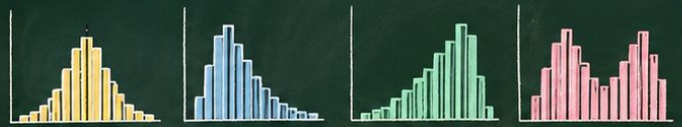
conocer la forma para decidir qué hacer

¿Por qué importa?

La forma de la distribución nos dice:

- qué estadísticos usar,
- qué transformaciones aplicar,
- qué modelos son razonables,
- dónde pueden aparecer outliers.

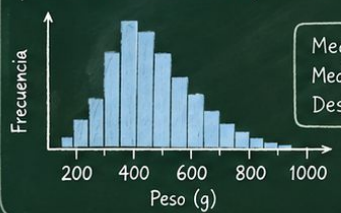
Formas más comunes



Simétrica	Asimétrica a la derecha	Asimétrica a la izquierda	Multimodal
media ≈ mediana	media > mediana	media < mediana	varios grupos

Ejemplo: peso de los patitos (g)

El histograma muestra una cola a la derecha: algunos patitos son mucho más pesados.



Media = 520
Mediana = 460
Desvío = 180

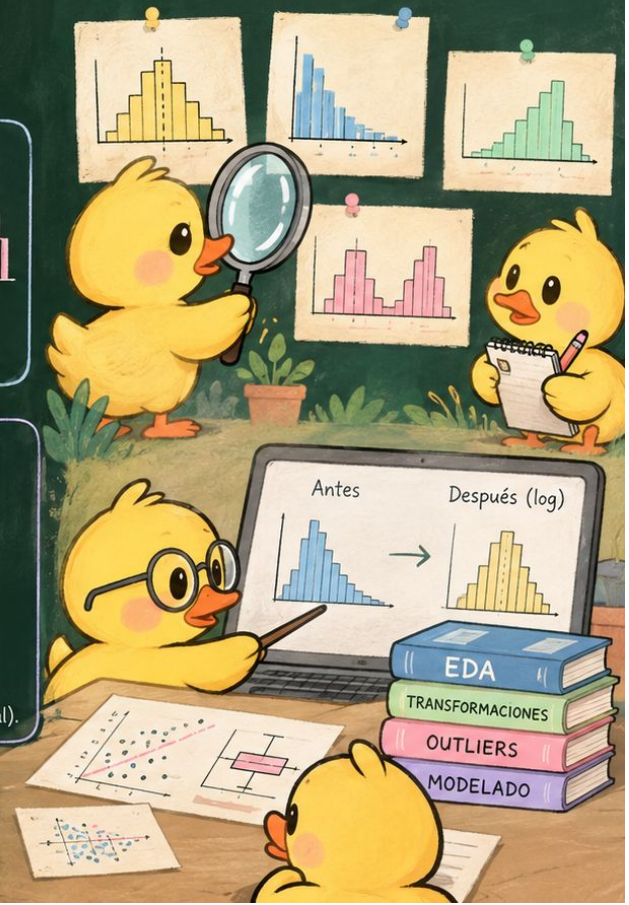
La media es mayor que la mediana por la cola derecha.

¿Qué podemos hacer?

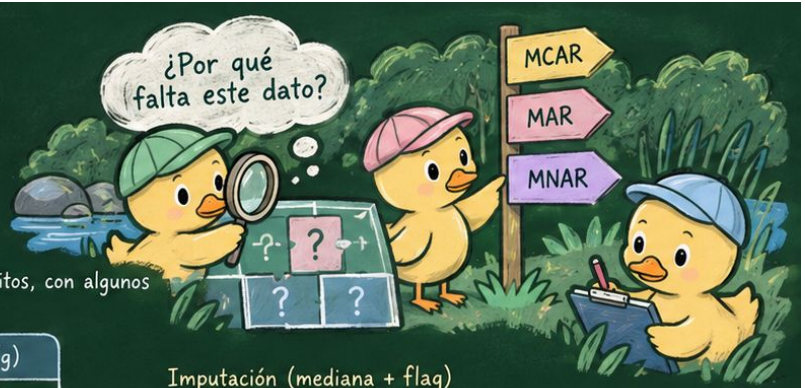
- **Transformación** (log, raíz)
  Reduce la asimetría.
- **Estadísticos robustos**
  Usar mediana, IQR.
- **Tratamiento de outliers**
  Winsorización, recorte o modelos robustos.
- **Segmentación**
  Si hay varios grupos (multimodal).

Puente P&E → ML

- Descriptiva: la forma de la distribución se estudia con histogramas, cuantiles y medidas de forma.
- Inferencia: la elección de transformaciones y estadísticos afecta los estimadores.
- En ML: condiciona el preprocesamiento, el tipo de modelo y la función de pérdida.



06 Datos faltantes: ¿qué hacer y cómo no introducir sesgos?



1. ¿Por qué hay faltantes?

- Error de registro (dato no cargado).
- No se midió (encuesta incompleta).
- No aplica (variable no corresponde).
- Valor sensible (el usuario no lo informa).

2. Mecanismos de faltantes

- **MCAR**: falta al azar (independiente de X e Y).
- **MAR**: depende de otras variables observadas.
- **MNAR**: depende del propio valor no observado.

3. Estrategias de imputación

- Variables numéricas: media, mediana, modelos de imputación (p. ej. KNN, regresión).
- Variables categóricas: categoría "desconocido" o imputación por moda/modelo.
- MNAR: considerar un indicador (flag) y analizar sensibilidad.
- Siempre ajustar la imputación solo en el set de entrenamiento (evitar leakage).

4. Ejemplo simple

Tenemos el peso (g) de varios patitos, con algunos valores faltantes.

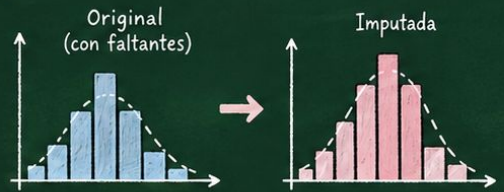
Patito	Alimento (g)	Peso (g)
A	20	420
B	30	—
C	40	510
D	—	530
E	60	—

Imputación (mediana + flag)

Patito	Alimento (g)	Peso (g)	Peso_faltante
A	20	420	0
B	30	515	1
C	40	510	0
D	45	530	1
E	60	515	1

5. Efecto en la distribución

Imputar cambia la distribución. Hay que verificar que sea razonable.



Puente P&E → ML

El mecanismo de faltantes es un supuesto sobre la distribución P(X, Y). La imputación es un estimador de los valores no observados. Si se ajusta con toda la data, se filtra información del set de test (leakage).

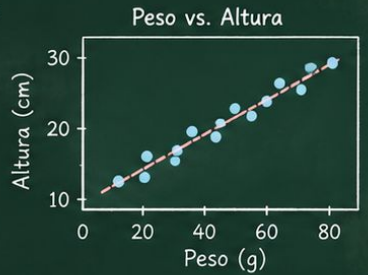
07 Variables correlacionadas

Información repetida y qué hacer con ella

1 ¿Qué es? Dos o más variables están correlacionadas cuando contienen información muy similar.

Se mide con la correlación de Pearson:

$$r_{X,Z} = \frac{\text{cov}(X,Z)}{\sigma_X \sigma_Z} \qquad -1 \le r \le 1$$



2 Ejemplo En un dataset de patitos:

- X = peso (g)
- Z = altura (cm)

r = 0,95 → alta correlación positiva

Matriz de correlación (ejemplo)

	Peso	Altura	Largo de ala	Edad
Peso	1,00	0,95	0,85	0,20
Altura	0,95	1,00	0,80	0,18
Largo de ala	0,85	0,80	1,00	0,15
Edad	0,20	0,18	0,15	1,00

3 ¿Cómo detectarla?

- Matriz de correlación (numéricas)
- Gráfico de dispersión

Valores |r| > 0,8 suelen indicar información redundante.

4 ¿Qué hacer?

- Conservar la más interpretable (según el dominio).
- Combinar (PCA) si varias aportan lo mismo.
- Usar regularización (Lasso/Ridge) en modelos lineales.
- En árboles o boosting, suele ser menos problemático.



Puente P&E → ML

La correlación es una medida de dependencia **lineal** entre variables aleatorias. En ML, variables fuertemente correlacionadas aportan información redundante: pueden afectar la interpretación de modelos lineales y aumentar la varianza de los estimadores, aunque suelen tener menor impacto en modelos de árboles.



Slide 08. Variables categóricas de alta cardinalidad: target encoding y suavizado bayesiano

① El problema

Variables categóricas con muchas categorías (ID de usuario, producto, ubicación) no se pueden one-hot encodear: generan miles de columnas, modelos inestables y riesgo de sobreajuste.

② La idea

Reemplazar cada categoría por una estimación de la media del target: $\hat{\mu}_c = \frac{1}{n_c}\sum_{i} y_i$

En clasificación es la tasa: $\hat{p}_c = \frac{1}{n_c}\sum_{i} y_i$ (proporción de clase positiva).

③ El problema de la media cruda

Con pocas observaciones, la media es ruidosa. Ejemplo (clasificación):

Categoría	n	# positivos	Tasa observada
A	100	30	0,30
B	10	5	0,50
C	2	2	1,00

La categoría C parece perfecta, pero es solo por tener muy pocos datos.

④ Suavizado bayesiano

Combinamos la media de la categoría con la media global (prior) según cuántos datos tiene:

$$\tilde{\mu}_c = \underbrace{\frac{n_c}{n_c+\alpha}\hat{\mu}_c}_{\text{información de la categoría}} + \underbrace{\frac{\alpha}{n_c+\alpha}\mu_0}_{\text{información global (prior)}}$$

α controla cuánto confiamos en la media global. Con pocos datos (n_c pequeño), $\tilde{\mu}_c$ se acerca a μ_0. Con muchos datos, $\tilde{\mu}_c$ se acerca a $\hat{\mu}_c$.

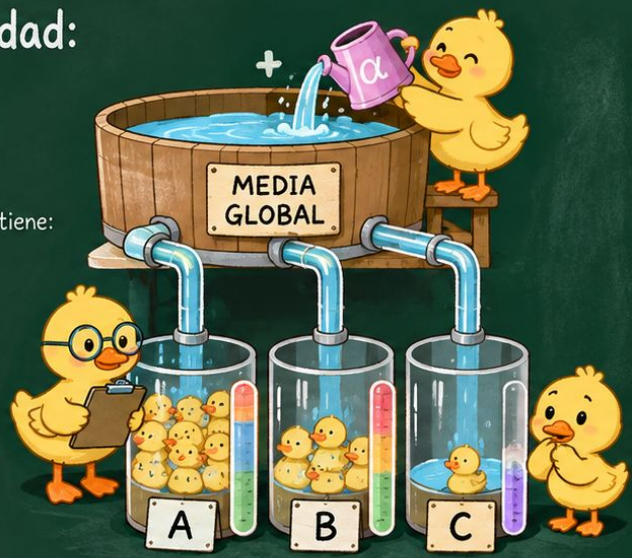
⑤ Ejemplo numérico

Supongamos $\mu_0 = 0{,}20$ y $\alpha = 10$.

Categoría	n	Tasa observada	Tasa suavizada
A	100	0,30	0,29
B	10	0,50	0,35
C	2	1,00	0,33

⑥ Buenas prácticas

- Calcular el encoding solo con el train (evita leakage).
- Usar validación cruzada out-of-fold para obtener valores sin "ver" el target de la misma fila.
- Elegir α por validación (puede variar por dataset).
- Para regresión, el mismo esquema aplica a la media del target.



Puente P&E → ML

- Estimación bayesiana = combinar información muestral y un prior.
- Sesgo-varianza: el suavizado reduce la varianza de estimadores con pocos datos.
- En ML, és esto se usa como una transformación de variables para mejorar la generalización.

09 Feature Engineering: transformaciones que cuentan

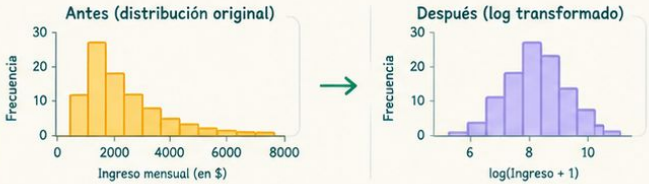
No se trata de aplicar transformaciones por receta, sino de usar lo que vimos en el EDA para mejorar la relación entre las variables y el modelo.

1 Transformaciones comunes y su sentido

Transformación	¿Qué problema resuelve?	Ejemplo
Log / Box-Cox	Reduce asimetría y estabiliza la varianza.	$x' = \log(x + 1)$
Binarización	Convierte a categorías (útil en reglas o modelos simples).	$x' = 1$ si $x > 0$, 0 si no
Escalado	Evita que unas variables dominen a otras.	$z = (x - \mu) / \sigma$
Interacciones	Modela relaciones no lineales o efectos combinados.	$x_1 \cdot x_2$, x_1^2

2 Ejemplo: transformar una variable asimétrica

Supongamos que tenemos el ingreso mensual (en $) de los patitos.



3 ¿Cómo decidir qué transformación usar?

1. **Mirá el EDA:**
   - ¿Hay asimetría? → log o Box-Cox.
   - ¿Hay muchas categorías? → binarización o target encoding.
   - ¿Hay variables en distintas escalas? → escalado.
   - ¿Se observan relaciones no lineales? → interacciones.
2. **Probá y compará:**
   Evaluá el cambio en la distribución y en la performance del modelo (validación).

Idea clave

Las transformaciones no "arreglan" todos los problemas. La elección depende del patrón que vimos en el EDA y del modelo que vamos a usar.

4 Puente P&E → ML

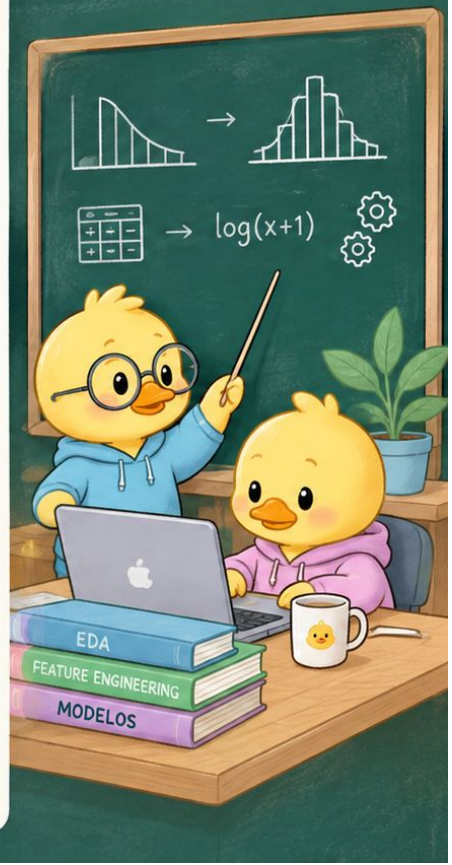
El EDA nos muestra la forma de la distribución y las relaciones entre variables. Esa información guía las transformaciones (feature engineering), que mejoran la capacidad del modelo para aprender.

EDA (patrones) → Feature Engineering (transformaciones) → Mejor modelo (más estable y preciso)



Puente P&E → ML

El EDA nos muestra la forma de la distribución y las relaciones entre variables.
Esa información guía las transformaciones (feature engineering), que mejoran la capacidad del modelo para aprender.



Slide 10

Feature Engineering: unir, crear y seleccionar

De variables crudas a representaciones más informativas

1. Combinar información

- Crear variables que capturen relaciones relevantes entre columnas.
- Ejemplos:
  - ratios: ingreso / gasto
  - diferencias: fecha_(hoy) – fecha_(evento)
  - interacciones: $X_1 \times X_2$

2. Variables de tiempo

- Convertir fechas en información útil.
- Componentes: año, mes, día, día de la semana, estacionalidad.
- Ejemplos:
  - antigüedad en días
  - es fin de semana
  - seno y coseno para estacionalidad

3. Variables categóricas

- Codificar según cardinalidad.
  - Baja: one-hot encoding.
  - Media/alta: target encoding con suavizado o agrupación.
  - Ordinales: respetar el orden.

4. Variables de texto o libre

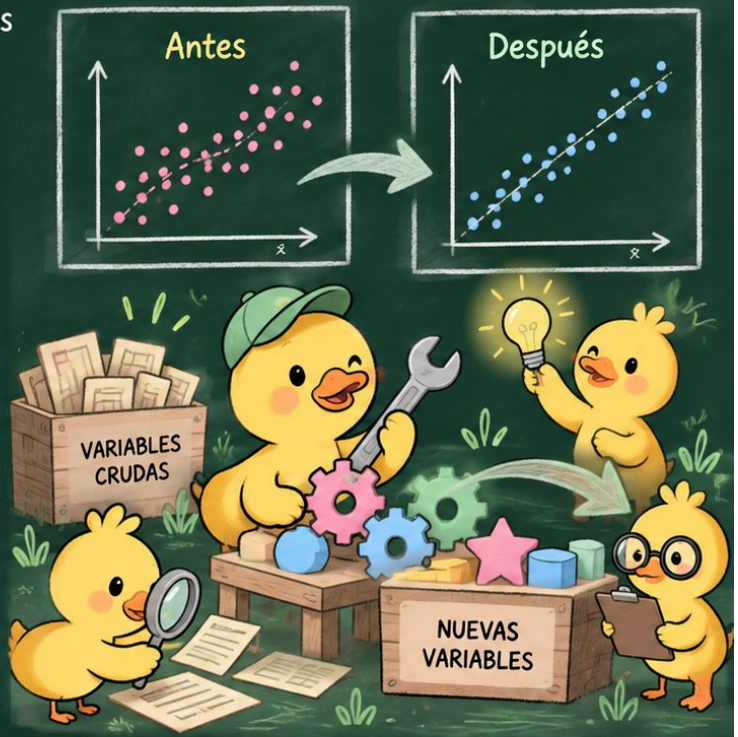
- Convertir texto en representaciones numéricas.
  - Bag of words / TF-IDF.
  - Embeddings.
  - Variables derivadas (longitud, conteos).

5. Seleccionar y reducir

- Eliminar variables irrelevantes o redundantes.
- Métodos: correlación, VIF, selección basada en modelos (Lasso, árboles).
- Objetivo: mejorar generalización y simplicidad del modelo.

Ejemplo integrado

Característica cruda	Nueva variable
fecha_compra	antigüedad_días
ingreso, gasto	ratio_ingreso_gasto
edad, ingreso	interacción_edad_ingreso
descripción	embedding_texto



Puente P&E ⟶ ML

Transformar y seleccionar variables es aplicar funciones a variables aleatorias para construir nuevas variables con mayor poder explicativo de Y.

En P&E estudiamos transformaciones y correlaciones.
En ML usamos estas herramientas para que el modelo aprenda mejor y generalice.

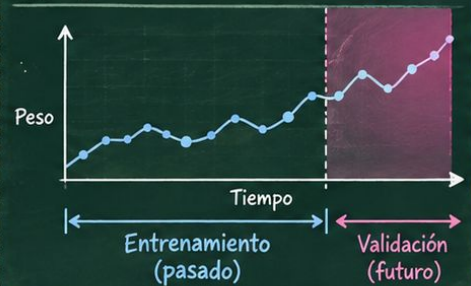
11. El tiempo cambia las reglas

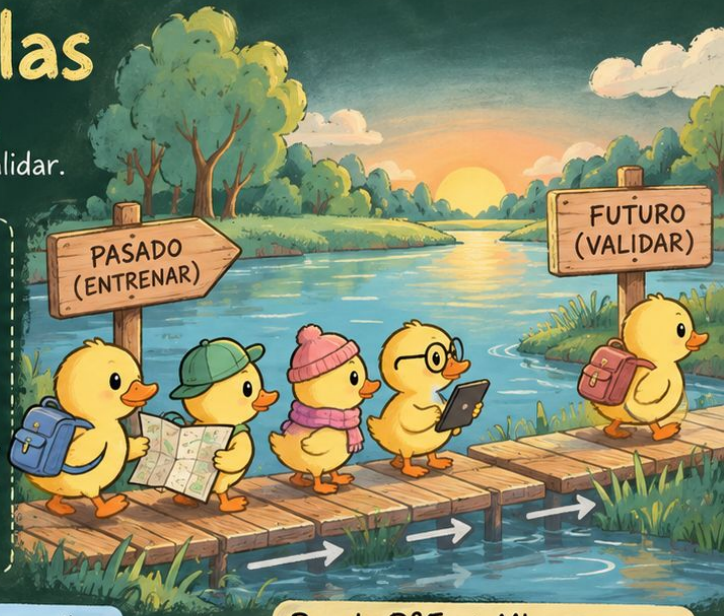
En datos temporales, las observaciones no son i.i.d. y la distribución puede cambiar. Debemos respetar el orden temporal al entrenar y validar.

¿Qué pasa en una serie temporal?

- Las observaciones están **ordenadas** en el tiempo.
- Puede haber **autocorrelación** y **estacionalidad**.
- La distribución puede **cambiar** (tendencia, nivel, varianza).
- No se puede mezclar pasado y futuro al entrenar.

Ejemplo: alimento diario vs. peso



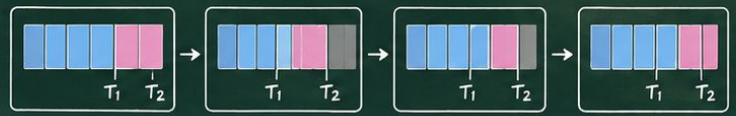


Estrategia de validación

- **Split temporal**: una sola división train (pasado) / test (futuro).
- Validación en ventana deslizante (walk-forward).
- Usar solo información disponible hasta el momento t.
- Evaluar estabilidad del modelo en diferentes períodos.

Validación en ventana deslizante (walk-forward)

1. Entrenar en $1 \ldots T_1$
2. Validar en $T_1{+}1 \ldots T_2$
3. Avanzar la ventana
4. Repetir



Puente P&E → ML

- Las series temporales violan el supuesto i.i.d. de muchas técnicas.
- Conceptos de P&E como autocorrelación, estacionalidad y cambio de distribución explican por qué el tiempo importa.
- La validación temporal es una forma de estimar el error fuera de muestra bajo las condiciones reales de uso.

11. El tiempo cambia las reglas

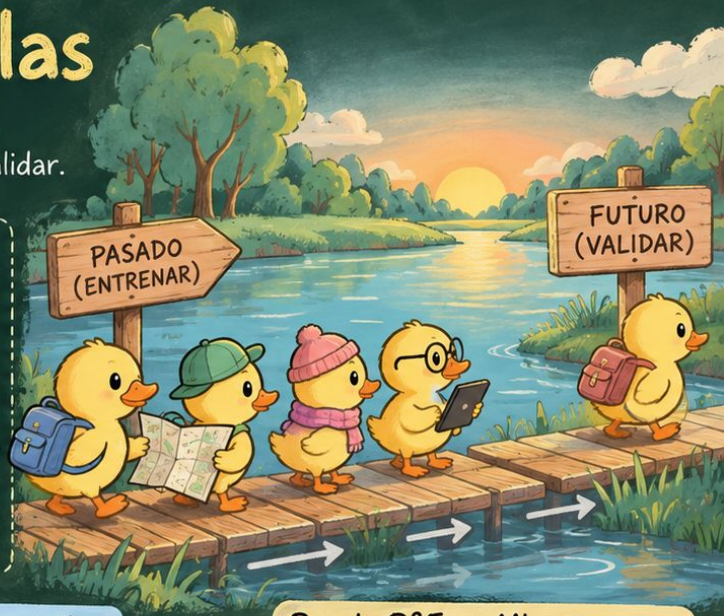
En datos temporales, las observaciones no son i.i.d. y la distribución puede cambiar. Debemos respetar el orden temporal al entrenar y validar.

¿Qué pasa en una serie temporal?

- Las observaciones están **ordenadas** en el tiempo.
- Puede haber **autocorrelación** y **estacionalidad**.
- La distribución puede **cambiar** (tendencia, nivel, varianza).
- No se puede mezclar pasado y futuro al entrenar.

Ejemplo: alimento diario vs. peso



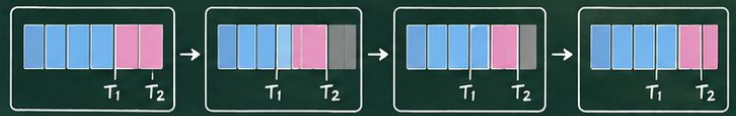


Estrategia de validación

- **Split temporal**: una sola división train (pasado) / test (futuro).
- Validación en ventana deslizante (walk-forward).
- Usar solo información disponible hasta el momento t.
- Evaluar estabilidad del modelo en diferentes períodos.

Validación en ventana deslizante (walk-forward)

1. Entrenar en $1 \ldots T_1$
2. Validar en $T_1{+}1 \ldots T_2$
3. Avanzar la ventana
4. Repetir



Puente P&E → ML

- Las series temporales violan el supuesto i.i.d. de muchas técnicas.
- Conceptos de P&E como autocorrelación, estacionalidad y cambio de distribución explican por qué el tiempo importa.
- La validación temporal es una forma de estimar el error fuera de muestra bajo las condiciones reales de uso.

Slide 12

Leakage: cuando el futuro se filtra en el modelo

Un modelo solo debe usar información disponible en el momento de la predicción.
Si usamos datos del futuro, sobrestimamos su desempeño.

¿Qué es el leakage?

Ocurre cuando una variable o transformación contiene **información del futuro** respecto del momento de la predicción.

El modelo aprende patrones que no estarán disponibles en producción, por eso parece funcionar mejor de lo que realmente lo hará.

Ejemplos comunes

- Usar información del target o variables derivadas del futuro.
- Calcular estadísticas (media, tasa) con todo el dataset, incluyendo test.
- Usar variables que solo existen después del evento (ej.: resultados, aprobaciones, cierres).
- Transformaciones que miran hacia adelanto (ej.: rolling mal definido).

Ejemplo: predicción de churn

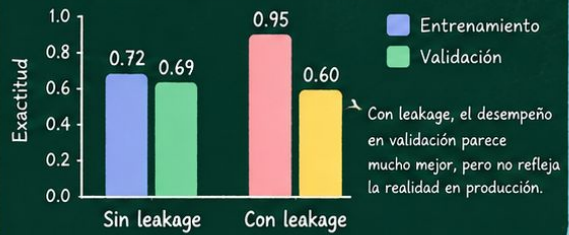
Problema:
Queremos predecir si un cliente cancelará el servicio al final del mes.

Dos conjuntos de variables:

Sin leakage (solo información pasada)		Con leakage (incluye información futura)	
Uso en los últimos 3 meses	✓	Pago del próximo mes	✗
Cantidad de reclamos	✓	Estado de cancelación	✗
Antigüedad del cliente	✓	Total gastado al final del año	✗
Plan contratado	✓	Resultado de una encuesta posterior	✗



Impacto en la validación



Con leakage, el desempeño en validación parece mucho mejor, pero no refleja la realidad en producción.

¿Cómo prevenirlo?

- ☑ Definir claramente el momento de la predicción.
- ☑ Usar solo información disponible hasta ese momento.
- ☑ Calcular transformaciones dentro de cada fold de validación.
- ☑ Hacer validación temporal cuando hay orden cronológico.
- ☑ Revisar que ninguna variable sea una consecuencia del target.

Puente P&E → ML

En estadística trabajamos con muestras **i.i.d. y sin sesgos.**

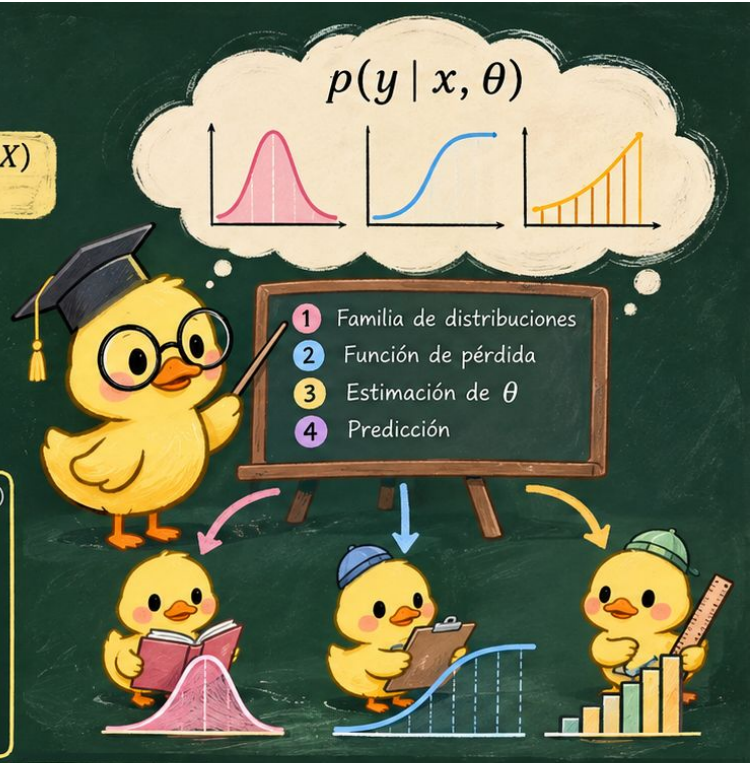
El leakage viola este supuesto, porque introduce información que no estaría **disponible para nuevas observaciones**, generando una estimación optimista del error.

13 Modelos probabilísticos; una misma idea, distintas tareas

Un modelo en ML define una distribución para Y (o para $Y \mid X$) con algunos parámetros θ, y los estima a partir de los datos.

Idea general

1. Elegimos una familia de distribuciones $p(y \mid x, \theta)$
2. Definimos una función de pérdida (derivada de la verosimilitud).
3. Estimamos θ con los datos (entrenamos).
4. Usamos el modelo para predecir o generar nuevas observaciones.



Tres ejemplos

Regresión (variable continua)

$Y \mid X \sim \mathcal{N}(\mu, \sigma^2)$

$\mu = \beta_0 + \beta_1 x$



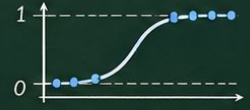
Predice el valor esperado

$E[Y \mid X] = \mu$

Clasificación (variable discreta)

$Y \mid X \sim \text{Bernoulli}(p)$

$p = \sigma(\beta_0 + \beta_1 x)$



Predice una probabilidad

$P(Y = 1 \mid X) = p$

Conteo (eventos raros o frecuentes)

$Y \mid X \sim \text{Poisson}(\lambda)$

$\log(\lambda) = \beta_0 + \beta_1 x$



Predice la tasa esperada

$E[Y \mid X] = \lambda$

Interpretación

- Los parámetros θ controlan la forma de la distribución.
- Las predicciones incluyen **incertidumbre** (varianza).
- Un buen modelo tiene supuestos compatibles con los datos y con el objetivo del problema.

PUENTE P&E → ML

- Tal como en estadística elegimos una distribución para modelar un fenómeno y estimamos sus parámetros, en ML hacemos lo mismo para $Y \mid X$.
- La función de pérdida suele ser la **log-verosimilitud** (o una aproximación) y la estimación se realiza con MLE o variantes (MAP, regularización).

Verosimilitud Estadística

Mide qué tan compatibles son los datos observados con un modelo estadístico y sus parámetros.



1 Probabilidad vs. verosimilitud

Ambas parten de la misma expresión:

$$P(X = x \mid \theta)$$

Pero cambia su interpretación:

Concepto	Conocemos	Buscamos
Probabilidad (visión clásica)	Parámetros del modelo (θ)	Probabilidad de observar datos (x)
Verosimilitud (likelihood)	Datos observados (x)	Parámetros que mejor explican los datos (θ)

Probabilidad:

- Fijamos θ y variamos x.



Verosimilitud:

- Fijamos x y variamos θ.



$$L(\theta \mid x) = P(X = x \mid \theta)$$

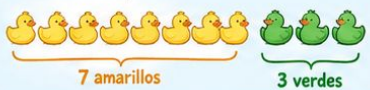
Para variables continuas se usa la función de densidad en lugar de una probabilidad puntual.

2 Ejemplo con patitos: distribución binomial

Una máquina produce patitos amarillos y verdes.
Desconocemos la proporción real de patitos amarillos, p.



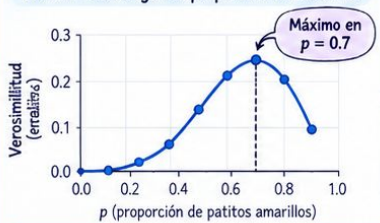
Observamos 10 patitos:



La verosimilitud binomial es:

$$L(p) = \binom{10}{7} p^7 (1-p)^3$$

Verosimilitud según la proporción de amarillos



La curva alcanza su máximo cuando:

$$\hat{p} = \frac{7}{10} = 0.7$$

El parámetro más verosímil es que el 70 % de los patitos sean amarillos.

Estimación por máxima verosimilitud (MLE):

$$\hat{\theta}_{MLE} = \arg\max_{\theta} L(\theta \mid x)$$

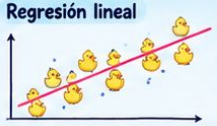
Importante: que $p = 0.7$ maximice la verosimilitud no significa que exista un 70 % de probabilidad de que ese parámetro sea el verdadero.



3 Relación con Machine Learning

Muchos modelos de ML se entrenan buscando los parámetros que maximizan la verosimilitud de los datos (o minimizando su negativo).

Regresión lineal



- Suponemos errores gaussianos independientes.
- Minimizar MSE equivale a **maximizar la verosimilitud.**

$$y = \beta_0 + \beta_1 x + \varepsilon \qquad \varepsilon \sim N(0, \sigma^2)$$

Regresión logística



- Modelo Bernoulli.
- Minimizar binary cross-entropy equivale a maximizar la log-verosimilitud.

$$P(y = 1 \mid x) = \sigma(\beta_0 + \beta_1 x)$$

Naive Bayes



- Utiliza verosimilitudes de las características condicionadas a cada clase.
- Combinadas con probabilidades a priori mediante Bayes.

4 Log-verosimilitud y función de pérdida

Log-verosimilitud:

$$\ell(\theta) = \log L(\theta \mid x)$$

- Es más estable numéricamente.
- Convertir productos en sumas.

Función de pérdida en ML:

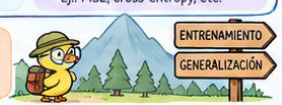
$$Loss = -\log L(\theta \mid x)$$

- Muchos algoritmos minimizan el negativo de la log-verosimilitud.
- Ej.: MSE, cross-entropy, etc.

El puente entre Estadística y ML

- En estadística buscamos parámetros que **expliquen** los datos observados.
- En ML usamos esa misma idea para ajustar modelos mediante **funciones de pérdida.**

! Maximizar la verosimilitud sobre los datos de entrenamiento no garantiza que el modelo generalice bien a datos nuevos. Necesitamos validación (e.g., datos de test, cross-validation).



14 Entrenar = máxima verosimilitud

Aprender un modelo es estimar los parámetros que hacen más probables los datos observados.

1 Planteamos un modelo probabilístico

- Asignamos una distribución a $Y \mid X$ con parámetros θ.
- Ejemplo (regresión lineal):

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

2 Escribimos la verosimilitud

- La probabilidad de observar todos los datos $\{(x_i, y_i)\}_{i=1}^n$ como función de θ.
- Para el ejemplo:

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right)$$

3 Optimizamos (equivalente a minimizar una pérdida)

- Maximizamos L o, más fácil, su logaritmo.
- En este caso es equivalente a minimizar el Error Cuadrático Medio (MSE):

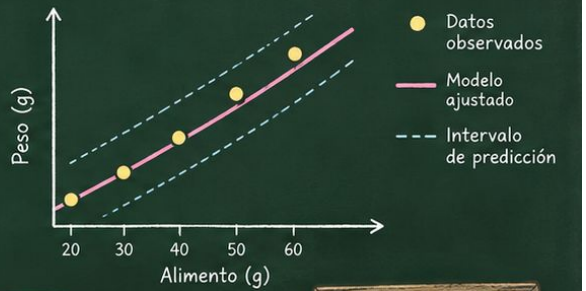
$$\hat{\beta}_0, \hat{\beta}_1 = \arg\min_{\beta_0, \beta_1} \frac{1}{n} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

4 Obtenemos predicciones e incertidumbre

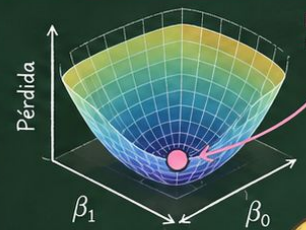
- Predicción puntual: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.
- Distribución de la predicción: $\hat{Y} \mid X = x \sim \mathcal{N}(\hat{\beta}_0 + \hat{\beta}_1 x, \sigma^2)$.
- Podemos construir intervalos de predicción: $\hat{y} \pm 1{,}96 \cdot \sigma$ (aprox. 95%)

Ejemplo con datos de patitos

Alimento (g)	Peso (g)
20	420
30	455
40	475
50	520
60	535



Paisaje de la función de pérdida





Puente P&E → ML



- Estimar parámetros de una distribución (P&E) ↔ entrenar un modelo (ML).
- La máxima verosimilitud conecta ambos: elegir los parámetros que hacen más probables los datos.
- La función de pérdida es (en muchos modelos) la log-verosimilitud con otro nombre.
- Las predicciones van acompañadas de incertidumbre, igual que en inferencia estadística.

15 Modelo lineal: ¿qué supone y qué estima?

La idea

El modelo lineal relaciona X con Y mediante una combinación lineal de variables:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

donde ε es un error con media 0 y varianza σ^2.

Supuestos principales

1. Relación lineal en los parámetros.
2. Errores con media 0 y varianza constante (homoscedasticidad).
3. Errores independientes.
4. Sin multicolinealidad perfecta.
5. (Para inferencia) Errores aproximadamente normales.

¿Qué estima?

Encuentra los coeficientes $\hat{\beta}$ que minimizan la suma de errores cuadráticos (MSE):

$$\hat{\beta} = \arg\min_{\beta} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

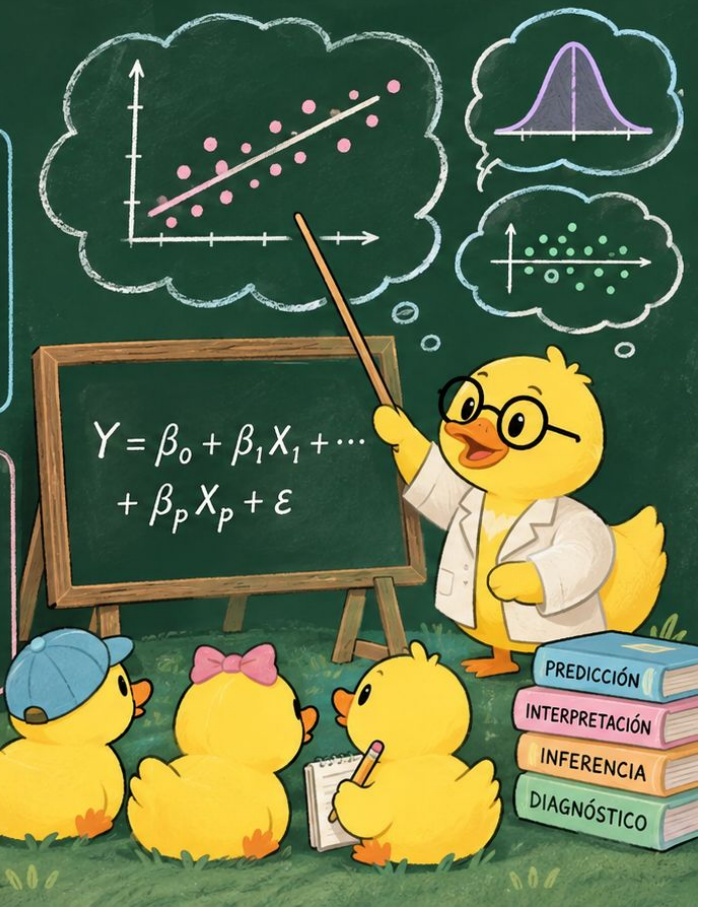
Equivale a máxima verosimilitud si $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

¿Qué nos da?

- Predicciones: $\hat{y} = X\hat{\beta}$.
- Interpretación: cada β_j es el cambio promedio en Y por una unidad de X_j, manteniendo las demás constantes.
- Medidas de ajuste: MSE, R^2.
- Incertidumbre: errores estándar e intervalos para los coeficientes.

Puente P&E → ML

Estimación de parámetros (OLS) → - entrenar un modelo.
Supuestos del modelo → - hipótesis sobre la distribución de los errores.
Inferencia de β → - interpretar y cuantificar incertidumbre.
Diagnóstico de residuos → validar si los supuestos son razonables.



Slide 16

Modelos de conjunto: muchos modelos, una mejor predicción

Idea central

- Combinan muchos modelos simples para reducir error y mejorar la generalización.
- Cada modelo aprende un patrón distinto de los datos.
- Al combinarlos, se reduce la **varianza**, el **sesgo** o ambos.

Principales enfoques

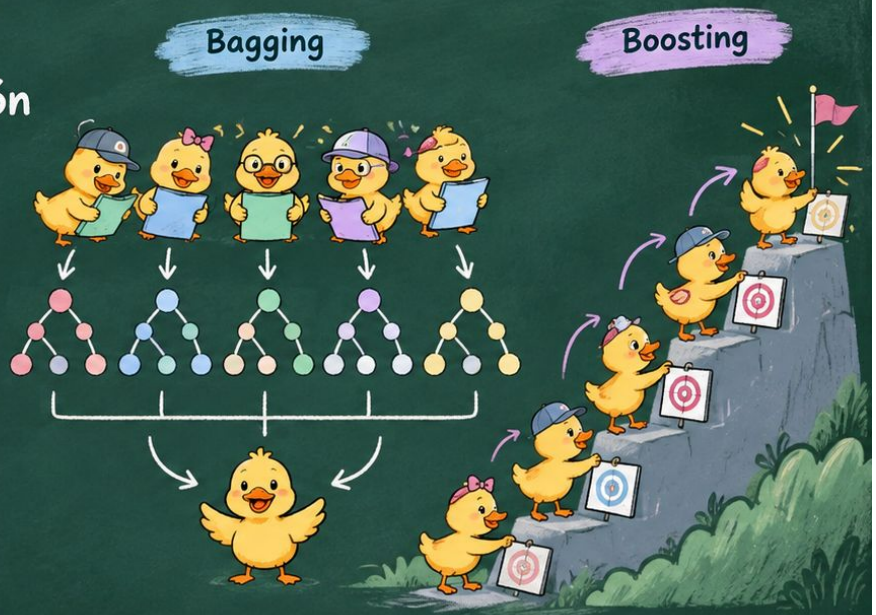
- **Bagging** (ej. Random Forest): entrena muchos modelos en muestras distintas y promedia sus predicciones.
- **Boosting** (ej. Gradient Boosting): entrena secuencialmente, cada modelo corrige los errores del anterior.
- **Resultado:** menor error de generalización que un modelo individual (típicamente baja la varianza y puede reducir el sesgo).

Ejemplo intuitivo

Predecimos si un patito tendrá sobrepeso (sí/no) usando 5 árboles.
Cada árbol mira una muestra distinta de los datos y votan.
La predicción final es la clase con más votos.

- **Predicciones de los árboles:**





Puente P&E → ML

- **Combinación de estimadores:** el promedio de varios modelos reduce la varianza (para modelos poco correlacionados).
- Bagging ≈ bootstrap + agregación de estimadores.
- Boosting ≈ construcción secuencial que reduce el sesgo.
- Se apoya en los conceptos de **sesgo**, **varianza** y error de generalización.

17 Validación = inferencia sobre el error

Evaluamos si el modelo generaliza y si la mejora es real.

1 Estimamos el error de generalización

- Dividimos los datos: train / valid (o cross-validation).
- La métrica en valid es un estimador del error en datos nuevos.

2 Cuantificamos la incertidumbre

- Usamos el TCL (o bootstrap) para construir intervalos de confianza de la métrica.
- Ejemplo: exactitud = 0.82 con IC 95% [0.78, 0.86].

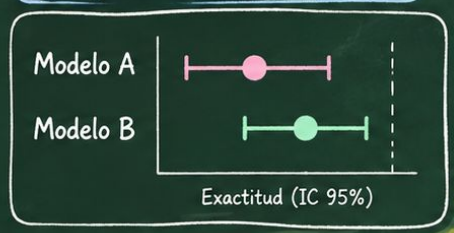
3 Comparamos modelos como un test de hipótesis

- H_0: no hay diferencia real entre modelos.
- Si los intervalos se superponen mucho, la mejora puede ser solo ruido.

4 Errores Tipo I y Tipo II en ML

- Tipo I: declarar "mejor" un modelo que no lo es.
- Tipo II: no detectar una mejora real.
- Elegimos el riesgo aceptable según el problema.

Ejemplo: comparar dos modelos

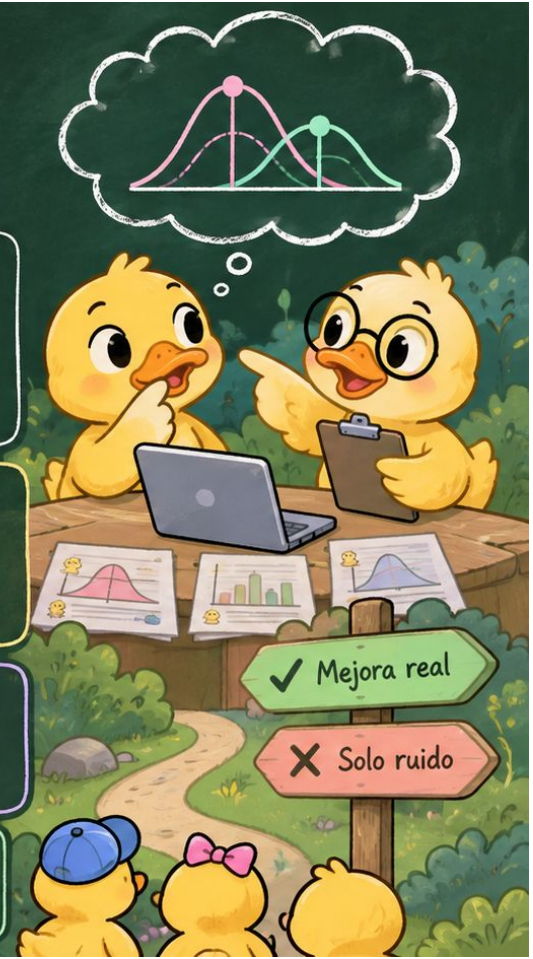


Interpretación

- Si los IC se solapan: no hay evidencia de que uno sea mejor.
- Si no se solapan: la diferencia es estadísticamente significativa.

Otras métricas

- Clasificación: exactitud, F1, AUC.
- Regresión: MAE, RMSE.
- Reportar siempre la incertidumbre (IC o bootstrap).



Puente P&E → ML

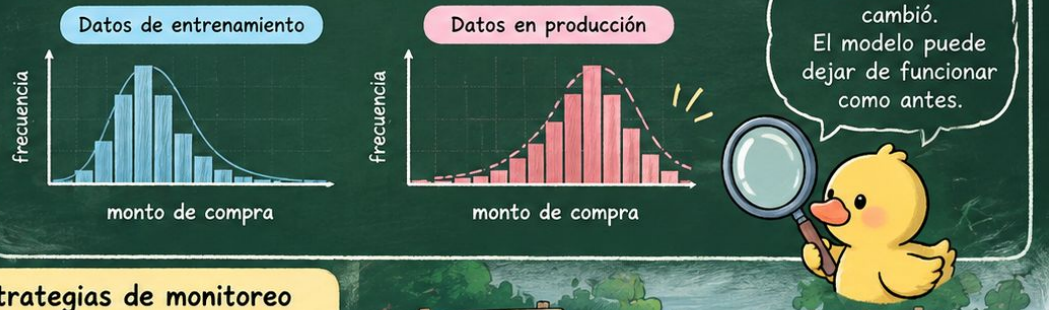
En estadística, usamos test de hipótesis e intervalos para decidir si un efecto es real. → En ML, usamos las mismas ideas para decidir si un modelo generaliza mejor y por cuánto.

18. De la validación a la producción: drift, monitoreo y decisiones

¿Qué puede cambiar?

- **P(X):** las características de los datos.
  Ej.: cambia la distribución de edades.
- **P(Y | X):** la relación entre **X e Y.**
  Ej.: cambia el comportamiento de los clientes.
- **Proceso de predicción:** diferencias entre entrenamiento y producción.
  Ej.: otras reglas de negocio o datos incompletos.

Ejemplo: drift en la distribución de una variable

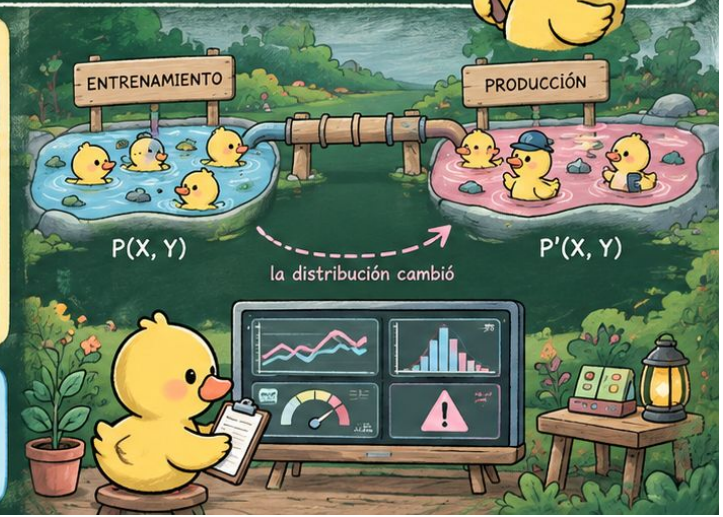


Tipos de drift

Covariate shift	Cambia P(X), pero P(Y | X) se mantiene.
Concept shift	Cambia P(Y | X). La relación entre variables ya no es la misma.
Training-serving skew	Los datos en producción difieren de los usados en entrenamiento (por procesos, reglas o latency).

Estrategias de monitoreo

- Monitorear la distribución de variables clave.
- Seguir métricas de performance en el tiempo.
- Definir umbrales y alertas.
- Reentrenar o ajustar cuando se detecta drift.



Puente P&E → ML

En estadística vimos que una estimación vale bajo ciertos supuestos sobre la población. En producción, esos supuestos pueden dejar de cumplirse.
Drift = cambio en la distribución = violación de supuestos.
Monitorear es verificar que el modelo siga siendo válido para la nueva distribución.

19 Tipos de datos: cómo define qué variable aleatoria tenés

1. Estructurado

Filas y columnas con tipos claros.

id	edad	ingresos	compró
1	28	1200	1
2	35	950	0
3	42	2000	1
...	...	...	...

- Variables numéricas, categóricas, binarias, fechas.
- Representa variables aleatorias de soporte finito o continuo.

2. Semi-estructurado

Tiene una estructura flexible.

```
{
   "usuario": 123,
   "dispositivo": "móvil",
   "ubicación": {
      "lat": -34.6,
   }   "lon": -58.4
}
```

- Ejemplos: JSON, XML, logs, datos de sensores.
- Contiene variables anidadas, listas o de longitud variable.
- Se modela como variables aleatorias estructuradas.

3. No estructurado

Sin formato fijo, alta complejidad.



- Ejemplos: texto libre, imágenes, audio, video.
- Representa variables aleatorias de alta dimensión (píxeles, palabras, frecuencias).
- Requiere representaciones especiales (embeddings, features aprendidas).

¿Qué tareas y modelos son típicos?

- **Clasificación / regresión** (tabular clásica)
- **Modelos:** regresión lineal, logística, árboles, ensembles.
- **Ejemplos:** scoring, churn, demanda.

- **Clasificación / regresión**
- **Detección de patrones**
- **Modelos:** árboles, gradient boosting, modelos secuenciales.
- **Ejemplos:** análisis de logs, IoT, clickstream.

- NLP (texto)
- Visión por computadora (imágenes)
- **Audio** (voz, sonidos)
- **Modelos:** redes neuronales, transformers, modelos generativos.
- **Ejemplos:** análisis de sentimiento, detección de objetos, transcripción.





Puente P&E → ML

- El tipo de dato define qué espacio muestral tiene la variable aleatoria X.
- La tarea define qué distribución o función estimamos (P(Y | X), E[Y | X], densidad, etc.).
- El área de ML determina qué supuestos y representaciones son razonables.

20 Detección de anomalías
valores atípicos y baja densidad



1. ¿Qué es?

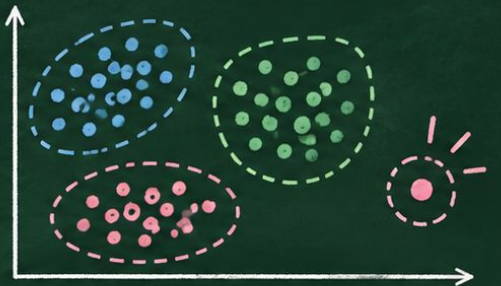
Una anomalía es una observación poco probable bajo el comportamiento normal de los datos.
Puede ser un valor atípico en una variable o una combinación rara de varias variables.

2. ¿Por qué importa?

Permite detectar fraudes, fallas, eventos inusuales o comportamientos nuevos que requieren atención.

3. Enfoques principales

- Univariado: valores atípicos por IQR o z-score.
- Multivariado: baja densidad en el espacio de variables (p. ej. distancia, clustering, Isolation Forest).
- Por aprendizaje: autoencoders, One-Class SVM.



4. Ejemplo simple

Peso de los patitos (g).
Media = 500, desvío = 50.
Un patito de 700 g tiene z = 4 → valor atípico.

5. Consideraciones

- No toda anomalía es un error (puede ser un caso real).
- Validar con conocimiento del dominio.



PUENTE P&E → ML

Un valor atípico es una observación en la cola de la distribución. En ML, la anomalía suele definirse como baja densidad o gran distancia a los datos normales.

21. NLP: del texto al significado

Los textos también son datos: cómo representarlos y modelarlos.

Problema

Clasificar el sentimiento de opiniones de patitos sobre un producto: positivo, neutro o negativo.

Datos

- Textos cortos (reseñas).
- Etiqueta de sentimiento (positivo, neutro, negativo).
- Ejemplo: "Me encantó el alimento, mis patitos están felices" → positivo.

Análisis estadistico

- Limpieza: minúsculas, sin signos, sin palabras vacías.
- Exploración: frecuencia de palabras, nubes, n-gramas.
- Representación: Bag of Words, TF-IDF o embeddings.
- Revisión de balance de clases y longitud de textos.

Decisión de ML

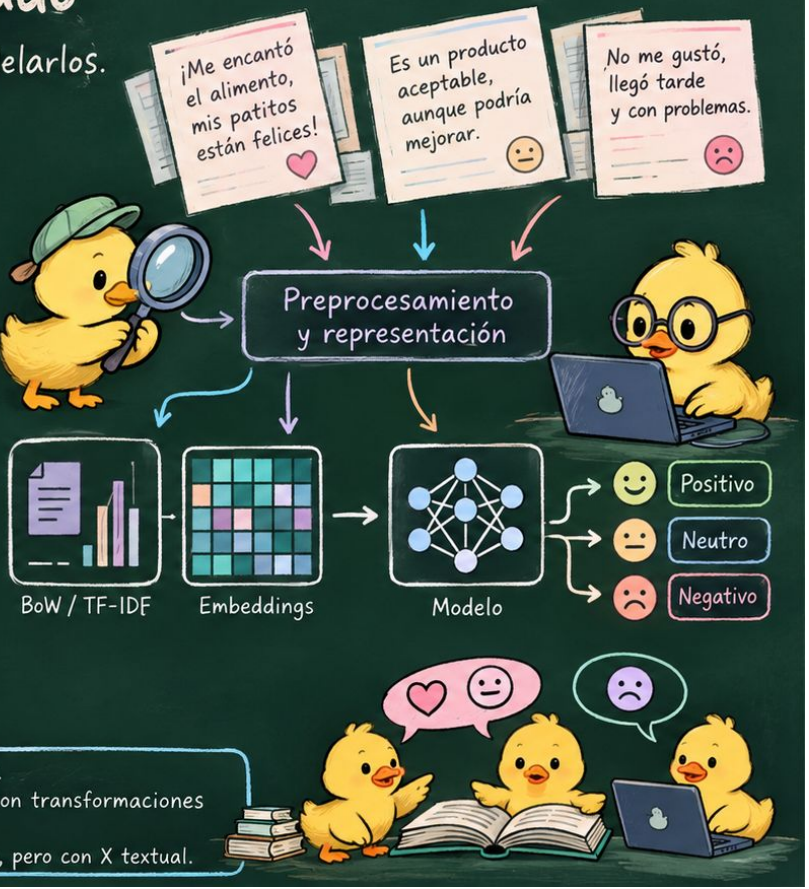
- Modelos: regresión logística, SVM, redes neuronales (embeddings + fine-tuning).
- La entrada es una representación numérica del texto: vector de frecuencias o embedding denso.
- El modelo estima P(Y = sentimiento | texto).

Validación

- Métricas: exactitud, precisión, recall, F1 (por clase).
- Validación cruzada.
- Analizar errores: sarcasmo, negaciones, ambigüedad.

Puente P&E → ML

- El texto es una variable aleatoria X (secuencia de palabras).
- Las representaciones (frecuencias, TF-IDF, embeddings) son transformaciones de X que conservan información relevante.
- El modelo estima P(Y | X) igual que en clasificación clásica, pero con X textual.



22 LLM: lenguaje, probabilidad y generación de texto

¿Cómo se predice la siguiente palabra?

1 Idea central

- Un LLM modela la probabilidad de la siguiente palabra dada una secuencia: $P(w_t \mid w_1, \ldots, w_{t-1})$.
- Se entrena para maximizar la verosimilitud de los textos.
- Luego genera texto eligiendo palabras según esa distribución.

2 Datos y representación

- Texto → secuencia de tokens (palabras o subpalabras).
- Cada token se convierte en un vector (embedding).
- La secuencia se procesa con una arquitectura Transformer que captura relaciones de largo alcance.

3 Objetivo de entrenamiento

Maximizar la verosimilitud (o minimizar la pérdida):

$$\mathcal{L} = -\sum_{t=1}^{T} \log P(w_t \mid w_1, \ldots, w_{t-1})$$

- Equivale a minimizar la entropía cruzada entre el texto real y el modelo.
- Se aprende con técnicas de optimización (gradiente descendente).

4 Generación de texto

- Dado un contexto, se calcula $P(w_t \mid \text{contexto})$.
- Se elige la siguiente palabra (por ejemplo, con muestreo, top-k o temperatura).
- Se repite el proceso para completar la secuencia.

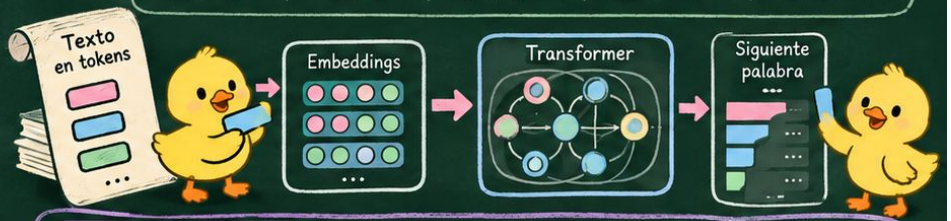
Ejemplo: predicción de la siguiente palabra

Contexto	Distribución $P(w_t \mid \text{contexto})$	
Los patitos	nadan	0,55
	comen	0,25
	duermen	0,10
	...	
Los patitos nadan	en	0,60
	rápido	0,20
	juntos	0,10
	...	



Aplicaciones

- Asistentes virtuales
- Resumen de textos
- Traducción automática
- Generación de contenido
- Búsqueda semántica



Puente P&E → ML

- Probabilidad condicional → modelo de lenguaje $P(w_t \mid \text{contexto})$.
- Estimación de parámetros → maximización de verosimilitud en grandes textos.
- Inferencia → generación y evaluación de texto en tareas reales.
- Supuestos → dependencia entre tokens (no i.i.d.), modelada con Transformers.

23. CASO DE USO 1

Fraude en transacciones

Cómo pasamos de datos crudos a un modelo que detecta operaciones sospechosas.

1. Problema y objetivo

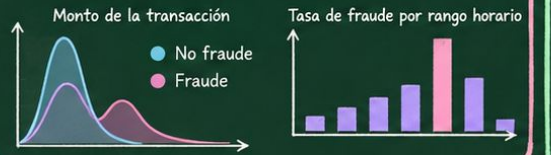
- Identificar transacciones fraudulentas en tiempo real.
- **Objetivo:** estimar P(Y = fraude | X) para bloquear, revisar o aprobar.

2. Datos y contexto

- Datos: transacciones con monto, comercio, ubicación, dispositivo, hora, historial del usuario.
- Variable objetivo: fraude (sí/no).
- Particularidades:
  - clases muy desbalanceadas (fraude < 1%),
  - variables categóricas de alta cardinalidad,
  - patrones que cambian en el tiempo.

3. Análisis exploratorio (P&E)

- Tasa de fraude según variables clave.
- Distribuciones de monto y hora.
- Relaciones entre variables (correlación, mutua información).

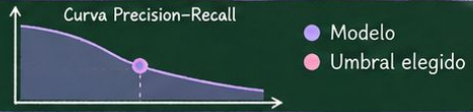


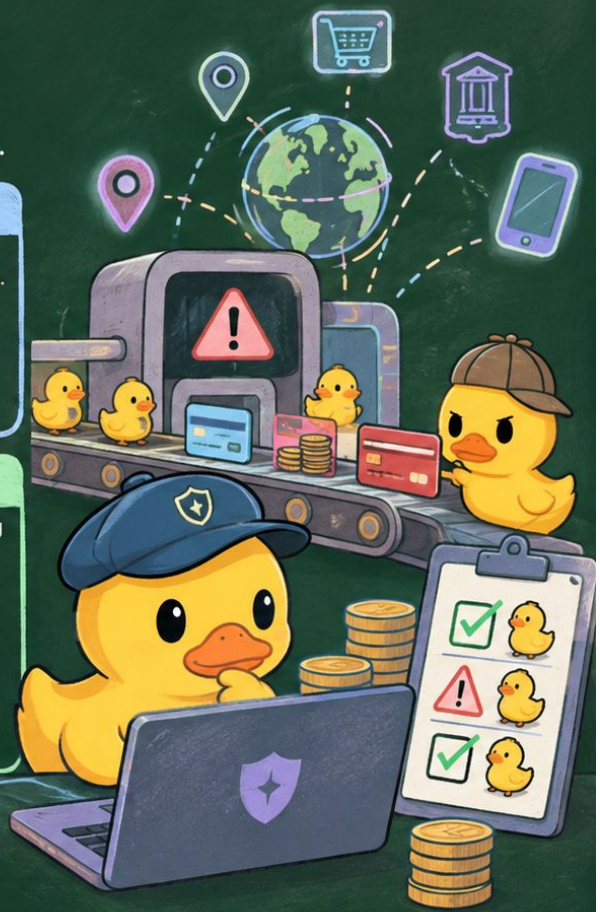
4. Decisión de Machine Learning

- Modelo: regresión logística, árboles con boosting o modelos de ensamblado.
- Features clave:
  - transformaciones de monto (log),
  - frecuencias por comercio (con suavizado),
  - variables de comportamiento reciente.
- Manejamos el desbalanceo con:
  - ponderación de clases,
  - submuestreo / sobremuestreo,
  - o umbrales ajustados al costo de errores.

5. Validación e interpretación

- Métricas adecuadas para clases desbalanceadas:
  - curva Precision–Recall y su área,
  - matriz de confusión a un umbral elegido,
  - análisis de costo: ¿cuánto cuesta un falso negativo vs. un falso positivo?





CASO 2 Scoring de crédito: de los datos al modelo

Predecir la probabilidad de que un cliente no pague su préstamo, combinando análisis estadístico, ingeniería de features y un modelo probabilístico.

Objetivo didáctico

- Aplicar todo el puente P&E → ML en un caso real.
- Ver cómo cada decisión se justifica con evidencia de los datos.
- Interpretar resultados y validar el modelo.

1. Problema y datos

¿Qué queremos predecir?

La probabilidad de que un cliente no pague en los próximos 12 meses.

Datos disponibles

- Información del cliente (edad, ingresos, historial).
- Variables del préstamo (monto, plazo, tasa).
- Comportamiento de pago (en los últimos meses).



2. Análisis estadístico (EDA)

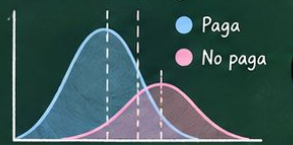
Variable objetivo

Tasa de no pago: 8%

Variables clave

- **Ingresos:** menor en clientes que no pagan.
- **Historial de pago:** más atrasos en clientes que no pagan.
- **Monto del préstamo:** más alto en clientes que no pagan.

Distribución de ingresos



3. Ingeniería de features

Variables transformadas:

- Ratio deuda/ingreso.
- Cantidad de atrasos (últimos 12m).
- Antigüedad del cliente.
- Tipo de producto (one-hot).
- Interacciones relevantes (p. ej. monto x plazo).



4. Modelo: regresión logística

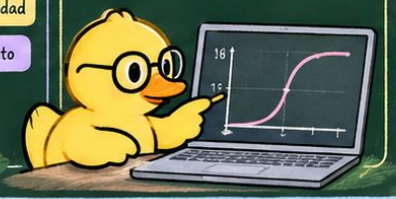
Estimamos la probabilidad de no pago como:

$$P(Y=1 \mid X) = \sigma(\beta_0 + \beta^T X)$$

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

Interpretación:

- Cada coeficiente indica cómo una variable afecta la probabilidad de no pago, manteniendo las demás constantes.
- Se entrena por máxima verosimilitud (equivale a minimizar la log-loss).

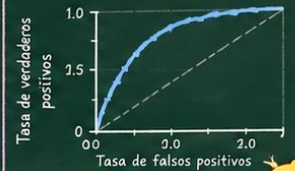


5. Validación y resultados

Desempeño en test

AUC:	0,82
Precisión:	0,76
Recall:	0,68
F1:	0,72

Curva ROC



Conclusiones

- El modelo discrimina bien (AUC 0,82).
- Las variables más importantes coinciden con la intuición del negocio.
- Listo para producción con monitoreo de drift y performance.



Puente P&E → ML

EDA = estadística descriptiva para entender la distribución de X e Y → Feature engineering = transformaciones de variables aleatorias → Entrenar = estimar parámetros por máxima verosimilitud → Validar = inferencia sobre el error de generalización

25 Caso 3 – Fraude en transacciones

¿Cómo detectamos operaciones sospechosas sin generar muchas falsas alarmas?

1 Problema y objetivo

Detectar transacciones fraudulentas en tiempo real.
El fraude es poco frecuente y costoso: si no lo detectamos, la pérdida es alta; si bloqueamos de más, afectamos a clientes reales.

2 Datos

- Cada fila: una transacción con monto, comercio, ubicación, dispositivo, hora y características del cliente.
- Variable objetivo: fraude (sí / no).
- Desbalance: por ejemplo, 0,5% de transacciones son fraude.

Ejemplo simplificado

Monto	Hora	País	Fraude
120	14:32	AR	0
980	02:11	BR	1
45	16:20	AR	0
300	03:47	AR	1

3 Análisis estadístico (EDA)

- El fraude es raro: la tasa global es 0,5%.
- Los fraudes tienen, en promedio, montos más altos y ocurren más de noche.
- Algunas categorías (comercio, país) muestran tasas de fraude distintas.
- Hay correlación temporal: varios intentos en poco tiempo.



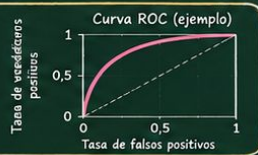


4 Decisión de Machine Learning

- Tarea: clasificación binaria con desbalance.
- Modelo: regresión logística, árboles (Gradient Boosting) o modelos de ensamble.
- Features: transformaciones del monto (log), variables temporales (hora, día), conteo de transacciones recientes, target encoding con suavizado.
- Estrategia: ponderar clases o re-muestrear para manejar el desbalance.

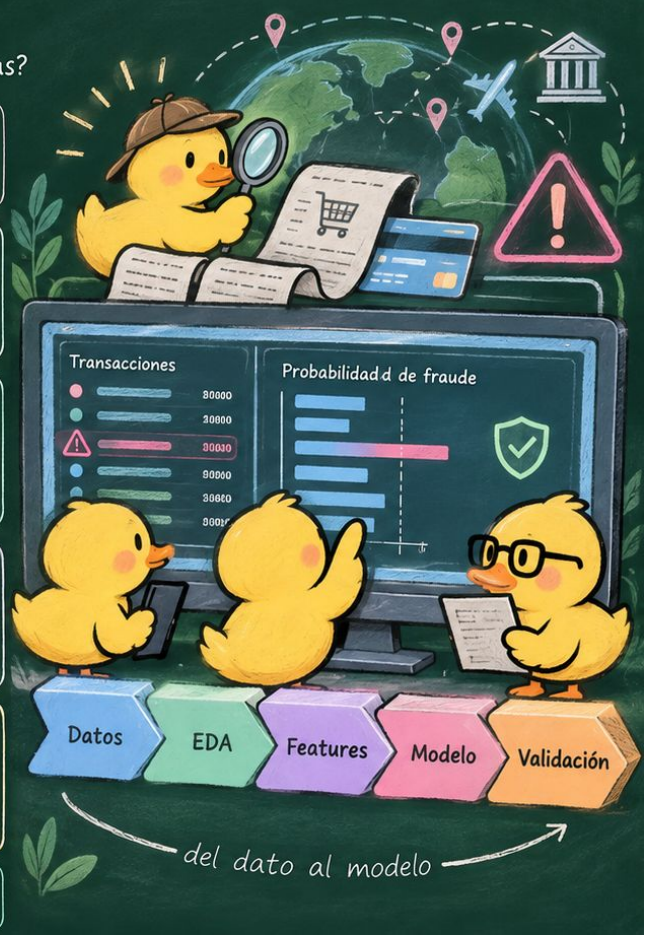
5 Validación y resultados

- Métrica principal: curva ROC y AUC. También precision-recall por el desbalance.
- Elegir un umbral según el costo de error (pérdida por fraude vs. cliente molesto).
- Validación temporal: entrenar con datos de meses anteriores y probar con meses futuros.
- Ejemplo de resultado: AUC = 0,95. Con un umbral que da recall = 0,80, precision = 0,60 (se detecta 80% de fraudes, con 40% de falsas alarmas).



Puente P&E → ML

- Distribución y desbalance → estimación de probabilidades $P(Y = 1 \mid X)$.
- Test de hipótesis → elección de umbral y control de errores (Tipo I: falsa alarma, Tipo II: fraude no detectado).
- Series temporales → validación temporal para evitar leakage.
- Inferencia → intervalos de confianza para métricas y monitoreo de drift en producción.



26 Ciberseguridad: convertir logs en señales de anomalía

1 Problema

Detectar comportamientos inusuales en la red para identificar posibles ataques y reducir falsos positivos.

2 Datos

- Logs de eventos de red por usuario o dispositivo.
- Variables: hora, IP origen, tipo de evento, bytes, sesión, geo, etc.
- Datos desbalanceados: muy pocas anomalías.

tiempo	usuario	evento	bytes
...	...	...	...
...	...	...	...
...	...	...	...

3 Análisis estadístico (EDA)

- Distribuciones: sesiones por usuario, bytes por hora, duración.
- Patrones temporales: picos inusuales.
- Relaciones: ciertos eventos ocurren en secuencia.
- Variables categóricas de alta cardinalidad: IP, país, tipo de dispositivo.



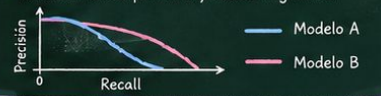
4 Decisión de ML

- Construir features que capturen comportamiento:
  - frecuencia de eventos en ventanas de tiempo,
  - estadísticos por usuario o IP (media, varianza),
  - ratios (bytes por sesión, conexiones fallidas / totales),
  - embeddings de secuencias (opcional).
- Modelos según objetivo:
  - clasificación (logs etiquetados) → Regresión logística, árboles, gradient boosting.
  - detección de anomalías (pocos o sin etiquetados) → Isolation Forest, One-Class SVM, autoencoders.



5 Validación

- Separación temporal: entrenar con logs pasados, validar con período posterior.
- Evaluar con métricas robustas al desbalance:
  - Precision, Recall, F1
  - curva Precision-Recall
- Analizar falsos positivos y falsos negativos.



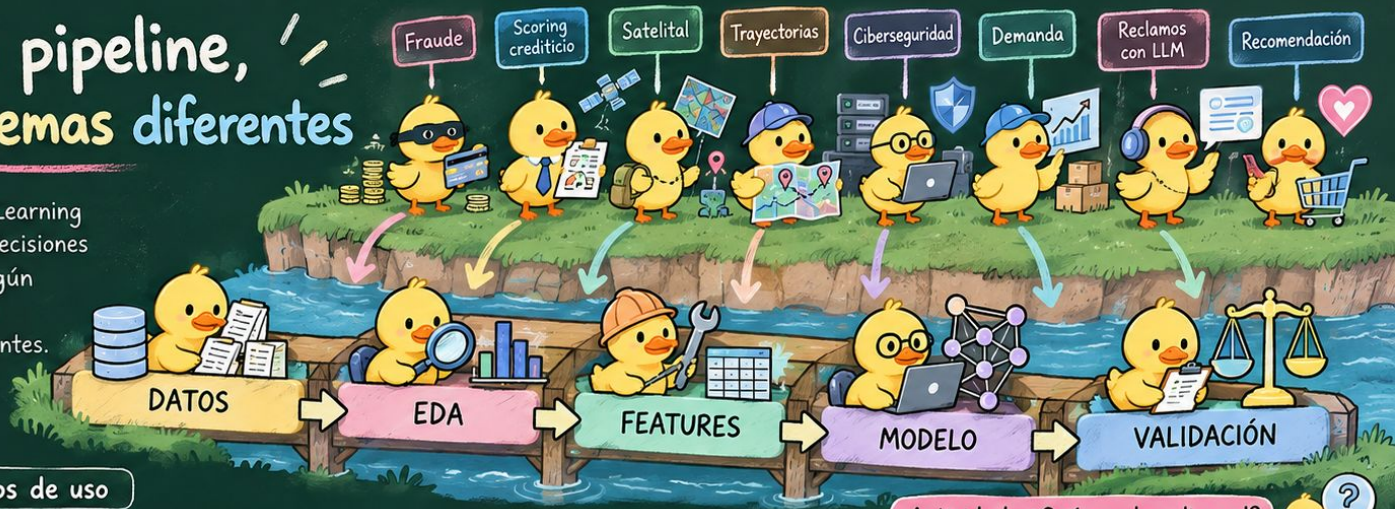


Puente P&E → ML

- EDA = estadística descriptiva de procesos de eventos.
- Features = resumen de una distribución o dependencia temporal.
- Modelos = estiman P(anomalía | X) o detectan baja densidad.
- Validación = inferencia sobre la capacidad de generalizar a eventos futuros.

Un mismo pipeline, ocho problemas diferentes

El proceso de Machine Learning es el mismo, pero las decisiones estadísticas cambian según el tipo de dato, la tarea y las dependencias presentes.



Comparación de casos de uso

Caso	Tipo de dato	Tarea	P&E clave	Features posibles	Validación
Fraude	Transacciones	Clasificación	Poisson, colas	Frecuencia, monto atípico	Temporal
Scoring crediticio	Tabular	Clasificación	Bayes, log-odds	Deuda/ingreso, WoE	Temporal y por cohorte
Satelital	Imágenes	Clasificación	Autocorrelación espacial	NDVI, bandas	Espacial
Trayectorias	Secuencias	Predicción	Procesos temporales	Velocidad, aceleración	Por trayectoria
Ciberseguridad	Logs	Detección de anomalías	Entropía, Poisson	Conexiones/min, puertos	Temporal y por host
Demanda	Series de tiempo	Predicción	ACF, estacionalidad	Lags, rolling mean	Temporal
Reclamos con LLM	Texto	Clasificación	Probabilidad condicional	TF-IDF, embeddings	Por documento/grupo
Recomendación	Interacciones	Rankeo	P(B|A), sesgo	Historial, recencia	Temporal y por usuario

Actividad: ¿Qué puede salir mal?

1. **Dependencia**
   ¿Qué observaciones no son independientes entre sí?
2. **Feature Engineering**
   ¿Qué estadístico transformarías en una variable predictora?
3. **Validación**
   ¿Qué sucedería si separaras train/test de forma aleatoria?

Puente P&E → ML

- La estadística determina cómo interpretar los datos, construir variables y estimar la incertidumbre.
- Generalizar no significa únicamente obtener una buena métrica: significa que esa métrica sea representativa del escenario donde se utilizará el modelo.

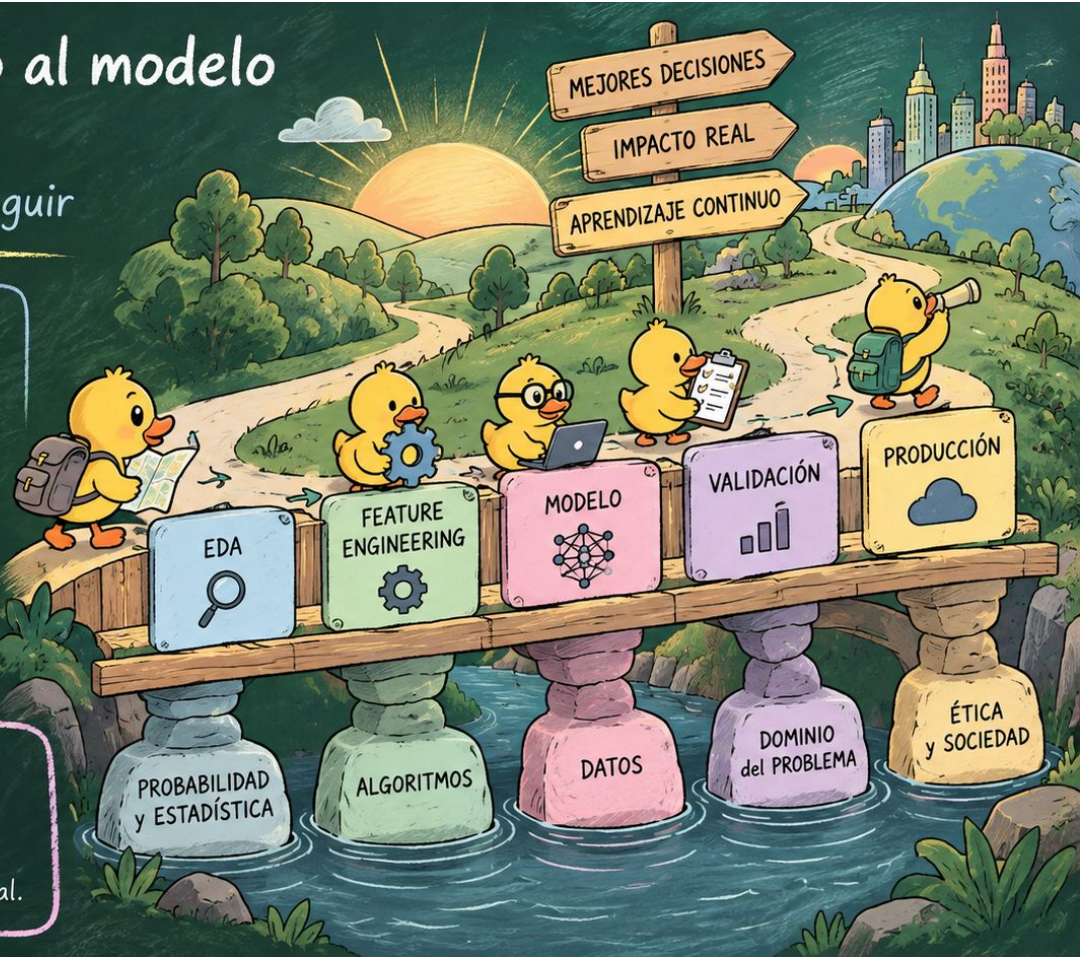
28 Cierre: del dato al modelo y más allá

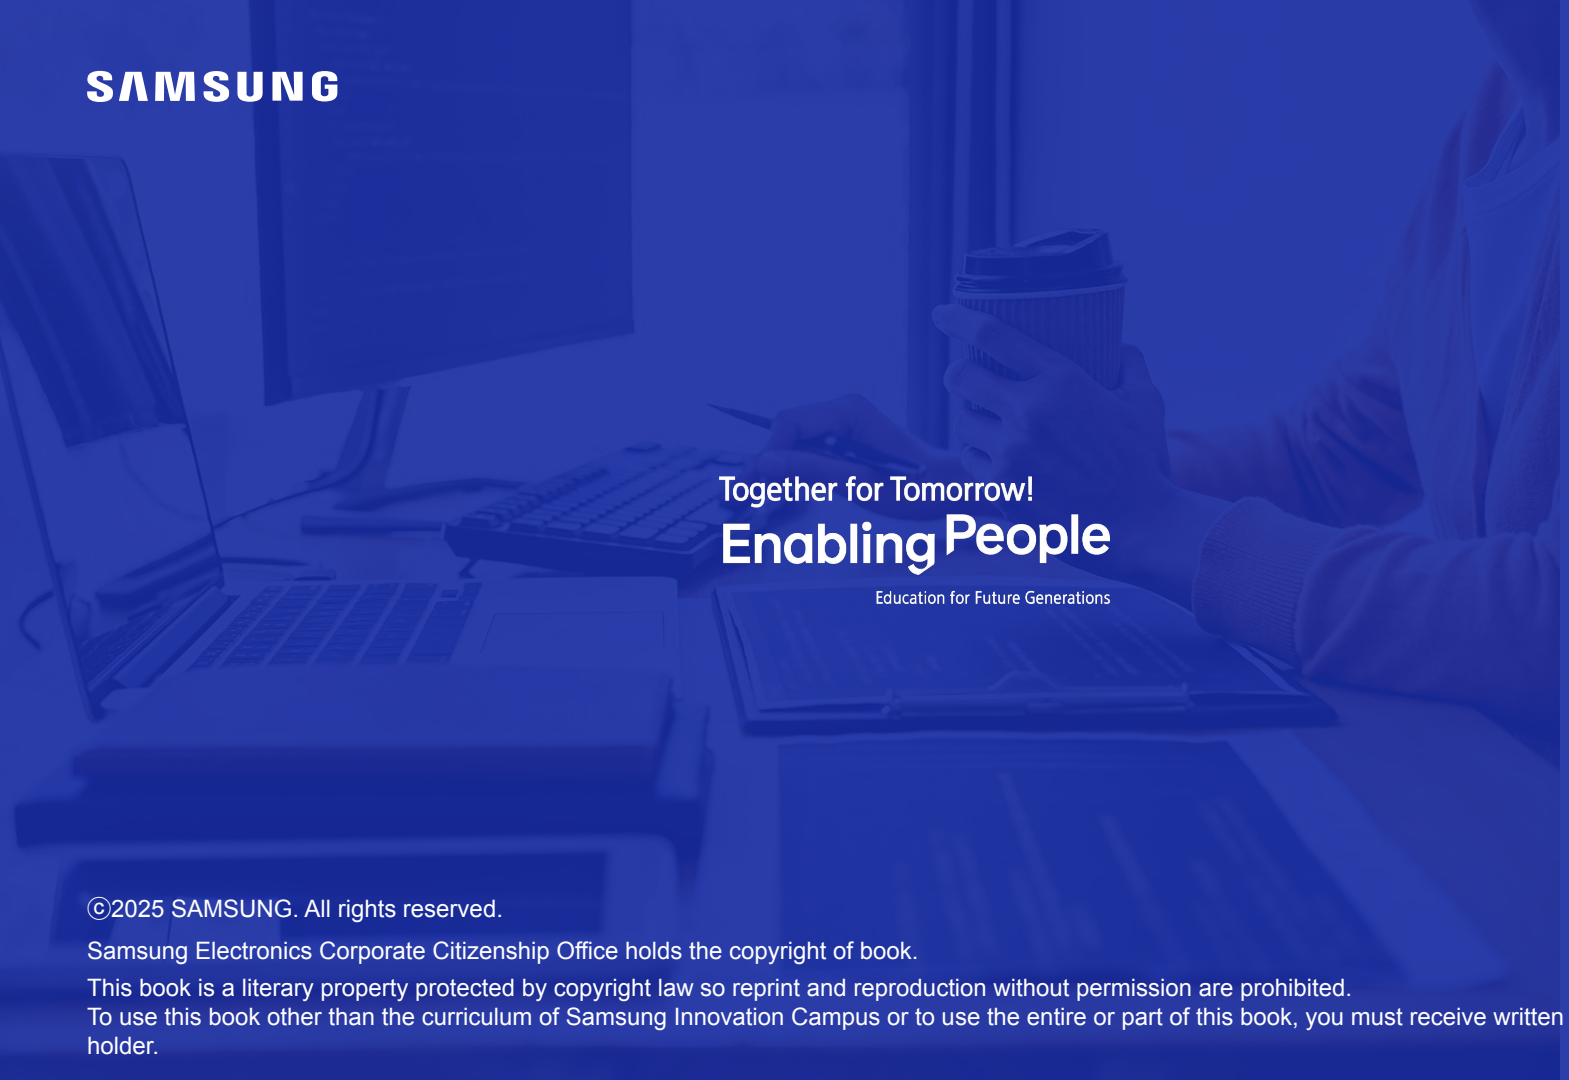
Lo que integramos y cómo seguir

- ☑ Leer un dataset como una muestra.
- ☑ Justificar cada feature con EDA.
- ☑ Explicar los supuestos probabilísticos.
- ☑ Validar como un problema de inferencia.
- ☑ Detectar leakage y drift.
- ☑ Ubicar cualquier caso según dato, tarea y área.

Idea clave

Machine Learning no es una caja negra: es estadística aplicada con propósito, desde los datos hasta decisiones en el mundo real.





ⓒ2025 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of book.

This book is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this book other than the curriculum of Samsung Innovation Campus or to use the entire or part of this book, you must receive written consent from copyright holder.